Universidad Comunera

Facultad de Informática

Fusión de imágenes infrarrojas y visibles mediante morfología matemática

Tesis para optar al título de Maestría en Ciencia de Datos

Autores: Juan Pablo Bazán y Yan Bajac
Tutor: D.Sc. Julio César Mello

Asunción, Paraguay
Diciembre 2026

Fusión de imágenes infrarrojas y visibles mediante morfología matemática

Un operador Top-Hat de una sola escala con un banco de cinco elementos estructurantes: calidad de la fusión y aplicación a la detección de objetos

Tesis presentada a la Facultad de Informática de la Universidad Comunera como requisito para optar al título de Maestría en Ciencia de Datos.

Lic. Juan Pablo Bazán Ing. Yan Bajac

Tutor: D.Sc. Julio César Mello

Universidad Comunera
Asunción, Paraguay

Fusión de imágenes infrarrojas y visibles mediante morfología matemática

Tesis presentada por Lic. Juan Pablo Bazán e
Ing. Yan Bajac a la Facultad de Informática de la
Universidad Comunera como requisito para optar al
título de Maestría en Ciencia de Datos, y aprobada por
el siguiente Tribunal Examinador.

_____

Nombre y firma

_____

Nombre y firma

_____

Nombre y firma

Fecha de aprobación: _____

Resumen

Se propone un algoritmo de fusión de imágenes infrarrojas y visibles basado en morfología matemática: un Top-Hat de una sola escala con un disco y cuatro segmentos orientados. Suma al promedio de las dos imágenes el detalle claro y le resta el oscuro, ambos multiplicados por un peso. Mediante optimización por enjambre de partículas, el peso quedó en el mínimo permitido, 0.30, y se eligió el radio de 25 píxeles, que da más realce. La hipótesis es que el algoritmo supera al Top-Hat clásico en calidad y en detectar objetos que ve una sola cámara, y que es comparable en calidad a cinco métodos multiescala. Con seis métricas sin referencia en veinte pares nocturnos, superó al Top-Hat clásico en cuatro, perdió en una y empató en otra. Obtuvo el mejor rango promedio de los siete métodos, aunque por poco y con un orden que cambia según las métricas: frente a los métodos multiescala, ganó contraste y nitidez y perdió parecido con las fuentes. En otro conjunto, de día y de noche, la tasa de acierto equilibrada del detector entrenado con sus fusiones fue del 61.4 %. Promedia el acierto sobre los objetos que ve solo la cámara visible y sobre los que ve solo la infrarroja. Esa tasa quedó cuarta entre ocho entradas fusionadas y 3.0 puntos por encima del Top-Hat clásico, una ventaja mínima que cambió de signo según la semilla. En calidad la hipótesis se sostiene en lo principal; en detección, queda por confirmar con nuevos entrenamientos y datos.

Palabras clave: Fusión de imágenes infrarrojas y visibles; Morfología matemática; Transformada Top-Hat; Optimización por enjambre de partículas; Detección de objetos.

Abstract

An algorithm for fusing infrared and visible images based on mathematical morphology is proposed: a single-scale Top-Hat with a disk and four oriented line segments. It adds the bright detail to the average of the two images and subtracts the dark detail, both multiplied by a weight. Through particle swarm optimization, the weight settled at the lowest allowed value, 0.30, and the radius of 25 pixels, which gives more enhancement, was chosen. The hypothesis is that the algorithm outperforms the classical Top-Hat in quality and in detecting objects seen by only one camera, and that it is comparable in quality to five multiscale methods. With six no-reference metrics on twenty nighttime pairs, it outperformed the classical Top-Hat on four, lost on one and tied on another. It achieved the best average rank of the seven methods, though narrowly and with an order that changes with the metrics: against the multiscale methods, it gained contrast and sharpness and lost similarity to the source images. On another dataset, with daytime and nighttime scenes, the balanced hit rate of the detector trained on its fused images was 61.4%. It averages the hit rates on objects seen only by the visible camera and on those seen only by the infrared one. It ranked fourth among eight fused inputs and was 3.0 points above the classical Top-Hat, a minimal advantage that changed sign with the seed. The hypothesis largely holds for quality; for detection, it remains to be confirmed with new training runs and data.

Keywords: Infrared and visible image fusion; Mathematical morphology; Top-Hat transform; Particle swarm optimization; Object detection.

Agradecimientos

A nuestras familias, por la paciencia y el apoyo de todos estos meses, en los que la tesis ocupó muchas noches y fines de semana que también eran suyos.

Al D.Sc. Julio César Mello, nuestro tutor, por su guía a lo largo de todo el trabajo y por sus observaciones, que nos llevaron a revisar más de una vez lo que creíamos terminado.

A J. L. Vázquez Noguera y a H. Legal-Ayala, coautores del artículo sobre la fusión con la transformada Top-Hat del que parte esta tesis.

A la Facultad de Informática de la Universidad Comunera y a los docentes de la Maestría en Ciencia de Datos, por la formación recibida, y a nuestros compañeros de la maestría, por las discusiones y la ayuda de cada semana.

Por último, a los autores de las colecciones de imágenes TNO y M3FD, que las pusieron a disposición de todos y permitieron hacer este trabajo con datos públicos.

Índice general

Resumen III

Abstract IV

Agradecimientos V

Lista de Abreviaturas y Símbolos IX

Índice de figuras XI

Índice de tablas XII

1. Introducción **1**

1.1. Objetivos del trabajo 4

1.1.1. Objetivo general 4

1.1.2. Objetivos específicos 4

1.2. Alcance y delimitaciones 5

1.3. Estructura del documento 6

2. Marco teórico y conceptual **7**

2.1. Conceptos básicos 7

2.1.1. Imagen digital 7

2.1.2. Imágenes visible e infrarroja 7

2.1.3. Niveles de fusión 8

2.1.4. Evaluación sin imagen de referencia 8

2.2. Fusión de imágenes visibles e infrarrojas 8

2.2.1. Familias de métodos 9

2.2.2. Métodos multiescala comparativos 9

2.3. Morfología matemática y transformada Top-Hat 11

2.3.1. Operaciones básicas 11

2.3.2. Transformada Top-Hat 13

2.3.3. Tamaño y forma del elemento estructurante 13

2.3.4. Realce de contraste . . . 13
2.3.5. Fusión basada en la transformada Top-Hat . . . 14
2.4. Métricas de evaluación sin referencia . . . 14
2.4.1. Métricas de actividad . . . 15
2.4.2. Métricas de fidelidad . . . 16
2.4.3. Selección de las seis métricas . . . 17
2.4.4. Métricas complementarias . . . 17
2.5. Pruebas estadísticas . . . 18
2.6. Optimización por enjambre de partículas . . . 19
2.7. Detección de objetos . . . 20
2.7.1. Funcionamiento de un detector . . . 20
2.7.2. Intersección sobre la unión, precisión y exhaustividad . . . 20
2.7.3. Precisión media . . . 21
2.7.4. La detección como evaluación de la fusión . . . 21
2.8. Estado del arte y brecha existente . . . 21

3. Metodología **23**
3.1. Conjuntos de imágenes y preprocesamiento . . . 25
3.2. El algoritmo de fusión propuesto . . . 26
3.2.1. Banco de elementos estructurantes . . . 26
3.2.2. Combinación de las respuestas . . . 27
3.2.3. Implementación y métodos comparativos . . . 28
3.3. Ajuste de los parámetros por enjambre de partículas . . . 30
3.4. Protocolo de evaluación de la calidad de imagen . . . 31
3.5. Aplicación a la detección de objetos . . . 33
3.5.1. Partición de los datos . . . 33
3.5.2. Detector y entrenamiento . . . 34
3.5.3. Objetos de una sola cámara y tasa de acierto equilibrada . . . 34
3.5.4. Comparación con el Top-Hat clásico y medidas secundarias . . . 35
3.6. Examen de la hipótesis . . . 36

4. Resultados **38**
4.1. Caracterización de los conjuntos . . . 38
4.2. Ajuste de los parámetros . . . 39
4.3. Comparación cualitativa . . . 40
4.4. Resultados cuantitativos . . . 43
4.5. Análisis estadístico . . . 44
4.5.1. Prueba de Friedman y rango promedio . . . 45
4.5.2. Contrastes de Wilcoxon . . . 46
4.5.3. Solidez del orden . . . 47

4.6. Aplicación a la detección de objetos 48
4.6.1. Objetos de una sola cámara y tasas de acierto 48
4.6.2. Comparación con el Top-Hat clásico 51
4.6.3. Medidas secundarias y entrenamiento 53
4.7. Examen de la hipótesis 55

5. Discusión **57**
5.1. La calidad de la fusión y su costo 57
5.2. El ajuste de los parámetros 59
5.3. La aplicación a la detección 59
5.4. Relación entre calidad y detección 61
5.5. Limitaciones del estudio 61

6. Conclusiones **63**

7. Recomendaciones **66**

Referencias **68**

Anexos **74**

Lista de Abreviaturas y Símbolos

AP	Precisión media (*Average Precision*)
AP50	Precisión media con un umbral de superposición (IoU) de 0.5
BTH	Transformada Top-Hat negra (*Black Top-Hat*)
db4	Base *wavelet* de Daubechies de orden cuatro
DTCWT	Transformada *wavelet* compleja de doble árbol (*Dual-Tree Complex Wavelet Transform*)
DWT	Transformada *wavelet* discreta (*Discrete Wavelet Transform*)
EN	Entropía (*Entropy*)
FE	Eficiencia de fusión (*Fusion Efficiency*)
FMI	Información mutua de características (*Feature Mutual Information*)
IC	Intervalo de confianza
IoU	Intersección sobre la unión (*Intersection over Union*)
IR	Imagen infrarroja térmica (*Infrared*)
JPEG	Formato de compresión de imágenes (*Joint Photographic Experts Group*)
M3FD	Conjunto de pares de imágenes visibles e infrarrojas de varios escenarios, con objetos marcados (*Multi-scenario Multi-modality Dataset*)
mAP50	Media de la AP50 sobre las clases de objetos (*mean Average Precision*)
MG	Gradiente medio (*Mean Gradient*)
MI	Información mutua (*Mutual Information*)
MSE	Error cuadrático medio (*Mean Squared Error*)
Nabf	Medida del ruido y los artefactos que agrega la fusión
PASCAL VOC	Desafío de reconocimiento visual de objetos (*Pattern Analysis, Statistical Modelling and Computational Learning Visual Object Classes*)
PSNR	Relación señal-ruido de pico (*Peak Signal-to-Noise Ratio*)
PSO	Optimización por enjambre de partículas (*Particle Swarm Optimization*)
Q0, QW, QE	Índices de calidad de Piella: ponderado por la varianza local, ponderado por ventana y de bordes

Qabf	Índice que mide cuánta información de bordes pasa de las fuentes a la fusión
SCD	Suma de las correlaciones de las diferencias (*Sum of the Correlations of Differences*)
SD	Desviación estándar (*Standard Deviation*)
SF	Frecuencia espacial (*Spatial Frequency*)
SSIM	Índice de similitud estructural (*Structural Similarity*)
TNO	Organización neerlandesa de investigación científica aplicada (*Nederlandse Organisatie voor Toegepast Natuurwetenschappelijk Onderzoek*)
VIF	Fidelidad de la información visual (*Visual Information Fidelity*)
VIS	Imagen visible (*Visible*)
WTH	Transformada Top-Hat blanca (*White Top-Hat*)
YOLO	Detector de objetos de una sola pasada (*You Only Look Once*)
YOLOv8	Octava versión de YOLO
YOLOv8n	Variante más pequeña (*nano*) de YOLOv8
H, W	Número de filas y de columnas de una imagen
f	Cualquier imagen normalizada
I_{VIS}, I_{IR}	Imágenes fuente visible e infrarroja, normalizadas entre cero y uno
F	Imagen fusionada
b	Elemento estructurante
ε, δ	Erosión y dilatación
γ, φ	Apertura y cierre
r	Radio de los elementos estructurantes, en píxeles
D_r	Disco de radio r
$S_{r,\theta}$	Segmento de radio r y orientación θ
m	Peso del detalle agregado en la regla de fusión
VP, FP, FN	Verdaderos positivos, falsos positivos y falsos negativos de un detector
P, R	Precisión y exhaustividad de un detector

Índice de figuras

1.1. Escena nocturna en la imagen visible, en la infrarroja y fusionada con el algoritmo propuesto 2

2.1. Operaciones morfológicas básicas y transformada Top-Hat sobre una señal de una dimensión 12

3.1. Etapas del estudio 24
3.2. Banco de cinco elementos estructurantes del algoritmo propuesto 27
3.3. Diagrama de bloques del algoritmo propuesto 29

4.1. Aptitud según el peso m y reparto de las corridas del enjambre por radio final 39
4.2. Fuentes y fusiones de una escena nocturna del TNO (Kaptein 1123) 41
4.3. Fuentes y fusiones de una escena del TNO con un soldado tendido tras una cortina de humo 42
4.4. Valores de las seis métricas en los veinte pares, por método 44
4.5. Rango promedio de cada método sobre las seis métricas 46
4.6. Detecciones del Top-Hat clásico y de la propuesta en un cuadro nocturno de M3FD 50
4.7. Detecciones en dos cuadros de M3FD con un objeto de una sola cámara . . 52
4.8. Tasa equilibrada por entrada y diferencia entre la propuesta y el Top-Hat clásico 54

Índice de tablas

3.1. Las seis métricas de evaluación de calidad 32

4.1. Media de las seis métricas por método, sobre los veinte pares del corpus . . 43
4.2. Prueba de Friedman por métrica, con siete métodos y veinte pares 45
4.3. Rango promedio de cada método, por métrica y global 45
4.4. Contrastes de Wilcoxon pareados de la propuesta frente a los demás métodos 47
4.5. Tasa de acierto de las entradas fusionadas en la detección de objetos 49
4.6. Diferencia de tasa equilibrada entre la propuesta y el Top-Hat clásico . . . 51

A.1. Contrastes de Wilcoxon pareados de las seis métricas, con corrección de Holm 75

Capítulo 1

Introducción

Una misma escena se ve de manera diferente según la cámara que la observe. La cámara común forma la imagen con la luz que reflejan las superficies; por eso recoge el color y la textura. La cámara térmica mide, en cambio, la radiación infrarroja que emite cada cuerpo según su temperatura. Gracias a eso, una persona o un vehículo con el motor caliente resaltan sobre el fondo aun de noche o entre el humo. A cambio, la imagen térmica pierde buena parte de esa textura. Ninguna de las dos cámaras basta por sí sola en todas las condiciones. La fusión de imágenes infrarrojas y visibles combina ambas fuentes en una sola imagen que conserve lo útil de cada una (Ma, Ma, & Li, 2019).

La Figura 1.1 muestra una escena nocturna en sus dos imágenes, la visible y la infrarroja, junto con la que resulta de fusionarlas con el algoritmo que propone este trabajo. En la imagen visible se distinguen los arbustos, el empedrado y la entrada del edificio, pero la persona que camina junto a la entrada se confunde con los arbustos que tiene detrás. En la infrarroja, la persona resalta en blanco, mientras el follaje queda oscuro y casi sin textura. La imagen fusionada conserva a la vez la figura de la persona y la textura del fondo.

Los métodos de fusión se agrupan en varias familias (S. Li et al., 2017; Singh et al., 2023). Los multiescala, como las pirámides y las transformadas *wavelet*, descomponen cada fuente en capas según el tamaño del detalle, combinan las capas y reconstruyen la imagen. Otros recurren a representaciones dispersas, que describen cada región con pocos elementos de un diccionario. Los más recientes emplean redes neuronales que aprenden la regla de fusión a partir de ejemplos. La morfología matemática ofrece un camino distinto. Sus operadores recorren la imagen con una forma pequeña, el elemento estructurante, y la transforman según cómo esa forma encaja en cada región. Con ellos, la transformada Top-Hat separa del fondo los detalles claros u oscuros más pequeños que el elemento (Gonzalez & Woods, 2018; Soille, 2004). Esa separación ya se aprovechó para fusionar imágenes infrarrojas y visibles (Bai, 2013; Bajac Figueredo et al., 2025; Mello Román et al., 2020).

Figura 1.1

Escena nocturna en la imagen visible, en la infrarroja y fusionada con el algoritmo propuesto



Nota. Elaboración propia a partir de imágenes del conjunto de Toet (2014, 2017). La escena corresponde al par Kaptein 1123, uno de los veinte con que se evalúa la calidad (Sección 3.1). La imagen fusionada, recuadrada a la derecha, se obtuvo con la configuración adoptada, radio $r = 25$ y peso $m = 0.30$ (Sección 3.3). La Figura 4.2 muestra la misma escena fusionada con los demás métodos del estudio.

Este trabajo propone un algoritmo de fusión de imágenes infrarrojas y visibles basado en morfología matemática. Su núcleo es un operador Top-Hat de una sola escala. En lugar de un único elemento estructurante, emplea un banco de cinco: un disco y cuatro segmentos lineales orientados a 0°, 45°, 90° y 135°. El detalle de cada fuente es la suma de lo que extrae el disco y el promedio de lo que extraen los cuatro segmentos. La regla de fusión parte del promedio de las dos fuentes, le suma el detalle claro y le resta el oscuro. Un peso m regula cuánto detalle se agrega. El algoritmo queda así definido por dos parámetros: el radio r de los elementos y el peso m. Ambos se ajustan mediante optimización por enjambre de partículas. En esa búsqueda, un grupo de soluciones candidatas recorre el espacio de los parámetros, guiado por las mejores posiciones halladas. En las veinticinco corridas del enjambre, el peso terminó en 0.30, que es el límite inferior del rango de búsqueda. El radio quedó casi siempre en 1 o en 25 píxeles. De esos dos valores se adoptó $r = 25$, porque prioriza el realce: da más contraste y nitidez que $r = 1$, a cambio de una imagen menos fiel a las fuentes.

El problema que aborda la tesis tiene dos partes. La primera se refiere a la calidad: si las imágenes del algoritmo propuesto están a la altura de las que producen los métodos clásicos de fusión. Como referencia se toman el Top-Hat clásico, que aplica la misma regla con un único disco, y cinco métodos multiescala: dos pirámides y tres transformadas *wavelet*. La segunda parte es la aplicación: si esas imágenes ayudan a un detector automático a encontrar objetos. La variable que se manipula es el método de fusión; las que se miden son la calidad de la imagen y el acierto del detector.

Medir la calidad tiene una dificultad propia, porque no existe una imagen fusionada ideal con la cual comparar. Por eso se recurre a métricas sin referencia, que prescinden de ella pero no siempre coinciden entre sí. El trabajo de Bajac Figueredo et al. (2025), en el

que participaron los autores de esta tesis, ilustra ese desacuerdo. En la escena Camp, con elementos estructurantes de tamaños 7 y 9, la fusión con Top-Hat de ese trabajo quedó primera en desviación estándar, entropía y frecuencia espacial, que miden el contraste, la información y la nitidez. Al mismo tiempo quedó última en información mutua, que mide el parecido con las fuentes.

La propuesta reúne piezas que provienen de trabajos distintos. El banco de cinco elementos estructurantes se diseñó para realzar el contraste local y la nitidez en mamografías (Flores et al., 2026). La forma de combinar las respuestas del disco y de los segmentos se tomó de un método de realce de imágenes de fondo de ojo (Bala et al., 2024). La regla de fusión con un peso y el ajuste del radio y del peso por enjambre de partículas provienen de Ortega Rodríguez y Espinoza Ríos (2025), que trabajaron con un único disco. El Top-Hat clásico sigue la fusión con Top-Hat del trabajo ya citado (Bajac Figueredo et al., 2025) y se aplica aquí con un disco de radio 5 y peso 1. En la literatura revisada no se encontró el banco aplicado a la fusión de imágenes infrarrojas y visibles. El aporte de la tesis es llevarlo a esa fusión, junto con el ajuste de sus parámetros. Sobre esa base se caracteriza la calidad de las imágenes resultantes y se evalúa la aplicación del algoritmo a la detección. A diferencia de una red neuronal, un operador morfológico puede explicarse paso a paso. Esa transparencia permite relacionar lo que premia cada métrica con lo que hace la regla de fusión.

Las métricas de imagen dicen poco sobre lo que la fusión aporta a un uso concreto. Por eso, trabajos recientes la evalúan también por su efecto en una tarea posterior, como la detección o la segmentación de objetos (Liu et al., 2022; Tang et al., 2022). Un detector que recibe la imagen fusionada debería encontrar en ella lo que cada cámara muestra por separado. Un peatón en la sombra y un farol encendido ilustran el caso. Al primero lo ve casi solo la cámara térmica; al segundo, casi solo la común. En la aplicación, la propuesta se compara con el Top-Hat clásico, que pertenece a la misma familia y usa la misma regla. Así, la comparación mide el efecto de cambiar el operador en su conjunto, con sus elementos estructurantes, su radio y su peso.

Se plantean, en consecuencia, dos preguntas de investigación, una sobre la calidad de la fusión y otra sobre su aplicación. ¿Qué calidad tienen las imágenes del algoritmo propuesto, frente al Top-Hat clásico y a cinco métodos multiescala? ¿Encuentra un detector entrenado con esas imágenes más objetos vistos por una sola cámara que uno entrenado con las del Top-Hat clásico?

La hipótesis del trabajo es la siguiente.

El algoritmo de fusión propuesto, con sus parámetros ajustados mediante optimización por enjambre de partículas, produce imágenes de mejor calidad que el Top-Hat clásico y de calidad comparable a la de cinco métodos multiescala, medida con seis métricas sin referencia. En su aplicación a la detección de objetos, un detector entrenado con sus

imágenes encuentra más objetos vistos por una sola cámara que el entrenado con las imágenes del Top-Hat clásico.

Las dos oraciones de la hipótesis reúnen tres afirmaciones: dos sobre la calidad (frente al Top-Hat clásico y frente a los métodos multiescala) y una sobre la aplicación a la detección. Cada una se examina con las pruebas de la evaluación que le corresponde, sin agregar otras (Sección 3.6).

El trabajo se sitúa en el año 2026 y se desarrolló en el marco de la Maestría en Ciencia de Datos de la Universidad Comunera. Sus beneficiarios son, en primer lugar, los investigadores en procesamiento de imágenes, que disponen de un operador morfológico descrito paso a paso y comparado con métodos establecidos. También lo son quienes desarrollan sistemas de vigilancia o de detección con cámaras visibles y térmicas y deben decidir cómo fusionar sus imágenes.

1.1. Objetivos del trabajo

1.1.1. Objetivo general

Proponer un algoritmo de fusión de imágenes infrarrojas y visibles basado en morfología matemática, con sus parámetros ajustados mediante optimización por enjambre de partículas, y evaluar la calidad de sus imágenes y su aplicación a la detección de objetos.

1.1.2. Objetivos específicos

Para alcanzar el objetivo general se plantean cuatro objetivos específicos. Las conclusiones del Capítulo 6 los retoman en el mismo orden.

- Implementar el algoritmo propuesto y ajustar su radio y su peso mediante optimización por enjambre de partículas.
- Evaluar la calidad de sus imágenes con seis métricas sin referencia y pruebas estadísticas no paramétricas, frente al Top-Hat clásico y a cinco métodos multiescala.
- Evaluar su aplicación a la detección de objetos vistos por una sola cámara, frente al Top-Hat clásico, con detectores entrenados sobre cada tipo de imagen.
- Examinar la hipótesis con los resultados de las dos evaluaciones.

1.2. Alcance y delimitaciones

Los resultados del estudio deben leerse dentro de los límites siguientes:

- **Validez interna:** Las métricas sin referencia premian propiedades distintas de la imagen, de modo que el orden entre los métodos depende del conjunto de métricas elegido. Los métodos comparativos se aplican con sus parámetros por defecto, sin ajuste. En cambio, la aptitud del enjambre se calculó sobre tres de los veinte pares con que se evalúa la calidad, y el radio se eligió entre los dos que dio el enjambre comparándolos sobre los veinte.

- **Detección:** Los detectores entrenados con cada cámara, y no una revisión humana, definen cuáles son los objetos vistos por una sola cámara. Los objetos de la prueba provienen de pocos tramos de video, y casi dos de cada tres luces salen de un mismo grupo de tramos. Se emplea un solo modelo de detector, el más pequeño de su familia, entrenado durante cuarenta épocas (pasadas completas por los datos de entrenamiento).

- **Validez externa:** La calidad se mide en veinte pares de un único conjunto, el *TNO Image Fusion Dataset* (Toet, 2014, 2017). TNO es la sigla de la organización neerlandesa de investigación científica aplicada (del neerlandés *Nederlandse Organisatie voor Toegepast Natuurwetenschappelijk Onderzoek*), que reunió las imágenes. En buena parte de esos pares, la imagen visible proviene de cámaras con intensificador de imagen, que amplifican la escasa luz disponible. La detección se evalúa en otro conjunto, M3FD (del inglés *Multi-scenario Multi-modality Dataset*), con pares de escenas diurnas y nocturnas en los que los objetos están marcados (Liu et al., 2022). De sus seis clases de objetos, el análisis se centra en dos, las personas y las luces. La imagen visible se usa en escala de grises. El radio se expresa en píxeles y no se adapta al tamaño de la imagen.

- **Alcance:** El estudio usa solo conjuntos públicos, cuyos pares ya vienen registrados por sus autores; el corrimiento vertical de varios píxeles que muestran algunos pares del TNO no se corrigió (Sección 3.1). No incluye captura propia de imágenes, alineación de pares ni medición del tiempo de cómputo. Su foco es un operador de una sola escala. Por eso quedan fuera, para trabajos futuros (Capítulo 7), la fusión con redes neuronales y los métodos morfológicos multiescala de Bai (2013) y Mello Román et al. (2020).

1.3. Estructura del documento

Después de esta introducción, el documento se organiza de la manera siguiente:

- El Capítulo 2 expone el marco teórico y conceptual. Parte de los conceptos básicos sobre la imagen digital y la fusión. Trata después los métodos de fusión de imágenes visibles e infrarrojas, la morfología matemática, las métricas sin referencia y las pruebas estadísticas. Siguen la optimización por enjambre de partículas y la detección de objetos, y el capítulo cierra con el estado del arte y la brecha existente.
- El Capítulo 3 describe los conjuntos de imágenes, el algoritmo propuesto y el ajuste de sus parámetros, las dos evaluaciones y el examen de la hipótesis.
- El Capítulo 4 presenta los resultados en ese mismo orden: la caracterización de los conjuntos, el ajuste, la calidad de imagen con su análisis estadístico, la detección y el examen de la hipótesis.
- El Capítulo 5 discute la calidad y su costo, el ajuste, la detección y la relación entre ambas, y precisa las limitaciones del estudio.
- El Capítulo 6 presenta las conclusiones, una por cada objetivo específico.
- El Capítulo 7 reúne las recomendaciones para trabajos futuros.
- Los Anexos reúnen la participación de los autores en congresos y la tabla completa de los contrastes de Wilcoxon (Tabla A.1).

Capítulo 2

Marco teórico y conceptual

Este capítulo reúne los conceptos y los métodos en que se apoya el trabajo.

2.1. Conceptos básicos

2.1.1. Imagen digital

Una imagen digital en escala de grises, es decir, sin color, es una cuadrícula de H filas y W columnas de puntos llamados píxeles. Cada píxel guarda un número entero, su nivel de gris, que indica cuán claro se ve ese punto (Gonzalez & Woods, 2018). En las imágenes de este trabajo, ese nivel va de 0, el negro, a 255, el blanco. La fusión y las seis métricas que se usan aquí operan sobre la intensidad normalizada, que lleva esos niveles al intervalo de cero a uno:

$$f(x, y) = \frac{g(x, y)}{255}. \tag{2.1}$$

En ella, $g(x, y)$ es el nivel de gris del píxel de la columna x y la fila y, y $f(x, y)$ es su intensidad normalizada. En adelante, la letra f designa cualquier imagen normalizada.

2.1.2. Imágenes visible e infrarroja

La imagen visible (VIS) es la que toma una cámara común. Registra la luz que reflejan los objetos, dentro de la franja que percibe el ojo humano. Por eso muestra bien la textura, los bordes y los carteles, pero pierde calidad con poca luz o con mal tiempo. La imagen infrarroja térmica (IR) registra en cambio el calor que emite cada cuerpo según su temperatura. Distingue a una persona o a un motor a oscuras, aunque suele ofrecer menos detalle fino y poca textura (Bajac Figueredo et al., 2025; Ma, Ma, & Li, 2019). Aquí, la imagen visible en color se pasa a escala de grises antes de fusionarla.

Un par visible-infrarrojo está formado por dos imágenes de la misma escena, una de cada cámara, tomadas al mismo tiempo. Para fusionarlas, las dos imágenes deben estar registradas, es decir, alineadas de modo que un mismo píxel corresponda al mismo punto

de la escena (Gonzalez & Woods, 2018). El registro corrige las diferencias de posición, giro y tamaño que aparecen porque las cámaras no miran desde el mismo lugar. Si el registro falla, el detalle de una imagen queda desplazado respecto del de la otra, y un borde puede aparecer dos veces. Este trabajo no registra imágenes: usa conjuntos públicos cuyos pares ya vienen registrados por sus autores.

2.1.3. Niveles de fusión

Las imágenes que se combinan se llaman fuentes. Según qué se combina, la fusión se clasifica en tres niveles: de píxel, de características y de decisiones (Singh et al., 2023). El nivel de características combina rasgos ya extraídos de cada fuente, como los bordes. El de decisiones combina los resultados de sistemas que analizan cada fuente por separado, como dos detectores de objetos. El nivel de píxel combina las fuentes punto por punto, sobre sus intensidades o sobre una versión transformada (S. Li et al., 2017). Todos los métodos de este trabajo son de este último nivel. Su resultado es una imagen del mismo tamaño que las fuentes:

$$F = \Phi\left(I_{\mathrm{VIS}},\, I_{\mathrm{IR}}\right). \tag{2.2}$$

En ella, I_{VIS} e I_{IR} son las fuentes visible e infrarroja normalizadas, Φ es el método de fusión y F es la imagen fusionada. Aquí F también toma valores entre cero y uno, porque todos los métodos recortan su resultado a ese intervalo.

2.1.4. Evaluación sin imagen de referencia

En la fusión de imágenes no siempre existe una imagen de referencia, es decir, una imagen fusionada correcta con la cual comparar el resultado (Singh et al., 2023). En la fusión visible-infrarroja no existe, porque ninguna cámara puede tomar la imagen ideal que reúna lo mejor de las dos. Por eso la calidad se estima con métricas sin referencia, indicadores numéricos que no necesitan esa imagen. Unas se calculan sobre la imagen fusionada sola y miden cuánta información, contraste o nitidez contiene. Otras la comparan con cada fuente y miden cuánto conserva de la visible y de la infrarroja. Como cada métrica premia una propiedad distinta, dos métricas pueden ordenar de manera diferente a los mismos métodos. La Sección 2.4 presenta las que se usan aquí.

2.2. Fusión de imágenes visibles e infrarrojas

Cada cámara capta una parte de la escena y pierde otra. La fusión visible-infrarroja reúne en una sola imagen la textura de la visible y el calor de la infrarroja (Ma, Ma, & Li, 2019). Sus usos van de la vigilancia a la detección y el seguimiento de objetos (S. Li et al.,

2017; Zhang & Demiris, 2023). Las revisiones del área agrupan los métodos de fusión en varias familias (S. Li et al., 2017; Ma, Ma, & Li, 2019; Singh et al., 2023).

2.2.1. Familias de métodos

Una de las familias más difundidas es la multiescala (S. Li et al., 2017). Sus métodos descomponen cada imagen en una base, con el brillo general, y en capas de detalle de distintos tamaños. Luego combinan cada capa con su propia regla y reconstruyen el resultado. Son de este tipo las pirámides, que representan la imagen a resoluciones cada vez menores, y las transformadas *wavelet*, que la analizan con ondas breves. También lo son los cinco métodos multiescala con que se compara la propuesta, descritos en la Sección 2.2.2.

Otra familia usa representaciones dispersas: cada bloque pequeño de la imagen se escribe como la suma de pocos patrones tomados de un repertorio llamado diccionario, cada uno con su peso. En la fusión visible-infrarroja, J. Wang et al. (2014) aplican esa idea sin admitir pesos negativos.

Una tercera familia usa redes neuronales, modelos que aprenden a fusionar a partir de ejemplos (Zhang & Demiris, 2023). FusionGAN, por ejemplo, enfrenta dos redes: una produce la imagen fusionada y la otra la juzga. Así, la regla de fusión se aprende de los ejemplos en lugar de diseñarse a mano (Ma, Yu, et al., 2019). Por eso, estos métodos necesitan entrenarse antes de usarse. Los métodos morfológicos, en cambio, siguen pasos explícitos: extraen el detalle comparando la imagen con una figura pequeña de forma conocida (Serra, 1982). La propuesta de este trabajo pertenece a este grupo. Sus herramientas y su uso en la fusión se presentan en la Sección 2.3.

2.2.2. Métodos multiescala comparativos

La propuesta se compara con cinco métodos multiescala y con el Top-Hat clásico, que se presenta en la Sección 2.3.5. Los cinco multiescala separan cada imagen en capas de distinto detalle, las combinan y reconstruyen la imagen fusionada. En los cinco métodos, el resultado se recorta al intervalo de cero a uno.

Pirámide de Laplace

La pirámide de Laplace (Burt & Adelson, 1983) se propuso como método de codificación compacta de imágenes. Usa copias G_ℓ cada vez más suaves y reducidas a la mitad, desde G_0, que es la imagen. Cada capa L_ℓ guarda lo que se pierde al reducir. Con K capas,

$$L_\ell = G_\ell - \operatorname{amp}(G_{\ell+1}), \quad \ell = 0, 1, \ldots, K-2, \qquad L_{K-1} = G_{K-1}. \tag{2.3}$$

Aquí $\operatorname{amp}(\cdot)$ amplía una copia al doble y la suaviza. La capa fusionada L_ℓ^F, incluida la más gruesa, toma en cada píxel el valor de la fuente de mayor actividad local. Esa actividad es

el valor absoluto de la capa, suavizado en una ventana cuadrada que pesa más el centro. Para reconstruir, se amplía L^F_{K-1}, se le suma L^F_{K-2} y se repite el paso hasta L^F_0.

Pirámide de razón

La pirámide de razón de Toet (1989), pensada para la fusión, divide en lugar de restar. Con K niveles usa $K+1$ de esas copias, de G_0 a G_K:

$$R_\ell = \frac{G_\ell + \eta}{\mathrm{amp}(G_{\ell+1}) + \eta}, \qquad \ell = 0, 1, \ldots, K-1. \tag{2.4}$$

La constante η evita dividir por cero. Una razón igual a uno indica que no hay contraste local. Si es mayor que uno, el punto es más claro que su entorno, y si es menor, más oscuro. En cada píxel, la razón fusionada R^F_ℓ es la más alejada de uno, la de mayor contraste. La copia fusionada más gruesa, G^F_K, es el promedio de las dos G_K. Desde ella se reconstruye por multiplicación:

$$G^F_\ell = R^F_\ell \left[\mathrm{amp}(G^F_{\ell+1}) + \eta\right], \qquad \ell = K-1, \ldots, 1, 0. \tag{2.5}$$

La imagen fusionada es G^F_0.

Transformada *wavelet* discreta

La transformada *wavelet* discreta (DWT, del inglés *Discrete Wavelet Transform*) mide los cambios de la imagen con una *wavelet*, una onda breve usada como patrón. En cada nivel separa la imagen en una aproximación suavizada, de alrededor de la mitad de ancho y alto, y tres detalles: horizontal, vertical y diagonal (Gonzalez & Woods, 2018). El proceso se repite sobre la aproximación, y cada valor obtenido es un coeficiente. El trabajo de H. Li et al. (1995) la aplica a la fusión de imágenes de distintos sensores. La primera de las dos DWT comparadas, llamada DWT (Haar), usa la base de Haar. Esa base es la onda más simple: suma y resta píxeles vecinos por pares (Gonzalez & Woods, 2018). La aproximación A se promedia. Cada coeficiente de detalle D se toma de la fuente en que es mayor en valor absoluto:

$$A^F = \tfrac{1}{2}\left(A^{\mathrm{VIS}} + A^{\mathrm{IR}}\right), \qquad D^F = \begin{cases} D^{\mathrm{VIS}} & \text{si } |D^{\mathrm{VIS}}| \geq |D^{\mathrm{IR}}|, \\ D^{\mathrm{IR}} & \text{en otro caso.} \end{cases} \tag{2.6}$$

Transformada *wavelet* compleja de doble árbol

Según Kingsbury (2001), la DWT tiene dos límites: sus coeficientes cambian mucho si la imagen se desplaza un píxel, y solo distingue tres direcciones. La transformada *wavelet* compleja de doble árbol (DTCWT, del inglés *Dual-Tree Complex Wavelet Transform*) busca un análisis casi invariante al desplazamiento, es decir, estable ante esos cambios. Usa dos cadenas de filtros en paralelo, llamadas árboles; un filtro es una operación que deja pasar solo ciertos detalles. Las salidas de los árboles forman coeficientes complejos, números con una parte real y otra imaginaria. El módulo de cada coeficiente, que reúne las dos partes en un solo valor, varía poco ante desplazamientos pequeños. Cada nivel ofrece, además, seis orientaciones. Para fusionar se aplica la regla de la Ecuación (2.6), con el módulo en lugar del valor absoluto.

Transformada *wavelet* discreta con la base de Daubechies

El quinto método multiescala es una segunda DWT, con la regla de la Ecuación (2.6) y la base de Daubechies de orden cuatro (Daubechies, 1988). Esa base tiene filtros más largos y una onda más suave que la de Haar. Como sigue siendo una DWT, distingue las mismas tres direcciones. En adelante se la llama DWT (db4), para distinguirla de la DWT (Haar).

2.3. Morfología matemática y transformada Top-Hat

La morfología matemática analiza la forma de las estructuras de una imagen (Serra, 1982). Para eso la compara con una figura pequeña de forma conocida, llamada elemento estructurante, que se desplaza por todos los píxeles. En escala de grises, cada nivel de gris se lee como una altura, y la imagen se ve como un relieve de montes claros y valles oscuros. El elemento estructurante b es el conjunto de desplazamientos (j, k) de sus píxeles respecto de su centro, e incluye al centro mismo. El desplazamiento j se mide en columnas y k en filas, como x e y en la imagen. La forma y el tamaño del elemento deciden qué detalles se conservan.

2.3.1. Operaciones básicas

Las operaciones morfológicas parten de dos básicas, la erosión y la dilatación (Gonzalez & Woods, 2018; Soille, 2004). La erosión, ε, toma en cada píxel el menor nivel de gris bajo el elemento centrado en él, y la dilatación, δ, el mayor:

$$\varepsilon(f,b)(x,y) = \min_{(j,k)\in b} f(x+j,\, y+k), \qquad \delta(f,b)(x,y) = \max_{(j,k)\in b} f(x+j,\, y+k). \tag{2.7}$$

Los vecinos que caen fuera de la imagen se ignoran. El elemento es plano: solo indica qué vecinos se comparan. La erosión angosta los montes y borra los más estrechos que el elemento, y la dilatación hace lo mismo con los valles. Algunos textos, como el de Gonzalez y Woods (2018), giran el elemento media vuelta en la dilatación. Con elementos simétricos respecto de su centro, como los de este trabajo, ese giro no cambia el resultado.

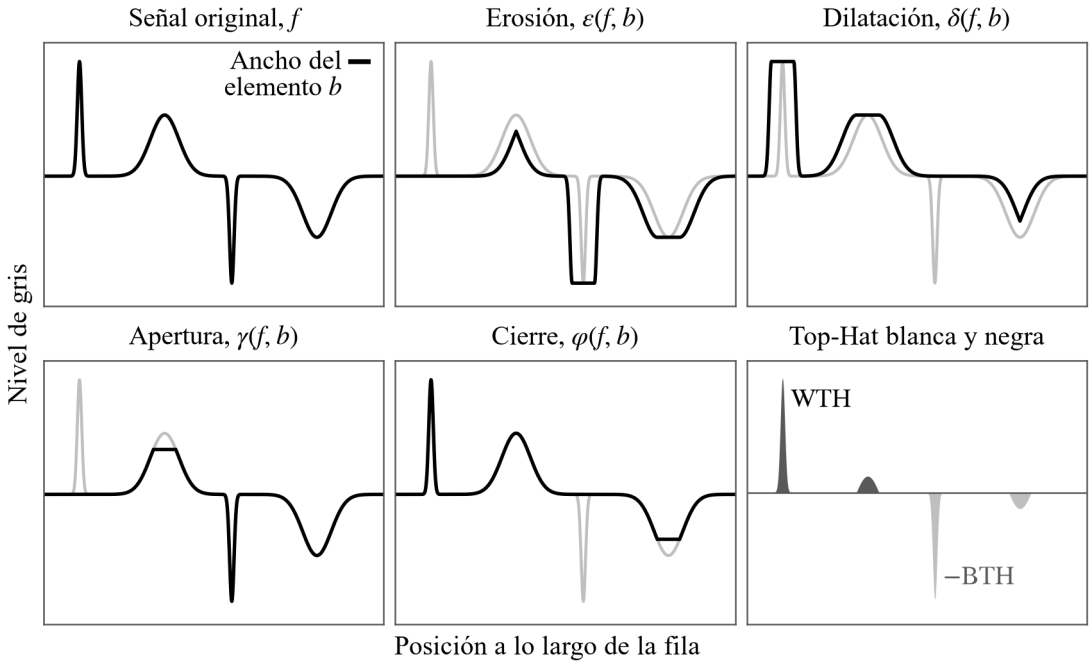
La apertura, γ, es una erosión seguida de una dilatación con el mismo elemento. El cierre, φ, es una dilatación seguida de una erosión:

$$\gamma(f, b) = \delta\Big(\varepsilon(f, b),\, b\Big), \qquad \varphi(f, b) = \varepsilon\Big(\delta(f, b),\, b\Big). \tag{2.8}$$

La apertura rebaja los montes en los que el elemento no cabe hasta la altura en que sí cabe, y deja casi intacto el resto. El cierre rellena, del mismo modo, los valles en los que el elemento no cabe. Por eso la apertura nunca supera a la imagen y el cierre nunca queda por debajo de ella (Soille, 2004). La Figura 2.1 muestra el efecto de estas cuatro operaciones sobre una señal de una dimensión, como los niveles de gris a lo largo de una fila. Su último panel anticipa la transformada Top-Hat, que se define a continuación.

Figura 2.1

Operaciones morfológicas básicas y transformada Top-Hat sobre una señal de una dimensión



Nota. Elaboración propia. La barra del primer panel marca el ancho del elemento estructurante b. En los cuatro paneles siguientes se repite en gris la señal original f. En el último, la Top-Hat blanca se dibuja hacia arriba y la negra, con el signo cambiado, hacia abajo. Los montes y valles más estrechos que b pasan enteros a la Top-Hat; de los más anchos, solo pasa la parte más estrecha que b.

2.3.2. Transformada Top-Hat

La transformada Top-Hat mide cuánto cambia la imagen al aplicarle la apertura o el cierre. La Top-Hat blanca (WTH, del inglés *White Top-Hat*) es la imagen menos su apertura. La negra (BTH, del inglés *Black Top-Hat*) es el cierre menos la imagen (Gonzalez & Woods, 2018; Soille, 2004):

$$\mathrm{WTH}(f,b) = f - \gamma(f,b), \qquad \mathrm{BTH}(f,b) = \varphi(f,b) - f. \tag{2.9}$$

La blanca conserva los detalles claros más estrechos que el elemento, y la negra, los oscuros. Las dos son mayores o iguales que cero, y casi nulas en las zonas planas o de variación suave. Así separan el detalle fino, que queda en las dos Top-Hat, del fondo, que queda en la apertura y en el cierre.

2.3.3. Tamaño y forma del elemento estructurante

El tamaño del elemento fija la frontera entre el detalle y el fondo (Gonzalez & Woods, 2018; Soille, 2004). De cada monte o valle, la Top-Hat recoge la parte más estrecha que el elemento, y el resto queda en el fondo. Con un elemento pequeño, la Top-Hat recoge solo la textura fina, las líneas delgadas y el ruido. Con uno grande puede recoger además objetos enteros, como una persona o un vehículo que se destacan de su entorno. En este trabajo el tamaño se expresa con un radio r, en píxeles, y cada elemento se extiende unos r píxeles a cada lado de su centro.

La forma del elemento decide en qué direcciones se mide ese ancho (Serra, 1982; Soille, 2004). Un disco mide lo mismo en todas las direcciones y no distingue la orientación de los detalles. Un segmento de recta, en cambio, mira en una sola dirección. La apertura con un segmento conserva las estructuras claras que se extienden en esa dirección al menos tanto como el segmento, y rebaja las demás. Por eso el segmento no extrae las estructuras alineadas con él: como cabe en ellas, estas sobreviven a la apertura y la Top-Hat vale cero allí. Extrae, en cambio, los detalles más angostos que su largo en esa dirección. Así, un objeto alargado queda en el fondo con un segmento paralelo y pasa a la Top-Hat con uno perpendicular más largo que su ancho.

2.3.4. Realce de contraste

La Top-Hat sirve también para realzar el contraste, es decir, para que un detalle se distinga mejor de su entorno. Su forma más simple suma a la imagen su Top-Hat blanca y le resta la negra (Bai et al., 2012):

$$f_{\mathrm{R}} = f + \mathrm{WTH}(f,b) - \mathrm{BTH}(f,b). \tag{2.10}$$

Aquí f_{R} es la imagen realzada. Los detalles claros se aclaran, los oscuros se oscurecen y el fondo casi no cambia. Los trabajos de Mukhopadhyay y Chanda (2000) y Bai et al. (2012) llevan esta idea a varias escalas, con elementos de tamaños crecientes. Algunos métodos morfológicos de fusión la aplican a dos imágenes a la vez (Bai, 2013; Mello Román et al., 2020), y así lo hace también el algoritmo propuesto.

2.3.5. Fusión basada en la transformada Top-Hat

En su versión más simple, la fusión basada en la transformada Top-Hat separa en cada fuente el detalle del fondo y agrega el detalle de ambas a una imagen base común (Mello Román et al., 2020; Ortega Rodríguez & Espinoza Ríos, 2025). La regla siguiente es común al Top-Hat clásico y a la propuesta. Retoma la de Ortega Rodríguez y Espinoza Ríos (2025), incluido el peso que regula cuánto detalle se agrega, y recorta el resultado de forma explícita al intervalo de cero a uno. Sean $\mathrm{WTH}_{\mathrm{VIS}}$ y $\mathrm{BTH}_{\mathrm{VIS}}$ las transformadas Top-Hat blanca y negra de la visible, y $\mathrm{WTH}_{\mathrm{IR}}$ y $\mathrm{BTH}_{\mathrm{IR}}$ las de la infrarroja. La imagen fusionada es

$$F = \mathrm{recorte}\Big(\tfrac{1}{2}\big(I_{\mathrm{VIS}} + I_{\mathrm{IR}}\big) + m\,\mathrm{máx}\big(\mathrm{WTH}_{\mathrm{VIS}},\, \mathrm{WTH}_{\mathrm{IR}}\big) - m\,\mathrm{máx}\big(\mathrm{BTH}_{\mathrm{VIS}},\, \mathrm{BTH}_{\mathrm{IR}}\big)\Big). \tag{2.11}$$

Aquí m es un peso no negativo, y el máximo se toma píxel a píxel. La función $\mathrm{recorte}(z) = \mathrm{mín}\{1, \mathrm{máx}\{0, z\}\}$ lleva a cero los valores negativos y a uno los mayores que uno.

La regla parte del promedio de las dos fuentes, que hace de imagen base. En cada píxel toma el mayor detalle claro y el mayor detalle oscuro de las dos fuentes, así que un detalle se conserva si al menos una de las cámaras lo capta. El claro se suma a la base y el oscuro se resta. Como las transformadas Top-Hat nunca son negativas, la suma aclara los detalles claros y la resta oscurece los oscuros. Así crece el contraste local, la diferencia de brillo entre un detalle y su entorno. Con $m = 0$ la fusión es el promedio simple, y cuanto mayor es m, más detalle se agrega. Un peso alto puede sacar más píxeles del intervalo de cero a uno, que el recorte deja en negro o en blanco. El Top-Hat clásico sigue la fusión con Top-Hat de Bajac Figueredo et al. (2025) y aplica esta regla con un único disco como elemento estructurante.

2.4. Métricas de evaluación sin referencia

La calidad de una fusión visible-infrarroja se estima con métricas que no necesitan una imagen fusionada ideal (Ma, Ma, & Li, 2019; Singh et al., 2023). Para Singh et al. (2023), sin referencia son solo las que usan la fusión sola; las que la comparan con las fuentes son de referencia parcial. Aquí se usan seis, en dos grupos de tres. Las del primer grupo

miden la actividad: cuánta información, cuánto contraste y cuánta nitidez de bordes tiene la fusión por sí misma. Las del segundo miden la fidelidad, es decir, cuánto se parece la fusión a cada fuente. En las seis, un valor mayor se considera mejor. En lo que sigue, F es la imagen fusionada, de H filas y W columnas, y X designa una fuente, sea I_{VIS} o I_{IR}.

2.4.1. Métricas de actividad

Las tres métricas de actividad son la entropía (EN, del inglés *Entropy*), la desviación estándar (SD, del inglés *Standard Deviation*) y el gradiente medio (MG, del inglés *Mean Gradient*).

La entropía mide cuán repartidos están los píxeles entre los niveles de gris (Ortega Rodríguez & Espinoza Ríos, 2025; Singh et al., 2023). Para calcularla, el intervalo de cero a uno se divide en 256 tramos iguales, y p_a es la proporción de píxeles de F que caen en el tramo a. Ese reparto se llama histograma. La entropía es

$$\mathrm{EN}(F) = -\sum_{a=0}^{255} p_a \log_2 p_a. \tag{2.12}$$

Los tramos vacíos no aportan. Se mide en bits, la unidad de información, y alcanza su máximo, 8 bits, cuando todos los tramos tienen la misma proporción.

La desviación estándar mide el contraste general, es decir, cuánto se alejan en promedio las intensidades de su valor medio μ_F (Ortega Rodríguez & Espinoza Ríos, 2025; Singh et al., 2023). Una imagen de tono parejo tiene una desviación baja, y una con zonas muy claras junto a zonas muy oscuras la tiene alta. Se calcula como

$$\mathrm{SD}(F) = \sqrt{\frac{1}{HW}\sum_{x=1}^{W}\sum_{y=1}^{H}\big(F(x,y)-\mu_F\big)^2}, \qquad \mu_F = \frac{1}{HW}\sum_{x=1}^{W}\sum_{y=1}^{H} F(x,y). \tag{2.13}$$

Aquí $F(x, y)$ es la intensidad del píxel de la columna x y la fila y. La suma de cuadrados se divide por el número total de píxeles, HW. Como las intensidades van de cero a uno, SD no puede superar 0.5. Su cuadrado se llama varianza.

El gradiente medio mide la nitidez de los bordes (Singh et al., 2023). El gradiente indica cuánto cambia la intensidad de un píxel a sus vecinos, y crece donde la imagen salta de claro a oscuro. En el interior de la imagen se calcula con diferencias centrales, entre el vecino anterior y el siguiente:

$$G_x(x,y) = \frac{F(x+1,y)-F(x-1,y)}{2}, \qquad G_y(x,y) = \frac{F(x,y+1)-F(x,y-1)}{2}. \tag{2.14}$$

Aquí G_x es el cambio horizontal y G_y el vertical. En las filas y columnas extremas, donde falta un vecino, se usa la diferencia con el único disponible, sin dividir por dos. Así,

$$\mathrm{MG}(F) = \frac{1}{HW} \sum_{x=1}^{W} \sum_{y=1}^{H} \sqrt{G_x(x,y)^2 + G_y(x,y)^2}. \tag{2.15}$$

El valor depende de la fórmula de las diferencias, así que solo se comparan valores calculados de la misma manera.

2.4.2. Métricas de fidelidad

Las tres métricas de fidelidad son la información mutua (MI, del inglés *Mutual Information*), la similitud estructural (SSIM, del inglés *Structural Similarity*) y la relación señal-ruido de pico (PSNR, del inglés *Peak Signal-to-Noise Ratio*).

La información mutua mide cuánto baja la incertidumbre sobre el nivel de gris de un píxel en una fuente X al conocer su nivel en F (Qu et al., 2002). Para calcularla, cada intensidad se multiplica por 63 y se trunca al entero inferior, lo que deja 64 niveles. Con ellos se arma el histograma conjunto, donde $p_{FX}(a, c)$ es la proporción de píxeles con nivel a en F y nivel c en X. Así,

$$\mathrm{MI}(F, X) = \sum_{a=0}^{63} \sum_{c=0}^{63} p_{FX}(a, c) \, \log_2 \frac{p_{FX}(a, c)}{p_F(a)\, p_X(c)}. \tag{2.16}$$

Aquí $p_F(a)$ y $p_X(c)$ son las proporciones en cada imagen sola, y las casillas vacías no aportan. La métrica del trabajo promedia las dos fuentes en cada par de imágenes:

$$\mathrm{MI} = \tfrac{1}{2}\Big[\mathrm{MI}(F, I_{\mathrm{VIS}}) + \mathrm{MI}(F, I_{\mathrm{IR}})\Big]. \tag{2.17}$$

Si se sumaran los dos términos, el valor se duplicaría sin cambiar el orden de los métodos.

El índice de similitud estructural compara dos imágenes por zonas pequeñas, o ventanas (Z. Wang et al., 2004). En cada ventana w compara el brillo medio, el contraste y el patrón de variación de X y de F:

$$\mathrm{SSIM}_w(X, F) = \frac{(2\mu_X\mu_F + C_1)(2\sigma_{XF} + C_2)}{(\mu_X^2 + \mu_F^2 + C_1)(\sigma_X^2 + \sigma_F^2 + C_2)}. \tag{2.18}$$

Aquí μ_X y μ_F son las medias en la ventana, σ_X^2 y σ_F^2 las varianzas, y σ_{XF} la covarianza, que mide cuánto varían juntas. Las constantes $C_1 = (0.01)^2$ y $C_2 = (0.03)^2$ evitan dividir por cero. En este trabajo la ventana mide 7×7 píxeles, todos con el mismo peso, y las varianzas y la covarianza se dividen por 48. La versión original usa una ventana mayor que pesa más el centro (Z. Wang et al., 2004). El índice promedia SSIM_w sobre las ventanas

que caben enteras, y la métrica final promedia las dos fuentes:

$$\mathrm{SSIM} = \tfrac{1}{2}\Big[\mathrm{SSIM}(I_{\mathrm{VIS}}, F) + \mathrm{SSIM}(I_{\mathrm{IR}}, F)\Big]. \tag{2.19}$$

La relación señal-ruido de pico expresa el error numérico entre dos imágenes en escala logarítmica, que reúne en un rango corto valores muy distintos (Singh et al., 2023). Se apoya en el error cuadrático medio (MSE, del inglés *Mean Squared Error*), el promedio de los cuadrados de las diferencias píxel a píxel. Siguiendo a Ortega Rodríguez y Espinoza Ríos (2025), primero se promedian los errores frente a las dos fuentes y después se toma el logaritmo. Así,

$$\begin{aligned} \mathrm{MSE}(F, X) &= \frac{1}{HW} \sum_{x=1}^{W} \sum_{y=1}^{H} \Big(F(x,y) - X(x,y)\Big)^2, \\ \mathrm{PSNR} &= 10 \log_{10} \frac{1}{\frac{1}{2}\Big[\mathrm{MSE}(F, I_{\mathrm{VIS}}) + \mathrm{MSE}(F, I_{\mathrm{IR}})\Big]}. \end{aligned} \tag{2.20}$$

El 1 del numerador es el cuadrado de la mayor intensidad posible. La PSNR se mide en decibelios, la unidad de esa escala, y un valor alto indica que la fusión se aparta poco de sus fuentes. En la escala de 0 a 255 el valor no cambia, porque el numerador y el error crecen en la misma proporción. Promediar los errores no equivale a promediar las dos PSNR.

2.4.3. Selección de las seis métricas

Las seis resultan de depurar con dos criterios una batería inicial de nueve métricas. Esa batería incluye las cinco que usan Ortega Rodríguez y Espinoza Ríos (2025). El primer criterio es no repetir información. La eficiencia de fusión (FE, del inglés *Fusion Efficiency*) divide la EN de la fusión por la EN media de las fuentes. Como ese divisor es fijo en cada par, FE ordena los métodos igual que EN. La frecuencia espacial (SF, del inglés *Spatial Frequency*) mide el cambio entre píxeles vecinos (Eskicioglu & Fisher, 1995), casi lo mismo que MG. La batería contaba aparte la MI con cada fuente, lo que duplicaba su peso. Sin esas tres repeticiones quedan las seis. El segundo criterio es el equilibrio. La actividad sube también con el ruido, y la fidelidad, con solo copiar las fuentes; por eso los dos grupos tienen tres métricas cada uno.

2.4.4. Métricas complementarias

Otras ocho métricas se calculan solo como comprobación, y el Capítulo 4 las usa con ese fin. El índice de información de bordes (Qabf) mide cuánta información de bordes pasa de las fuentes a la fusión (Xydeas & Petrović, 2000). La medida de ruido y artefactos de fusión (Nabf) se propuso después en ese marco (Petrović & Xydeas, 2005). Pondera los píxeles

donde la fusión tiene bordes más fuertes que las dos fuentes, y es la única en que un valor menor es mejor. Aquí se usa la ponderación modificada de Shreyamsha Kumar (2013). La suma de las correlaciones de las diferencias (SCD, del inglés *Sum of the Correlations of Differences*) suma, para cada fuente, su correlación con la diferencia entre la imagen fusionada y la otra fuente (Aslantas & Bendes, 2015). La fidelidad de la información visual (VIF, del inglés *Visual Information Fidelity*) mide cuánta información visual de un original conserva otra imagen (Sheikh & Bovik, 2006); aquí, el original es cada fuente. La información mutua de características (FMI, del inglés *Feature Mutual Information*) aplica la información mutua a los gradientes (Haghighat et al., 2011). Las tres variantes de Piella y Heijmans (2003) calculan por ventanas el índice de la Ecuación (2.18) sin C_1 ni C_2 y combinan esos valores con distintos pesos. Son el índice ponderado por la varianza local (Q0), el ponderado por ventana (QW) y el de bordes (QE). En el primero, el índice de cada fuente pesa en cada ventana según su varianza local. El segundo da además más peso a las ventanas de mayor varianza, y el tercero multiplica QW por el mismo índice calculado sobre los bordes de las imágenes. En esa obra el primero se llama Q; aquí figura como Q0, aunque sus autores reservan ese nombre para el índice sin ponderar. Las ocho comparan la fusión con sus fuentes, y sumarlas inclinaría el equilibrio hacia la fidelidad.

2.5. Pruebas estadísticas

Para comparar la calidad de los métodos se usan pruebas no paramétricas, que no suponen una distribución normal de los datos. La prueba de Friedman (Friedman, 1937) trata cada par de imágenes como un bloque: ordena los métodos dentro de cada par y pregunta si alguno tiende a quedar mejor o peor ubicado. La prueba de Wilcoxon de rangos con signo (Wilcoxon, 1945) compara dos métodos a partir de sus diferencias en los mismos pares. Cada prueba da un valor de p: la probabilidad de ver una diferencia al menos tan grande si los métodos fueran iguales. Como las comparaciones por pares son muchas, esos valores se corrigen con el procedimiento de Holm (1979). Ese procedimiento los ordena de menor a mayor y los compara con umbrales que empiezan muy estrictos y se aflojan paso a paso.

Cuando las observaciones de un mismo grupo no son independientes, como los cuadros de un mismo tramo de video, el error estándar se calcula por grupos y no por observación (Cameron & Miller, 2015). Con pocos grupos, ese error tiende a subestimar la variación, y el *bootstrap* salvaje por grupos estudentizado ofrece una prueba más confiable (Cameron et al., 2008; Webb, 2023). Este repite el cálculo miles de veces, con el aporte de cada grupo multiplicado por un peso al azar, y en cada repetición divide la estimación por su propio error estándar. La correlación de rangos de Spearman (Spearman, 1904), por último, mide cuánto coinciden dos ordenamientos de los mismos elementos.

2.6. Optimización por enjambre de partículas

La optimización por enjambre de partículas (PSO, del inglés *Particle Swarm Optimization*) es un método de búsqueda propuesto por Kennedy y Eberhart (1995). El método mueve un grupo de soluciones posibles, llamadas partículas, dentro de una región de búsqueda. En la fusión de imágenes, Tao et al. (2010) combinan la PSO con la DTCWT, y Malviya y Saxena (2014), con la transformada *wavelet*. Por su parte, Ortega Rodríguez y Espinoza Ríos (2025) la aplican a los parámetros de la transformada Top-Hat en la fusión visible-infrarroja.

La búsqueda avanza por iteraciones, es decir, por pasos sucesivos. En la iteración t, la partícula i ocupa la posición $\mathbf{x}_i^t$ y tiene la velocidad $\mathbf{v}_i^t$, que indica hacia dónde y cuánto se desplaza. Al comenzar, las posiciones y las velocidades se sortean al azar. Cada partícula recuerda la mejor posición que ha visitado, $\mathbf{p}_i^t$, y conoce la mejor posición del grupo, $\mathbf{g}^t$. Para decidir cuál es mejor se usa una función de aptitud, que asigna a cada posición un número, mayor cuanto mejor es la solución. En cada iteración se evalúan las partículas y se actualizan esas mejores posiciones. Luego cada partícula cambia su velocidad:

$$\mathbf{v}_i^{t+1} = w_t\,\mathbf{v}_i^t + c_1\,\boldsymbol{\rho}_1 \odot \left(\mathbf{p}_i^t - \mathbf{x}_i^t\right) + c_2\,\boldsymbol{\rho}_2 \odot \left(\mathbf{g}^t - \mathbf{x}_i^t\right). \tag{2.21}$$

Con ella, la nueva posición es

$$\mathbf{x}_i^{t+1} = \text{mín}\Big(\text{máx}\Big(\mathbf{x}_i^t + \mathbf{v}_i^{t+1},\, \mathbf{x}_{\text{mín}}\Big),\, \mathbf{x}_{\text{máx}}\Big). \tag{2.22}$$

Los vectores $\boldsymbol{\rho}_1$ y $\boldsymbol{\rho}_2$ contienen números al azar entre cero y uno, todos igual de probables. Se sortean de nuevo en cada iteración, para cada partícula y cada coordenada. El símbolo $\odot$ indica el producto coordenada a coordenada. Los coeficientes c_1 y c_2 regulan la atracción hacia la mejor posición propia y hacia la del grupo. En la Ecuación (2.22), el mínimo y el máximo mantienen cada coordenada dentro de los límites $\mathbf{x}_{\text{mín}}$ y $\mathbf{x}_{\text{máx}}$ de la región de búsqueda. El factor w_t, llamado inercia, regula cuánto conserva cada partícula de su velocidad anterior. Ese factor no figura en la versión original de Kennedy y Eberhart (1995); lo introducen Shi y Eberhart (1998).

Cuando la inercia decrece en línea recta a lo largo de las T iteraciones, va de $w_{\text{máx}}$ en la primera a $w_{\text{mín}}$ en la última. Su valor en la iteración t es entonces

$$w_t = w_{\text{máx}} - (w_{\text{máx}} - w_{\text{mín}})\,\frac{t}{T-1}, \qquad t = 0, 1, \ldots, T-1. \tag{2.23}$$

Con una inercia alta pesa más la velocidad anterior, y con una baja, la atracción hacia las mejores posiciones halladas. Al terminar las iteraciones, la solución es la mejor posición del grupo.

2.7. Detección de objetos

2.7.1. Funcionamiento de un detector

La detección automática de objetos consiste en encontrar y ubicar en una imagen los objetos de ciertas clases, como personas o luces. El detector se entrena con imágenes en las que cada objeto está marcado con una caja rectangular y su clase. Luego, ante una imagen nueva, devuelve predicciones: cajas con una clase y un puntaje de confianza, que indica cuán seguro está el modelo. El detector YOLO (del inglés *You Only Look Once*, «solo se mira una vez») propone las cajas y sus clases en una sola pasada, al ritmo del video (Redmon et al., 2016). Su octava versión, YOLOv8, es de libre distribución y ofrece cinco tamaños y pesos preentrenados, es decir, valores internos ya aprendidos con otras imágenes (Jocher et al., 2023).

2.7.2. Intersección sobre la unión, precisión y exhaustividad

Para juzgar una predicción, su caja B se compara con la caja marcada A. Se usa la intersección sobre la unión (IoU, del inglés *Intersection over Union*), con la que YOLO define también la confianza de sus cajas (Redmon et al., 2016):

$$\mathrm{IoU}(A, B) = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}. \tag{2.24}$$

Aquí $A \cap B$ es la zona común a las dos cajas, y $|\cdot|$ indica el área. La IoU vale uno si las cajas coinciden y cero si no se superponen. Solo cuentan las predicciones cuyo puntaje de confianza alcanza un umbral. Cada objeto marcado se une, como máximo, a una predicción de su misma clase: la de mayor IoU entre las que siguen libres. En este trabajo, si esa IoU alcanza 0.5, el objeto cuenta como encontrado. Ese umbral es el del desafío de reconocimiento visual de objetos PASCAL VOC (del inglés *Pattern Analysis, Statistical Modelling and Computational Learning Visual Object Classes*), descrito por Everingham et al. (2010). La predicción es entonces un verdadero positivo, VP, y deja de estar libre.

Las predicciones que quedan libres son falsos positivos, FP, y los objetos sin pareja, falsos negativos, FN. Con esos conteos se definen la precisión P y la exhaustividad R:

$$P = \frac{VP}{VP + FP}, \qquad R = \frac{VP}{VP + FN}. \tag{2.25}$$

La primera mide qué parte de las predicciones es correcta; la segunda, qué parte de los objetos se encuentra. Ambas dependen del umbral de confianza. Al bajarlo, R crece o se mantiene, y P suele caer. La exhaustividad se llama también tasa de acierto. Calculada sobre un grupo elegido de objetos, es la base de la medida de detección de este trabajo, descrita en la Sección 3.5.

2.7.3. Precisión media

La precisión media (AP, del inglés *Average Precision*) resume la relación entre P y R en todos los umbrales de confianza. Se calcula para cada clase por separado:

$$\mathrm{AP} = \int_0^1 \tilde{P}(R)\, dR. \tag{2.26}$$

Aquí $\tilde{P}(R)$ es la mayor precisión lograda con una exhaustividad de R o más. La integral se aproxima con 101 valores de R repartidos por igual entre cero y uno, como hace la biblioteca Ultralytics (Jocher et al., 2023). La AP depende también del umbral de IoU que decide los aciertos; con 0.5 se escribe AP50. La mAP50 es la media de la AP50 sobre las C clases con objetos marcados:

$$\mathrm{mAP50} = \frac{1}{C} \sum_{c=1}^{C} \mathrm{AP50}_c. \tag{2.27}$$

Aquí $\mathrm{AP50}_c$ es la de la clase c.

2.7.4. La detección como evaluación de la fusión

La detección sirve también para evaluar una fusión. Esa evaluación exige cuidado, porque un detector aprende la apariencia de sus imágenes de entrenamiento, como el contraste y la textura. Si se lo aplica sin reentrenar a imágenes de otro aspecto, su acierto puede caer, como muestran Redmon et al. (2016) con pinturas. Así, el resultado de la detección puede reflejar en parte ese cambio de aspecto, y no solo la utilidad de la fusión. Para comparar métodos en igualdad de condiciones, Liu et al. (2022) entrenan un detector con las imágenes fusionadas de cada uno. Este trabajo sigue esa práctica, como detalla la Sección 3.5.

2.8. Estado del arte y brecha existente

Entre los antecedentes de fusión basados en la transformada Top-Hat, Bai et al. (2011) extraen de las fuentes sus regiones claras y oscuras de varias escalas con una Top-Hat de centro y entorno (*center-surround*). Esas regiones se incorporan a una imagen base calculada a partir de las fuentes. Más adelante, Bai (2013) propone una fusión morfológica que extrae las regiones con una Top-Hat multiescala, es decir, repetida con elementos de tamaño creciente. Los detalles los extrae con un operador de contraste por conmutación (*toggle contrast operator*). A su vez, Zhu et al. (2017) mejoran la Top-Hat de centro y entorno de varias escalas, y proponen una regla para fusionar las regiones de cada escala y otra para formar la imagen base. Dos años después, Saravia et al. (2019) extraen las regiones claras y oscuras con una Top-Hat multiescala y dos elementos estructurantes. En

la Universidad Nacional de Asunción, Mello Román et al. (2020) proponen otro método morfológico multiescala para fusionar imágenes visibles e infrarrojas. Ese trabajo y el de Saravia et al. (2019) se publicaron en el marco de la tesis doctoral de Mello Román (2021), que reúne esquemas Top-Hat multiescala para la mejora y la fusión de imágenes. Todos ellos operan en varias escalas; el algoritmo propuesto, en una sola. La Top-Hat se aplica también a otros pares de imágenes. Con una visible en color y una infrarroja cercana, no térmica, Herrera-Arellano et al. (2021) fusionan de forma selectiva las estructuras más relevantes para mejorar fotografías de exteriores degradadas por el mal tiempo.

El antecedente directo es el trabajo de Bajac Figueredo et al. (2025), entre cuyos autores figuran los de esta tesis. Ese trabajo aplica la Top-Hat a la fusión de imágenes infrarrojas y visibles. Después, Ortega Rodríguez y Espinoza Ríos (2025) emplean una regla con un peso que regula cuánto detalle se agrega, y ajustan ese peso y el radio del disco con optimización por enjambre de partículas.

El banco de cinco elementos estructurantes del algoritmo propuesto, un disco y cuatro segmentos orientados, se diseñó para el realce de mamografías (Flores et al., 2026). Ese trabajo lo usa con una Top-Hat de varias escalas. La forma de combinar sus respuestas proviene del realce de imágenes de fondo de ojo (Bala et al., 2024). Ninguno de los trabajos revisados aplica ese banco a la fusión visible-infrarroja.

Las métricas sin referencia juzgan la imagen o su parecido con las fuentes, pero no su utilidad para una tarea. Una alternativa reciente evalúa la fusión por su efecto en una tarea de alto nivel, es decir, una que interpreta la escena, como detectar objetos. En esa línea, Liu et al. (2022) orientan su red de fusión a los objetos de interés y publican M3FD, un conjunto de pares con objetos marcados. Por su parte, Tang et al. (2022) entrenan la red de fusión junto con una de segmentación, que asigna cada píxel a una clase de objeto. Esos trabajos presentan redes neuronales de fusión guiadas por la tarea. Para el banco de cinco elementos, la literatura revisada no ofrece una evaluación de ese tipo.

Esos dos vacíos, el uso del banco en la fusión visible-infrarroja y su evaluación por una tarea, forman la brecha que aborda este trabajo. A diferencia de las redes guiadas por la tarea, el algoritmo propuesto no aprende de la detección: la tarea solo sirve para evaluarlo.

Capítulo 3

Metodología

Este capítulo expone cómo se construyó el algoritmo propuesto y cómo se lo evaluó. Después del enfoque y las variables del estudio, la Sección 3.1 presenta los conjuntos de imágenes. La Sección 3.2 define el algoritmo y los métodos comparativos, y la Sección 3.3 describe el ajuste de su radio y su peso. Siguen la evaluación de la calidad (Sección 3.4), la de la aplicación a la detección (Sección 3.5) y el examen de la hipótesis (Sección 3.6). La Figura 3.1 reúne esas etapas en un diagrama. En él, los dos conjuntos de imágenes reciben el mismo preprocesamiento y se fusionan con los mismos siete métodos. A partir de ahí el diagrama se abre: la rama izquierda lleva a la evaluación de la calidad, con el conjunto TNO, y la derecha, a la de la detección, con el conjunto M3FD. Las dos ramas terminan en el examen de la hipótesis. La flecha doble indica que el enjambre evalúa el propio algoritmo y le devuelve el radio y el peso.

El enfoque fue cuantitativo. Cada conclusión se apoyó en mediciones numéricas sobre conjuntos fijos de imágenes, analizadas con pruebas estadísticas o, donde no hubo una prueba propia, de forma descriptiva, y no en el juicio de observadores. El diseño fue experimental y comparativo. Todos los métodos procesaron las mismas imágenes y se midieron con el mismo procedimiento, de modo que de una condición a otra solo varió la forma de fusionar.

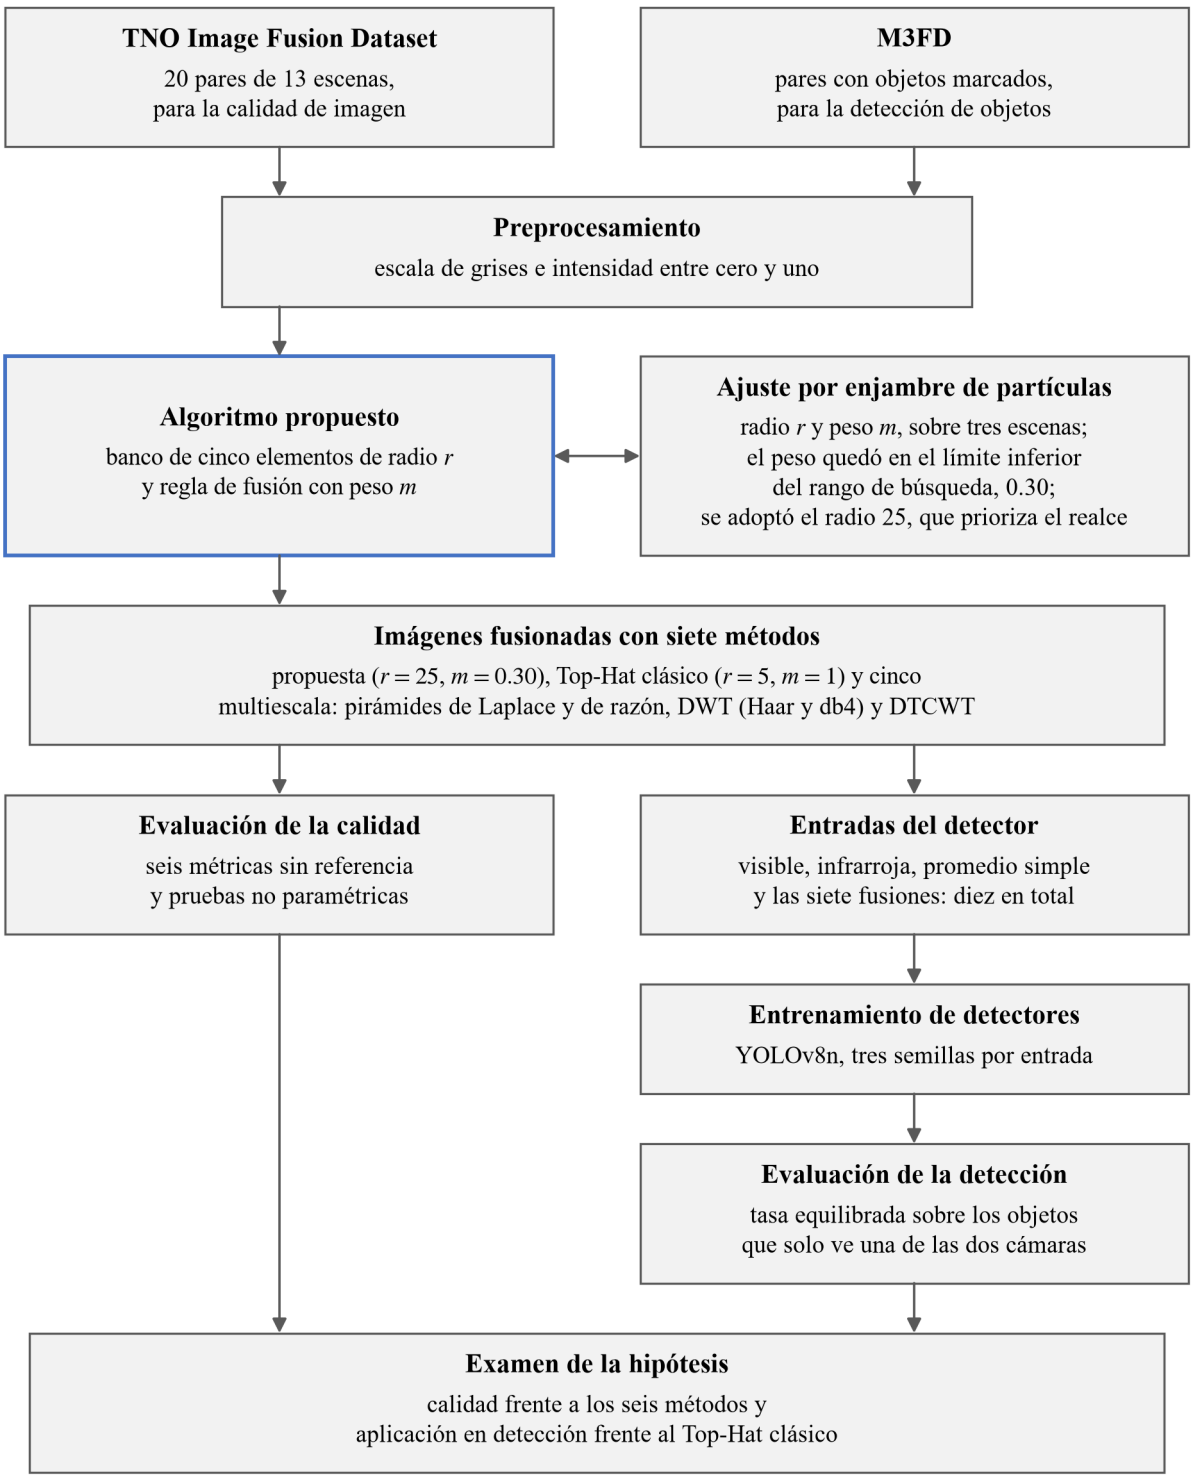
La evaluación se hizo en dos planos. El primero es la calidad de la imagen fusionada, juzgada por sí misma con métricas numéricas. El segundo es su aplicación, es decir, cuánto le sirve esa imagen a un detector automático de objetos. Cada plano usa su propio conjunto de imágenes y se informa por separado, porque un método puede destacar en uno y no en el otro.

Las variables del estudio fueron las siguientes:

- **Variable independiente:** El método de fusión. En la evaluación de calidad tomó siete valores: el algoritmo propuesto, el Top-Hat clásico y cinco métodos multiescala. En la detección hubo diez entradas para el detector: la imagen visible, la infrarroja, el promedio simple de ambas y las siete fusiones.

Figura 3.1

Etapas del estudio



Nota. Elaboración propia. El recuadro azul destaca el algoritmo propuesto.

- **Variables dependientes:** Las seis métricas de calidad de imagen y la tasa de acierto equilibrada del detector sobre los objetos vistos por una sola cámara.
- **Variables controladas:** En la calidad, los pares de imágenes, el preprocesamiento y el cálculo de las métricas. En la detección, los cuadros, las etiquetas de los objetos y la configuración del detector.

3.1. Conjuntos de imágenes y preprocesamiento

La calidad de imagen se midió sobre el *TNO Image Fusion Dataset* (Toet, 2014, 2017). El conjunto reúne pares de imágenes nocturnas de escenas militares y de vigilancia, captados a la vez por una cámara visible y por una térmica. En buena parte de los pares, la visible proviene de una cámara con intensificador de imagen, que amplifica la escasa luz nocturna. El TNO es el conjunto público más usado en la fusión visible-infrarroja (Liu et al., 2022), lo que facilita situar los resultados junto a los de otros trabajos.

Los pares vienen registrados por sus autores: las dos imágenes de cada par cubren la misma escena desde el mismo punto de vista. Aun así, en algunos se advierte un corrimiento vertical de varios píxeles entre ambas. Ese corrimiento no se corrigió, para trabajar con el conjunto tal como se distribuye, y tampoco se midió su efecto.

Se trabajó con veinte pares, que corresponden a trece escenas. Cuatro de esas escenas aportan más de una toma, en otro instante o desde otro ángulo, y entre ellas reúnen once pares. La distinción tiene peso en la estadística, porque dos tomas de una misma escena no son observaciones del todo independientes. La Sección 3.4 explica cómo se tuvo en cuenta esa dependencia. También se comprobó que en ningún par la imagen visible fuera una copia de la infrarroja.

El preprocesamiento se limitó a lo indispensable. Cada imagen se convirtió a escala de grises y sus niveles se llevaron al intervalo de cero a uno con la Ecuación (2.1). No se aplicó ningún realce, filtrado ni corrección de contraste previos, porque su efecto se habría confundido con el del método de fusión.

La aplicación a la detección se evaluó sobre M3FD (Liu et al., 2022), un conjunto de 4200 pares visible-infrarrojo registrados. Cada objeto está marcado con una caja y pertenece a una de seis clases: personas, autos, autobuses, motocicletas, luces y camiones. Las escenas, urbanas y naturales, se tomaron de día y de noche. Este conjunto se usó solo para la detección. Se le aplicó el mismo preprocesamiento que al TNO, y por eso el detector recibió la imagen visible en escala de grises. Las imágenes de todas las entradas del detector se guardaron en formato JPEG (del inglés *Joint Photographic Experts Group*) de 8 bits. La Sección 3.5.1 describe cómo se repartieron sus cuadros.

3.2. El algoritmo de fusión propuesto

El algoritmo propuesto es un operador Top-Hat de una sola escala: todos sus elementos estructurantes comparten un mismo tamaño. Para fusionar aplica la regla de la Ecuación (2.11), que retoma la de Ortega Rodríguez y Espinoza Ríos (2025). Esa regla parte del promedio de las dos fuentes, le suma el mayor detalle claro y le resta el mayor detalle oscuro, ambos multiplicados por el peso m. Lo nuevo está en la manera de extraer ese detalle. En lugar de un disco único se usa el banco de cinco elementos estructurantes de Flores et al. (2026), que lo emplean para realzar mamografías con una Top-Hat de varias escalas. Aquí se lo aplica en una sola escala, y sus respuestas se combinan como proponen Bala et al. (2024) para el realce de imágenes de fondo de ojo.

3.2.1. Banco de elementos estructurantes

El banco consta de un disco y cuatro segmentos de recta, definidos todos por un mismo radio r, que es un número entero de píxeles. El disco D_r es la versión digital de un círculo de radio r:

$$D_r = \left\{ (j,k) \in \mathbb{Z}^2 : |k| \le r,\ |j| \le \left\lfloor \sqrt{r^2 - k^2} + \tfrac{1}{2} \right\rfloor \right\}. \tag{3.1}$$

Cada par de enteros (j,k) indica la posición de un píxel respecto del centro, en columnas y en filas. La expresión $\lfloor u + \frac{1}{2} \rfloor$ redondea el número u al entero más cercano. Con esa definición, el disco mide $2r+1$ píxeles de ancho y otros tantos de alto.

Los cuatro segmentos, $S_{r,\theta}$, cruzan el centro con orientaciones de 0°, 45°, 90° y 135°. Como es habitual en imágenes, las filas se numeran hacia abajo, y por eso el segmento de 45° desciende de izquierda a derecha. Los segmentos quedan definidos así:

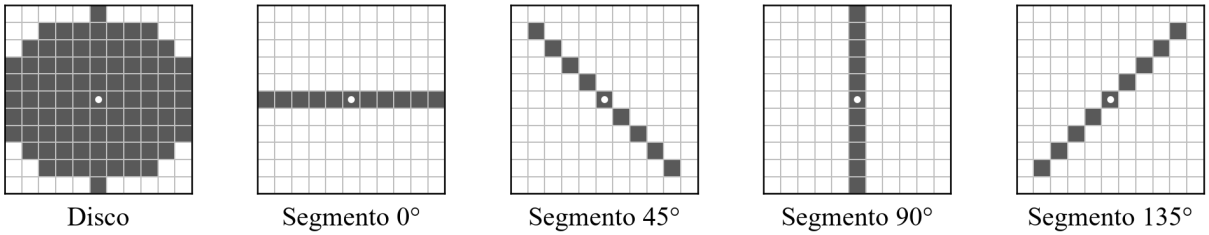
$$\begin{aligned} S_{r,0^\circ} &= \{(j,0) : |j| \le r\}, & S_{r,90^\circ} &= \{(0,k) : |k| \le r\}, \\ S_{r,45^\circ} &= \{(j,j) : |j| \le q_r\}, & S_{r,135^\circ} &= \{(-j,j) : |j| \le q_r\}. \end{aligned} \tag{3.2}$$

Aquí, $q_r = \lfloor r/\sqrt{2} + \frac{1}{2} \rfloor$. El segmento horizontal y el vertical tienen $2r+1$ píxeles, lo mismo que el ancho del disco. Los diagonales tienen $2q_r + 1$, porque en diagonal la distancia entre píxeles vecinos es mayor. Cubren así casi la misma longitud con menos píxeles. Con $r = 25$, el disco y los segmentos horizontal y vertical miden 51 píxeles; los diagonales, 37.

La Figura 3.2 dibuja píxel por píxel los cinco elementos del banco, con un radio menor, $r = 5$, para que los píxeles se distingan. Los cinco comparten el mismo centro. Con ese radio, el disco coincide con el único elemento del Top-Hat clásico (Sección 3.2.3).

Figura 3.2

Banco de cinco elementos estructurantes del algoritmo propuesto



Nota. Elaboración propia. Cada cuadro es un píxel; los cuadros grises forman el elemento, y el punto blanco marca su centro. Con $r = 5$, cada cuadrícula mide 11×11 píxeles, y los segmentos diagonales tienen 9 píxeles en lugar de 11. Con la configuración adoptada, $r = 25$, cada elemento ocupa una cuadrícula de 51×51 píxeles. El disco termina en un solo píxel arriba y abajo, y no a los costados, porque la Ecuación (3.1) lo arma fila por fila y redondea el ancho de cada una.

3.2.2. Combinación de las respuestas

Con cada elemento del banco se calculan las dos transformadas de la Ecuación (2.9): la blanca, que recoge los detalles claros, y la negra, que recoge los oscuros. Como se vio en la Sección 2.3, el disco no distingue orientaciones, mientras que cada segmento deja en el fondo las estructuras alineadas con él. Una estructura larga y angosta, como un poste o un cable, queda entonces en el fondo con el segmento paralelo a ella y pasa al detalle con los otros tres. De ahí las cuatro orientaciones: promediar sus respuestas evita que el resultado dependa de una sola dirección.

Las respuestas de los cuatro segmentos se promedian, y ese promedio se suma a la respuesta del disco. Las transformadas del banco quedan así:

$$\begin{aligned} \mathrm{WTH}_{\mathrm{banco}}(f) &= \mathrm{WTH}(f, D_r) + \frac{1}{4}\sum_{\theta} \mathrm{WTH}(f, S_{r,\theta}), \\ \mathrm{BTH}_{\mathrm{banco}}(f) &= \mathrm{BTH}(f, D_r) + \frac{1}{4}\sum_{\theta} \mathrm{BTH}(f, S_{r,\theta}). \end{aligned} \tag{3.3}$$

En esta ecuación, θ recorre los cuatro ángulos. El promedio pesa por igual las cuatro direcciones y deja la parte de los segmentos en el mismo rango que la del disco. Con fuentes entre cero y uno, cada parte queda entre cero y uno, y la suma, entre cero y dos: el doble del rango que daría un único elemento.

La propuesta lleva estas transformadas a la regla de la Ecuación (2.11). Para la imagen visible toma

$$\mathrm{WTH}_{\mathrm{VIS}} = \mathrm{WTH}_{\mathrm{banco}}(I_{\mathrm{VIS}}),$$

y define del mismo modo las otras tres. El resto de la regla, con su imagen base, sus máximos píxel a píxel y su recorte, no cambia.

La Figura 3.3 reúne el algoritmo completo en un diagrama de bloques, desde las dos imágenes de entrada hasta la imagen fusionada. Cada imagen pasa por separado por el banco, y los detalles de las dos se combinan después con la regla y el peso m.

3.2.3. Implementación y métodos comparativos

La propuesta se comparó con seis métodos: el Top-Hat clásico, presentado en la Sección 2.3.5, y los cinco multiescala de la Sección 2.2.2. Sus parámetros fueron los siguientes:

- **Top-Hat clásico:** Sigue la fusión con Top-Hat de Bajac Figueredo et al. (2025), quienes ensayaron elementos estructurantes de tamaños 3, 5, 7 y 9. Aquí se usa, sin ajuste, un único disco de radio 5, es decir, de 11 píxeles de ancho, y la regla de la Ecuación (2.11) con peso 1. Con ese peso, la regla agrega todo el detalle extraído, como el realce clásico de la Ecuación (2.10).
- **Pirámide de Laplace:** Cuatro niveles ($K = 4$), con la actividad suavizada en una ventana de 5×5 píxeles que pesa más el centro.
- **Pirámide de razón:** Cuatro niveles ($K = 4$), con las copias G_0 a G_4 y $\eta = 10^{-6}$.
- **DWT (Haar) y DWT (db4):** Tres niveles de descomposición.
- **DTCWT:** Cuatro niveles de descomposición.

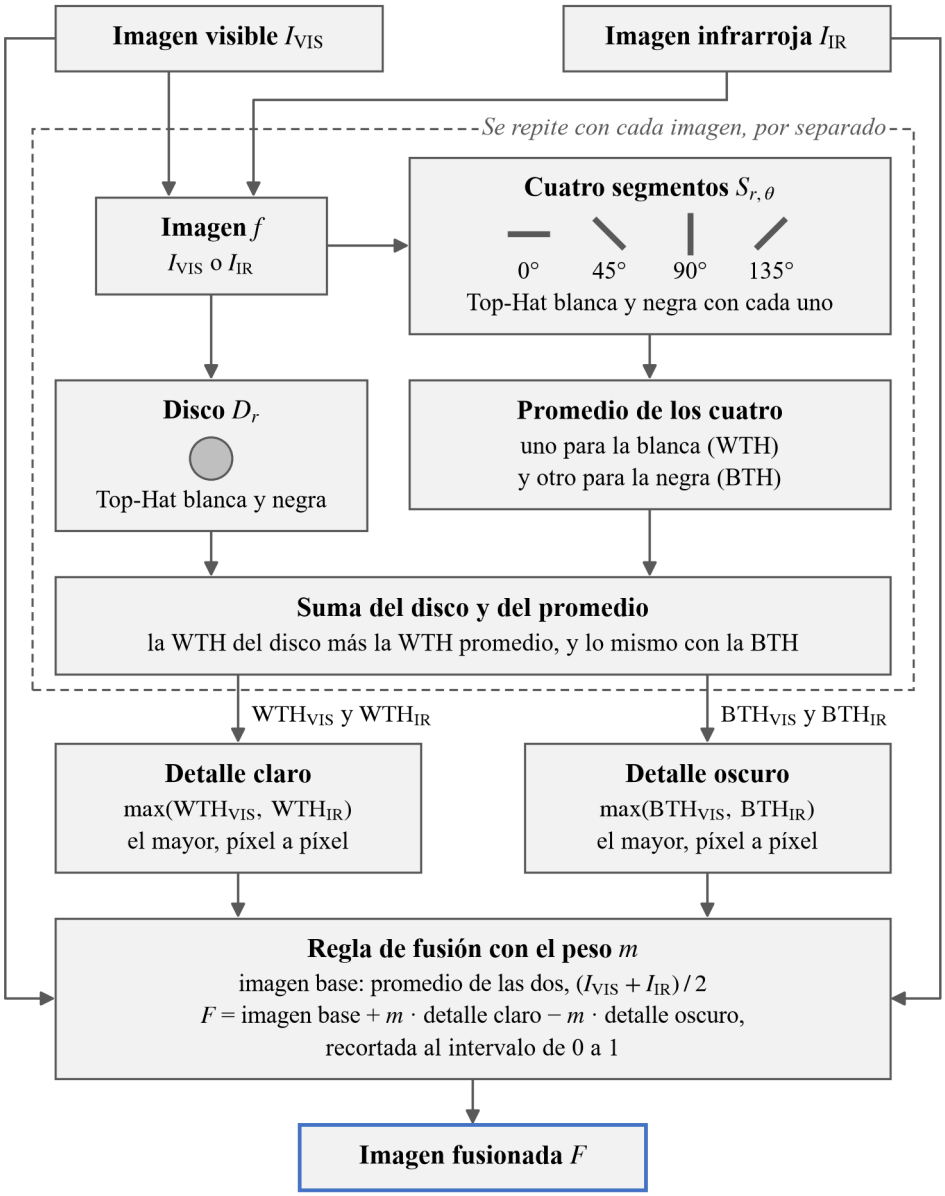
Los cinco métodos multiescala se usaron con esos parámetros, que son sus valores por defecto, sin ajustarlos a este corpus. El Top-Hat clásico tampoco se ajustó. Entre la propuesta y el Top-Hat clásico cambian a la vez los elementos estructurantes, el radio y el peso. Por eso, una diferencia entre los dos no puede atribuirse al banco por sí solo.

Todos los métodos se implementaron en Python. La morfología y las pirámides se programaron con OpenCV (Bradski, 2000); las transformadas *wavelet*, con PyWavelets (Lee et al., 2019), y la DTCWT, con el paquete dtcwt. Las métricas se calcularon con NumPy (Harris et al., 2020), SciPy (Virtanen et al., 2020) y scikit-image (van der Walt et al., 2014). Los siete métodos recibieron las mismas entradas y pasaron por el mismo cálculo de métricas; ningún resultado se tomó de trabajos publicados por otros autores.

Los experimentos se ejecutaron en una computadora portátil con un procesador Intel Core i7-13620H de 16 núcleos lógicos, 31.7 GB de memoria y una tarjeta gráfica NVIDIA GeForce RTX 4050. La fusión y las métricas se calcularon en el procesador, y el entrenamiento y la evaluación de los detectores se hicieron en la tarjeta gráfica. Las versiones de los programas fueron Python 3.11, NumPy 1.26.4, OpenCV 4.13.0, SciPy 1.17.1, scikit-image 0.26.0, PyWavelets 1.9.0, dtcwt 0.14.0, PyTorch 2.5.1 y Ultralytics 8.4.68.

Figura 3.3

Diagrama de bloques del algoritmo propuesto



Nota. Elaboración propia. El recuadro de línea discontinua se recorre dos veces, una con la imagen visible y otra con la infrarroja; en cada pasada, f es la imagen que se procesa. Los elementos D_r y $S_{r,\theta}$ se definen en las Ecuaciones (3.1) y (3.2); WTH y BTH son las transformadas de la Ecuación (2.9). Las líneas de los costados llevan las dos imágenes de entrada directamente a la imagen base, sin pasar por el recuadro. En la configuración adoptada, $r = 25$ y $m = 0.30$.

3.3. Ajuste de los parámetros por enjambre de partículas

El algoritmo tiene dos parámetros. El radio r define el tamaño de los cinco elementos y, con él, el del detalle extraído, porque solo pasan a la Top-Hat los detalles en los que los elementos no caben. El peso m regula cuánto de ese detalle se suma a la imagen base. Las transformadas no dependen de m: el peso solo escala el detalle antes del recorte.

Para ajustarlos se eligió la optimización por enjambre de partículas (Sección 2.6), porque es el método con que Ortega Rodríguez y Espinoza Ríos (2025) ajustan la fusión Top-Hat visible-infrarroja. De esa obra se adaptó la función de aptitud y se tomó el rango de búsqueda: el radio entre 1 y 25 píxeles y el peso entre 0.30 y 2.00. Las posiciones iniciales se sortearon de manera uniforme en ese rango, y las que salían de él durante la búsqueda se llevaron al borde. Los coeficientes de la Ecuación (2.21) valieron $c_1 = c_2 = 1.5$. La inercia bajó en línea recta, según la Ecuación (2.23), de $w_{\text{máx}} = 0.9$ en la primera iteración a $w_{\text{mín}} = 0.4$ en la última. La obra de referencia también usa una inercia decreciente, pero no publica sus extremos ni los coeficientes.

La aptitud adapta la función que esa obra llama F_o. El radio de cada partícula se redondea al entero más cercano, porque los elementos se arman con un número entero de píxeles. Con el radio y el peso se fusionan los N pares del ajuste, y F_n es la imagen que resulta del par n. La aptitud es

$$\begin{aligned}\operatorname{Apt}(r, m) = \frac{1}{N} \sum_{n=1}^{N} \Bigg[& \frac{\operatorname{SSIM}(I_{\text{VIS},n}, F_n) + \operatorname{SSIM}(I_{\text{IR},n}, F_n)}{2} \\ & + \frac{\operatorname{EN}(F_n)}{8} + \frac{\operatorname{PSNR}(F_n)}{100} \Bigg].\end{aligned} \tag{3.4}$$

El primer término es la similitud estructural media con las dos fuentes. A diferencia de la métrica de la Ecuación (2.18), usa la ventana que proponen Z. Wang et al. (2004). Esa ventana mide 11×11 píxeles, ponderados con una curva gaussiana de desviación estándar 1.5, y el índice se promedia sobre todas las posiciones de la imagen. El segundo término es la entropía de la Ecuación (2.12) dividida por 8, su máximo. El tercero es la PSNR de la Ecuación (2.20) dividida por 100. De los tres términos, dos premian el parecido con las fuentes y solo la entropía premia la información de la imagen.

La obra de referencia ajusta los parámetros escena por escena. Aquí, en cambio, se buscó una sola configuración, con la aptitud evaluada sobre tres escenas: dos con vehículos blindados y una con un soldado detrás de una cortina de humo. De cada escena se tomó un par, y los tres pares forman parte de los veinte con que se evaluó la calidad. El ajuste comprendió estos ensayos:

- **Configuraciones del enjambre:** Veinticinco corridas que, como en la obra de referencia, cruzan cinco cantidades de partículas (2, 4, 6, 8 y 10) con cinco de iteraciones (10, 20, 30, 40 y 50).
- **Repeticiones:** Como control de la variación al azar, las veinticinco configuraciones se repitieron veinte veces, lo que da quinientas corridas en total.
- **Grilla:** La aptitud se calculó en cinco mil combinaciones, que cruzan los veinticinco radios con doscientos pesos de 0.01 a 2.00. La grilla incluye pesos menores que 0.30, fuera del rango de búsqueda.
- **Barrido del peso:** En las mismas tres escenas, las seis métricas se calcularon con once pesos, de 0.05 a 2.0. El barrido abarcó la propuesta con $r = 25$ y el Top-Hat clásico con $r = 5$ y con $r = 25$.

Como las corridas pueden terminar en radios distintos, la configuración se eligió entre los dos radios a los que llegaron más corridas. Esos dos candidatos se compararon sobre los veinte pares del corpus con las nueve métricas iniciales (Sección 2.4), con prioridad para las de actividad, que reflejan el realce. La comparación usó las mismas imágenes con que después se evaluó la calidad, una limitación que señala la Sección 1.2. La configuración adoptada fue $r = 25$ y $m = 0.30$. Ese radio es uno de los dos resultados del enjambre, y se lo adoptó porque prioriza el realce. La Sección 4.2 informa en qué radios y pesos terminaron las corridas.

3.4. Protocolo de evaluación de la calidad de imagen

Como la fusión visible-infrarroja no dispone de una imagen ideal con la cual comparar el resultado, la calidad se midió con seis métricas sin referencia, presentadas en la Sección 2.4. Tres son de actividad y miden la información, el contraste y la nitidez de la imagen. Las otras tres son de fidelidad y miden cuánto se parece la fusión a sus fuentes. La Tabla 3.1 las resume.

Las seis surgen de depurar una batería inicial de nueve con dos criterios: no repetir información y equilibrar los dos grupos. De esas nueve, las de actividad eran EN, SD, FE, MG y SF, y las de fidelidad, la MI con cada fuente, la SSIM y la PSNR. Como comprobación, la clasificación se repitió con esas nueve y con diecisiete: las mismas más las ocho métricas complementarias de la Sección 2.4.

Equilibrar los grupos no impide que el ruido reciba premio, porque el ruido también eleva la actividad de una imagen. Para medir ese efecto se agregó un control con el promedio simple y versiones degradadas de él:

- **Promedio simple:** La media píxel a píxel de la visible y la infrarroja, sin detalle agregado.

Tabla 3.1: Las seis métricas de evaluación de calidad

Métrica	**Qué mide**	**Grupo**
Entropía (EN)	cantidad de información de la imagen	actividad
Desviación estándar (SD)	contraste general	actividad
Gradiente medio (MG)	nitidez de los bordes	actividad
Información mutua (MI)	cuánto de las fuentes se conserva	fidelidad
Similitud estructural (SSIM)	parecido estructural con las fuentes	fidelidad
Relación señal-ruido de pico (PSNR)	fidelidad numérica a las fuentes	fidelidad

Nota. Elaboración propia. Las métricas de actividad se calculan solo con la imagen fusionada, y las de fidelidad la comparan con sus fuentes.

- **Promedio con ruido:** El promedio simple con ruido gaussiano de desviación estándar 0.02, 0.05, 0.10 y 0.20.
- **Promedio desenfocado:** El promedio simple suavizado con núcleos gaussianos de 5×5 y de 11×11 píxeles.

Esas siete versiones de cada par se ordenaron junto con los siete métodos de fusión, con las mismas seis métricas. Si una imagen con ruido sube en la clasificación, una actividad alta no basta para probar que el detalle agregado sea útil.

El análisis estadístico fue no paramétrico. Con veinte pares no podía suponerse que las métricas siguieran una distribución normal, y lo que interesaba era el orden entre los métodos. Para cada métrica se aplicó primero la prueba de Friedman (Friedman, 1937), con cada par de imágenes como bloque. Cuando resultó significativa, se aplicó la prueba de Wilcoxon de rangos con signo (Wilcoxon, 1945) a once contrastes entre pares de métodos. La propuesta se enfrentó con el Top-Hat clásico y con cada uno de los cinco multiescala, y el Top-Hat clásico, con esos mismos cinco. Los valores de p se corrigieron con el procedimiento de Holm (Holm, 1979) dentro de cada métrica.

Cada contraste se resumió en uno de tres desenlaces. Si el valor de p corregido era menor que 0.05, contaba como victoria o como derrota, según el signo de la diferencia de medias entre los dos métodos. Si no lo era, contaba como empate. Con seis métricas, el análisis reúne sesenta y seis decisiones de este tipo.

Para resumir el desempeño se usó la clasificación por rango promedio. Dentro de cada par se ordenaron los siete métodos según cada métrica, con el rango medio en caso de empate. Esos puestos se promediaron luego sobre los pares y las métricas, y un valor más bajo indica un método mejor ubicado. El procedimiento respeta la estructura en bloques del experimento y evita promediar magnitudes de unidades distintas. El cálculo se repitió por separado con las métricas de actividad y con las de fidelidad, lo que da el perfil de cada método. El rango promedio no tiene una prueba propia y se lee de forma descriptiva.

Las pruebas tratan los veinte pares como bloques independientes, pero once de ellos provienen de solo cuatro escenas. Para ver si esa dependencia alteraba las conclusiones, el

análisis completo se repitió con trece bloques, uno por escena. En cada escena con varias tomas, las métricas se promediaron sobre ellas.

La evaluación se completó con una comparación visual de dos escenas, que es solo ilustrativa. Se las eligió porque muestran dos maneras distintas en que las cámaras se complementan. En la primera, una persona apenas se distingue en la imagen visible nocturna. En la segunda, una cortina de humo le oculta la escena a la cámara visible. Esta segunda escena es una de las tres que se usaron en el ajuste de los parámetros.

3.5. Aplicación a la detección de objetos

En la aplicación que se estudia, la imagen fusionada alimenta un detector automático de objetos. La pregunta es si, con ella, el detector encuentra lo que cada cámara ve por separado. Como un detector aprende la apariencia de sus imágenes de entrenamiento, se entrenaron detectores propios para cada tipo de imagen, según la práctica de Liu et al. (2022), descrita en la Sección 2.7. Hubo diez entradas: la visible, la infrarroja, el promedio simple y las siete fusiones. Todas usaron los mismos cuadros, las mismas etiquetas y la misma configuración del detector.

3.5.1. Partición de los datos

Las imágenes de M3FD son cuadros de secuencias de video, y los cuadros vecinos se parecen mucho entre sí. Si un cuadro de prueba tuviera un vecino casi idéntico en el entrenamiento, el detector se evaluaría sobre algo que ya vio. Para evitarlo, los cuadros se agruparon en bloques de cien números de cuadro consecutivos, y los bloques se cortaron también donde cambia el tamaño de la imagen. Los bloques, enteros, se sortearon hasta reunir cerca del 25 % de los cuadros para la prueba y del 10 % para la validación, y el resto fue al entrenamiento. Se tomó el primer sorteo que dejaba en la prueba entre el 20 y el 35 % de las personas y de las luces. Donde se tocaban bloques de partes distintas, se descartaron diez cuadros a cada lado del límite, 496 en total.

De los bloques de entrenamiento se tomaron al azar 2000 cuadros para entrenar. Los 474 restantes, que aquí se llaman cuadros de seguimiento, se reservaron para seguir el entrenamiento y calibrar el umbral de confianza. Los bloques de validación no intervinieron en el entrenamiento ni en ninguna elección, y se sumaron a la prueba. Sobre la prueba se aplicaron luego dos filtros:

- **Casi duplicados en la visible:** En la imagen visible, cada cuadro se comparó con los de entrenamiento mediante la similitud estructural. Se lo descartó si con alguno alcanzaba la mediana de esa similitud entre cuadros consecutivos. Este filtro sacó 33 cuadros, todos de los bloques de prueba, y dejó 1197.

- **Parecido en las dos cámaras:** Cada cuadro se comparó también con los de entrenamiento mediante la correlación, en la visible y en la infrarroja. Se lo descartó si, con un mismo cuadro de entrenamiento, alcanzaba en ambas a la vez el primer cuartil de esa medida entre cuadros consecutivos. Este filtro sacó otros 130.

La prueba final quedó en 1067 cuadros, con 2045 personas y 864 luces marcadas. Sus bloques se unieron cuando eran contiguos, y así se formaron once grupos. En la inferencia, la unidad independiente fue el grupo y no el cuadro, porque los cuadros de un mismo tramo de video no son independientes entre sí.

3.5.2. Detector y entrenamiento

El detector fue YOLOv8 (Jocher et al., 2023) en su variante más pequeña, YOLOv8n, con la biblioteca Ultralytics 8.4.68. Cada detector partió de los pesos con que se distribuye la red YOLOv8n, entrenados sobre las fotografías comunes del conjunto de Lin et al. (2014). Se lo entrenó con las seis clases de M3FD y los 2000 cuadros de entrenamiento durante cuarenta épocas, es decir, cuarenta pasadas completas por esos cuadros. Las imágenes se procesaron a 640 píxeles de lado, en lotes de dieciséis. Los pesos de la red se actualizaron con el algoritmo AdamW (Loshchilov & Hutter, 2019), con una tasa de aprendizaje de 0.001 y un momento de 0.9. El detector se evaluó tal como quedó al final, sin elegir ninguna época intermedia.

Para cada entrada se entrenaron tres detectores, con tres semillas distintas, y se obtuvieron así treinta en total. La semilla fija las elecciones aleatorias del entrenamiento, entre ellas el orden de las imágenes en los lotes y las transformaciones que se les aplican al azar. Cambiarla introduce, por lo tanto, una variación ajena al método de fusión, que la repetición del entrenamiento permite estimar. Los detectores de la visible y de la infrarroja se entrenaron con semillas propias, distintas de las que usaron el promedio simple y las siete fusiones. Solo el primero de los tres entrenamientos de cada entrada se siguió época por época, con la mAP50 sobre los cuadros de seguimiento.

3.5.3. Objetos de una sola cámara y tasa de acierto equilibrada

De las seis clases, el análisis se centró en las personas y las luces, porque su visibilidad en las dos cámaras es opuesta. Una persona se destaca en la imagen térmica aunque esté a oscuras; una luz encendida, en la visible. Los detectores entrenados con cada cámara lo reflejan en los 1197 cuadros que dejó el primer filtro. En personas, la precisión media AP50 fue de 0.697 con la infrarroja y de 0.431 con la visible. En luces fue de 0.124 con la visible y de 0.020 con la infrarroja. Entre las seis clases, la de personas es la que muestra la mayor ventaja de la infrarroja sobre la visible, y la de luces, la mayor ventaja de la visible sobre la infrarroja.

Un objeto marcado cuenta como encontrado si el detector predice su clase con una confianza igual o mayor que el umbral y una IoU de al menos 0.5 (Ecuación 2.24). Un objeto es de una sola cámara si lo encuentran al menos dos de los tres detectores de esa cámara y a lo sumo uno de los tres de la otra. Si lo encuentran al menos dos de los tres detectores de cada cámara, es un objeto de las dos.

La medida principal es la tasa de acierto equilibrada. Es el promedio de dos tasas: la de acierto sobre los objetos de solo la visible y la de acierto sobre los de solo la infrarroja. Así, ninguno de los dos tipos de objeto pesa más por ser más numeroso. Para cada entrada, un objeto aporta la fracción de los tres detectores de esa entrada, uno por semilla, que lo encuentran. Las tasas de la visible y de la infrarroja no se informan, porque sus detectores son los que definen los objetos.

La confianza de cada detector tiene su propia escala, de modo que un mismo umbral no pone a todos en igualdad de condiciones. Por eso el umbral principal se calibró detector por detector. Como referencia se tomó la cantidad de falsos positivos de personas y luces que, en promedio, cometen por imagen los detectores de la visible con un umbral de 0.25. A cada detector se le asignó, entre los umbrales de 0.05 a 0.95 en pasos de 0.01, el umbral con que comete la cantidad más cercana a esa. La calibración se hizo sobre los cuadros de seguimiento, nunca sobre la prueba. Para el análisis de sensibilidad se usaron el umbral fijo de 0.25 y el umbral de mejor equilibrio por clase. Este último maximiza, en cada clase, la media armónica de la precisión y la exhaustividad en esos mismos cuadros.

3.5.4. Comparación con el Top-Hat clásico y medidas secundarias

La comparación central resta a la tasa equilibrada de la propuesta la del Top-Hat clásico, y expresa la diferencia en puntos porcentuales. Su intervalo de confianza del 95 % toma como unidad cada grupo de cuadros y no cada objeto, porque los objetos de un mismo tramo de video no son independientes. Se lo calculó con un error estándar robusto por grupos y con la distribución t. Sus grados de libertad equivalen a la cantidad de grupos con objetos de una sola cámara, menos uno (Cameron & Miller, 2015).

Tres análisis de sensibilidad revisaron la solidez de esa diferencia:

- ***Bootstrap* salvaje por grupos:** Se generan 9999 réplicas con la hipótesis nula impuesta. En cada una, los residuos de cada grupo se multiplican por un peso sorteado entre seis valores fijos, y el estadístico t de la réplica se compara con el observado (Cameron et al., 2008; Webb, 2023). El intervalo reúne las diferencias que esta prueba no rechaza al 5 %.

- **Otros umbrales:** La diferencia y su intervalo se recalculan con el umbral fijo de 0.25 y con el de mejor equilibrio por clase.

- **Pares de semillas:** Con tres semillas por entrada hay nueve combinaciones de un detector de la propuesta con uno del Top-Hat clásico, y cada una da su propia diferencia. La comparación se considera robusta a la semilla si las nueve diferencias tienen el mismo signo.

Las tasas de las demás entradas, entre ellas el promedio simple y los cinco métodos multiescala, se informan de manera descriptiva, como referencia. La diferencia entre la propuesta y el promedio simple se calculó, además, con el mismo intervalo por grupos. Como el promedio simple es la regla de la Ecuación (2.11) con peso cero, esa diferencia estima el aporte del detalle agregado. También se informa como referencia y no forma parte del examen de la hipótesis.

Se calcularon, además, cuatro medidas secundarias:

- **Precisión media global:** La mAP50 de la Ecuación (2.27), sobre las seis clases y los 1197 cuadros que dejó el primer filtro, promediada sobre las tres semillas. Se la calculó sin aplicar el segundo filtro, de modo que incluye los 130 cuadros que este descartó, y no interviene en el examen de la hipótesis.

- **Objetos de las dos cámaras:** La tasa de acierto sobre los objetos que encuentran a la vez los detectores de la visible y los de la infrarroja.

- **Cuadros con un objeto de cada cámara:** En los cuadros con al menos un objeto de solo la visible y uno de solo la infrarroja, la fracción en que el detector encuentra al menos uno de cada tipo.

- **Relación entre calidad y detección:** Para los siete métodos de fusión, la correlación de rangos de Spearman (Spearman, 1904) entre su rango promedio de calidad y su tasa equilibrada.

En estas medidas, las diferencias entre métodos no se sometieron a prueba.

3.6. Examen de la hipótesis

La hipótesis del trabajo, enunciada en el Capítulo 1, reúne tres afirmaciones: dos sobre la calidad de imagen y una sobre la aplicación a la detección. Cada una se examinó con las pruebas de su evaluación, sin agregar otras:

- **Mejor calidad que el Top-Hat clásico:** Se usaron los seis contrastes de Wilcoxon contra el Top-Hat clásico, uno por métrica, con la corrección de Holm. Un contraste significativo al 5 % contó como victoria o como derrota, según el signo de la diferencia, y uno no significativo, como empate. El reparto se informa tal como resulta, con el rango promedio de los dos métodos como complemento.

- **Calidad comparable a la de los cinco métodos multiescala:** Se usaron el rango promedio con las seis métricas y el perfil de la propuesta. El perfil reúne sus contrastes contra cada uno de los cinco y su puesto en actividad y en fidelidad. Como el rango promedio no tiene una prueba propia y depende de las métricas elegidas, se lo leyó junto con las clasificaciones de nueve y de diecisiete métricas. Esta afirmación se examinó, por lo tanto, de forma descriptiva.
- **Más objetos de una sola cámara que el Top-Hat clásico:** La afirmación se sostiene si, con el umbral principal, el límite inferior del intervalo de confianza con la distribución t supera el cero. Se revisaron además los otros dos umbrales, el *bootstrap* salvaje por grupos y los nueve pares de semillas. Si la diferencia no resulta robusta a la semilla, se la informa como un hallazgo por confirmar, aunque se cumpla esa condición.

En la detección, la propuesta se comparó solo con el Top-Hat clásico porque pertenece a la misma familia y usa la misma regla de fusión (Ecuación 2.11). La comparación mide, así, el efecto de cambiar el operador en su conjunto, con sus elementos, su radio y su peso (Sección 3.2.3).

Capítulo 4

Resultados

Este capítulo presenta los resultados en el orden general en que el Capítulo 3 describió los procedimientos. Primero se describen los dos conjuntos de imágenes y el ajuste de los parámetros. Siguen la comparación visual, las mediciones de calidad y su análisis estadístico, y después la aplicación a la detección de objetos. La última sección reúne los resultados con que se examina la hipótesis. El capítulo los informa sin discutirlos; la discusión queda para el Capítulo 5.

4.1. Caracterización de los conjuntos

Los veinte pares del TNO con que se evaluó la calidad provienen de trece escenas. Tres escenas aportan tres tomas cada una, otra aporta dos y las nueve restantes, una sola. Así, once pares se concentran en cuatro escenas, y por eso el análisis estadístico se repitió con un bloque por escena (Sección 4.5.3). Diecisiete pares pertenecen a la colección Athena y tres a la colección Triclobs.

Las imágenes no tienen todas el mismo tamaño. Entre los veinte pares aparecen once resoluciones, desde 359×247 hasta 768×576 píxeles, y la mayor es también la más frecuente, con nueve pares. Dentro de cada par, la imagen visible y la infrarroja tienen el mismo tamaño, de modo que ninguna debió redimensionarse.

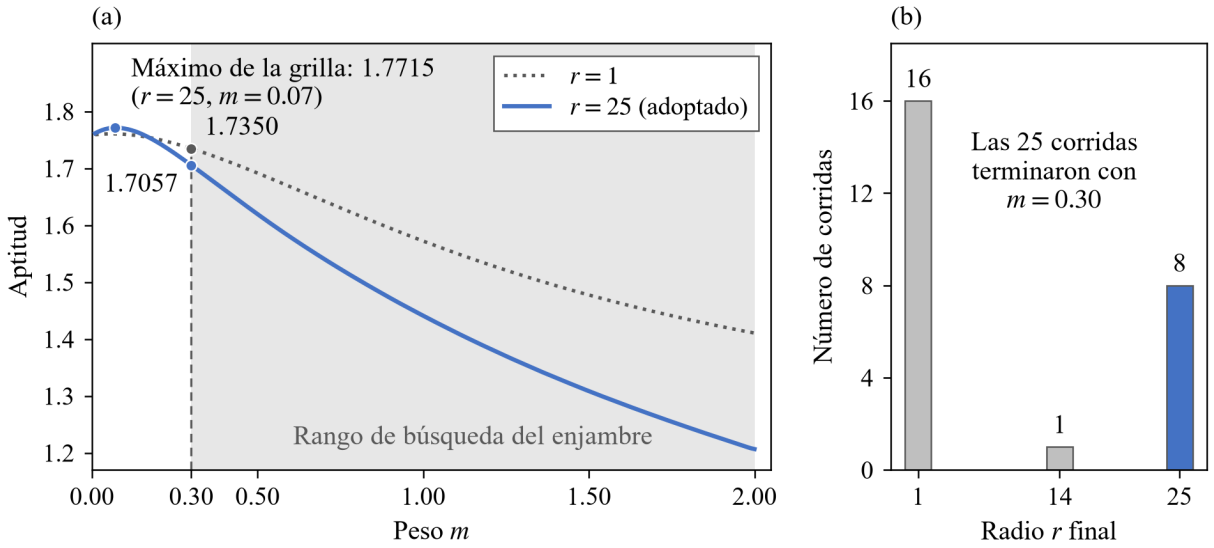
En M3FD, la prueba de detección quedó formada por 1067 cuadros con 2045 personas y 864 luces, repartidos en once grupos de bloques contiguos (Sección 3.5.1). Las luces no se distribuyen de forma pareja entre esos grupos: aparecen solo en cinco de ellos, y uno reúne 555 de las 864, el 64.2 %, casi dos de cada tres.

4.2. Ajuste de los parámetros

Las corridas del enjambre coincidieron en el peso, pero no en el radio. Las veinticinco, una por configuración, terminaron con $m = 0.30$, el límite inferior del rango de búsqueda. En cambio, dieciséis terminaron en $r = 1$, ocho en $r = 25$ y una en $r = 14$. La aptitud, la función que el enjambre optimiza, fue de 1.7350, 1.7057 y 1.6990 en esos tres resultados, respectivamente. El panel (b) de la Figura 4.1 muestra ese reparto de los radios, y el panel (a), cómo cambia la aptitud con el peso en $r = 1$ y en $r = 25$.

Figura 4.1

Aptitud según el peso m y reparto de las corridas del enjambre por radio final



Nota. Elaboración propia. (a) Aptitud de la propuesta (Ecuación 3.4) sobre las tres escenas del ajuste, en función del peso m, con los radios $r = 1$ (gris, línea punteada) y $r = 25$ (azul, línea continua). Las curvas se trazaron con los valores de la grilla, que recorre los pesos de 0.01 a 2.00 cada 0.01. La zona sombreada es el rango de búsqueda del enjambre, de 0.30 a 2.00, y la línea discontinua marca $m = 0.30$. Los rótulos indican la aptitud de cada radio en ese peso y el máximo de la grilla. (b) Número de corridas del enjambre que terminaron en cada radio, de un total de veinticinco, una por configuración de partículas e iteraciones. En azul está el radio adoptado.

Las quinientas corridas de control, que repitieron cada configuración para medir la variación al azar, mostraron el mismo patrón. En 499 de ellas, el 99.8 %, el peso terminó en 0.30, y en la restante, en 0.36. El radio volvió a dividirse entre los dos extremos del rango: el 51.4 % de las corridas terminó en $r = 25$, el 45.6 % en $r = 1$ y el 3.0 % restante en otros radios.

La grilla de cinco mil combinaciones de radio y peso, de la que sale el panel (a), muestra la forma de la aptitud. Su máximo, 1.7715, se dio en $r = 25$ y $m = 0.07$, fuera del rango de búsqueda. En cada radio, el mejor peso estuvo entre 0.05 y 0.07, y en los veinticinco radios la aptitud bajó en cada paso del peso a partir de $m = 0.30$. Dentro del rango de búsqueda, la mayor aptitud fue la de $r = 1$ y $m = 0.30$, el punto al que llegaron dieciséis

corridas. Con el peso en 0.30, la aptitud presentó dos máximos locales en el radio: uno en $r = 1$, el mayor, y otro en $r = 25$.

Como las corridas se repartieron entre $r = 1$ y $r = 25$, los dos radios se compararon sobre los veinte pares del corpus, con $m = 0.30$ y las nueve métricas iniciales. El radio 25 fue mejor en las de actividad, que miden información, contraste y nitidez, y peor en las de fidelidad, que miden el parecido con las fuentes. Las cinco de actividad son la entropía, la desviación estándar, la eficiencia de fusión, el gradiente medio y la frecuencia espacial. En cada una, el radio mayor superó a $r = 1$ en los veinte pares. Las cuatro de fidelidad son la información mutua con cada fuente, la similitud estructural y la relación señal-ruido de pico. En cada una de estas, $r = 1$ quedó por delante en diecinueve o en veinte pares.

Con las seis métricas del trabajo, el patrón fue el mismo: $r = 25$ obtuvo valores mayores en las tres de actividad y menores en las tres de fidelidad. Al pasar de $r = 1$ a $r = 25$, la desviación estándar media subió de 0.1092 a 0.1439 y el gradiente medio, de 0.0234 a 0.0355. En sentido contrario, la similitud estructural bajó de 0.7484 a 0.6584 y la información mutua, de 0.9670 a 0.7486. Se adoptó $r = 25$, uno de los dos resultados del enjambre, porque prioriza el realce. La configuración de la propuesta que se evalúa en el resto del capítulo es, entonces, $r = 25$ y $m = 0.30$.

El barrido del peso sobre las tres escenas del ajuste mostró que, al aumentar m, las métricas de actividad subieron y las de fidelidad bajaron, con una sola excepción en la propuesta. Con la propuesta en $r = 25$, la desviación estándar y el gradiente medio subieron en cada paso, desde $m = 0.05$ hasta $m = 2.0$. La información mutua, la similitud estructural y la relación señal-ruido de pico, en cambio, bajaron en cada paso. La excepción fue la entropía, que subió hasta $m = 1.2$ y luego descendió. En el Top-Hat clásico, tanto con $r = 5$ como con $r = 25$, no hubo excepciones: las tres métricas de actividad subieron y las tres de fidelidad bajaron en cada paso.

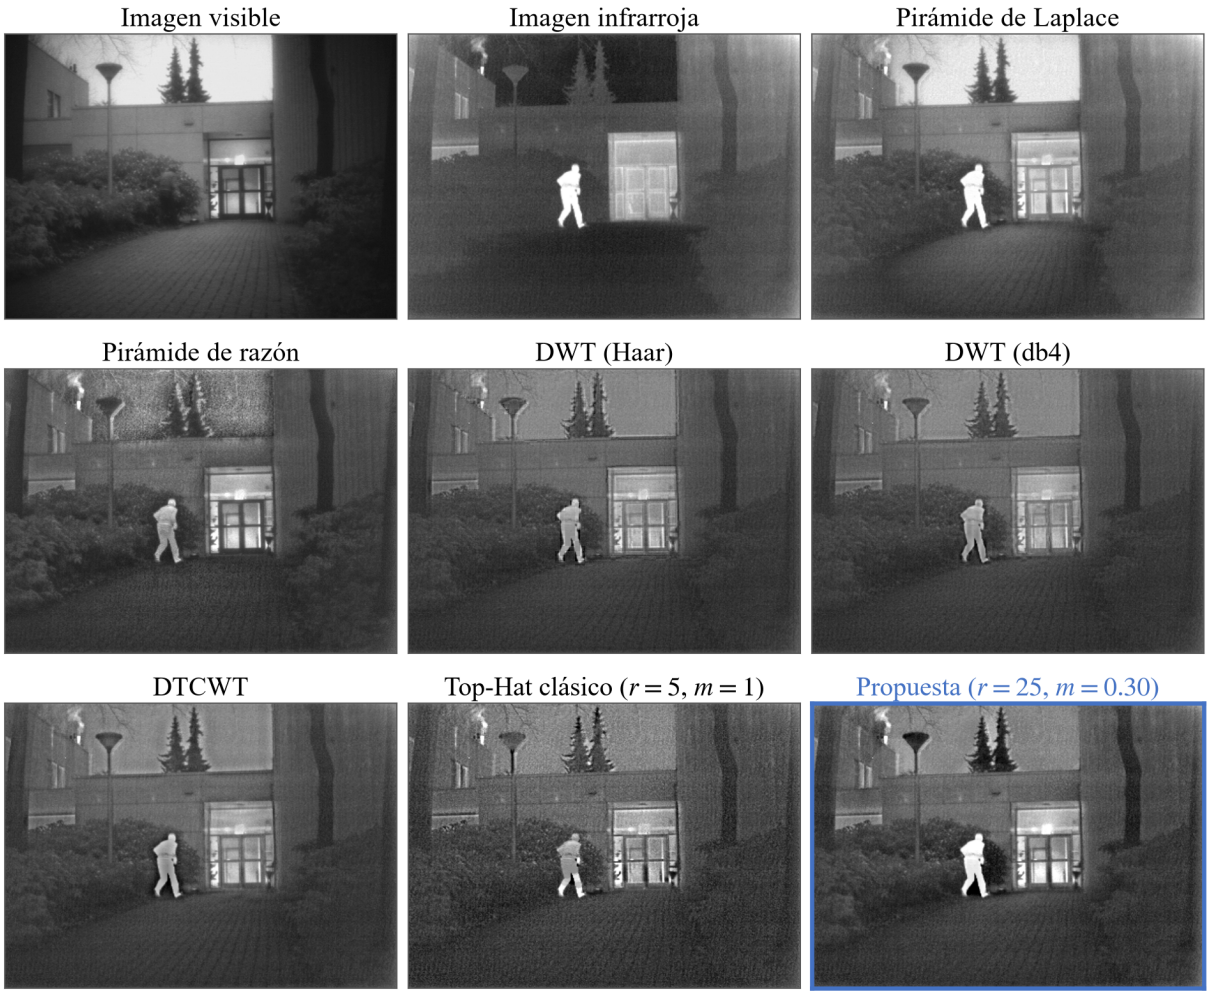
4.3. Comparación cualitativa

Las Figuras 4.2 y 4.3 presentan dos escenas del corpus, cada una con sus dos fuentes y las imágenes de los siete métodos. Muestran dos maneras en que las cámaras se complementan. En la primera, la cámara visible casi no capta a una persona. En la segunda, una cortina de humo oculta la escena a la cámara visible, y solo la térmica la atraviesa. La comparación es ilustrativa y no sostiene conclusiones por sí misma.

En la escena nocturna, la imagen visible deja ver con nitidez el edificio, el farol, los árboles y el sendero de adoquines. La persona que avanza por el sendero, en cambio, se confunde con los arbustos oscuros. En la infrarroja aparece como una figura brillante, pero el follaje pierde buena parte de su textura. Las siete fusiones reunieron la silueta de la persona con el fondo de la visible. La pirámide de razón dejó granulado el cielo, y el Top-Hat clásico, la imagen entera. La pirámide de Laplace y la propuesta fueron las que

Figura 4.2

Fuentes y fusiones de una escena nocturna del TNO (Kaptein 1123)

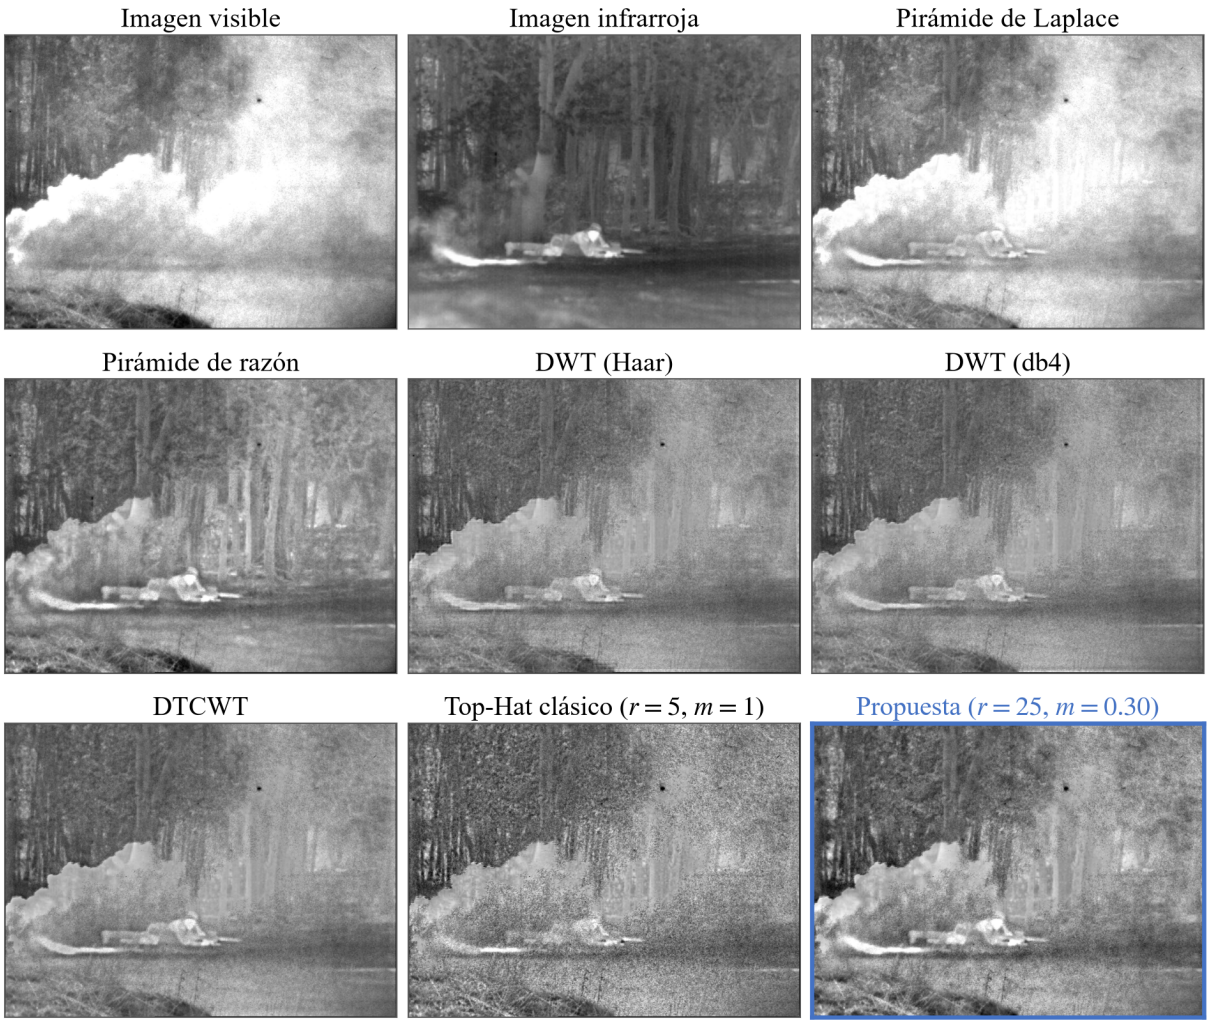


Nota. Elaboración propia a partir de imágenes del *TNO Image Fusion Dataset* (Toet, 2014, 2017). En la escena hay una persona que en la imagen visible casi no se distingue del fondo. Las dos primeras imágenes son las fuentes, y las siete siguientes, en orden de lectura, las fusiones de cada método. La fusión de la propuesta está recuadrada en azul.

más separaron a la persona del fondo. En la propuesta se formó, además, un borde oscuro alrededor de la figura, con un relleno negro entre las piernas.

Figura 4.3

Fuentes y fusiones de una escena del TNO con un soldado tendido tras una cortina de humo



Nota. Elaboración propia a partir de imágenes del *TNO Image Fusion Dataset* (Toet, 2014, 2017). Es una de las tres escenas usadas en el ajuste de los parámetros (Sección 3.3). Las dos primeras imágenes son las fuentes, y las siete siguientes, en orden de lectura, las fusiones de cada método. La fusión de la propuesta está recuadrada en azul.

En la escena del humo, una nube blanca cubre buena parte de la imagen visible y oculta al soldado tendido detrás de ella. La térmica atraviesa el humo y muestra al soldado junto con los troncos del bosque. La pirámide de Laplace conservó gran parte del brillo del humo, y en ella el soldado apenas se insinúa. Las otras seis fusiones atenuaron la cortina y recuperaron la figura del soldado. El Top-Hat clásico volvió a ser el más granulado. La propuesta, como él, mostró en los árboles y en el pasto más textura que los cinco métodos multiescala. También dejó algo de grano, aunque menos que el del Top-Hat clásico.

4.4. Resultados cuantitativos

La Tabla 4.1 reúne la media de cada métrica sobre los veinte pares. En las seis, un valor mayor es mejor. Las tres primeras métricas de la tabla son las de actividad y las tres últimas, las de fidelidad.

Tabla 4.1: Media de las seis métricas por método, sobre los veinte pares del corpus

Método	EN	SD	MG	MI	SSIM	PSNR
Propuesta	**6.9855**	0.1439	0.0355	0.7486	0.6584	16.84
DTCWT	6.6877	0.1172	0.0255	0.8755	**0.7249**	17.60
Pirámide de Laplace	6.8400	**0.1550**	0.0252	**1.4210**	0.7059	14.94
Pirámide de razón	6.8098	0.1271	0.0275	0.7995	0.7051	17.37
DWT (db4)	6.6445	0.1132	0.0260	0.8828	0.7162	**17.65**
Top-Hat clásico	6.9220	0.1352	**0.0478**	0.6398	0.5640	16.87
DWT (Haar)	6.6816	0.1166	0.0275	0.8711	0.7014	17.59

Nota. Elaboración propia. En las seis métricas, un valor mayor es mejor, y la negrita marca el mejor valor de cada columna. Los métodos siguen el orden del rango promedio (Tabla 4.3). EN: entropía. SD: desviación estándar. MG: gradiente medio. MI: información mutua. SSIM: similitud estructural. En MI y en SSIM, el valor es el promedio del calculado contra la imagen visible y del calculado contra la infrarroja. PSNR: relación señal-ruido de pico, en decibelios, calculada con el promedio de los dos errores cuadráticos medios. DWT (Haar) y DWT (db4) son la misma transformada con dos bases distintas (Sección 2.2.2). Propuesta: el algoritmo de fusión presentado en este trabajo.

En las métricas de actividad, la propuesta quedó siempre primera o segunda. Obtuvo la mayor entropía de los siete métodos, 6.9855, seguida por el Top-Hat clásico, con 6.9220. En desviación estándar quedó segunda, con 0.1439, detrás de la pirámide de Laplace, que llegó a 0.1550. También fue segunda en gradiente medio, con 0.0355, esta vez detrás del Top-Hat clásico, con 0.0478. En entropía y en gradiente medio, los dos métodos morfológicos ocuparon los dos primeros puestos, por delante de los cinco multiescala.

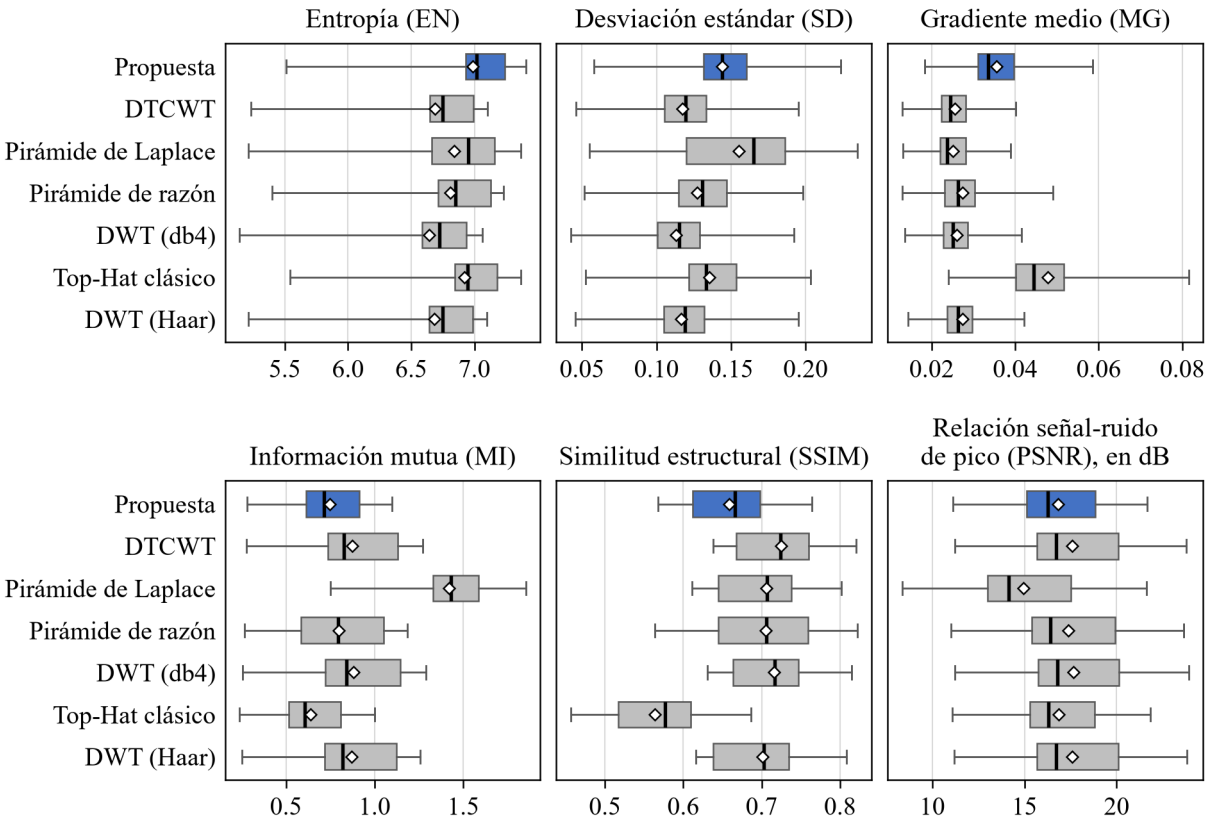
En fidelidad, el orden cambió: la propuesta quedó sexta de siete en cada métrica. Obtuvo 0.7486 en información mutua, 0.6584 en similitud estructural y 16.84 decibelios en relación señal-ruido de pico. Cada una de esas métricas tuvo un método distinto en el primer puesto. En información mutua fue la pirámide de Laplace, con 1.4210; en similitud estructural, la DTCWT, con 0.7249, y en relación señal-ruido de pico, la DWT (db4), con 17.65 decibelios. Solo un método quedó por debajo de la propuesta: el Top-Hat clásico en las dos primeras y la pirámide de Laplace en la tercera.

La Figura 4.4 muestra los veinte valores de cada método en cada métrica, y no solo su media. La variación de un par a otro es grande frente a la distancia entre las medias. En relación señal-ruido de pico, por ejemplo, la propuesta va de 11.12 a 21.65 decibelios según el par, mientras que las medias de los siete métodos quedan entre 14.94 y 17.65. Por eso las cajas se superponen en buena parte, aunque algunas se separan del resto. En

gradiente medio, las de la propuesta y del Top-Hat clásico quedan enteras a la derecha de las de los cinco métodos multiescala. En información mutua, la de la pirámide de Laplace queda a la derecha de todas las demás.

Figura 4.4

Valores de las seis métricas en los veinte pares, por método



Nota. Elaboración propia. Cada caja reúne los veinte valores de un método en una métrica, uno por par del corpus. La caja abarca la mitad central de esos valores, del primer al tercer cuartil, y la línea negra es la mediana. El rombo blanco es la media de la Tabla 4.1, y los bigotes llegan al mínimo y al máximo. Arriba están las tres métricas de actividad y abajo, las tres de fidelidad. Los métodos siguen el orden del rango promedio (Tabla 4.3), y la propuesta está en azul.

4.5. Análisis estadístico

Ni las medias ni las cajas indican si las diferencias se repiten par a par. Para eso se siguió el análisis de la Sección 3.4: la prueba de Friedman por métrica, la clasificación por rango promedio, los contrastes de Wilcoxon y varias comprobaciones de la solidez del orden.

4.5.1. Prueba de Friedman y rango promedio

La prueba de Friedman, con los veinte pares como bloques y seis grados de libertad, encontró diferencias entre los siete métodos en las seis métricas (Tabla 4.2). El valor de p fue menor que 0.001 en todas. El estadístico varió entre 88.3, en entropía, y 111.8, en relación señal-ruido de pico.

Tabla 4.2: Prueba de Friedman por métrica, con siete métodos y veinte pares

Métrica	$\boldsymbol{\chi^2}$	$\boldsymbol{p}$	**¿Difieren?**
EN	88.3	< 0.001	sí
SD	105.1	< 0.001	sí
MG	101.7	< 0.001	sí
MI	91.2	< 0.001	sí
SSIM	100.5	< 0.001	sí
PSNR	111.8	< 0.001	sí

Nota. Elaboración propia. La prueba contrasta si los rangos promedio de los métodos difieren más de lo esperable por azar. Con siete métodos, tiene seis grados de libertad. La columna ¿Difieren? indica si la diferencia fue significativa, como ocurrió en las seis métricas. En ese caso, algunos métodos quedan mejor o peor ubicados de forma sistemática, par tras par.

La Tabla 4.3 y la Figura 4.5 muestran el rango promedio de cada método. Es el puesto medio que ocupa sobre los pares y las métricas, de modo que un valor menor es mejor. La propuesta encabezó la clasificación con 3.642, seguida por la DTCWT, con 3.783, y por la pirámide de Laplace, con 3.908. Su ventaja sobre la DTCWT fue de 0.14 puestos y no se sometió a una prueba propia. El Top-Hat clásico quedó sexto de siete, con 4.242.

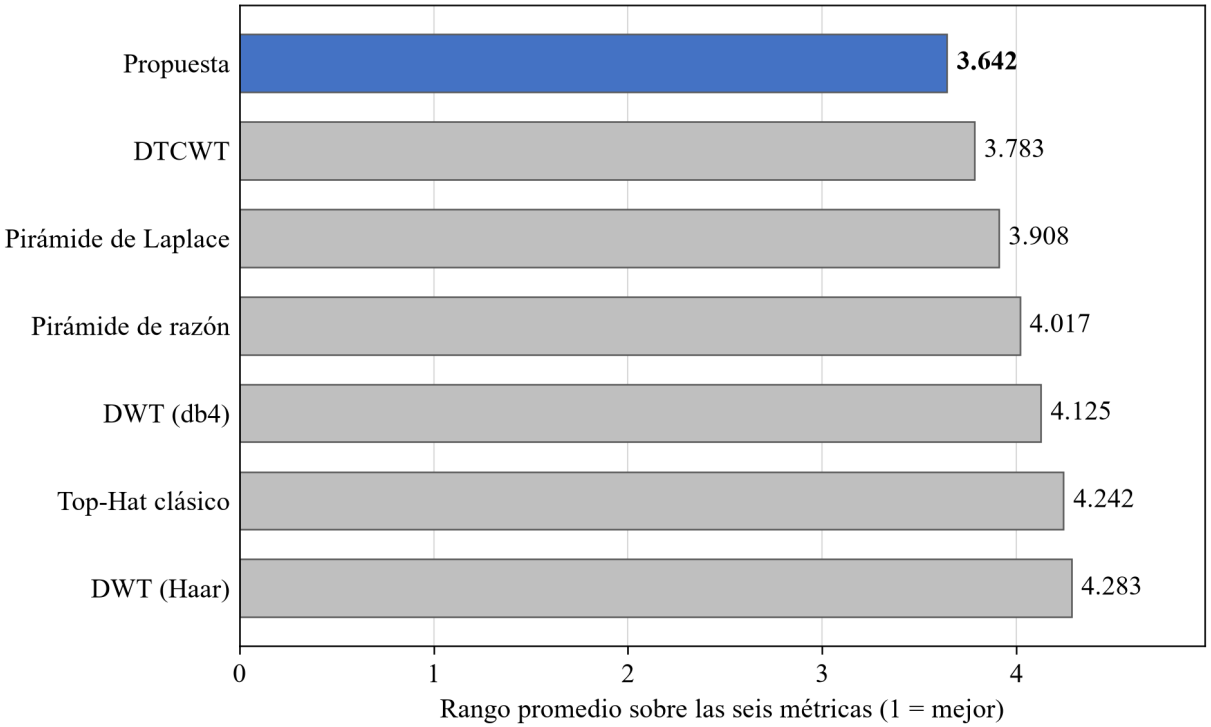
Tabla 4.3: Rango promedio de cada método, por métrica y global

Puesto	**Método**	**EN**	**SD**	**MG**	**MI**	**SSIM**	**PSNR**	**Global**
1	Propuesta	1.50	1.65	2.00	5.45	5.90	5.35	**3.642**
2	DTCWT	4.90	5.05	6.05	3.15	1.30	2.25	3.783
3	Pirámide de Laplace	3.25	2.00	6.25	1.20	3.80	6.95	3.908
4	Pirámide de razón	3.55	3.60	4.65	4.95	3.00	4.35	4.017
5	DWT (db4)	6.85	7.00	4.75	2.65	2.50	1.00	4.125
6	Top-Hat clásico	2.45	2.85	1.00	6.80	7.00	5.35	4.242
7	DWT (Haar)	5.50	5.85	3.30	3.80	4.50	2.75	4.283

Nota. Elaboración propia. En cada par y en cada métrica, el rango 1 corresponde al mejor método. Cada columna de métrica promedia esos rangos sobre los pares, y la columna Global promedia las seis columnas de métrica. Un valor menor es mejor, y la negrita marca el mejor rango global. La prueba de Friedman opera sobre estos mismos rangos. Propuesta: el algoritmo de fusión presentado en este trabajo.

Calculado por separado en cada grupo de métricas, el rango promedio muestra perfiles distintos. En las tres de actividad, la propuesta tuvo 1.717, el mejor de los siete, y en las

Figura 4.5
Rango promedio de cada método sobre las seis métricas



Nota. Elaboración propia. Cada barra es el puesto medio del método sobre los pares y las métricas, y un valor menor indica un método mejor ubicado. La propuesta está en azul.

tres de fidelidad, 5.567, el sexto. La DTCWT tuvo el perfil opuesto: 5.333 en actividad, sexta, y 2.233 en fidelidad, segunda. La suma de los dos rangos fue de 7.28 en la propuesta y de 7.57 en la DTCWT. El Top-Hat clásico, sexto en la clasificación global, obtuvo 2.100 en actividad y 6.383 en fidelidad.

4.5.2. Contrastes de Wilcoxon

Como la prueba de Friedman resultó significativa en las seis métricas, en cada una se aplicaron los once contrastes de Wilcoxon, que comparan dos métodos sobre los mismos pares de imágenes. Son sesenta y seis en total, y sus valores de p se corrigieron con el procedimiento de Holm dentro de cada métrica. La Tabla 4.4 resume los que comparan a la propuesta con los demás métodos. Los once de cada métrica, incluidos los del Top-Hat clásico frente a los cinco multiescala, figuran en los Anexos (Tabla A.1).

Frente a los cinco métodos multiescala, la propuesta ganó casi todos los contrastes de actividad y perdió casi todos los de fidelidad. Ganó los cinco de entropía y los cinco de gradiente medio, y en desviación estándar ganó cuatro y empató con la pirámide de Laplace. En fidelidad perdió los cinco contrastes de similitud estructural. En información mutua perdió cuatro y empató con la pirámide de razón, y en relación señal-ruido de pico perdió cuatro y le ganó a la pirámide de Laplace.

Tabla 4.4: Contrastes de Wilcoxon pareados de la propuesta frente a los demás métodos

	Contra los cinco multiescala			Contra el Top-Hat clásico		
Métrica	**Gana**	**Pierde**	**Empata**	**Resultado**	**Diferencia**	***p* corregido**
EN	5	0	0	gana	0.0636	< 0.001
SD	4	0	1	gana	0.0087	< 0.001
MG	5	0	0	pierde	-0.0123	< 0.001
MI	0	4	1	gana	0.1089	< 0.001
SSIM	0	5	0	gana	0.0944	< 0.001
PSNR	1	4	0	empata	-0.0319	0.674

Nota. Elaboración propia. Gana, Pierde y Empata cuentan los contrastes de la propuesta con los cinco métodos multiescala. Resultado, Diferencia y p corregido se refieren a su contraste con el Top-Hat clásico. Un contraste significativo al 5 % después de corregir por comparaciones múltiples, con Holm sobre los once contrastes de cada métrica, cuenta como victoria o derrota de la propuesta según el signo de la diferencia de medias. Uno no significativo cuenta como empate. Diferencia: media de la propuesta menos media del Top-Hat clásico, en las unidades de cada métrica (decibelios en PSNR). El Top-Hat clásico se usó con radio 5 y peso 1.

Frente al Top-Hat clásico, la propuesta ganó en cuatro métricas, perdió en una y empató en otra. Las cuatro victorias tuvieron un p corregido menor que 0.001, con diferencias de medias de 0.0636 en entropía, 0.0087 en desviación estándar, 0.1089 en información mutua y 0.0944 en similitud estructural. La derrota fue en gradiente medio, con una diferencia de -0.0123 y un p corregido también menor que 0.001. En relación señal-ruido de pico, la diferencia de -0.0319 decibelios no fue significativa: su p corregido fue de 0.674, de modo que esa métrica cuenta como empate.

4.5.3. Solidez del orden

Al repetir el análisis con trece bloques, uno por escena, la cabeza de la clasificación no cambió: la propuesta siguió primera, con 3.590, y la DTCWT, segunda, con 3.756. La prueba de Friedman volvió a ser significativa en las seis métricas, con p menor que 0.001 y estadísticos entre 56.6 y 73.0. Los sesenta y seis contrastes de Wilcoxon conservaron su signo, y sesenta y cinco conservaron además su decisión. El único que cambió fue el del Top-Hat clásico frente a la pirámide de razón en desviación estándar. Su p corregido pasó de 0.005 con veinte pares a 0.098 con trece bloques, y el contraste dejó de ser significativo.

El puesto de la propuesta, en cambio, dependió del conjunto de métricas. Con las nueve métricas iniciales quedó primera, con 3.394, seguida por la pirámide de Laplace, con 3.911. Con las diecisiete que se calcularon quedó tercera, con 3.459, detrás de la pirámide de Laplace, con 3.147, y de la DTCWT, con 3.259. Las ocho métricas que se suman a las nueve iniciales, entre ellas Qabf, Nabf, SCD, VIF y FMI, comparan la fusión con sus fuentes, de modo que doce de las diecisiete son de ese tipo. Las tres clasificaciones

usan la misma escala, de 1 a 7, pero promedian métricas distintas; por eso se compara el puesto y no el valor.

En el control con imágenes degradadas, que mide si el ruido recibe premio, se ordenaron catorce entradas con las seis métricas, en una escala de 1 a 14. Las entradas fueron los siete métodos, el promedio simple y seis imágenes degradadas a partir de ese promedio. El promedio con ruido ganó puestos a medida que crecía el ruido. Con una desviación estándar del ruido de 0.02 quedó decimotercero; con 0.05, duodécimo, y con 0.10, décimo. Con 0.20 empató en el octavo puesto con el Top-Hat clásico, ambos con 7.483, y fue la mejor de las catorce entradas en las tres métricas de actividad. El Top-Hat clásico quedó así como el último de los siete métodos en ese control.

La cabeza del control la ocuparon la pirámide de Laplace, con 6.633, y el promedio simple, con 6.650. La propuesta quedó tercera, con 6.725. Ese puesto depende de las entradas que se ordenan. Con solo los siete métodos y el promedio simple, en una escala de 1 a 8, la propuesta queda primera, con 4.142, y el promedio, sexto, con 4.633. El cambio lo producen las dos versiones desenfocadas, que en puesto medio quedan delante de la propuesta en las tres métricas de fidelidad y detrás del promedio simple en las seis.

4.6. Aplicación a la detección de objetos

Los treinta detectores previstos, tres por cada una de las diez entradas, completaron su entrenamiento. Esta sección presenta primero los objetos de una sola cámara y las tasas de acierto de cada entrada. Después compara la propuesta con el Top-Hat clásico, y al final reúne las medidas secundarias y el seguimiento del entrenamiento.

4.6.1. Objetos de una sola cámara y tasas de acierto

Los cuadros de seguimiento sirvieron para calibrar el umbral principal. En ellos, con el umbral de 0.25, los detectores de la visible cometieron en promedio 0.948 falsos positivos de personas y luces por imagen. Los umbrales con que cada detector más se acercó a ese valor, que forman el umbral principal de la Sección 3.5.3, quedaron entre 0.24 y 0.27.

Con el umbral principal, los detectores de la visible y de la infrarroja definieron 211 objetos vistos solo por la visible y 622 vistos solo por la infrarroja. Otros 724 los encontraron los detectores de las dos cámaras. Con el umbral fijo de 0.25, esos tres conjuntos tuvieron 209, 624 y 728 objetos, y con el de mejor equilibrio por clase, 197, 633 y 667. Los objetos de una sola cámara quedaron repartidos en diez de los once grupos de la prueba. El reparto fue muy desigual: de los 211 objetos de solo la visible, 176 provienen de dos grupos, con 86 y 90. El de 90, el mayor de la prueba, reúne también 219 de los 622 de solo la infrarroja.

La Figura 4.6 muestra un cuadro nocturno de la prueba con dos objetos de una sola cámara, uno de cada cámara. El semáforo encendido, que M3FD marca como luz, solo lo encuentran los detectores de la imagen visible, y la persona del borde izquierdo, solo los de la infrarroja. Con la primera semilla, es decir, en el primer entrenamiento de cada entrada, el detector del Top-Hat clásico encontró el semáforo y el de la propuesta no. Ninguno de los dos encontró a la persona del borde, y los dos encontraron a la que está delante del auto y a otra lejana. Como se trata de un solo cuadro y una sola semilla, el ejemplo no representa el resultado de conjunto.

La Tabla 4.5 presenta la tasa de acierto de las ocho entradas fusionadas. Están ordenadas por tasa equilibrada, que promedia la tasa sobre los objetos de solo la visible y la tasa sobre los de solo la infrarroja. La visible y la infrarroja no figuran en ella, porque sus detectores son los que definen los objetos de una sola cámara.

Tabla 4.5: Tasa de acierto de las entradas fusionadas en la detección de objetos

Entrada	**Solo visible**	**Solo infrarroja**	**Equilibrada**	**De ambas**
Pirámide de Laplace	60.5	72.5	**66.5**	97.1
DTCWT	53.7	72.2	62.9	94.1
DWT (Haar)	53.7	70.9	62.3	95.9
Propuesta	55.6	67.2	61.4	94.4
DWT (db4)	51.2	69.2	60.2	96.0
Promedio simple	49.1	71.3	60.2	95.1
Top-Hat clásico	51.3	65.5	58.4	94.1
Pirámide de razón	49.0	57.3	53.1	93.0

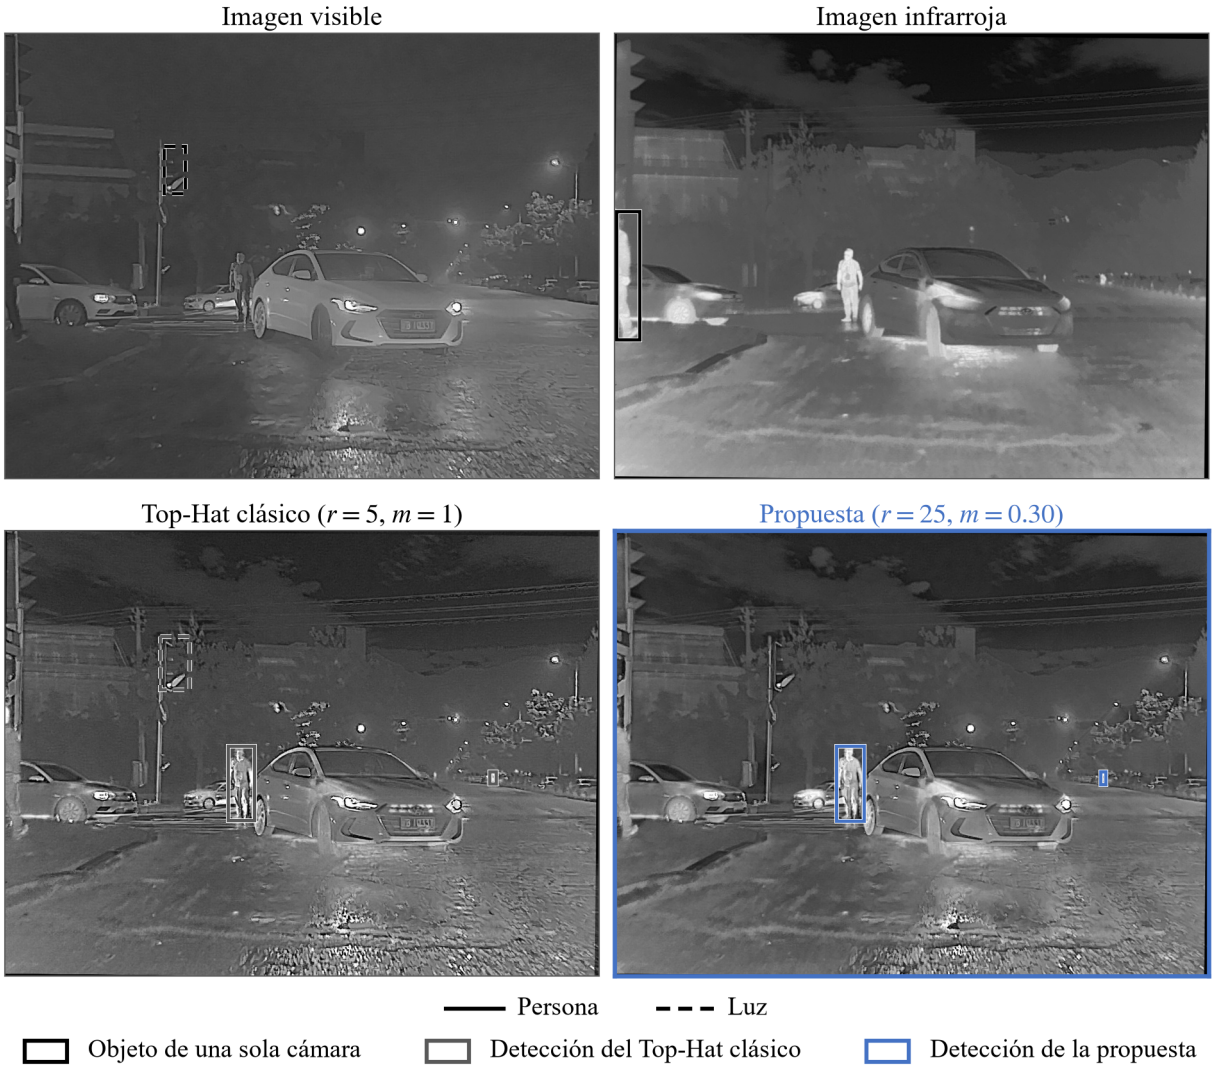
Nota. Elaboración propia. Las tasas están en porcentaje y se calcularon con el umbral principal. El umbral principal de cada detector se fijó para que este cometiera, en los cuadros de seguimiento, tantos falsos positivos de personas y luces por imagen como los detectores de la visible con un umbral de 0.25. Solo visible y Solo infrarroja se calculan sobre los objetos que ve una sola cámara: 211 vistos solo por la visible y 622 solo por la infrarroja. La columna De ambas se calcula sobre los 724 objetos que ven las dos cámaras. La columna Equilibrada es el promedio de las dos columnas anteriores. Las filas van de mayor a menor tasa equilibrada, y la mayor está en negrita. Cada tasa promedia, sobre tres semillas, la fracción de objetos encontrados. La visible y la infrarroja no figuran porque sus detectores definen qué objetos ve una sola cámara. Propuesta: el algoritmo de fusión presentado en este trabajo.

La pirámide de Laplace obtuvo la mayor tasa equilibrada, 66.5 %. La propuesta quedó cuarta de ocho, con 61.4 %, y el Top-Hat clásico, séptimo, con 58.4 %. El Top-Hat clásico quedó así por debajo del promedio simple, que obtuvo 60.2 %, aunque esa diferencia no se sometió a prueba.

Al separar las dos tasas que forman la equilibrada, la propuesta fue segunda en los objetos vistos solo por la visible, con 55.6 %, detrás de la pirámide de Laplace. En los vistos solo por la infrarroja fue sexta, con 67.2 %. Sobre los objetos que veían las dos cámaras, todas las entradas alcanzaron al menos el 93.0 %. Con el umbral fijo de 0.25, la

Figura 4.6

Detecciones del Top-Hat clásico y de la propuesta en un cuadro nocturno de M3FD



Nota. Elaboración propia a partir de imágenes de M3FD (Liu et al., 2022). Es el cuadro 437 del conjunto y pertenece a la prueba. Se eligió sin mirar las detecciones de las fusiones. De los 49 cuadros con al menos un objeto de solo la visible y uno de solo la infrarroja, 12 tienen marcadas en M3FD las dos clases del análisis, personas y luces. Entre esos 12, es el que tiene los objetos de una sola cámara más grandes. Arriba están las fuentes en escala de grises, tal como las recibe el detector. En cada una, el recuadro negro marca su objeto de una sola cámara. Abajo, cada fusión lleva las detecciones de su detector, con la primera semilla y su umbral principal: 0.26 en el Top-Hat clásico y 0.25 en la propuesta. La línea continua marca personas, y la discontinua, luces.

propuesta obtuvo una tasa equilibrada de 61.1 % y quedó cuarta; con el de mejor equilibrio por clase, obtuvo 59.0 % y quedó quinta.

La Figura 4.7 muestra dos escenas de la prueba con un objeto de una sola cámara, uno de cada cámara, que el detector de la propuesta encontró. Arriba, en un cuadro nocturno, la persona de la derecha apenas se distingue del fondo en la imagen visible y se ve nítida en la infrarroja. Con la primera semilla, el detector de la visible no la encontró, y sí los de la infrarroja, del Top-Hat clásico y de la propuesta. Abajo, en un cuadro diurno, la imagen visible muestra encendidas las flechas de los dos semáforos y el número del de la derecha; en la infrarroja, los dos son manchas claras sin esos detalles. Con la primera semilla, los detectores de la visible, del Top-Hat clásico y de la propuesta encontraron el semáforo de la derecha, y el de la infrarroja no. En toda la prueba, las dos fusiones coincidieron en la mayoría de estos objetos: con esa misma semilla, de los que encontró al menos una de ellas, las dos encontraron 83 de 143 de solo la visible y 355 de 460 de solo la infrarroja. Como la Figura 4.6, esta ilustra cómo una fusión puede encontrar un objeto que una de las cámaras pierde, y no el resultado de conjunto, que es el de la Tabla 4.5.

4.6.2. Comparación con el Top-Hat clásico

La Tabla 4.6 reúne la diferencia de tasa equilibrada entre la propuesta y el Top-Hat clásico, con su intervalo de confianza del 95 %, para cada umbral y para el *bootstrap* salvaje por grupos.

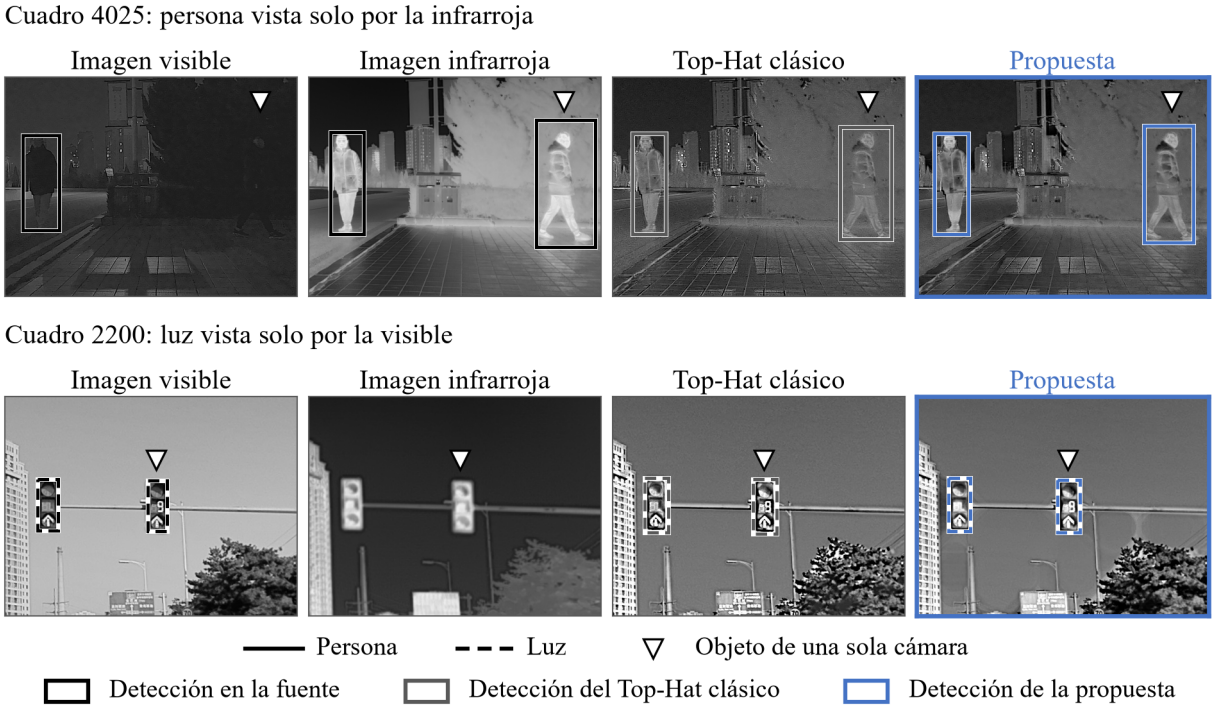
Tabla 4.6: Diferencia de tasa equilibrada entre la propuesta y el Top-Hat clásico

Cálculo	**Diferencia**	**Intervalo del 95 %**
Umbral principal	3.0	[0.0, 6.0]
Umbral fijo de 0.25	2.7	[0.0, 5.3]
Umbral de mejor equilibrio por clase	2.5	[1.1, 3.9]
Bootstrap salvaje por grupos	3.0	[−3.5, 5.5]

Nota. Elaboración propia. La diferencia, en puntos porcentuales, es la tasa de acierto equilibrada de la propuesta menos la del Top-Hat clásico. El cálculo de los intervalos de confianza del 95 % se describe en la Sección 3.5.4. La unidad del análisis es el grupo de bloques contiguos de cuadros: de los once grupos de la prueba, entran los diez que tienen objetos de una sola cámara. Las tres primeras filas usan un error estándar robusto por grupos y la distribución t con nueve grados de libertad (Cameron & Miller, 2015). La última fila usa el umbral principal y un *bootstrap* salvaje por grupos, estudentizado y con la hipótesis nula impuesta (Cameron et al., 2008; Webb, 2023). Su intervalo reúne las diferencias que esa prueba no rechaza al 5 %, y el valor p para una diferencia nula es 0.17. Los límites inferiores que se muestran como 0.0 son positivos: 0.02 puntos con el umbral principal y 0.05 con el umbral fijo. Según el par de semillas, la diferencia va de −3.1 a 7.8 puntos con el umbral principal. Con el umbral fijo va de −2.9 a 7.1, y con el de mejor equilibrio por clase, de −5.2 a 9.1. Con cada umbral, tres de las nueve diferencias son negativas: frente a una misma semilla del Top-Hat clásico, las tres semillas de la propuesta quedan por debajo. Por eso la diferencia no es robusta a la semilla.

Figura 4.7

Detecciones en dos cuadros de M3FD con un objeto de una sola cámara



Nota. Elaboración propia a partir de imágenes de M3FD (Liu et al., 2022). Son los cuadros 4025 y 2200 del conjunto y pertenecen a la prueba. Se eligieron con una regla fija que no usa las detecciones del Top-Hat clásico. Entre los objetos de una sola cámara que encontró el detector de la propuesta con la primera semilla, fuera del grupo del cuadro 437 de la Figura 4.6, arriba está el de solo la infrarroja de mayor área según su marca en M3FD, y abajo, el de solo la visible de mayor área entre los de otro grupo que el de arriba. Como la regla parte de los objetos que encontró la propuesta, la figura no indica con qué frecuencia los encuentra. Arriba se muestra el cuadro entero, y abajo, un recorte de 475 × 356 píxeles alrededor del objeto, el mismo en los cuatro paneles. Cada panel lleva las detecciones de su detector con la primera semilla y el umbral principal: 0.25 en la visible y en la propuesta, y 0.26 en la infrarroja y en el Top-Hat clásico. Los objetos de una sola cámara se definen con los tres detectores de cada cámara, y los paneles muestran solo el primero. Por eso, abajo, el de la infrarroja tampoco encuentra el semáforo de la izquierda, que es de las dos cámaras porque lo encontraron los otros dos detectores de la infrarroja. El triángulo señala el objeto de una sola cámara. A diferencia de la Figura 4.6, los recuadros negros no son objetos marcados, sino detecciones en las fuentes; los gris oscuro, del Top-Hat clásico ($r = 5$, $m = 1$), y los azules, de la propuesta ($r = 25$, $m = 0.30$). La línea continua marca personas, y la discontinua, luces.

Con el umbral principal, la propuesta aventajó al Top-Hat clásico, pero el intervalo de confianza apenas dejó fuera el cero. Su tasa equilibrada fue 3.0 puntos porcentuales mayor, con un intervalo de 0.0 a 6.0. El límite inferior exacto fue de 0.02 puntos, que con un decimal se muestra como 0.0. La diferencia, además, no es robusta a la semilla: según el par de semillas, va de -3.1 a 7.8 puntos.

Con el umbral fijo de 0.25, la diferencia fue de 2.7 puntos, con un intervalo de 0.0 a 5.3 y un límite inferior exacto de 0.05. Con el umbral de mejor equilibrio por clase fue de 2.5 puntos, con un intervalo de 1.1 a 3.9. Los tres intervalos calculados con la distribución t dejaron fuera el cero, los dos primeros por muy poco. El *bootstrap* salvaje por grupos, estudentizado y con la hipótesis nula impuesta, no lo excluyó. Con el umbral principal dio un valor de p de 0.17 y un intervalo de -3.5 a 5.5, y con los otros dos umbrales, valores de p de 0.17 y 0.08. Al dejar fuera el grupo mayor de la prueba, la diferencia con el umbral principal bajó de 3.0 a 1.5 puntos; al dejar fuera cualquiera de los otros, quedó entre 2.3 y 3.6.

La Figura 4.8 muestra la tasa equilibrada de cada semilla en las ocho entradas fusionadas y las nueve diferencias entre las semillas de la propuesta y las del Top-Hat clásico. Las tres semillas de la propuesta quedaron a menos de un punto entre sí, mientras que las del Top-Hat clásico se separaron casi diez. Por eso las diferencias entre pares de semillas no mantuvieron el signo. Con el umbral principal, seis fueron positivas y tres negativas, de -2.2, -3.1 y -2.3 puntos. Las tres negativas se dieron frente a la misma semilla del Top-Hat clásico, la de tasa más alta, que superó a las tres de la propuesta. Con los otros dos umbrales hubo también tres diferencias negativas, otra vez frente a esa semilla. Según el par de semillas, la diferencia fue de -2.9 a 7.1 puntos con el umbral fijo de 0.25 y de -5.2 a 9.1 con el de mejor equilibrio por clase.

Como referencia, con el mismo cálculo, la diferencia entre la propuesta y el promedio simple fue de 1.2 puntos, con un intervalo de -6.6 a 9.0, que incluye valores de los dos signos. Frente a la pirámide de Laplace, la propuesta quedó por debajo en los nueve pares de semillas, con diferencias de -5.8 a -4.6 puntos.

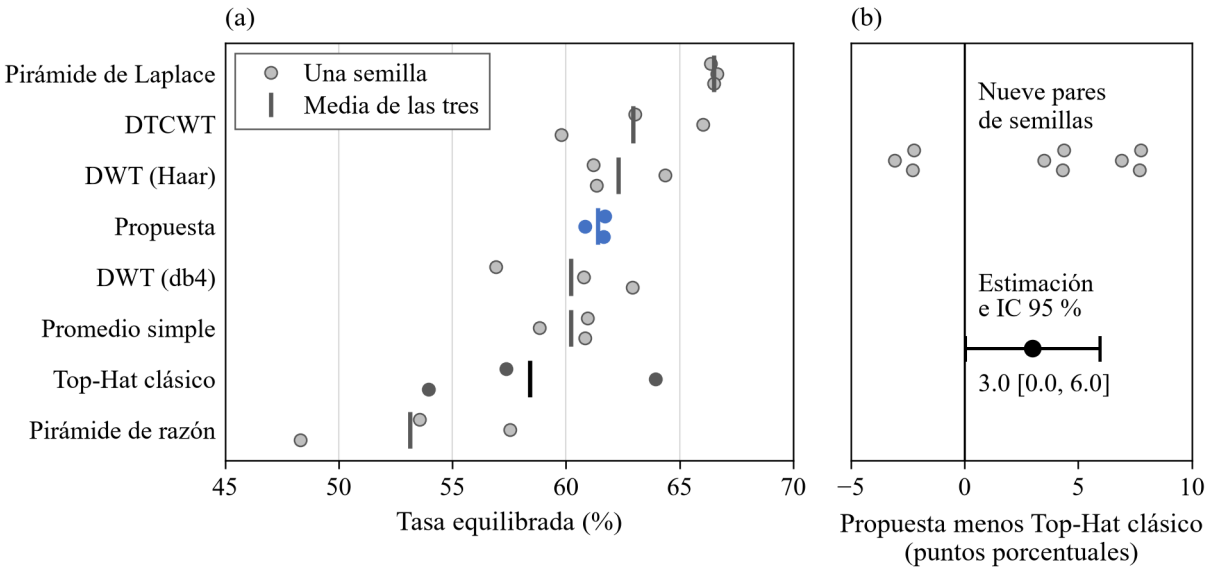
La ventaja de la propuesta frente al Top-Hat clásico es, entonces, mínima y depende de la semilla, por lo que queda como un hallazgo por confirmar.

4.6.3. Medidas secundarias y entrenamiento

La mAP50, la precisión media global sobre las seis clases, se midió en los 1197 cuadros que dejó el primer filtro (Sección 3.5.1). En esta medida, la propuesta quedó séptima de diez, por debajo del Top-Hat clásico. La pirámide de Laplace obtuvo el mayor valor, 0.441, muy cerca de la DTCWT, con 0.440, y del promedio simple, con 0.439. Siguieron el Top-Hat clásico, con 0.434, la DWT (db4), con 0.430, la infrarroja sola, con 0.429, y la

Figura 4.8

Tasa equilibrada por entrada y diferencia entre la propuesta y el Top-Hat clásico



Nota. Elaboración propia. Las tasas corresponden al umbral principal. (a) Las ocho entradas fusionadas de la Tabla 4.5, ordenadas de mayor a menor tasa. Cada punto es la tasa de una semilla del detector, y la línea vertical, la media de las tres semillas, que es el valor de la tabla. La propuesta está en azul y el Top-Hat clásico, en gris oscuro, con su media en negro. (b) Diferencia de tasa equilibrada, propuesta menos Top-Hat clásico, en puntos porcentuales. Arriba están las nueve diferencias entre cada semilla de la propuesta y cada semilla del Top-Hat clásico. Abajo están la estimación principal y su intervalo, con los límites entre corchetes. A la derecha del cero, la propuesta acierta más que el Top-Hat clásico. Los dos paneles tienen la misma escala horizontal: un punto porcentual mide lo mismo en ambos. IC 95 %: intervalo de confianza del 95 %.

propuesta, con 0.427. Cerraron la lista la DWT (Haar), con 0.415, la pirámide de razón, con 0.411, y la visible sola, con 0.363.

Así, cinco de las ocho entradas fusionadas superaron en mAP50 a la infrarroja sola. La propuesta no estuvo entre ellas: quedó apenas por debajo, con 0.427 frente a 0.429, una diferencia menor que la variación entre sus propias semillas, que fue de 0.419 a 0.440.

En los 49 cuadros con al menos un objeto de solo la visible y uno de solo la infrarroja, los detectores de la propuesta encontraron al menos uno de cada tipo en el 57.1 % de los casos. Con el Top-Hat clásico la proporción fue algo mayor, 57.8 %, y con la pirámide de Laplace llegó al 72.1 %. Sobre los objetos vistos por las dos cámaras, la propuesta y el Top-Hat clásico quedaron casi iguales, con 94.4 % y 94.1 %. Ninguna de estas diferencias, ni las de mAP50, se sometió a prueba.

El seguimiento época por época se hizo solo con la primera semilla de cada entrada, midiendo la mAP50 sobre los 474 cuadros de seguimiento. Esos cuadros provienen de los mismos bloques que el entrenamiento. En la época 40, su mAP50 fue de 0.73 a 0.76, muy superior a la de esos mismos detectores en los 1197 cuadros, de 0.35 a 0.46. Por eso, ese seguimiento refleja más el ajuste a cuadros parecidos a los de entrenamiento que la capacidad de generalizar. Al final del entrenamiento, esa medida seguía subiendo en casi todos los detectores: en las últimas cinco épocas, nueve de los diez tenían todavía una pendiente positiva. La excepción fue el de la DWT (Haar). Entre las épocas 30 y 40 cambió, además, el orden de la propuesta frente a dos métodos. En la época 30 quedaba por debajo de la pirámide de Laplace y de la DWT (db4), y en la 40, por encima de ambas. En ese tramo, la propuesta pasó de 0.7347 a 0.7636; la pirámide de Laplace, de 0.7406 a 0.7616, y la DWT (db4), de 0.7372 a 0.7512.

Por último, se calculó la correlación de Spearman entre el rango promedio de calidad, con 1 para el mejor, y la tasa equilibrada de los siete métodos. Resultó de $\rho = -0.32$, con $p = 0.48$. El signo negativo indica que los métodos mejor ubicados en calidad detectaron algo más, pero la correlación no fue significativa. Los dos órdenes, además, provienen de conjuntos distintos: el de calidad, del TNO, y el de detección, de M3FD.

4.7. Examen de la hipótesis

Esta sección reúne, para cada afirmación de la hipótesis (Capítulo 1), los resultados con que se la examina según la Sección 3.6. No se hizo ninguna prueba nueva: todos los valores provienen de las secciones anteriores.

La primera afirmación compara la calidad de la propuesta con la del Top-Hat clásico. En los seis contrastes de Wilcoxon con la corrección de Holm, la propuesta ganó en entropía, desviación estándar, información mutua y similitud estructural (Tabla 4.4). Perdió en gradiente medio y empató en relación señal-ruido de pico, donde el p corregido fue de

0.674. Como complemento, el rango promedio fue de 3.642 en la propuesta, primera de siete, y de 4.242 en el Top-Hat clásico, sexto.

La segunda afirmación se refiere a los cinco métodos multiescala. Con las seis métricas, la propuesta encabezó la clasificación por rango promedio: obtuvo 3.642, frente a 3.783 de la DTCWT. El margen, de 0.14 puestos, no tiene una prueba propia. Con las nueve métricas iniciales también quedó primera, y con las diecisiete, tercera. Su perfil fue desigual entre los dos grupos de métricas. Ganó los cinco contrastes de entropía y de gradiente medio, y cuatro de cinco en desviación estándar. Perdió los cinco de similitud estructural y cuatro de cinco en información mutua y en relación señal-ruido de pico. Por grupos de métricas, su rango promedio fue el mejor de los siete en actividad, 1.717, y el sexto en fidelidad, 5.567.

La tercera afirmación corresponde a la aplicación. Con el umbral principal, la tasa equilibrada de la propuesta superó a la del Top-Hat clásico en 3.0 puntos, con un intervalo de 0.0 a 6.0 y un límite inferior exacto de 0.02. Esa diferencia no es robusta a la semilla: entre los nueve pares de semillas fue de -3.1 a 7.8 puntos, y cada uno de los tres umbrales dejó tres diferencias negativas. Con los otros dos umbrales, el límite inferior del intervalo también quedó por encima de cero. El *bootstrap* salvaje por grupos, en cambio, no excluyó el cero: con el umbral principal, su valor de p fue de 0.17.

Con esos resultados, la parte de la hipótesis que trata de la calidad se sostiene en lo principal. La propuesta superó al Top-Hat clásico en cuatro de las seis métricas, y su calidad fue comparable a la de los cinco métodos multiescala. Su primer puesto por rango promedio se apoya en un margen estrecho, sin una prueba propia, y cambia con el conjunto de métricas. En la aplicación, la ventaja frente al Top-Hat clásico es mínima: el límite inferior del intervalo apenas superó el cero, el *bootstrap* no lo excluyó y la diferencia no es robusta a la semilla. Esa parte de la hipótesis queda, por eso, como un hallazgo que falta confirmar con más grupos, más semillas y otros detectores (Capítulo 7).

Capítulo 5

Discusión

El Capítulo 1 planteó dos preguntas, y los resultados las responden con distinto grado de firmeza. La primera se refería a la calidad de las imágenes del algoritmo propuesto. Esas imágenes fueron mejores que las del Top-Hat clásico en cuatro de las seis métricas. Frente a los cinco métodos multiescala, la calidad del algoritmo fue comparable, aunque con un perfil propio: más actividad y menos fidelidad. Sus imágenes tienen más información, contraste y nitidez, pero se parecen menos a las fuentes. La propuesta encabezó la clasificación por rango promedio, pero por un margen estrecho y sin que ese margen se sometiera a prueba. La segunda pregunta era si un detector entrenado con esas imágenes encuentra más objetos vistos por una sola cámara que uno entrenado con las del Top-Hat clásico. El detector encontró algo más, pero la ventaja es mínima. La tasa equilibrada, que promedia el acierto en los objetos de solo la visible y de solo la infrarroja, fue 3.0 puntos mayor que la del Top-Hat clásico, con un intervalo de 0.0 a 6.0. Según el par de semillas, esa diferencia cambia de signo. Así, en calidad la hipótesis se sostiene en lo principal; en la detección, la ventaja queda como un hallazgo por confirmar. El capítulo discute esos resultados en cinco ejes: el perfil de calidad y su costo, el ajuste de los parámetros, la aplicación a la detección, la relación entre calidad y detección y, al final, las limitaciones del estudio.

5.1. La calidad de la fusión y su costo

El primer puesto por rango promedio, con 3.642 frente a 3.783 de la DTCWT (Tabla 4.3), no autoriza a decir que la propuesta supere a ese método. Esa diferencia no tiene una prueba propia, y los dos métodos llegan a la cabeza por caminos opuestos. La propuesta fue primera en actividad y sexta en fidelidad; la DTCWT, sexta en actividad y segunda en fidelidad. Como cada grupo reúne tres métricas, el rango global lo decide la suma de los dos rangos parciales: 7.28 para la propuesta y 7.57 para la DTCWT. Un

perfil marcado no basta, por sí solo, para llegar a la cabeza. La DWT (db4), todavía más desequilibrada que la DTCWT entre los dos grupos, quedó quinta.

El perfil de la propuesta nace de la regla de fusión (Ecuación 2.11), que toma su forma del realce de contraste de la Ecuación (2.10) (Bai et al., 2012). Sumar el detalle claro y restar el oscuro agranda la diferencia de brillo entre cada detalle y su entorno, pero aleja la imagen de sus fuentes. El barrido del peso lo confirma (Sección 4.2). Con la propuesta y con el Top-Hat clásico, subir m elevó la desviación estándar y el gradiente medio y bajó las tres métricas de fidelidad. El compromiso es, entonces, propio de la regla y no depende del banco de elementos. Algo parecido observaron Bajac Figueredo et al. (2025) con otra variable. Al agrandar el elemento estructurante de 3 a 9, subieron la desviación estándar, la entropía y la frecuencia espacial, y la información mutua bajó o se mantuvo.

El costo se ve también en las imágenes. La resta del detalle oscuro es el único término de la regla que lleva un píxel por debajo del promedio de las fuentes, y puede bajarlo hasta el negro, donde el valor se recorta. De ahí el borde oscuro que rodea a la persona en la Figura 4.2.

Frente al Top-Hat clásico, la propuesta ganó en entropía, desviación estándar, información mutua y similitud estructural, perdió en gradiente medio y empató en PSNR (Tabla 4.4). Ese reparto no puede atribuirse al banco, porque entre los dos métodos cambian a la vez los elementos, el radio y el peso. Según el barrido, el peso mueve por sí solo tres de esas métricas en la dirección observada. Con los dos operadores, un peso menor reduce el gradiente medio y eleva la información mutua y la similitud estructural. La propuesta usa un peso de 0.30, y el Top-Hat clásico, de 1, así que parte de esas diferencias puede deberse solo a ese peso menor.

El primer puesto depende también del conjunto de métricas. Con las nueve métricas iniciales, cinco de ellas de actividad, la propuesta quedó primera. Con un conjunto de diecisiete, en el que doce comparan la fusión con sus fuentes, bajó al tercer puesto, detrás de la pirámide de Laplace y de la DTCWT. Por otra parte, los cinco métodos multiescala se usaron con sus parámetros por defecto, mientras que el radio de la propuesta se eligió sobre los mismos veinte pares de la evaluación (Sección 3.3). Nada asegura que el orden se mantenga si todos se ajustan con un mismo criterio.

El control con imágenes degradadas marca el límite de las métricas de actividad: una ventaja en ellas no prueba, por sí sola, que el detalle agregado sea útil. Cuanto más ruido se agregó al promedio simple, más puestos ganó la imagen resultante, hasta empatar en el octavo con el Top-Hat clásico (Sección 4.5.3). Con la mayor intensidad fue, además, la mejor de las catorce entradas en las tres métricas de actividad. En ese mismo control, la propuesta quedó tercera, detrás de la pirámide de Laplace y del promedio simple sin degradar. Ese puesto lo producen las dos versiones desenfocadas, que en fidelidad quedaron delante de la propuesta y, en las seis métricas, detrás del promedio simple. Al ordenar solo los siete métodos y el promedio, la propuesta quedó primera, y el promedio, sexto.

La cabeza de la clasificación resistió también el análisis por escenas. Con un bloque por escena, la propuesta siguió primera y la DTCWT segunda, y solo uno de los sesenta y seis contrastes cambió su decisión.

5.2. El ajuste de los parámetros

Las veinticinco corridas del enjambre terminaron con el peso en 0.30, el límite inferior del rango de búsqueda. La grilla de comprobación indica que ese valor es un borde y no un máximo interior. En cada radio, el mejor peso quedó muy por debajo de ese límite. A partir de 0.30, la aptitud, la función que el enjambre busca maximizar, bajó con cada aumento del peso (Sección 4.2). Una explicación posible está en la forma de la aptitud (Ecuación 3.4). Dos de sus tres términos, la similitud estructural y la PSNR, premian el parecido con las fuentes, y cada aumento del peso aleja de ellas la fusión. La entropía, el tercer término, no compensa esa pérdida.

El resultado difiere del de Ortega Rodríguez y Espinoza Ríos (2025), que buscaron el peso en el mismo rango. Hicieron 125 corridas, con veinticinco configuraciones en cada una de cinco escenas, y el peso terminó en 0.30 solo en 17, todas de una misma escena. Aquel trabajo usó la aptitud original, que aquí se adaptó, ajustó los parámetros escena por escena y empleó un disco único. Cualquiera de esas diferencias podría explicar el contraste, que no se investigó. La última tiene una lectura directa. El detalle del banco puede llegar al doble del de un disco del mismo radio (Ecuación 3.3), así que un mismo peso aleja más la fusión de sus fuentes.

En el radio, el enjambre no llegó a un valor único, porque con $m = 0.30$ la aptitud tiene dos máximos locales: uno en $r = 1$ y otro, menor, en $r = 25$. Casi todas las corridas, incluidas las quinientas de control, terminaron en uno de esos dos radios (Sección 4.2), y la mayor aptitud corresponde a $r = 1$. Aun así, se adoptó $r = 25$ porque prioriza el realce: con $r = 1$, el disco y los segmentos miden apenas tres píxeles de ancho y solo extraen detalles muy finos. Frente a $r = 1$, el radio adoptado fue mejor en todas las métricas de actividad y peor en todas las de fidelidad. Esa elección explica en parte la ventaja de la propuesta sobre los métodos multiescala en entropía, desviación estándar y gradiente medio.

5.3. La aplicación a la detección

La ventaja de la propuesta frente al Top-Hat clásico, de 3.0 puntos de tasa equilibrada, admite dos lecturas (Tabla 4.6). La primera se apoya en el intervalo de confianza del 95 %, de 0.0 a 6.0, que excluye el cero por muy poco: su límite inferior es de 0.02 puntos. El cero queda fuera también con los otros dos umbrales, pero no con el *bootstrap* salvaje por grupos, más confiable cuando los grupos son pocos y de tamaño desigual. Con el umbral

principal, ese cálculo dio un intervalo de -3.5 a 5.5 y un valor de p de 0.17. La segunda lectura surge de los pares de semillas. Sus nueve diferencias van de -3.1 a 7.8 puntos, y las tres negativas enfrentan a la propuesta con una misma semilla del Top-Hat clásico.

Las dos lecturas no se contradicen. El intervalo mide cómo varía la diferencia entre los grupos de cuadros. Como la tasa de cada objeto llega ya promediada sobre las tres semillas, el intervalo no recoge por completo la variación del entrenamiento. Los pares de semillas, en cambio, la dejan a la vista: basta que un detector del Top-Hat clásico acierte más que los otros dos para invertir el signo en tres de los nueve pares. Por eso la ventaja es mínima, y queda como un hallazgo por confirmar con más grupos, más semillas y otros detectores (Capítulo 7).

El hallazgo, además, no aísla el efecto del banco. Entre la propuesta y el Top-Hat clásico cambian a la vez los elementos, el radio y el peso (Sección 3.2.3), y la comparación no dice cuál de esos cambios produce la diferencia. Tampoco muestra que el detalle agregado ayude a detectar. El promedio simple es la regla de la Ecuación (2.11) con peso cero, de modo que la comparación con él mide el aporte del detalle. El Top-Hat clásico tuvo una tasa menor que la de ese promedio (58.4 % contra 60.2 %, sin prueba entre ambos). Como referencia, la propuesta superó a ese promedio por apenas 1.2 puntos. El intervalo de esa diferencia, calculado del mismo modo que el de la Tabla 4.6, va de -6.6 a 9.0 e incluye el cero.

Aun si se confirmara, la ventaja frente al Top-Hat clásico no pondría a la propuesta entre las mejores entradas para detectar. Entre las ocho entradas fusionadas quedó cuarta, con 61.4 %, y la pirámide de Laplace tuvo la mayor tasa, 66.5 % (Tabla 4.5). Esa pirámide superó a la propuesta con todas las combinaciones de semillas. En la mAP50, una medida secundaria calculada sobre todas las clases, cinco de las ocho entradas fusionadas superaron a la infrarroja sola. La propuesta no estuvo entre ellas, aunque su diferencia con la infrarroja fue menor que la variación entre sus propias semillas (Sección 4.6.3). En esa medida y en los cuadros con un objeto de cada cámara, además, el Top-Hat clásico quedó apenas por encima de la propuesta, sin prueba entre ambos.

Estas comparaciones valen para un entrenamiento de cuarenta épocas. En el seguimiento hecho con la primera semilla de cada entrada, nueve de los diez detectores todavía mejoraban al final del entrenamiento su mAP50 sobre los cuadros de seguimiento, que no son los de la prueba. Entre las épocas 30 y 40, además, la propuesta pasó de estar por debajo a estar por encima de la pirámide de Laplace y de la DWT (db4) en esa medida (Sección 4.6.3). Con un entrenamiento más largo, el orden entre entradas de tasa parecida podría cambiar.

5.4. Relación entre calidad y detección

Los dos planos de la evaluación no ordenaron a los métodos de la misma manera. La correlación de Spearman entre los dos órdenes fue de -0.32 y no resultó significativa (Sección 4.6.3). Con siete métodos la prueba es débil, y solo una relación muy fuerte habría alcanzado la significación. Los dos órdenes provienen, además, de conjuntos distintos: la calidad se midió en el TNO y la detección en M3FD. Los dos métodos morfológicos ilustran la distancia entre la actividad y la detección. Fueron los mejores en actividad, pero en detección, entre las ocho entradas fusionadas, la propuesta quedó cuarta y el Top-Hat clásico, séptimo. Esto no prueba que la calidad sea irrelevante para detectar, pero el orden por métricas de imagen no anticipó el orden en la tarea. Ese desacuerdo respalda evaluar la fusión también por su efecto en una tarea, como proponen Liu et al. (2022) y Tang et al. (2022).

5.5. Limitaciones del estudio

Los resultados permiten precisar las limitaciones anunciadas en la Sección 1.2. En calidad, el primer puesto no equivale a superioridad. Descansa en diferencias de rango promedio que no se sometieron a prueba y cambia con el conjunto de métricas. Ese puesto se ganó en actividad a costa de la fidelidad. Además, se obtuvo en condiciones que pueden favorecer a la propuesta: su radio se eligió sobre los mismos veinte pares de la evaluación, y los métodos con los que se la comparó no se ajustaron. Tres de esos veinte pares sirvieron también para calcular la aptitud del enjambre. Todo lo dicho vale para una sola configuración, $r = 25$ y $m = 0.30$, y el barrido muestra que el perfil se desplaza con el peso. El radio se mide en píxeles, sin adaptarse al tamaño de la imagen. En el TNO, el disco de 51 píxeles de ancho cubre entre el 8.9 % y el 20.6 % del lado menor de la imagen. Un mismo radio abarca, así, detalles de distinto tamaño relativo.

En la detección, los objetos de una sola cámara quedaron definidos por los detectores de la visible y de la infrarroja, sin revisión humana. Los objetos de ese tipo se reparten en solo diez grupos de cuadros, y con tan pocos grupos la comparación tiene poca potencia, es decir, poca capacidad de revelar una diferencia real. Cuando los grupos son pocos y de tamaño muy desigual, además, el error estándar robusto por grupos tiende a quedarse corto, y el intervalo puede resultar más estrecho de lo debido. Sin el mayor de esos grupos, la diferencia con el Top-Hat clásico baja de 3.0 a 1.5 puntos. Las luces, por su parte, están concentradas: casi dos de cada tres provienen de un solo grupo (Sección 4.1). Se usó un solo tipo de detector, de tamaño pequeño, con tres semillas por entrada y cuarenta épocas de entrenamiento.

El estudio no incluyó métodos de fusión basados en redes neuronales ni los morfológicos multiescala de Bai (2013) y Mello Román et al. (2020). El foco estuvo en un operador

de una sola escala, y la comparación con esas familias queda para trabajos futuros (Capítulo 7).

Capítulo 6

Conclusiones

En los veinte pares nocturnos del TNO, el algoritmo propuesto produce imágenes de calidad comparable a la de los cinco métodos multiescala. Frente al Top-Hat clásico, la propuesta es mejor en cuatro de las seis métricas. Lo que la distingue es su perfil. Por su puesto medio en cada grupo de métricas, queda primera en las de actividad, que miden información, contraste y nitidez, y sexta de siete en las de fidelidad, que miden el parecido con las fuentes. Con las seis métricas encabeza la clasificación por rango promedio, es decir, por el puesto medio de cada método en todos los pares y métricas. Lo hace, sin embargo, por un margen estrecho y sin una prueba que lo respalde. Ese primer lugar depende, además, del conjunto de métricas, y se obtuvo con los métodos comparados en sus parámetros por defecto. Por eso no se concluye que la propuesta supere a los métodos multiescala, sino que se ubica entre ellos con un perfil propio, que privilegia el realce sobre la fidelidad. En la aplicación a la detección, el detector entrenado con las imágenes de la propuesta aventaja por un margen mínimo al entrenado con las del Top-Hat clásico. Esa diferencia depende de la semilla aleatoria del entrenamiento y queda como un hallazgo por confirmar.

Las conclusiones particulares siguen el orden de los objetivos específicos (Sección 1.1):

1. **Implementación y ajuste del algoritmo:** El algoritmo quedó implementado como se describe en la Sección 3.2, con el banco de cinco elementos estructurantes y la regla de fusión con peso. Su radio y su peso se ajustaron mediante optimización por enjambre de partículas, con un rango de búsqueda de 1 a 25 para el radio y de 0.30 a 2.00 para el peso. Las veinticinco corridas terminaron con el peso en el límite inferior, $m = 0.30$. En el radio, en cambio, se repartieron sobre todo entre los dos extremos del rango: dieciséis terminaron en $r = 1$, ocho en $r = 25$ y una en $r = 14$. Ese valor del peso es un borde del rango y no un máximo interior: la grilla de comprobación mostró que la aptitud, la función que el enjambre busca maximizar, era mayor con pesos menores que 0.30. El mejor peso de cada radio estuvo entre 0.05 y 0.07. Se adoptó $r = 25$, uno de los dos resultados del enjambre, porque prioriza

el realce. Frente a $r = 1$, sobre los veinte pares y con las nueve métricas iniciales, ese radio fue mejor en las cinco de actividad y peor en las cuatro de fidelidad. Esa elección se hizo sobre las mismas imágenes con que después se evaluó la calidad, y explica en parte la ventaja de la propuesta en actividad.

2. **Calidad de imagen:** Frente al Top-Hat clásico, la propuesta ganó en entropía, desviación estándar, información mutua y similitud estructural. Perdió en gradiente medio y empató en la relación señal-ruido de pico. Frente a los cinco métodos multiescala, su calidad fue comparable. Obtuvo el mejor rango promedio, 3.642 frente a 3.783 de la DTCWT, pero la diferencia es de 0.14 puestos y no tiene prueba propia. Con diecisiete métricas, en cambio, la propuesta quedó tercera (Sección 4.5.3). Los contrastes de Wilcoxon frente a los métodos multiescala muestran el mismo perfil: la propuesta ganó catorce de los quince de actividad y perdió trece de los quince de fidelidad. Ese intercambio entre realce y fidelidad proviene de la regla de fusión. En el barrido del peso, al subir m crecieron la desviación estándar y el gradiente medio y bajaron las tres métricas de fidelidad. Con el Top-Hat clásico ocurrió lo mismo. La cabeza de la clasificación se mantuvo al tomar un bloque por escena. Con esos trece bloques, la propuesta siguió primera y sesenta y cinco de los sesenta y seis contrastes conservaron su decisión. El control con versiones degradadas del promedio simple, en cambio, señala un límite de las métricas de actividad. Con el ruido más intenso, ese promedio obtuvo el mejor valor de las catorce entradas en esas tres métricas. Por eso, una ventaja en actividad no prueba, por sí sola, que el detalle agregado sea útil.

3. **Aplicación a la detección:** En el conjunto M3FD, el detector entrenado con las imágenes de la propuesta alcanzó una tasa de acierto equilibrada del 61.4 %. Esa tasa es el promedio entre el acierto sobre los objetos que solo ve la cámara visible y el acierto sobre los que solo ve la infrarroja. La propuesta quedó cuarta entre las ocho entradas fusionadas; la mayor tasa correspondió a la pirámide de Laplace, con 66.5 % (Tabla 4.5). Frente al Top-Hat clásico, la tasa fue 3.0 puntos mayor, con un intervalo de confianza del 95 % de 0.0 a 6.0 (Tabla 4.6). Es una ventaja mínima: el límite inferior, de 0.02 puntos, apenas supera el cero. Con los otros dos umbrales de confianza también lo supera, pero no con el *bootstrap* salvaje por grupos, otra forma de calcular el intervalo, más confiable cuando los grupos son pocos y desiguales. Con el umbral principal, ese cálculo dio un intervalo de -3.5 a 5.5 y un valor de p de 0.17. La diferencia tampoco es robusta a la semilla: según el par de semillas, fue de -3.1 a 7.8 puntos. Se trata, por lo tanto, de un hallazgo por confirmar con más grupos, más semillas y otros detectores (Capítulo 7). Aunque se confirmara, la ventaja no podría atribuirse al banco, porque entre los dos métodos cambian a la vez los elementos estructurantes, el radio y el peso. Tampoco se mostró que el

detalle agregado ayude a detectar: frente al promedio simple, la diferencia fue de 1.2 puntos, con un intervalo de -6.6 a 9.0.

4. **Examen de la hipótesis:** En su parte de calidad, la hipótesis planteada en el Capítulo 1 se sostiene en lo principal (Sección 4.7). La propuesta superó al Top-Hat clásico en cuatro de las seis métricas, y su calidad resultó comparable a la de los cinco métodos multiescala. En la aplicación a la detección, la ventaja frente al Top-Hat clásico es mínima. Con el umbral principal, el límite inferior del intervalo supera el cero por muy poco, y la diferencia cambia de signo según el par de semillas. Esa parte de la hipótesis queda, por eso, como un hallazgo que falta confirmar.

El aporte del trabajo es un algoritmo de fusión de imágenes infrarrojas y visibles que puede explicarse paso a paso. El algoritmo lleva a esta fusión el banco de cinco elementos estructurantes que Flores et al. (2026) emplearon para realzar mamografías, y combina sus respuestas según Bala et al. (2024). La regla con peso y el ajuste del radio y del peso por enjambre de partículas siguen a Ortega Rodríguez y Espinoza Ríos (2025). Cada parámetro tiene una lectura directa: el radio determina el tamaño del detalle que se extrae, y el peso, cuánto de ese detalle se suma. La calidad de sus imágenes quedó caracterizada con seis métricas y pruebas no paramétricas. Frente a los métodos multiescala, esas imágenes ganan contraste y nitidez y pierden fidelidad a las fuentes, en una medida que regula el peso. La aplicación a la detección se evaluó con detectores entrenados sobre cada tipo de imagen, y la ventaja frente al Top-Hat clásico quedó por confirmar. No se halló una relación significativa entre el puesto de cada método en calidad y su tasa equilibrada (Sección 5.4). Los dos métodos morfológicos, los mejores en actividad, quedaron cuarto y séptimo de ocho en detección. Esa falta de correspondencia respalda medir la fusión también por su efecto en una tarea que use sus imágenes (Liu et al., 2022; Tang et al., 2022).

Capítulo 7

Recomendaciones

Las recomendaciones que siguen se desprenden de los resultados y de las limitaciones señaladas en las Secciones 1.2 y 5.5.

- **Contraste de la hipótesis:** La hipótesis del trabajo (Capítulo 1) se planteó a partir de estos resultados, cuando ya se los conocía. Su examen muestra que es compatible con ellos, pero esa compatibilidad no equivale a ponerla a prueba. Se recomienda contrastarla con datos nuevos y con una regla de decisión fijada de antemano, que indique qué resultado la sostiene y cuál la contradice.

- **Confirmación del hallazgo en detección:** La ventaja de la propuesta sobre el Top-Hat clásico fue mínima y dependió de la semilla. La tasa equilibrada de la propuesta, que promedia el acierto sobre los objetos de cada cámara, fue 3.0 puntos mayor que la del Top-Hat clásico, con un intervalo de confianza de 0.0 a 6.0. Con el *bootstrap* salvaje por grupos, el intervalo fue de -3.5 a 5.5 e incluyó el cero. Según el par de semillas, la diferencia fue de -3.1 a 7.8 puntos. Confirmar esa ventaja exige, ante todo, más grupos independientes en la prueba, de tamaño más parejo, armados por secuencia de video y no solo por cuadros contiguos. También conviene entrenar con más semillas por entrada, porque las tres diferencias negativas se dieron frente a una misma semilla del Top-Hat clásico. Las luces, por su parte, deberían provenir de más tramos de video: en la prueba, un solo grupo reunió casi dos de cada tres. Por último, la comparación debería repetirse con otros detectores y con más épocas de entrenamiento. En nueve de los diez detectores seguidos época por época, la mAP50 sobre los cuadros de seguimiento todavía subía en las últimas cinco épocas. En esa misma medida, entre las épocas 30 y 40 cambió además el orden de la propuesta frente a la pirámide de Laplace y la DWT (db4).

- **Ajuste con un mismo criterio:** Los métodos comparativos se usaron con sus parámetros por defecto, mientras que el radio de la propuesta se eligió sobre los mismos veinte pares con que se evaluó la calidad. Se recomienda ajustar todos los

métodos, la propuesta incluida, con un mismo criterio y sobre pares que luego no entren en la evaluación. Sería útil, además, medir la calidad en otros conjuntos, cuyas imágenes visibles provengan de cámaras comunes y no de cámaras con intensificador de imagen.

- **Aptitud del ajuste:** La grilla mostró que la aptitud, la función que el enjambre busca maximizar, era mayor con pesos por debajo del rango de búsqueda: el mejor peso de cada radio estuvo entre 0.05 y 0.07. Con pesos tan bajos, la regla de la Ecuación (2.11) deja la fusión cerca del promedio simple. Esa preferencia por pesos bajos podría deberse a que dos de los tres términos de la aptitud (Ecuación 3.4) premian el parecido con las fuentes. Se recomienda definir una aptitud en la que ese parecido no domine, calcularla sobre pares ajenos a la evaluación y tomar el promedio simple como referencia.

- **Otros métodos comparativos:** Este trabajo se centró en un operador de una sola escala. Como se indicó en la Sección 1.2, dejó fuera la fusión con redes neuronales y los métodos morfológicos multiescala de Bai (2013) y de Mello Román et al. (2020). Incluirlos permitiría ubicar la propuesta frente a esas dos familias.

- **Revisión humana de los objetos de una sola cámara:** Un objeto se contó como visto por una sola cámara si lo encontraban al menos dos de los tres detectores de esa cámara y a lo sumo uno de los de la otra. Con ese criterio, un objeto que muestran ambas cámaras pudo contarse como de una sola cámara si los detectores de la otra no lo encontraron. Conviene confirmar esa condición con una revisión humana.

- **Radio relativo al tamaño de la imagen:** El radio se expresó en píxeles, de modo que la parte de la imagen que abarca depende de su resolución. Con $r = 25$, el disco de 51 píxeles de ancho cubre entre el 8.9 y el 20.6 % del lado menor de las imágenes del TNO. Si el radio se expresara en proporción al tamaño de la imagen, abarcaría detalles de igual tamaño relativo en todas ellas.

- **Fusión con la imagen visible en color:** La imagen visible se usó en escala de grises. Queda por estudiar una fusión que combine el brillo de las dos imágenes y conserve el color de la visible. Esa fusión interesa sobre todo para las luces, la clase en que la cámara común más aventaja a la térmica.

Referencias

Aslantas, V., & Bendes, E. (2015). A new image quality metric for image fusion: The sum of the correlations of differences. *AEU - International Journal of Electronics and Communications*, *69*(12), 1890–1896. https://doi.org/10.1016/j.aeue.2015.09.004

Bai, X. (2013). Morphological image fusion using the extracted image regions and details based on multi-scale top-hat transform and toggle contrast operator. *Digital Signal Processing*, *23*(2), 542–554. https://doi.org/10.1016/j.dsp.2012.11.001

Bai, X., Zhou, F., & Xue, B. (2011). Fusion of infrared and visual images through region extraction by using multi scale center-surround top-hat transform. *Optics Express*, *19*(9), 8444–8457. https://doi.org/10.1364/OE.19.008444

Bai, X., Zhou, F., & Xue, B. (2012). Image enhancement using multi scale image features extracted by top-hat transform. *Optics & Laser Technology*, *44*(2), 328–336. https://doi.org/10.1016/j.optlastec.2011.07.009

Bajac Figueredo, Y. C., Bazan, J. P., Mello-Román, J. C., Vázquez Noguera, J. L., & Legal-Ayala, H. (2025). Infrared and visible image fusion using the Top Hat transform. *Proceeding Series of the Brazilian Society of Computational and Applied Mathematics*, *11*(1), Artículo 010158. https://proceedings.sbmac.emnuvens.com.br/sbmac/article/view/4917

Bala, A. A., Aruna Priya, P., & Maik, V. (2024). Hybrid technique for fundus image enhancement using modified morphological filter and denoising net. *The Journal of Supercomputing*, *80*(9), 13317–13340. https://doi.org/10.1007/s11227-024-05952-x

Bradski, G. (2000). The OpenCV library. *Dr. Dobb's Journal of Software Tools*.

Burt, P. J., & Adelson, E. H. (1983). The Laplacian pyramid as a compact image code. *IEEE Transactions on Communications*, *31*(4), 532–540. https://doi.org/10.1109/TCOM.1983.1095851

Cameron, A. C., Gelbach, J. B., & Miller, D. L. (2008). Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics*, *90*(3), 414–427. https://doi.org/10.1162/rest.90.3.414

Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources*, *50*(2), 317–372. https://doi.org/10.3368/jhr.50.2.317

Daubechies, I. (1988). Orthonormal bases of compactly supported wavelets. *Communications on Pure and Applied Mathematics*, *41*(7), 909–996. https://doi.org/10.1002/cpa.3160410705

Eskicioglu, A. M., & Fisher, P. S. (1995). Image quality measures and their performance. *IEEE Transactions on Communications*, *43*(12), 2959–2965. https://doi.org/10.1109/26.477498

Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. (2010). The Pascal visual object classes (VOC) challenge. *International Journal of Computer Vision*, *88*(2), 303–338. https://doi.org/10.1007/s11263-009-0275-4

Flores, S., Bujaico, C., Mello-Román, J. C., Vázquez Noguera, J. L., & Legal-Ayala, H. (2026). *Método de realce de contraste local y nitidez en imágenes mamográficas basado en la transformada top-hat multiescala con elementos estructurantes circulares y lineales* [Manuscrito inédito]. Universidad Autónoma de Asunción.

Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, *32*(200), 675–701. https://doi.org/10.1080/01621459.1937.10503522

Gonzalez, R. C., & Woods, R. E. (2018). *Digital image processing* (4.ª ed.). Pearson.

Haghighat, M. B. A., Aghagolzadeh, A., & Seyedarabi, H. (2011). A non-reference image fusion metric based on mutual information of image features. *Computers & Electrical Engineering*, *37*(5), 744–756. https://doi.org/10.1016/j.compeleceng.2011.07.012

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, *585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Herrera-Arellano, M., Peregrina-Barreto, H., & Terol-Villalobos, I. (2021). Visible-NIR image fusion based on top-hat transform. *IEEE Transactions on Image Processing*, *30*, 4962–4972. https://doi.org/10.1109/TIP.2021.3077310

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, *6*(2), 65–70.

Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8* [Software]. Ultralytics. https://github.com/ultralytics/ultralytics

Kennedy, J., & Eberhart, R. (1995). Particle swarm optimization. *Proceedings of ICNN'95 - International Conference on Neural Networks*, *4*, 1942–1948. https://doi.org/10.1109/ICNN.1995.488968

Kingsbury, N. (2001). Complex wavelets for shift invariant analysis and filtering of signals. *Applied and Computational Harmonic Analysis*, *10*(3), 234–253. https://doi.org/10.1006/acha.2000.0343

Lee, G. R., Gommers, R., Waselewski, F., Wohlfahrt, K., & O'Leary, A. (2019). PyWavelets: A Python package for wavelet analysis. *Journal of Open Source Software*, *4*(36), Artículo 1237. https://doi.org/10.21105/joss.01237

Li, H., Manjunath, B. S., & Mitra, S. K. (1995). Multisensor image fusion using the wavelet transform. *Graphical Models and Image Processing*, *57*(3), 235–245. https://doi.org/10.1006/gmip.1995.1022

Li, S., Kang, X., Fang, L., Hu, J., & Yin, H. (2017). Pixel-level image fusion: A survey of the state of the art. *Information Fusion*, *33*, 100–112. https://doi.org/10.1016/j.inffus.2016.05.004

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. En D. Fleet, T. Pajdla, B. Schiele, & T. Tuytelaars (Eds.), *Lecture notes in computer science*: *Vol. 8693. Computer vision – ECCV 2014* (pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48

Liu, J., Fan, X., Huang, Z., Wu, G., Liu, R., Zhong, W., & Luo, Z. (2022). Target-aware dual adversarial learning and a multi-scenario multi-modality benchmark to fuse infrared and visible for object detection. *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 5792–5801. https://doi.org/10.1109/CVPR52688.2022.00571

Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR)*. https://openreview.net/forum?id=Bkg6RiCqY7

Ma, J., Ma, Y., & Li, C. (2019). Infrared and visible image fusion methods and applications: A survey. *Information Fusion*, *45*, 153–178. https://doi.org/10.1016/j.inffus.2018.02.004

Ma, J., Yu, W., Liang, P., Li, C., & Jiang, J. (2019). FusionGAN: A generative adversarial network for infrared and visible image fusion. *Information Fusion*, *48*, 11–26. https://doi.org/10.1016/j.inffus.2018.09.004

Malviya, P., & Saxena, A. (2014). An improved image fusion technique based on texture feature optimization using wavelet transform and particle of swarm optimization (POS). *International Journal of Computer Applications*, *101*(6), 19–22. https://doi.org/10.5120/17691-8656

Mello Román, J. C. (2021). *Esquemas morfológicos multiescala basados en operaciones de Top-Hat para aplicaciones de mejora y fusión de imágenes* [Tesis doctoral, Facultad Politécnica, Universidad Nacional de Asunción]. Repositorio Institucional CONACYT. https://hdl.handle.net/20.500.14066/2933

Mello Román, J. C., Vázquez Noguera, J. L., & Legal-Ayala, H. (2020). A multiscale morphological method for visible and infrared images fusion. *2020 XLVI Latin*

American Computing Conference (CLEI), 488–495. https://doi.org/10.1109/CLEI52000.2020.00063

Mukhopadhyay, S., & Chanda, B. (2000). A multiscale morphological approach to local contrast enhancement. *Signal Processing*, *80*(4), 685–696. https://doi.org/10.1016/S0165-1684(99)00161-9

Ortega Rodríguez, M. A., & Espinoza Ríos, G. A. (2025). *Optimización de los parámetros de la transformada Top-Hat mediante PSO para la fusión de imágenes visibles e infrarrojas* [Trabajo final de grado inédito]. Facultad Politécnica, Universidad Nacional de Asunción.

Petrović, V., & Xydeas, C. S. (2005). Objective image fusion performance characterisation. *Tenth IEEE International Conference on Computer Vision (ICCV'05)*, *2*, 1866–1871. https://doi.org/10.1109/ICCV.2005.175

Piella, G., & Heijmans, H. (2003). A new quality metric for image fusion. *Proceedings 2003 International Conference on Image Processing*, *3*, III-173–III-176. https://doi.org/10.1109/ICIP.2003.1247209

Qu, G., Zhang, D., & Yan, P. (2002). Information measure for performance of image fusion. *Electronics Letters*, *38*(7), 313–315. https://doi.org/10.1049/el:20020212

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779–788. https://doi.org/10.1109/CVPR.2016.91

Saravia, C. A., Mereles Peralta, M. E., Mello Román, J. C., Vázquez Noguera, J. L., & Legal-Ayala, H. (2019). Fusion of infrared and visible images using multiscale morphology. *2019 XLV Latin American Computing Conference (CLEI)*, 1–10. https://doi.org/10.1109/CLEI47609.2019.235085

Serra, J. (1982). *Image analysis and mathematical morphology*. Academic Press.

Sheikh, H. R., & Bovik, A. C. (2006). Image information and visual quality. *IEEE Transactions on Image Processing*, *15*(2), 430–444. https://doi.org/10.1109/TIP.2005.859378

Shi, Y., & Eberhart, R. (1998). A modified particle swarm optimizer. *1998 IEEE International Conference on Evolutionary Computation Proceedings. IEEE World Congress on Computational Intelligence*, 69–73. https://doi.org/10.1109/ICEC.1998.699146

Shreyamsha Kumar, B. K. (2013). Multifocus and multispectral image fusion based on pixel significance using discrete cosine harmonic wavelet transform. *Signal, Image and Video Processing*, *7*(6), 1125–1143. https://doi.org/10.1007/s11760-012-0361-x

Singh, S., Singh, H., Bueno, G., Deniz, O., Singh, S., Monga, H., Hrisheekesha, P. N., & Pedraza, A. (2023). A review of image fusion: Methods, applications and perfor-

mance metrics. *Digital Signal Processing*, *137*, Artículo 104020. https://doi.org/10.1016/j.dsp.2023.104020

Soille, P. (2004). *Morphological image analysis: Principles and applications* (2.ª ed.). Springer. https://doi.org/10.1007/978-3-662-05088-0

Spearman, C. (1904). The proof and measurement of association between two things. *The American Journal of Psychology*, *15*(1), 72–101. https://doi.org/10.2307/1412159

Tang, L., Yuan, J., & Ma, J. (2022). Image fusion in the loop of high-level vision tasks: A semantic-aware real-time infrared and visible image fusion network. *Information Fusion*, *82*, 28–42. https://doi.org/10.1016/j.inffus.2021.12.004

Tao, J., Li, S., & Yang, B. (2010). Multimodal image fusion algorithm using dual-tree complex wavelet transform and particle swarm optimization. En D.-S. Huang, M. McGinnity, L. Heutte, & X.-P. Zhang (Eds.), *Communications in computer and information science*: *Vol. 93. Advanced intelligent computing theories and applications* (pp. 296–303). Springer. https://doi.org/10.1007/978-3-642-14831-6_40

Toet, A. (1989). Image fusion by a ratio of low-pass pyramid. *Pattern Recognition Letters*, *9*(4), 245–253. https://doi.org/10.1016/0167-8655(89)90003-2

Toet, A. (2014). *TNO Image Fusion Dataset* [Conjunto de datos]. figshare. https://doi.org/10.6084/m9.figshare.1008029

Toet, A. (2017). The TNO multiband image data collection. *Data in Brief*, *15*, 249–251. https://doi.org/10.1016/j.dib.2017.09.038

van der Walt, S., Schönberger, J. L., Nunez-Iglesias, J., Boulogne, F., Warner, J. D., Yager, N., Gouillart, E., & Yu, T. (2014). scikit-image: Image processing in Python. *PeerJ*, *2*, Artículo e453. https://doi.org/10.7717/peerj.453

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, *17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Wang, J., Peng, J., Feng, X., He, G., & Fan, J. (2014). Fusion method for infrared and visible images by using non-negative sparse representation. *Infrared Physics & Technology*, *67*, 477–489. https://doi.org/10.1016/j.infrared.2014.09.019

Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, *13*(4), 600–612. https://doi.org/10.1109/TIP.2003.819861

Webb, M. D. (2023). Reworking wild bootstrap-based inference for clustered errors. *Canadian Journal of Economics/Revue canadienne d'économique*, *56*(3), 839–858. https://doi.org/10.1111/caje.12661

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, *1*(6), 80–83. https://doi.org/10.2307/3001968

Xydeas, C. S., & Petrović, V. (2000). Objective image fusion performance measure. *Electronics Letters*, *36*(4), 308–309. https://doi.org/10.1049/el:20000267

Zhang, X., & Demiris, Y. (2023). Visible and infrared image fusion using deep learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *45*(8), 10535–10554. https://doi.org/10.1109/TPAMI.2023.3261282

Zhu, P., Ma, X., & Huang, Z. (2017). Fusion of infrared-visible images using improved multi-scale top-hat transform and suitable fusion rules. *Infrared Physics & Technology*, *81*, 282–295. https://doi.org/10.1016/j.infrared.2017.01.013

Anexos

Participación en congresos

Bajac Figueredo, Y. C., Bazan, J. P., Mello-Román, J. C., Vázquez Noguera, J. L., & Legal-Ayala, H. (2025). Infrared and visible image fusion using the Top Hat transform. *Proceeding Series of the Brazilian Society of Computational and Applied Mathematics*, *11*(1), Artículo 010158. https://proceedings.sbmac.emnuvens.com.br/sbmac/article/view/4917

Trabajo presentado en el XLIII Congresso Nacional de Matemática Aplicada e Computacional, Porto de Galinhas, Pernambuco, Brasil, del 16 al 20 de septiembre de 2024.

Contrastes de Wilcoxon completos

La Tabla A.1 reúne los sesenta y seis contrastes de Wilcoxon de las seis métricas, calculados sobre los veinte pares. En cada métrica hay once: seis comparan la propuesta con los demás métodos y cinco comparan el Top-Hat clásico con cada método multiescala. La corrección de Holm se aplicó dentro de cada métrica, sobre esos once contrastes. La columna Escenas repite la decisión con las trece escenas como bloques, en lugar de los veinte pares. Los contrastes de la propuesta se resumen en la Tabla 4.4, de la Sección 4.5.

Tabla A.1: Contrastes de Wilcoxon pareados de las seis métricas, con corrección de Holm

			p	**Decisión**	
Método	**Frente a**	**Diferencia**	**corregido**	**Pares**	**Escenas**
Entropía (EN)					
Propuesta	Top-Hat clásico	0.0636	< 0.001	gana	gana
Propuesta	Pirámide de Laplace	0.1455	0.024	gana	gana
Propuesta	Pirámide de razón	0.1758	< 0.001	gana	gana
Propuesta	DWT (Haar)	0.3040	< 0.001	gana	gana
Propuesta	DTCWT	0.2978	< 0.001	gana	gana
Propuesta	DWT (db4)	0.3410	< 0.001	gana	gana
Top-Hat clásico	Pirámide de Laplace	0.0820	0.189	empata	empata
Top-Hat clásico	Pirámide de razón	0.1122	0.002	gana	gana
Top-Hat clásico	DWT (Haar)	0.2404	< 0.001	gana	gana
Top-Hat clásico	DTCWT	0.2342	< 0.001	gana	gana
Top-Hat clásico	DWT (db4)	0.2775	< 0.001	gana	gana
Desviación estándar (SD)					
Propuesta	Top-Hat clásico	0.0087	< 0.001	gana	gana
Propuesta	Pirámide de Laplace	-0.0111	0.231	empata	empata
Propuesta	Pirámide de razón	0.0168	< 0.001	gana	gana
Propuesta	DWT (Haar)	0.0274	< 0.001	gana	gana
Propuesta	DTCWT	0.0267	< 0.001	gana	gana
Propuesta	DWT (db4)	0.0308	< 0.001	gana	gana
Top-Hat clásico	Pirámide de Laplace	-0.0198	0.053	empata	empata
Top-Hat clásico	Pirámide de razón	0.0081	0.005	gana	empata
Top-Hat clásico	DWT (Haar)	0.0187	< 0.001	gana	gana
Top-Hat clásico	DTCWT	0.0180	< 0.001	gana	gana
Top-Hat clásico	DWT (db4)	0.0220	< 0.001	gana	gana

Tabla A.1: Contrastes de Wilcoxon pareados de las seis métricas, con corrección de Holm (continuación)

			p	Decisión	
Método	**Frente a**	**Diferencia**	**corregido**	**Pares**	**Escenas**
Gradiente medio (MG)					
Propuesta	Top-Hat clásico	−0.0123	< 0.001	pierde	pierde
Propuesta	Pirámide de Laplace	0.0103	< 0.001	gana	gana
Propuesta	Pirámide de razón	0.0080	< 0.001	gana	gana
Propuesta	DWT (Haar)	0.0080	< 0.001	gana	gana
Propuesta	DTCWT	0.0100	< 0.001	gana	gana
Propuesta	DWT (db4)	0.0095	< 0.001	gana	gana
Top-Hat clásico	Pirámide de Laplace	0.0226	< 0.001	gana	gana
Top-Hat clásico	Pirámide de razón	0.0203	< 0.001	gana	gana
Top-Hat clásico	DWT (Haar)	0.0203	< 0.001	gana	gana
Top-Hat clásico	DTCWT	0.0223	< 0.001	gana	gana
Top-Hat clásico	DWT (db4)	0.0218	< 0.001	gana	gana
Información mutua (MI)					
Propuesta	Top-Hat clásico	0.1089	< 0.001	gana	gana
Propuesta	Pirámide de Laplace	−0.6723	< 0.001	pierde	pierde
Propuesta	Pirámide de razón	−0.0508	0.133	empata	empata
Propuesta	DWT (Haar)	−0.1224	< 0.001	pierde	pierde
Propuesta	DTCWT	−0.1268	< 0.001	pierde	pierde
Propuesta	DWT (db4)	−0.1342	< 0.001	pierde	pierde
Top-Hat clásico	Pirámide de Laplace	−0.7812	< 0.001	pierde	pierde
Top-Hat clásico	Pirámide de razón	−0.1597	< 0.001	pierde	pierde
Top-Hat clásico	DWT (Haar)	−0.2313	< 0.001	pierde	pierde
Top-Hat clásico	DTCWT	−0.2357	< 0.001	pierde	pierde
Top-Hat clásico	DWT (db4)	−0.2431	< 0.001	pierde	pierde
Similitud estructural (SSIM)					
Propuesta	Top-Hat clásico	0.0944	< 0.001	gana	gana
Propuesta	Pirámide de Laplace	−0.0474	< 0.001	pierde	pierde
Propuesta	Pirámide de razón	−0.0467	< 0.001	pierde	pierde
Propuesta	DWT (Haar)	−0.0429	< 0.001	pierde	pierde
Propuesta	DTCWT	−0.0665	< 0.001	pierde	pierde
Propuesta	DWT (db4)	−0.0578	< 0.001	pierde	pierde
Top-Hat clásico	Pirámide de Laplace	−0.1418	< 0.001	pierde	pierde
Top-Hat clásico	Pirámide de razón	−0.1411	< 0.001	pierde	pierde
Top-Hat clásico	DWT (Haar)	−0.1373	< 0.001	pierde	pierde
Top-Hat clásico	DTCWT	−0.1608	< 0.001	pierde	pierde
Top-Hat clásico	DWT (db4)	−0.1522	< 0.001	pierde	pierde

Tabla A.1: Contrastes de Wilcoxon pareados de las seis métricas, con corrección de Holm (continuación)

			p	Decisión	
Método	**Frente a**	**Diferencia**	**corregido**	**Pares**	**Escenas**
Relación señal-ruido de pico (PSNR)					
Propuesta	Top-Hat clásico	−0.0319	0.674	empata	empata
Propuesta	Pirámide de Laplace	1.9009	< 0.001	gana	gana
Propuesta	Pirámide de razón	−0.5279	< 0.001	pierde	pierde
Propuesta	DWT (Haar)	−0.7477	< 0.001	pierde	pierde
Propuesta	DTCWT	−0.7564	< 0.001	pierde	pierde
Propuesta	DWT (db4)	−0.8114	< 0.001	pierde	pierde
Top-Hat clásico	Pirámide de Laplace	1.9328	< 0.001	gana	gana
Top-Hat clásico	Pirámide de razón	−0.4960	0.001	pierde	pierde
Top-Hat clásico	DWT (Haar)	−0.7158	< 0.001	pierde	pierde
Top-Hat clásico	DTCWT	−0.7245	< 0.001	pierde	pierde
Top-Hat clásico	DWT (db4)	−0.7795	< 0.001	pierde	pierde

Nota. Elaboración propia. Cada métrica tiene once contrastes: la propuesta frente al Top-Hat clásico y cada uno de esos dos operadores frente a los cinco métodos multiescala. Diferencia: media del método de la columna Método menos media del método de la columna Frente a, sobre los veinte pares, en las unidades de cada métrica (decibelios en PSNR). p corregido: valor p con la corrección de Holm sobre los once contrastes de la métrica. Decisión: si el contraste es significativo al 5 % después de la corrección, el método de la columna Método gana o pierde según el signo de la diferencia; si no lo es, empata. En las seis métricas, un valor mayor es mejor. Pares: decisión con los veinte pares del corpus como bloques, como en la Tabla 4.4. Escenas: decisión con las trece escenas como bloques. Las métricas de cada escena se promedian sobre sus tomas, y se aplican la misma corrección y la misma regla. El Top-Hat clásico se usó con radio 5 y peso 1. Propuesta: el algoritmo de fusión presentado en este trabajo.