



**Universidad
Comunera**

FACULTAD DE CIENCIAS Y TECNOLOGÍA

MAESTRÍA EN CIENCIAS DE DATOS

FUSIÓN DE IMÁGENES INFRARROJAS Y VISIBLES MEDIANTE MORFOLOGÍA MATEMÁTICA

Una propuesta de Top-Hat/Bottom-Hat de una sola escala con elementos estructurantes de disco y lineales, optimizada por PSO

Autores:

Lic. Juan Pablo Bazán

Ing. Yan Bajac

Tesis presentada a la Universidad Comunera, Facultad de Ciencias y Tecnología, Maestría en Ciencias de Datos, como requisito parcial para la obtención del título de Magíster en Ciencias de Datos.

Asunción – Paraguay

SEPTIEMBRE 2026

FUSIÓN DE IMÁGENES INFRARROJAS Y VISIBLES MEDIANTE MORFOLOGÍA MATEMÁTICA

Una propuesta de Top-Hat/Bottom-Hat de una sola escala con elementos estructurantes de disco y lineales, optimizada por PSO

Autores:

Lic. Juan Pablo Bazán

Ing. Yan Bajac

Orientador:

D.Sc. Julio César Mello

Tesis presentada a la Universidad Comunera, Facultad de Ciencias y Tecnología, Maestría en Ciencias de Datos, como requisito parcial para la obtención del título de Magíster en Ciencias de Datos.

Asunción – Paraguay

SEPTIEMBRE 2026

PÁGINA DE APROBACIÓN

Esta tesis, titulada «Fusión de Imágenes Infrarrojas y Visibles mediante Morfología Matemática», fue presentada por Lic. Juan Pablo Bazán e Ing. Yan Bajac como requisito parcial para la obtención del título de Magíster en Ciencias de Datos, y aprobada por el siguiente tribunal examinador.

Director de Tesis – D.Sc. Julio César Mello

Examinador 1

Examinador 2

Asunción, Paraguay

2026

DEDICATORIA

A nuestras familias, por sostener cada noche larga y cada decisión difícil que llevó este trabajo a término.

A nuestros profesores y compañeros de la Maestría en Ciencias de Datos, por las discusiones que afilaron las ideas.

Y a la comunidad de software libre, sin la cual una tesis empírica como esta sería materialmente imposible.

AGRADECIMIENTOS

A la Universidad Comunera (UCOM) y a la Facultad de Ciencias y Tecnología, por brindar el marco académico de la Maestría en Ciencias de Datos.

A nuestro director de tesis, D.Sc. Julio César Mello, por el rigor metodológico, la paciencia y la orientación constante a lo largo del desarrollo de este trabajo.

A los autores y mantenedores del dataset TNO Image Fusion Dataset, cuyo material puesto a disposición pública hizo posible la evaluación experimental.

A los desarrolladores de las bibliotecas científicas de Python (NumPy, OpenCV, scikit-image, SciPy, PyWavelets, Matplotlib, Pandas), pilares de toda la implementación.

A nuestros colegas y compañeros de cohorte, por las revisiones cruzadas y los comentarios que mejoraron tanto el código como la redacción.

RESUMEN

La fusión de imágenes visible (VIS) e infrarroja (IR) busca una sola imagen que conserve el detalle del visible y la firma térmica del infrarrojo, y se aplica en vigilancia, conducción nocturna y búsqueda y rescate. Este trabajo propone la PROPUESTA NOVEDOSA, un método de fusión basado en la transformada Top-Hat que, sobre una única escala, promedia las respuestas de cuatro elementos estructurantes lineales (0° , 45° , 90° , 135°) y las suma a la respuesta de un disco para obtener transformadas Top-Hat y Bottom-Hat óptimas; la reconstrucción sigue el esquema aditivo–sustractivo de Bala et al., y el radio r del banco de elementos estructurantes y el peso de contraste m se ajustan automáticamente por Optimización por Enjambre de Partículas (PSO), cuya configuración se selecciona mediante un barrido sistemático de 25 combinaciones de partículas e iteraciones ($2-10 \times 10-50$), replicando el diseño experimental de Ortega y Espinoza (2025). Se lo compara con seis métodos: cinco representativos del estado del arte —pirámide de Laplace (LP), Ratio of low-pass Pyramid (RP), wavelet discreta (DWT), Dual-Tree Complex Wavelet (DTCWT) y curvelet (CVT)— y la metodología clásica de la transformada Top-Hat, sobre el TNO Image Fusion Dataset, con nueve métricas sin referencia bajo pruebas no paramétricas (Friedman y Wilcoxon con corrección de Holm). En su configuración óptima ($r=25$ por diseño; $m=0,30$, el piso del rango de búsqueda) la propuesta lidera la entropía y la eficiencia de fusión del estudio ($EN=6,9855$; $FE=1,1047$) y se ubica segunda en contraste, gradiente medio y frecuencia espacial ($SD=0,1439$; $MG=0,0355$; $SF=17,4425$), con ventaja estadísticamente significativa sobre los cinco métodos del estado del arte en EN , FE , MG y SF ; cede, en cambio, en las métricas de fidelidad a las fuentes ($SSIM=0,6584$; $PSNR=16,8409$) y en información mutua, lideradas por los métodos multiescala. En el ranking agregado de las nueve métricas —promedio de los rangos obtenidos dentro de cada par de imágenes— ocupa el primer lugar (3,39), por delante de la pirámide de Laplace (3,91) y del Top-Hat clásico (3,94). Como evaluación orientada a tarea, el reentrenamiento de un detector (YOLOv8n) sobre el conjunto etiquetado LLVIP —repetido con 5 semillas de entrenamiento por entrada, 45 corridas en total— muestra que toda fusión supera con claridad al visible solo (0,795 de media frente a la banda 0,904–0,952), en las 5 semillas y muy por encima del ruido de inicialización, que es de 0,0128 de desvío. El infrarrojo solo es la modalidad más fuerte (0,961) y supera a 6 de las siete fusiones, aunque de la séptima, la pirámide de laplace, no se distingue. La propuesta alcanza 0,9283 y queda 3.^a de siete, indistinguible de 4 de sus seis rivales, lo que evidencia que el realce que premian las métricas de actividad no se traslada a la detección. En un experimento complementario sobre M3FD, con dos clases de visibilidad opuesta (personas/IR y

luces/VIS) y un único detector entrenado con ambas modalidades, la Ratio Pyramid es la única entrada cuyo promedio del par complementario (0,622) supera a las dos modalidades por separado (0,618 del visible y 0,563 del infrarrojo), mientras la propuesta alcanza 0,564, al nivel del infrarrojo solo. Se concluye que la propuesta destaca en actividad, detalle y contenido informativo —superando de forma significativa al estado del arte en cuatro de las nueve métricas y a la metodología clásica en seis—, aporta un operador morfológico de una sola escala interpretable y de bajo costo optimizado con una metodología publicada (Ortega y Espinoza, 2025), y, en la evaluación orientada a tarea, documenta un hallazgo relevante: la configuración que maximiza las métricas de actividad no es la que maximiza el desempeño de detección, de modo que ambos criterios deben reportarse por separado.

Palabras clave: fusión de imágenes, morfología matemática, top-hat, infrarrojo, visible, PSO, métricas sin referencia.

SUMMARY

Visible (VIS) and infrared (IR) image fusion is key for computer perception under adverse conditions (surveillance, night driving, search and rescue). This work proposes the NOVEL PROPOSAL, a fusion method based on the Top-Hat transform that, on a single scale, averages the responses of four linear structuring elements (0° , 45° , 90° , 135°) and adds them to the disk response to obtain optimal Top-Hat and Bottom-Hat transforms; reconstruction follows the additive–subtractive scheme of Bala et al., and the structuring-element radius r and the contrast weight m are tuned automatically by Particle Swarm Optimization (PSO), whose configuration is selected through a systematic sweep of 25 particle/iteration combinations ($2\text{--}10 \times 10\text{--}50$), replicating the experimental design of Ortega and Espinoza (2025). It is compared against six methods: five representative of the state of the art —Laplacian pyramid (LP), Ratio of low-pass Pyramid (RP), Discrete Wavelet Transform (DWT), Dual-Tree Complex Wavelet Transform (DTCWT) and Curvelet (CVT)— plus the classical Top-Hat fusion methodology, on the TNO Image Fusion Dataset, using nine no-reference metrics under non-parametric testing (Friedman, Wilcoxon with Holm correction). At its optimal configuration ($r=25$ by design; $m=0.30$, the floor of the search range) the proposal leads the study in entropy and fusion efficiency ($EN=6.9855$; $FE=1.1047$) and ranks second in contrast, mean gradient and spatial frequency ($SD=0.1439$; $MG=0.0355$; $SF=17.4425$), with a statistically significant advantage over the five state-of-the-art methods in EN, FE, MG and SF; it yields, in turn, on the fidelity metrics ($SSIM=0.6584$; $PSNR=16.8409$) and on mutual information, led by the multiscale methods. In the aggregate ranking over the nine metrics —the average of the ranks obtained within each image pair— it ranks first (3.39), ahead of the Laplacian pyramid (3.91) and the classical Top-Hat (3.94). As a task-oriented evaluation, retraining a detector (YOLOv8n) on the labeled LLVIP dataset —repeated with 5 training seeds per input, 45 runs in total— shows that every fusion clearly outperforms the visible modality alone ($mAP@0.5$ from 0.81 to 0.91–0.95), although the infrared alone remains the strongest modality (0.971) and the proposal falls at the lower end of the fusion band (0.906), evidencing that the enhancement rewarded by activity metrics does not transfer to detection. In a complementary experiment on M3FD, with two classes of opposite visibility (people/IR and lamps/VIS) and a single detector trained on both modalities, the Ratio Pyramid is the only input whose complementary-pair average (0.622) exceeds both single modalities (0.618 for the visible and 0.563 for the infrared), while the proposal reaches 0.564, on par with the infrared alone. We conclude that the proposal stands out in activity, detail and information content —significantly outperforming the state of the art in

four of the nine metrics and the classical methodology in six—, contributes an interpretable single-scale morphological operator optimized with a published methodology (Ortega and Espinoza, 2025), and, in the task-oriented evaluation, documents a relevant finding: the configuration that maximizes activity metrics is not the one that maximizes detection performance, so both criteria must be reported separately.

Keywords: image fusion, mathematical morphology, top-hat, infrared, visible, PSO, no-reference metrics.

CONTENIDO

LISTA DE SIGLAS.....	13
LISTA DE FIGURAS.....	14
LISTA DE TABLAS.....	14
INTRODUCCIÓN.....	19
1. PROBLEMA DE INVESTIGACIÓN.....	21
1.1 Descripción del problema.....	21
1.2 Justificación e importancia.....	21
1.3 Objetivos.....	22
1.3.1 General.....	22
1.3.2 Específicos.....	22
1.4 Formulación del problema.....	23
1.4.1 Problema general.....	23
1.4.2 Problemas específicos.....	23
1.5 Hipótesis.....	24
1.6 Limitaciones de la investigación.....	24
1.7 Alcance.....	25
2. MARCO TEÓRICO.....	26
2.1 Estado del arte.....	26
2.2 Fundamentación teórica.....	27
2.2.1 Fusión de imágenes multimodal.....	27
2.2.2 Morfología matemática.....	28
2.2.3 Transformada Top-Hat.....	28
2.2.4 Metodología clásica de fusión Top-Hat.....	29
2.2.5 Propuesta Novedosa: método de fusión Top-Hat con elementos estructurantes circulares y lineales optimizado por PSO.....	30
2.2.6 Métodos comparativos del benchmark.....	36
2.2.7 Métricas de evaluación.....	37
3. MARCO CONCEPTUAL.....	41
3.1 Imagen visible (VIS).....	41
3.2 Imagen infrarroja (IR).....	41
3.3 Elemento estructurante (SE).....	41
3.4 White Top-Hat (WTH).....	41

3.5 Black Top-Hat (BTH).....	41
3.6 Descomposición multiescala.....	41
3.7 Regla de fusión por actividad local.....	42
3.8 Métrica sin referencia.....	42
3.9 Prueba de Friedman.....	42
3.10 Prueba de Wilcoxon.....	42
3.11 Elemento estructurante lineal.....	42
3.12 Combinación de respuestas por suma.....	42
3.13 Fusión Top-Hat clásica.....	42
3.14 Peso de ajuste de contraste (m).....	43
3.15 Optimización por Enjambre de Partículas (PSO).....	43
3.16 Función de aptitud.....	43
4. MARCO METODOLÓGICO.....	44
4.1 Enfoque.....	44
4.2 Tipo.....	44
4.3 Diseño.....	44
4.4 Operacionalización de las variables.....	44
4.5 Dataset y preprocesamiento.....	45
4.6 Implementación.....	46
4.7 Análisis estadístico.....	46
5. ANÁLISIS E INTERPRETACIÓN DE RESULTADOS.....	47
5.1 Caracterización del dataset.....	47
5.2 Análisis cualitativo: comparación visual.....	47
5.3 Resultados cuantitativos: promedio por método.....	48
5.4 Análisis estadístico no paramétrico.....	50
5.4.1 Prueba de Friedman global.....	50
5.4.2 Comparaciones pareadas Wilcoxon.....	50
5.4.3 Ranking promedio.....	50
5.5 Evaluación orientada a tarea: detección con YOLO (LLVIP y M3FD).....	52
5.6 Propuesta Novedosa (método central).....	55
5.7 Discusión integrada.....	58
5.8 Auditoría del protocolo de evaluación.....	59
5.8.1 Sensibilidad del orden de mérito y redundancia interna (H2, H4).....	60

5.8.2 Control negativo con degradaciones conocidas (H3).....	60
5.8.3 Aporte del banco con hiperparámetros igualados (H7).....	61
5.8.4 Robustez frente al ajuste simétrico de los comparativos.....	62
5.8.5 Alcance de la optimización y contraste con la tarea (H5, H6).....	63
6. CONCLUSIONES Y RECOMENDACIONES.....	64
6.1 Conclusiones.....	64
6.2 Recomendaciones.....	67
7. REFERENCIAS BIBLIOGRÁFICAS.....	69
8. APÉNDICE.....	73
A. Repositorio del código.....	73
B. Configuraciones del barrido PSO.....	73
C. Tablas estadísticas extendidas.....	73
D. Pseudocódigo de la fusión Top-Hat clásica.....	74
E. Refinamiento metodológico de la regla de fusión.....	74
F. Hardware y tiempos de ejecución.....	75

LISTA DE SIGLAS

Sigla	Significado
VIS	Espectro visible
IR	Infrarrojo
SE	Elemento estructurante (Structuring Element)
WTH	White Top-Hat (Top-Hat blanco)
BTH	Black Top-Hat (Top-Hat negro)
MM	Morfología matemática
EN	Entropía de Shannon
SD	Desviación estándar
FE	Factor / eficiencia de fusión
MG	Gradiente medio
MI	Información mutua (Mutual Information)
TNO	TNO Image Fusion Dataset (Países Bajos)
PCA	Análisis de componentes principales
DWT	Transformada wavelet discreta
DTCWT	Transformada wavelet compleja de árbol dual
CNN	Red neuronal convolucional
GAN	Red generativa antagónica
SF	Frecuencia espacial (Spatial Frequency)
Qabf	Métrica de preservación de bordes (Xydeas y Petrović, 2000)
Nabf	Artefactos añadidos por la fusión (menor es mejor)
SSIM	Índice de similitud estructural (Structural Similarity)
SCD	Suma de correlaciones de las diferencias
VIF	Fidelidad de información visual (Visual Information Fidelity)

Sigla	Significado
YOLO	You Only Look Once (detector de objetos)
FPS	Cuadros por segundo (Frames Per Second)
mAP	Precisión media promedio (mean Average Precision)
PSO	Optimización por Enjambre de Partículas (Particle Swarm Optimization)
PSNR	Relación señal-ruido de pico (Peak Signal-to-Noise Ratio)

LISTA DE FIGURAS

Figura 1. Operaciones morfológicas (erosión, dilatación, apertura y cierre) y transformada Top-Hat sobre un perfil de intensidad.

Figura 2. Esquema conceptual de la fusión Top-Hat clásica: disco único, combinación por máximo entre fuentes y reconstrucción sin ponderación.

Figura 3. Banco de cinco elementos estructurantes (un disco y cuatro líneas) empleados por el operador en la escala de radio r .

Figura 4. Flujograma de la Propuesta Novedosa (proceso paso a paso).

Figura 5. Optimización por enjambre de partículas (PSO) del vector de hiperparámetros (r , m).

Figura 6. Comparación cualitativa de los métodos de fusión sobre tres pares representativos del dataset.

Figura 7. Diagramas de caja de seis métricas representativas (SSIM, SF, EN, SD, MI_{ir}, PSNR) por método ($n = 20$ pares VIS/IR).

Figura 8. Ranking global por método (promedio de rangos sobre las nueve métricas, con la dirección de cada una corregida).

Figura 9. Detecciones del modelo único VIS+IR en dos escenas de M3FD: la fusión recupera personas y luces en una sola imagen, allí donde el infrarrojo apenas detecta luces.

Figura 10. Propuesta Novedosa ($r = 25$ por diseño; $m = 0,30$, piso del rango) frente a la metodología clásica Top-Hat y al estado del arte.

Figura 11. Aptitud F_o en función del peso de contraste con el radio fijo en $r = 25$ (izq.) y mejor aptitud alcanzada por cada combinación de partículas e iteraciones del barrido (der.), sobre tres escenas representativas. La aptitud decrece de forma monótona a partir de valores pequeños de m , de modo que el óptimo se sitúa en el piso del rango publicado.

LISTA DE TABLAS

Tabla 1. Notación empleada en el marco teórico.

Tabla 2. Configuración de la Propuesta Novedosa y del PSO.

Tabla 3. Métodos comparativos del benchmark.

Tabla 4. Promedios de las seis métricas clásicas por método ($n = 20$).

Tabla 5. Promedios de frecuencia espacial (SF), similitud estructural (SSIM) y PSNR por método ($n = 20$ pares).

Tabla 6. Prueba de Friedman por métrica (χ^2 , p-valor; $\alpha = 0,05$).

Tabla 7. Ranking promedio por método y métrica (1 = mejor).

Tabla 8. Detección de peatones en LLVIP — mAP por modalidad (YOLOv8n; subconjunto 2000 train / 500 val, 40 épocas).

Tabla 9. Clases complementarias en M3FD: AP@0,5 por clase y mAP global con un detector único VIS+IR.

Tabla 10. Propuesta Novedosa frente a la metodología clásica Top-Hat y al estado del arte — medias sobre 20 pares (n = 20).

Tabla 11. Barrido de configuraciones del PSO con el rango publicado $m \in [0,30; 2,00]$: mejor aptitud F_0 por combinación de partículas (n) e iteraciones (T). Las 25 configuraciones convergen al mismo peso óptimo ($m^* = 0,30$); las diferencias reflejan el radio hallado ($r = 1$ donde la aptitud llega a 1,7350 y $r = 25$ donde llega a 1,7057).

Tabla 12. Control negativo: rango medio de los siete métodos y de siete entradas degradadas, bajo tres composiciones del criterio (menor rango = mejor; $n = 20$ pares).

Tabla 13. Ablación del banco de elementos estructurantes con $(r, m) = (25; 0,30)$ fijos en los seis brazos (menor rango = mejor; $n = 20$ pares).

Tabla 14. Rango medio por escenario de ajuste: con los comparativos por defecto, con los comparativos ajustados, y con los comparativos ajustados sobre las diecisiete métricas (menor rango = mejor).

INTRODUCCIÓN

La percepción visual computacional moderna depende, en numerosas aplicaciones críticas, de la integración de información proveniente de sensores complementarios. Las cámaras del espectro visible (VIS) capturan la reflectancia de la luz solar, ofreciendo alta resolución textural y cromática, pero degradándose ante condiciones de iluminación adversas como noche cerrada, niebla densa o humo. Por su parte, las cámaras infrarrojas (IR), particularmente las del rango térmico de onda larga, registran la radiación emitida por los cuerpos según su temperatura, siendo robustas a la oscuridad y a la mayoría de los ocluidores atmosféricos, aunque con menor resolución espacial y escaso detalle de textura. La fusión de imágenes VIS+IR busca reunir estas fortalezas complementarias en una sola representación que sea, simultáneamente, rica en detalles, discriminativa térmicamente y útil para tareas posteriores de detección, clasificación o decisión.

Las aplicaciones que se benefician de esta integración son numerosas y de alto impacto: vigilancia perimetral, búsqueda y rescate, conducción de vehículos autónomos en condiciones de baja visibilidad, sistemas de visión nocturna para defensa, inspección no destructiva en líneas de producción y diagnóstico médico complementario. En todas ellas, la calidad de la imagen fusionada condiciona directamente la calidad del análisis subsiguiente.

Existen, en términos generales, tres familias de métodos de fusión: las de píxel, ampliamente estudiadas y operadas sobre intensidades; las de característica, que extraen rasgos abstractos antes de combinar; y las de decisión, que fusionan salidas de clasificadores. Dentro del nivel píxel, las técnicas multiescala (pirámides, wavelets, curvelets) y las morfológicas han sido pilares clásicos por su interpretabilidad y bajo costo computacional, en contraposición a los enfoques recientes basados en redes neuronales profundas, que ofrecen alto rendimiento pero demandan grandes volúmenes de datos pareados y operan como cajas negras.

Esta tesis se sitúa explícitamente en el espacio de los métodos clásicos interpretables. Propone como núcleo la Propuesta Novedosa, un método de fusión basado en la transformada Top-Hat que, sobre una única escala definida por el radio r , combina un banco de cinco elementos estructurantes —un disco y cuatro segmentos lineales a 0° , 45° , 90° y 135° , con las respuestas lineales promediadas y sumadas a la del disco para obtener transformadas óptimas— y reconstruye la imagen fusionada mediante el esquema aditivo–sustractivo de Bala et al. (2024) ponderado por el peso de contraste m ; sus hiperparámetros (radio r y peso m) se ajustan

automáticamente por Optimización por Enjambre de Partículas (PSO). Como línea base morfológica se emplea la metodología clásica de fusión Top-Hat —disco único, máximo entre fuentes y reconstrucción sin ponderación— y, como referencia externa, cinco métodos representativos del estado del arte (LP, RP, DWT, DTCWT y CVT). La hipótesis subyacente es que la sensibilidad direccional del banco de elementos estructurantes y la búsqueda automática de hiperparámetros permiten ajustar la fusión a las características del par VIS/IR sin renunciar a la transparencia algorítmica; complementariamente, se evalúa el impacto de la fusión en una tarea posterior de detección de objetos sobre un conjunto etiquetado (LLVIP).

El documento sigue este orden. En el capítulo de Problema de Investigación se delimita la pregunta científica y los objetivos. El Marco Teórico revisa el estado del arte y los fundamentos de morfología matemática, descomposición multiescala y métricas de evaluación. El Marco Conceptual define los términos operativos. El Marco Metodológico precisa el diseño experimental. El capítulo de Análisis e Interpretación de Resultados expone el benchmark de la propuesta frente a la metodología clásica Top-Hat y a los métodos de referencia del estado del arte, sustentado en pruebas estadísticas no paramétricas. Finalmente, las Conclusiones y Recomendaciones sintetizan los hallazgos y delinear trabajos futuros.

1. PROBLEMA DE INVESTIGACIÓN

1.1 Descripción del problema

Pese a más de tres décadas de investigación en fusión de imágenes multimodal, no existe un método universalmente óptimo: cada familia algorítmica presenta compromisos distintos entre preservación de detalle, contraste, transferencia de información y costo computacional. Los métodos basados en promedio, los más simples, sufren pérdida sistemática de detalle y reducción de contraste. Las pirámides de Laplace y los esquemas wavelet/curvelet ofrecen mejor manejo multiescala, pero pueden introducir artefactos de orla en bordes de alto contraste y son sensibles a desalineaciones residuales. Los métodos profundos, por su parte, requieren grandes corpora pareados y carecen de interpretabilidad.

La morfología matemática ofrece un marco intermedio: opera directamente sobre la geometría de las estructuras locales mediante elementos estructurantes (SE) parametrizables, lo cual la hace natural para preservar bordes y formas. La transformada Top-Hat, en particular, aísla con precisión los componentes de alta frecuencia que la apertura morfológica suprime. Sin embargo, la literatura existente sobre fusión morfológica suele restringirse a una única escala o a un único tipo de SE, sin un estudio sistemático que articule simultáneamente la geometría del SE, el número de niveles de descomposición y el radio base. Esta tesis aborda una parte de ese vacío —la geometría del banco de elementos estructurantes sobre una sola escala— mediante un benchmark contra la metodología clásica y cinco configuraciones de referencia, y audita además la validez discriminativa del protocolo con que se lo evalúa.

1.2 Justificación e importancia

La justificación de este trabajo descansa sobre tres ejes. Primero, la relevancia aplicada: en contextos de vigilancia, seguridad pública y operaciones militares, los algoritmos de fusión deben ejecutarse bajo restricciones de tiempo real, sobre hardware limitado y con garantías de auditoría. La interpretabilidad y el bajo costo computacional de los métodos morfológicos los tornan especialmente valiosos en estos escenarios. Segundo, la relevancia metodológica: aportar evidencia empírica sistemática sobre el efecto de cada hiperparámetro —la geometría del banco de SE, el radio r y el peso m — ayuda a desmitificar decisiones de diseño que históricamente se han tomado por convención. Tercero, la relevancia académica regional: existen pocas tesis en el ámbito paraguayo que aborden de manera rigurosa la evaluación cuantitativa con pruebas no paramétricas en problemas de fusión multimodal, y este trabajo busca aportar a esa base.

1.3 Objetivos

1.3.1 General

Diseñar, implementar y caracterizar un operador de fusión de imágenes visibles e infrarrojas basado en la transformada Top-Hat de una sola escala con un banco de cinco elementos estructurantes —un disco y cuatro segmentos lineales orientados—, determinando en qué dirección desplaza el punto de operación de la fusión frente a la metodología clásica y a cinco configuraciones de referencia del estado del arte sobre el TNO Image Fusion Dataset; y auditar, con ese mismo desarrollo como caso de estudio, la validez discriminativa del protocolo de evaluación empleado —una batería de métricas sin referencia interpretadas como «mayor es mejor», la elección de hiperparámetros guiada por esas mismas métricas y el contraste con una tarea posterior de detección de objetos—, estableciendo en qué medida el orden de mérito que ese protocolo produce autoriza conclusiones sobre la calidad de una imagen fusionada y sobre su utilidad en una tarea posterior.

1.3.2 Específicos

1. Formular e implementar el operador tal como efectivamente se evalúa: sobre una sola escala de radio r se calculan las transformadas Top-Hat y Bottom-Hat con un disco B_r y con cuatro elementos estructurantes lineales orientados a 0° , 45° , 90° y 135° de longitud $2r+1$; las cuatro respuestas lineales se promedian y ese promedio se suma a la respuesta del disco; la comparación por máximo por píxel se aplica únicamente entre las respuestas obtenidas del visible y del infrarrojo, no entre las ramas del banco; y la reconstrucción es aditivo-sustractiva ponderada sobre $I_{\text{base}} = (VIS + IR)/2$. Aislar el aporte del banco mediante una ablación con hiperparámetros fijos.

2. Delimitar el alcance real de la optimización por enjambre de partículas: establecer cuál de los hiperparámetros determina efectivamente la aptitud declarada y cuál constituye una decisión de diseño, caracterizar la forma de la función de aptitud sobre el espacio de búsqueda, y justificar el peso adoptado con criterios independientes de esa aptitud.

3. Comparar el operador con la metodología clásica y con cinco configuraciones de referencia del estado del arte sobre nueve métricas sin referencia, con pruebas no paramétricas (Friedman y Wilcoxon con corrección de Holm), organizando los resultados en bloques de actividad espacial y de fidelidad a las fuentes en lugar de un único orden agregado, y verificando la robustez del resultado frente a un ajuste simétrico de los hiperparámetros de los comparativos.

4. Evaluar si la batería de métricas empleada discrimina calidad de fusión, mediante tres pruebas: un control negativo con degradaciones conocidas, un análisis de redundancia interna entre métricas, y la sensibilidad del orden de mérito a la composición del conjunto.

5. Medir el efecto de la fusión sobre la detección de objetos con dos experimentos independientes, y contrastar el orden de mérito de las métricas de imagen con el orden de utilidad en la tarea, operacionalizando el objetivo mediante un conteo por escena de recuperación de clases complementarias y no solo mediante el mAP promedio.

1.4 Formulación del problema

1.4.1 Problema general

¿En qué dirección desplaza el punto de operación de la fusión VIS/IR un operador Top-Hat de una escala con banco de cinco elementos estructurantes, y en qué medida el protocolo de evaluación con el que se lo juzga —métricas sin referencia de tipo «mayor es mejor», hiperparámetros elegidos sobre esas mismas métricas y validación en tarea posterior— permite sostener conclusiones sobre la calidad de la imagen fusionada y sobre su utilidad práctica?

1.4.2 Problemas específicos

- ¿Cómo debe formularse el operador —banco de disco y líneas, combinación de las respuestas por promedio y suma, y regla de reconstrucción— para adaptar el realce morfológico multidireccional al esquema de fusión VIS/IR, y cuánto aporta el banco por encima del disco único con hiperparámetros igualados?
- ¿Cuál de los dos hiperparámetros (r , m) determina efectivamente la aptitud declarada, qué forma tiene esa aptitud sobre el espacio de búsqueda, y con qué criterios independientes de ella puede justificarse el peso adoptado?
- ¿Existen diferencias estadísticamente significativas entre la Propuesta Novedosa, la metodología clásica de fusión Top-Hat y los métodos del estado del arte (LP, RP, DWT, DTCWT y CVT), en qué métricas, y se sostiene el resultado cuando se concede a los comparativos el mismo paso de ajuste de hiperparámetros?
- ¿Discrimina la batería de nueve métricas sin referencia entre detalle útil y ruido inyectado, contiene componentes redundantes entre sí, y depende el orden de mérito de la composición del conjunto de métricas?

- ¿La fusión —y en particular el método propuesto— mejora el desempeño de un detector de objetos respecto de las modalidades visible e infrarroja por separado, y predice el orden de mérito de las métricas de imagen el orden de utilidad en la tarea?

1.5 Hipótesis

De la formulación anterior se derivan siete hipótesis de trabajo, todas contrastables con experimentos versionados en el repositorio. H1: el operador con banco de cinco elementos estructurantes no mejora la fusión de manera uniforme, sino que desplaza su punto de operación hacia el realce de la actividad espacial y en contra de la fidelidad a las fuentes. H2: el orden de mérito de los métodos no es una propiedad del operador sino del criterio con que se lo evalúa, de modo que cambia al cambiar la composición del conjunto de métricas sin que cambie ninguna imagen fusionada. H3: la batería de nueve métricas de tipo «mayor es mejor» es insuficiente como criterio de calidad, porque sus métricas de actividad crecen monótonamente con la varianza inyectada y no distinguen detalle útil de ruido. H4: la batería contiene al menos una métrica que no aporta información independiente de las demás. H5: la optimización no determina la configuración adoptada, dado que ambos hiperparámetros resultan de decisiones apoyadas en parte del mismo criterio con el que después se evalúa. H6: el orden de mérito de las métricas de imagen no predice el orden de utilidad en una tarea posterior de detección, y ninguna fusión supera por un margen distinguible a la mejor modalidad individual. H7: con el radio y el peso igualados, el banco de cinco elementos produce un perfil de métricas distinto del que produce el disco único. H1 se contrasta en las secciones 5.4 y 5.6; H6 en la sección 5.5; y H2, H3, H4, H5 y H7 en la sección 5.8, dedicada a la auditoría del protocolo de evaluación.

1.6 Limitaciones de la investigación

Esta investigación se circunscribe a las siguientes limitaciones, que deben tenerse presentes al interpretar los resultados. Primero, el corpus experimental son veinte pares del TNO Image Fusion Dataset, registrados principalmente en escenas militares y urbanas; las conclusiones pueden no transferirse íntegramente a otros dominios (médico, aéreo de muy alta resolución). Segundo, la evaluación se realiza con métricas sin referencia, dado que no existe una imagen fusionada óptima conocida; esto introduce inevitablemente una dependencia de las métricas elegidas. Tercero, la evaluación orientada a tarea con verdad de campo se realizó con un único detector (YOLOv8n), repetido con 5 semillas de entrenamiento por entrada en LLVIP —lo que permite separar la diferencia entre métodos del ruido de inicialización— pero con una sola en M3FD sobre un subconjunto de LLVIP (2.000 imágenes de entrenamiento y 500 de

validación, 40 épocas); extenderla a otros detectores y al conjunto completo queda como trabajo futuro. Cuarto, la regla de fusión por capa es la de selección por actividad local máxima, sin explorar reglas adaptativas. Quinto, no se evaluaron métodos basados en aprendizaje profundo, dado que tales comparaciones requieren protocolos de entrenamiento cuyos sesgos exceden el alcance de esta tesis. Sexto, los veinte pares corresponden a trece escenas distintas —cuatro de ellas con varias vistas o instantes del mismo sujeto—, de modo que los bloques de las pruebas no son plenamente independientes y el tamaño de muestra efectivo es menor que veinte. Séptimo, la eficiencia de fusión (FE) es la entropía reescalada por una constante por escena, por lo que la batería de nueve métricas contiene ocho cantidades independientes; excluyendo FE la propuesta sigue primera (3,631 frente a 3,994 de la pirámide de Laplace), aunque el resto del orden se reacomoda. Octavo, el comparador identificado como curvelet está implementado como una aproximación mediante wavelet 2D (db4) y no como una transformada curvelet propiamente dicha, de modo que los valores de CVT deben leerse referidos a esa aproximación. Noveno, la función de aptitud del trabajo de referencia y la batería de evaluación discrepan en el radio: F_0 favorece $r = 1$ y las nueve métricas $r = 25$, por lo que la configuración adoptada se apoya en el criterio de evaluación y no en la optimización, que sí determina el peso m . Décimo, en el conteo por escena sobre M3FD —232 escenas con ambas clases complementarias— la propuesta recupera las dos clases en el 50,0 % de los casos frente al 53,0 % del visible solo (8 escenas ganadas y 15 perdidas; McNemar exacto $p = 0,2100$) y resuelve 2 de las 90 escenas críticas, de manera que no mejora la tarea de clases complementarias.

1.7 Alcance

El alcance de la tesis abarca: la implementación íntegra y reproducible del método propuesto y de los baselines en Python (NumPy, OpenCV, scikit-image, SciPy, PyWavelets); la organización modular del código en un repositorio versionado; el preprocesamiento y emparejado del dataset; la ejecución del benchmark exhaustivo y de la comparación contra baselines; el análisis estadístico no paramétrico; la generación de tablas y figuras científicas; y la redacción del presente informe. Quedan fuera del alcance la generación de un nuevo dataset, la integración con sistemas en tiempo real y la comparación con métodos de aprendizaje profundo entrenados desde cero.

2. MARCO TEÓRICO

2.1 Estado del arte

La fusión de imágenes multimodal, particularmente VIS+IR, cuenta con una literatura abundante. Li et al. (2017) presentan una revisión integral de los métodos a nivel pixel, agrupándolos en cuatro grandes familias: dominios espaciales (promedio, máximo, PCA), dominios transformados multiescala (pirámides, wavelets, curvelets), métodos basados en representaciones dispersas y métodos híbridos. Ma et al. (2019) actualizan el panorama con énfasis en la creciente adopción de redes neuronales profundas, distinguiendo arquitecturas de auto-encoder, redes generativas antagónicas (GAN) y enfoques de fusión guiada por tareas. En paralelo, Zhang y Demiris (2023) documentan la consolidación de benchmarks estandarizados (TNO, RoadScene, M3FD) y el establecimiento progresivo de métricas sin referencia como estándar de facto.

Específicamente en fusión morfológica, Mukhopadhyay y Chanda (2000) introducen una de las primeras descomposiciones multiescala basadas en operadores Top-Hat para realce e interpretación de imágenes médicas. En el ámbito local, Bajac Figueredo et al. (2024) presentan un análisis visual y numérico de la fusión VIS/IR con la transformada Top-Hat sobre el mismo conjunto TNO, antecedente directo de esta tesis. Bai (2013) extiende la idea a fusión VIS+IR, mostrando que la transformada Top-Hat puede capturar simultáneamente detalles brillantes y oscuros con bajo costo computacional. Antes, Bai et al. (2012) habían usado los rasgos multiescala del Top-Hat para realce de imagen, y por otra vía Wang et al. (2014) combinan la fusión VIS+IR con representaciones dispersas no negativas. Pero ni esos trabajos ni los posteriores sistematizan el efecto cruzado del tipo de elemento estructurante, el número de niveles y el radio base sobre múltiples métricas.

Los métodos profundos, por su parte, han avanzado rápidamente. Ma et al. (2019, FusionGAN) y Tang et al. (2022, SeAFusion) ofrecen arquitecturas de fusión guiadas por percepción semántica. Sin embargo, su dependencia de datos pareados y la dificultad de auditarlos los hacen problemáticos en aplicaciones donde la trazabilidad es obligatoria. En este contexto, los métodos clásicos siguen siendo no solo relevantes sino estratégicamente valiosos como baselines reproducibles.

Una visión panorámica reciente la ofrece la revisión de Singh et al. (2023), que sistematiza la fusión de imágenes en tres grandes familias —dominio espacial, descomposición

multiescala (MSD: pirámides, wavelets y análisis geométrico multiescala) y aprendizaje automático— y en tres niveles de abstracción (píxel, característica y decisión). En esa taxonomía, la propuesta de esta tesis se ubica en la familia MSD, rama de pirámides morfológicas, y opera a nivel de píxel (PLIF). La revisión documenta además el uso de metaheurísticas para ajustar parámetros de fusión —enjambre de partículas (PSO), colonia de abejas, búsqueda cuco—, con precedentes específicos de PSO aplicado a la fusión (p. ej. Tao et al., 2010, DTCWT+PSO; Malviya y Saxena, 2014, WT+PSO), lo que respalda la estrategia de optimización adoptada aquí.

2.2 Fundamentación teórica

Tabla 1. Notación empleada en el marco teórico.

Símbolo	Significado
f	Imagen de entrada en escala de gris $[0,1]$ (VIS o IR)
b	Elemento estructurante (disco o segmento lineal)
$\varepsilon(f,b), \delta(f,b)$	Erosión y dilatación de f con b
$\gamma(f,b), \phi(f,b)$	Apertura y cierre de f con b
WTH, BTH	White Top-Hat y Black Top-Hat
r	Radio del elemento estructurante (disco y líneas)
m	Peso de ajuste de contraste
WTH_i, BTH_i	Top-Hat de líneas (promedio) y de disco (radio r)
$I_{\text{opt}}^{\text{top}}, I_{\text{opt}}^{\text{bot}}$	Transformadas óptimas: suma de ramas (líneas + disco) por fuente
I_{base}	Imagen base, $(I_{\text{VIS}} + I_{\text{IR}})/2$
F	Imagen fusionada
x, v	Posición y velocidad de una partícula (PSO)
$p_{\text{best}}, g_{\text{best}}$	Mejor posición individual y global del enjambre
w, c_1, c_2	Inercia y coeficientes cognitivo y social (PSO)

2.2.1 Fusión de imágenes multimodal

La fusión de imágenes a nivel píxel se formaliza como un operador $F: \mathbb{R}^{\{H \times W\}} \times \mathbb{R}^{\{H \times W\}} \rightarrow \mathbb{R}^{\{H \times W\}}$ que recibe dos imágenes alineadas espacialmente, I_{VIS} e I_{IR} , y produce una imagen fusionada $F(I_{\text{VIS}}, I_{\text{IR}})$ que maximice algún criterio de calidad. Tres

etapas son comunes a todas las pipelines: preprocesamiento (registro, normalización), descomposición y fusión por capa, reconstrucción. La descomposición transforma cada imagen en una representación multi-escala que expone los detalles a distintas resoluciones; la fusión por capa aplica una regla de selección (típicamente basada en actividad local máxima); la reconstrucción invierte la descomposición.

2.2.2 Morfología matemática

La morfología matemática es un cuerpo algebraico para el análisis de estructuras geométricas en imágenes, basado en la teoría de retículas completas (Serra, 1982; Soille, 2003; Gonzalez y Woods, 2018). Sus operaciones fundamentales en imágenes de niveles de gris son la erosión $\varepsilon(f, b)$ y la dilatación $\delta(f, b)$, definidas como mínimo y máximo locales bajo el patrón impuesto por el elemento estructurante b . A partir de ellas se derivan apertura $\gamma(f, b) = \delta(\varepsilon(f, b), b)$ y cierre $\phi(f, b) = \varepsilon(\delta(f, b), b)$, que eliminan respectivamente picos brillantes y valles oscuros menores que el SE. La elección del SE (geometría y radio) es la decisión de diseño central: define qué orientaciones, simetrías y escalas de detalle se preservan o suprimen.

Las dos operaciones fundamentales son la dilatación (δ) y la erosión (ε). En escala de grises, para un elemento estructurante b , se definen como el máximo y el mínimo local, respectivamente (Román et al., 2020):

$$\delta(f, b)(u, v) = \max_{(j, k) \in b} f(u - j, v - k), \varepsilon(f, b)(u, v) = \min_{(j, k) \in b} f(u + j, v + k) \quad (1)$$

$$\gamma(f, b) = \delta(\varepsilon(f, b), b), \phi(f, b) = \varepsilon(\delta(f, b), b) \quad (2)$$

2.2.3 Transformada Top-Hat

La transformada White Top-Hat se define como la diferencia entre la imagen original y su apertura: $WTH(f, b) = f - \gamma(f, b)$. Aísla las estructuras brillantes más pequeñas que el SE. Su dual, la Black Top-Hat, $BTH(f, b) = \phi(f, b) - f$, aísla los valles oscuros. Una propiedad clave es que el WTH es siempre no negativo y se anula en regiones donde la imagen es localmente plana a la escala del SE, lo que la convierte en un detector natural de detalles. La elección del tipo de SE (disco para isotropía, línea para direcciones específicas, cuadrado o cruz para sensibilidades distintas) determina qué tipo de detalle se enfatiza.

$$WTH(f, b) = f - \gamma(f, b), BTH(f, b) = \phi(f, b) - f \quad (3)$$

Para realzar estructuras direccionales, La combinación de elementos estructurantes circulares y lineales aplicados en distintas direcciones tiene un antecedente directo en el realce de

imágenes mamográficas de Flores et al. (s. f.), del mismo grupo de investigación. Bala et al. (2024) promedian las respuestas Top-Hat obtenidas con elementos estructurantes lineales en n orientaciones angulares:

$$WTH^m = \frac{1}{n} \sum_{\theta} (f - \gamma(f, b_{\theta})), BTH^m = \frac{1}{n} \sum_{\theta} (\varphi(f, b_{\theta}) - f) \quad (4)$$

y reconstruyen la imagen realzada sumando los reales claros y restando los oscuros, combinando las respuestas lineales (multidireccionales) y la del disco:

$$I_{en} = I + (I_{top} - I_{bot}), I_{top} = WTH^m + WTH^d, I_{bot} = BTH^m + BTH^d \quad (5)$$

Operaciones morfológicas básicas y transformada Top-Hat




Figura 1. Operaciones morfológicas (erosión, dilatación, apertura y cierre) y transformada Top-Hat sobre un perfil de intensidad.

2.2.4 Metodología clásica de fusión Top-Hat

La metodología clásica de fusión por transformada Top-Hat constituye la referencia morfológica directa de este trabajo. Dada cada imagen de entrada f (visible e infrarroja), se aplican la White Top-Hat y la Black Top-Hat con un único elemento estructurante de disco B_r (aquí, radio $r = 5$), extrayendo respectivamente el detalle brillante y el oscuro más finos que el disco. Los detalles de ambas fuentes se combinan conservando, píxel a píxel, la respuesta máxima —el detalle más saliente de cualquiera de las dos modalidades— y la imagen fusionada se reconstruye sobre la base $I_{base} = (I_{VIS} + I_{IR})/2$ mediante el esquema aditivo–sustractivo sin ponderación: $F = I_{base} + \max(WTH_{VIS}, WTH_{IR}) - \max(BTH_{VIS}, BTH_{IR})$. Se trata de un método interpretable y de muy bajo costo computacional, pero con dos limitaciones que motivan la propuesta: el disco único carece de sensibilidad direccional —trata por igual

estructuras alargadas e isotropas— y la reconstrucción sin peso de contraste inyecta todo el detalle extraído, lo que en la práctica dispara los artefactos y degrada la similitud estructural (SSIM), como se cuantifica en el capítulo de resultados.

La imagen fusionada final se reconstruye según la regla:

$$F = I_{base} + \max(WTH_{VIS}, WTH_{IR}) - \max(BTH_{VIS}, BTH_{IR}) \quad (6)$$

El operador clásico admite dos modos: emplear únicamente la White Top-Hat (realce del detalle brillante) o el esquema completo White+Black (realce de ambos extremos). En este trabajo se emplea el esquema completo con disco de radio $r = 5$, la configuración estándar reportada en la literatura, sin peso de contraste ($m = 1$) y sin optimización de hiperparámetros: esas dos carencias son precisamente las que la Propuesta Novedosa aborda.




Figura 2. Esquema conceptual de la fusión Top-Hat clásica: disco único, combinación por máximo entre fuentes y reconstrucción sin ponderación.

2.2.5 Propuesta Novedosa: método de fusión Top-Hat con elementos estructurantes circulares y lineales optimizado por PSO

La propuesta central de esta tesis —la Propuesta Novedosa— es un método de fusión morfológica que, sobre una única escala definida por el radio r , combina un banco de elementos estructurantes circulares y lineales. Integra tres ideas: el promediado multiangular de las respuestas lineales y la reconstrucción aditivo-sustractiva de Bala et al. (2024); el uso simultáneo de un disco y cuatro segmentos lineales para atender por igual a estructuras isotropas y orientadas; y la optimización por enjambre de partículas de Ortega y Espinoza (2025), que fija

automáticamente los hiperparámetros. Frente a la metodología clásica de la transformada Top-Hat —un único disco y reconstrucción sin ponderación—, la propuesta añade sensibilidad direccional y sustituye el ajuste manual por una búsqueda guiada por la calidad de fusión.

Elementos estructurantes circulares y lineales. El operador se calcula sobre una sola escala, fijada por el radio r . En cada fuente se emplean cinco elementos estructurantes: un disco B_r de radio r , isótropo, y cuatro segmentos lineales $L_{r,\theta}$ de longitud $2r+1$ orientados a 0° , 45° , 90° y 135° . Las cuatro respuestas lineales se promedian —siguiendo el esquema multiangular de Bala et al. (ecuaciones 2 y 4)— tanto para el White Top-Hat como para el Black Top-Hat. La respuesta del disco se calcula por separado con el mismo radio. El promedio multiangular atenúa el ruido y realza estructuras alargadas en cualquier orientación, mientras que el disco preserva las estructuras isótropas.

Para cada fuente f y radio r , la ecuación (7) define la respuesta lineal promediada —White y Black Top-Hat sobre los cuatro segmentos $L_{r,\theta}$ — y la ecuación (8) la respuesta del elemento circular B_r del mismo radio:

$$WTH_{lin} = \frac{1}{4} \sum_{\theta} [f - \gamma(f, L_{r,\theta})], BTH_{lin} = \frac{1}{4} \sum_{\theta} [\varphi(f, L_{r,\theta}) - f] \quad (7)$$

$$WTH_{disco} = f - \gamma(f, B_r), BTH_{disco} = \varphi(f, B_r) - f \quad (8)$$

Banco de 5 elementos estructurantes por fuente (radio r) — Propuesta Novedosa




Figura 3. Banco de cinco elementos estructurantes (un disco y cuatro líneas): las respuestas lineales promediadas se suman a la del disco.

Transformadas óptimas por suma. Siguiendo el esquema de Bala et al., la respuesta lineal promediada y la del disco se suman: el realce acumula la evidencia de ambas ramas, de modo que las estructuras orientadas e isótropas contribuyen conjuntamente al detalle extraído. Así se obtienen, para cada fuente, la transformada óptima superior I_{opt}^{top} y la inferior I_{opt}^{bot} , según la ecuación (9). Las transformadas de la imagen visible y de la infrarroja se combinan luego entre fuentes tomando de nuevo el máximo por píxel (ecuación 10), conservando el detalle más saliente de cada modalidad.

$$I_{opt}^{top} = WTH_{lin} + WTH_{disco}, I_{opt}^{bot} = BTH_{lin} + BTH_{disco} \quad (9)$$

$$I_{opt}^{top,F} = \max(I_{opt}^{top,IR}, I_{opt}^{top,VIS}), I_{opt}^{bot,F} = \max(I_{opt}^{bot,IR}, I_{opt}^{bot,VIS}) \quad (10)$$

Reconstrucción y regla de fusión. Sobre la imagen base $I_{base} = (I_{VIS} + I_{IR})/2$ —que retiene la iluminación del visible y la temperatura global del infrarrojo— se reconstruye la imagen fusionada según la ecuación (11): se añaden las estructuras brillantes (término con I_{opt}^{top}) y se restan las oscuras (término con I_{opt}^{bot}), moduladas por el peso de contraste m . Valores altos de m maximizan el contraste a costa de artefactos; valores bajos preservan la fidelidad. Esta regla adapta la reconstrucción aditivo-sustractiva de Bala et al. (ecuación 9 de ese trabajo, aquí ecuación 5) al esquema de fusión ponderada VIS/IR de Ortega y Espinoza.

$$F = I_{base} + m I_{opt}^{top,F} - m I_{opt}^{bot,F}, I_{base} = 1/2 (I_{VIS} + I_{IR}) \quad (11)$$




Figura 4. Flujograma de la Propuesta Novedosa: proceso paso a paso (banco de cinco elementos estructurantes por fuente, promediado de las respuestas lineales, suma con la respuesta del disco para obtener las transformadas óptimas, combinación entre fuentes por máximo y reconstrucción ponderada con el peso m).

Optimización por Enjambre de Partículas (PSO). El método tiene dos hiperparámetros —el radio r del banco de elementos estructurantes y el peso de contraste m — cuyo ajuste manual

es costoso y subjetivo. Para fijarlos se emplea la Optimización por Enjambre de Partículas (Kennedy y Eberhart, 1995), metaheurística poblacional inspirada en el comportamiento colectivo de las bandadas. Cada partícula es una solución candidata $x = (r, m)$ que recuerda su mejor posición propia (pbest) y la mejor del enjambre (gbest); en cada iteración su velocidad y posición se actualizan según la ecuación (13), donde w es la inercia y c_1, c_2 los coeficientes cognitivo y social. La configuración del enjambre se seleccionó mediante un barrido sistemático de 25 combinaciones —número de partículas de 2 a 10 en incrementos de 2 y número de iteraciones de 10 a 50 en incrementos de 10, replicando el diseño experimental de Ortega y Espinoza (2025)—, con $c_1 = c_2 = 1,5$ e inercia decreciente de 0,9 a 0,4.

El PSO optimiza el vector de hiperparámetros del método dentro del espacio de búsqueda acotado:

$$x = (r, m), r \in \{1, \dots, 25\}, m \in [0.30, 2.00] \quad (12)$$

$$v_{t+1} = w v_t + c_1 r_1 (p_{\text{best}} - x_t) + c_2 r_2 (g_{\text{best}} - x_t), x_{t+1} = x_t + v_{t+1} \quad (13)$$




Figura 5. Optimización por enjambre de partículas (PSO) del vector de hiperparámetros (r, m) . El esquema es ilustrativo: las posiciones de las partículas y las curvas de nivel no son datos de una corrida. El gbest que rotula corresponde al óptimo de la aptitud paralela F_{apt} ($r = 25$; $m = 0,0703$); el peso que esta tesis adopta es $m = 0,30$, el piso del rango de búsqueda heredado, por las razones que se desarrollan en la sección 5.2.

Función de aptitud (Ortega y Espinoza). Los hiperparámetros (r, m) se ajustan maximizando la función objetivo del trabajo de referencia, $F_o = \text{SSIMavg} + \text{En} + \text{PSNRn}$ (ecuación 14): la similitud estructural promedio con las fuentes (SSIMavg; Wang et al., 2004), la entropía normalizada ($\text{En} = E/8$) y la relación señal-ruido de pico normalizada ($\text{PSNRn} = \text{PSNR}/100$), sin pesos arbitrarios, equilibrando preservación estructural, contenido informativo y

reducción de la distorsión (Ortega y Espinoza, 2025). Conviene declarar una precisión de implementación: la ecuación (29) de ese trabajo define el PSNR como $10 \cdot \log_{10}((M \times N)^2 / \text{MSE})$, con el número de píxeles al cuadrado en el numerador, donde la definición estándar lleva la intensidad máxima al cuadrado. Para una imagen de 620×450 eso desplaza el resultado en 60,8 dB, y explica que los valores publicados en sus anexos vayan de 94 a 99 dB, cifras incompatibles con una fusión porque implicarían que la imagen fusionada es casi idéntica a las dos fuentes a la vez, mientras su propio SSIMavg mediano es 0,4481. Esta tesis emplea la definición estándar, $10 \cdot \log_{10}(\text{MAX}^2/\text{MSE})$, de modo que sus valores de Fo no son directamente comparables con los publicados allí: la diferencia está enteramente en ese término. El barrido de 25 configuraciones (partículas 2–10 $\times$ iteraciones 10–50, Cuadro 1 de dicho trabajo) se ejecuta sobre tres escenas representativas con el espacio de búsqueda del trabajo de referencia, $r \in [1, 25]$ y $m \in [0,30; 2,00]$. El peso óptimo converge al límite inferior del rango, $m^* = 0,30$, en las 25 configuraciones: los dos términos de fidelidad de Fo (SSIMavg y PSNRn) decrecen al aumentar el realce y dominan sobre la entropía normalizada. Para el radio, Fo favorece $r = 1$, el extremo inferior del rango. Con ese valor los cinco elementos estructurantes siguen activos, pero se reducen a una vecindad de 3×3 píxeles: el operador extrae apenas estructura a la escala de los objetivos y la fusión se acerca a la imagen base, que es justamente lo que maximizan los dos términos de fidelidad de Fo. Las nueve métricas de evaluación de esta tesis, todas de tipo «mayor es mejor», favorecen en cambio $r = 25$. Se adopta por tanto la configuración $r = 25$, $m = 0,30$: el peso que produce la metodología de referencia y el radio que maximiza el criterio de evaluación, con el banco de cinco elementos operando a una escala comparable al tamaño de los objetivos térmicos.

Tabla 2. Configuración de la Propuesta Novedosa y del PSO.

Parámetro	Valor
Elementos estructurantes	5: un disco (radio r) + cuatro líneas (0° , 45° , 90° , 135° ; longitud $2r+1$)
Combinación de las respuestas	Promedio de las 4 líneas (ec. 7) y suma con la respuesta del disco (ec. 9)
Escala (radio)	Única, de radio r (ajustado por PSO)
Regla de fusión entre fuentes	Máximo por píxel (ec. 10)
Función de aptitud	$Fo = \text{SSIMavg} + En + \text{PSNRn}$
Partículas del enjambre	2–10 (barrido, paso 2)
Iteraciones	10–50 (barrido, paso 10)

Inercia w	0,9 → 0,4 (decreciente)
Coeficientes c_1, c_2	1,5 ; 1,5
Rangos de búsqueda	$r \in [1, 25]$; $m \in [0,30; 2,00]$ (rango publicado)
Óptimo hallado	$r = 25$; $m = 0,30$ (m^* del barrido en las 25 configuraciones; $F_o = 1,7057$)

$$F_o = SSIM_{avg} + E_n + PSNR_n \quad (14)$$

2.2.6 Métodos comparativos del benchmark

Para situar el método propuesto en el panorama de la disciplina se utilizan seis métodos comparativos: cinco representativos del estado del arte en fusión multiescala y la metodología clásica de la transformada Top-Hat:

Tabla 3. Métodos comparativos del benchmark.

Método	Descripción	Referencia
Ratio of low-pass Pyramid (RP)	Razones entre niveles gaussianos consecutivos; se conserva en cada píxel la razón que más se aparta de 1 y se reconstruye multiplicativamente	Toet (1989)
Pirámide de Laplace (LP)	Descomposición Gaussiana–Laplaciana de 4 niveles; fusión por máxima actividad local y reconstrucción inversa	Burt y Adelson (1983)
Curvelet (CVT, vía wavelet 2D)	Subbandas direccionales (Daubechies db4, 3 niveles); máxima magnitud en detalle, promedio en aproximación	Candès et al. (2006)
Wavelet discreta (DWT)	Subbandas de detalle y aproximación (Haar, 3 niveles); detalle por máxima magnitud, aproximación por promedio	—
Dual-Tree Complex Wavelet (DTCWT)	Seis subbandas direccionales complejas por nivel (4 niveles), invariante al desplazamiento; fusión por máxima magnitud	Kingsbury (2001)
Top-Hat clásico	Fusión morfológica básica: disco único B_s , detalle entre fuentes por máximo y reconstrucción sin ponderación ($m = 1$)	—

2.2.7 Métricas de evaluación

Dado que en la fusión VIS/IR no existe una imagen de referencia (ground truth) —como subraya la revisión de Singh et al. (2023)—, la evaluación se realiza con nueve métricas que computan el puntaje a partir de la imagen fusionada y de sus fuentes: la entropía (EN), la desviación estándar (SD), la eficiencia de fusión (FE), el gradiente medio (MG), la información mutua con el visible y el infrarrojo (MI_vis, MI_ir), la frecuencia espacial (SF), la similitud estructural promedio con las fuentes (SSIM) y la relación señal-ruido de pico calculada frente a ambas fuentes (PSNR). Este subconjunto —alineado con la metodología de referencia (Ortega y Espinoza, 2025)— cubre la actividad y el contenido informativo, la fidelidad estructural y la distorsión. La literatura de fusión define además una familia de índices de calidad orientados a la preservación de bordes y a la reducción de artefactos (Qabf, Nabf, SCD, VIF, FMI y los índices de Piella y Heijmans, 2003), cuyas definiciones se recogen en la sección siguiente por completitud; la evaluación empírica de esta tesis reporta el subconjunto de nueve métricas descrito.

A continuación se formalizan las principales métricas sin referencia empleadas en la evaluación. Las cinco de actividad e información —entropía, desviación estándar, frecuencia espacial, gradiente medio e información mutua— son descriptores estándar sin una fuente única atribuible: se emplean en la forma que recogen las revisiones de Ma et al. (2019) y Singh et al. (2023) y el trabajo de referencia (Ortega y Espinoza, 2025). Las primeras cuantifican propiedades intrínsecas de la imagen fusionada (información, contraste, nitidez) y las restantes miden cuánta información de las fuentes se transfiere y con qué fidelidad estructural:

Entropía (EN). Cantidad de información de la imagen fusionada; mayor es mejor (p_1 = histograma normalizado, L niveles de gris).

$$EN = - \sum_{l=0}^{L-1} p_l \log_2 p_l \quad (15)$$

Eficiencia de fusión (FE). Cociente entre la entropía de la imagen fusionada y el promedio de las entropías de las dos fuentes, $FE = EN(F) / [(EN(A) + EN(B)) / 2]$; mayor es mejor. Se reporta porque la emplea el trabajo de referencia (Ortega y Espinoza, 2025), pero conviene advertir su dependencia de EN: para un par VIS/IR dado el denominador no depende del método de fusión, de modo que FE es la entropía reescalada por una constante por escena. En consecuencia produce los mismos rangos intra-bloque que EN, el mismo

estadístico de Friedman y los mismos signos en Wilcoxon, y no debe interpretarse como una novena fuente de evidencia independiente.

Desviación estándar (SD). Contraste global respecto de la media μ ; mayor SD indica mayor dispersión de intensidades.

$$SD = \sqrt{\frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N (F(i, j) - \mu)^2} \quad (16)$$

Frecuencia espacial (SF). Nitidez y nivel de detalle, combinando las frecuencias por filas (RF) y por columnas (CF). Es la única de las nueve que se evalúa sobre la escala de niveles de gris 0–255 y no sobre el rango normalizado $[0, 1]$ en el que se cargan las imágenes: así se reporta habitualmente en la literatura de fusión, y así la calcula el evaluador de este trabajo. Aplicar la ecuación (17) directamente a una imagen en $[0, 1]$ devuelve el mismo valor dividido por 255.

$$SF = \sqrt{RF^2 + CF^2}, RF = \sqrt{\frac{1}{MN} \sum_i \sum_j (F(i, j) - F(i, j-1))^2} \quad (17)$$

Gradiente medio (MG). Definición y agudeza de los bordes a partir de los gradientes $\Delta x, \Delta y$.

$$\bar{G} = \frac{1}{MN} \sum_i \sum_j \sqrt{\Delta x^2 + \Delta y^2} \quad (18)$$

Información mutua (MI). Información de las fuentes A y B transferida a la fusión F; suma de las MI por par.

$$MI = MI_{AF} + MI_{BF}, MI_{XF} = \sum_x \sum_f p(x, f) \log_2 \frac{p(x, f)}{p(x)p(f)} \quad (19)$$

$Q^{AB/F}$ (Xydeas y Petrović, 2000). Preservación de la información de bordes, ponderada por la intensidad de borde de cada fuente (w^A, w^B).

$$Q^{AB/F} = \frac{\sum_{i,j} (Q_{i,j}^{AF} w_{i,j}^A + Q_{i,j}^{BF} w_{i,j}^B)}{\sum_{i,j} (w_{i,j}^A + w_{i,j}^B)} \quad (20)$$

$N^{AB/F}$ (Nabf; mismo marco que $Q^{AB/F}$, Xydeas y Petrović, 2000). Tasa de ruido y artefactos introducidos por la fusión (AM = mapa de artefactos); menor es mejor.

$$N^{AB/F} = \frac{\sum_{i,j} A M_{i,j} (w_{i,j}^A + w_{i,j}^B)}{\sum_{i,j} (w_{i,j}^A + w_{i,j}^B)} \quad (21)$$

SSIM (Wang et al., 2004). Similitud estructural entre la fusión y las fuentes (luminancia, contraste y estructura; C_1, C_2 constantes de estabilidad).

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (22)$$

SCD (Aslantas y Bendes, 2015). Suma de correlaciones de las diferencias D_1, D_2 entre la fusión y cada fuente.

$$SCD = r(D_1, I_1) + r(D_2, I_2), D_1 = F - I_2, D_2 = F - I_1 \quad (23)$$

VIF (Sheikh y Bovik, 2006). Fidelidad visual de la información, basada en un modelo de información en el dominio de subbandas.

$$VIF = \frac{\sum_j I(C^j; F^j | s^j)}{\sum_j I(C^j; E^j | s^j)} \quad (24)$$

FMI. Información mutua de los mapas de características (gradiente), normalizada por las entropías (Haghighat et al., 2011).

$$FMI = \frac{MI_{AF}}{H_A + H_F} + \frac{MI_{BF}}{H_B + H_F} \quad (25)$$

Q_0 / Piella. Calidad estructural universal; las variantes Q_W y Q_E la ponderan por la saliencia y los bordes locales (Piella y Heijmans, 2003).

	$Q_0 = \frac{4\sigma_{xy}\mu_x\mu_y}{(\sigma_x^2 + \sigma_y^2)(\mu_x^2 + \mu_y^2)}$			(26)
Métrica	Definición operativa	Interpretación	Dirección	
EN	Entropía de Shannon del histograma de la imagen fusionada	Riqueza informacional global	↑	
SD	Desviación estándar de los niveles de gris	Contraste global	↑	
FE	$EN(F) \div \text{media}(EN(VIS), EN(IR))$	Ganancia informacional sobre las fuentes	↑	

MG	Promedio de la magnitud del gradiente	Nitidez y preservación de bordes	↑
MI_vis	Información mutua entre F y la imagen VIS	Fidelidad a la fuente visible	↑
MI_ir	Información mutua entre F y la imagen IR	Fidelidad a la fuente infrarroja	↑
SF	Frecuencia espacial: actividad espacial global (filas y columnas)	Detalle y textura global	↑
Qabf	Información de borde de las fuentes transferida a la fusión (Xydeas y Petrović, 2000)	Preservación de bordes	↑
Nabf	Bordes/ruido añadidos por la fusión inexistentes en las fuentes	Artefactos (menor es mejor)	↓
SSIM	Similitud estructural promedio respecto a VIS e IR	Fidelidad estructural	↑
SCD	Suma de correlaciones de las diferencias (Aslantas-Bendes)	Información de fuente retenida	↑
VIF	Fidelidad de información visual promedio (Sheikh-Bovik)	Fidelidad perceptual	↑

3. MARCO CONCEPTUAL

3.1 Imagen visible (VIS)

Imagen capturada en el rango espectral de 400 a 700 nanómetros, correspondiente a la sensibilidad del ojo humano. Resolución típica alta y dependencia fuerte de la iluminación ambiente.

3.2 Imagen infrarroja (IR)

Imagen capturada en el rango térmico (típicamente 8 a 14 micras, IR de onda larga) que registra la radiación emitida por los cuerpos en función de su temperatura. Resolución espacial típicamente inferior a la VIS pero independiente de la iluminación visible.

3.3 Elemento estructurante (SE)

Conjunto plano y compacto que define la geometría del vecindario sobre el que actúan las operaciones morfológicas. En esta tesis el banco consta de cinco elementos: un disco elíptico B_r y cuatro segmentos lineales de longitud $2r+1$ orientados a 0° , 45° , 90° y 135° . El radio se busca en $r \in [1, 25]$ y se adopta $r = 25$. No se emplean elementos cuadrados ni de cruz.

3.4 White Top-Hat (WTH)

Operador morfológico definido como la diferencia entre la imagen original y su apertura. Aísla las estructuras brillantes locales menores que el SE.

3.5 Black Top-Hat (BTH)

Operador morfológico dual del WTH, definido como la diferencia entre el cierre de la imagen y la imagen original: $BTH(f, b) = \phi(f, b) - f$. Aísla las estructuras oscuras locales (valles) menores que el SE. Incorporarlo permite capturar simultáneamente el detalle brillante (vía WTH) y el detalle oscuro (vía BTH) de cada escala.

3.6 Descomposición multiescala

Representación de una imagen como suma de capas que aíslan estructuras a distintas escalas. Es el principio de los cinco métodos comparativos —pirámides y wavelets—, no del operador propuesto: este trabaja sobre una sola escala de radio r y no construye ninguna descomposición iterativa con radio creciente. Prescindir de la cascada multiescala es precisamente la decisión de diseño que la tesis pone a prueba.

3.7 Regla de fusión por actividad local

Mecanismo de selección capa-a-capla que escoge el aporte de la fuente cuya actividad local (magnitud del coeficiente suavizada con un kernel gaussiano) es mayor en cada posición.

3.8 Métrica sin referencia

Indicador cuantitativo de calidad calculado únicamente a partir de la imagen fusionada o de su relación con las fuentes, sin requerir una imagen objetivo conocida.

3.9 Prueba de Friedman

Prueba estadística no paramétrica para muestras relacionadas con tres o más tratamientos. Se utiliza para detectar diferencias globales entre métodos cuando los datos no cumplen normalidad.

3.10 Prueba de Wilcoxon

Prueba estadística no paramétrica de rangos signados para comparaciones pareadas, utilizada en esta tesis para confrontar cada método morfológico contra cada comparativo y ambos entre sí.

3.11 Elemento estructurante lineal

Segmento recto de longitud $2r+1$ orientado a un ángulo determinado (0° , 45° , 90° o 135°), usado como elemento estructurante para resaltar estructuras alargadas en esa dirección. A diferencia del disco, que es isótropo, el SE lineal es direccional; el método óptimo combina un disco y cuatro líneas por escala para cubrir todas las orientaciones.

3.12 Combinación de respuestas por suma

Regla que, dadas las transformadas Top-Hat obtenidas con distintos elementos estructurantes sobre la misma imagen, acumula sus respuestas sumándolas píxel a píxel (la lineal promediada y la del disco), de modo que las estructuras captadas por cada geometría contribuyen conjuntamente al detalle extraído.

3.13 Fusión Top-Hat clásica

Esquema de fusión morfológica de referencia: White y Black Top-Hat con un único disco sobre cada fuente, combinación del detalle entre fuentes por máximo píxel a píxel y reconstrucción aditivo–sustractiva sin ponderación sobre la imagen base.

3.14 Peso de ajuste de contraste (m)

Escalar que pondera cuánto se suman los realces brillantes (WTH) y se restan los oscuros (BTH) sobre la imagen base en la regla de fusión. Valores altos aumentan el contraste a riesgo de artefactos; valores bajos preservan la fidelidad a las fuentes. En el método óptimo se ajusta automáticamente por PSO.

3.15 Optimización por Enjambre de Partículas (PSO)

Metaheurística poblacional (Kennedy y Eberhart, 1995) que busca el óptimo de una función moviendo un conjunto de partículas según su mejor posición individual (pbest) y la mejor global del enjambre (gbest). En esta tesis ajusta automáticamente los hiperparámetros (r , m) dla Propuesta Novedosa.

3.16 Función de aptitud

Criterio escalar que el PSO maximiza para evaluar cada solución candidata. Aquí es la función objetivo del trabajo de referencia, $F_o = SSIM_{avg} + E_n + PSNR_n$: la suma sin pesos de la similitud estructural promedio con las fuentes, la entropía normalizada y el PSNR normalizado. No incluye ningún término explícito de preservación de bordes, de correlación ni de penalización de artefactos; dos de sus tres sumandos son de fidelidad a las fuentes, de modo que decrece al aumentar el realce.

4. MARCO METODOLÓGICO

4.1 Enfoque

La investigación adopta un enfoque cuantitativo. Todos los hallazgos se sostienen en mediciones numéricas sobre conjuntos de imágenes definidos a priori, calculadas mediante implementaciones reproducibles y contrastadas con pruebas estadísticas no paramétricas.

4.2 Tipo

La investigación es de tipo experimental, con carácter descriptivo y comparativo. Se manipulan sistemáticamente los hiperparámetros del método propuesto y se observan los efectos sobre las métricas de calidad. La comparación con baselines aporta el componente comparativo.

4.3 Diseño

El diseño es comparativo inter-método: siete métodos de fusión —la Propuesta Novedosa, la metodología clásica Top-Hat y cinco representativos del estado del arte (LP, RP, DWT, DTCWT y CVT)— se aplican a cada uno de los 20 pares del dataset, totalizando 140 fusiones evaluadas con las nueve métricas sin referencia, base del análisis estadístico inter-método. Los dos hiperparámetros de la propuesta (el radio r del banco de elementos estructurantes y el peso de contraste m) se ajustan mediante PSO, seleccionando la configuración del enjambre con un barrido de 25 combinaciones (partículas $2-10 \times$ iteraciones $10-50$, replicando el diseño de Ortega y Espinoza, 2025) sobre un subconjunto de tres escenas representativas; la configuración óptima resultante ($r = 25$, $m = 0,30$) se compara sobre los 20 pares con las nueve métricas, incluyendo contrastes pareados de Wilcoxon con corrección de Holm.

4.4 Operacionalización de las variables

Variable	Tipo	Definición operacional	Indicador / Valores
Método	Independiente	Algoritmo de fusión empleado	7 métodos del benchmark (§4.3)
Radio del SE (r)	Independiente	Radio del disco y longitud ($2r+1$) de las líneas del banco de SE	1–25 (ajustado por PSO)
Peso de contraste (m)	Independiente	Ponderación del realce en la regla de fusión	0,30–2,00 (ajustado por PSO)
Entropía (EN)	Dependiente	Entropía de Shannon de la fusionada	Bits, $\uparrow$ mejor

Variable	Tipo	Definición operacional	Indicador / Valores
Desv. estándar (SD)	Dependiente	σ de niveles de gris	Adimensional, $\uparrow$ mejor
Eficiencia FE	Dependiente	EN(F) sobre media de fuentes	Razón, $\uparrow$ mejor
Gradiente medio (MG)	Dependiente	$ \nabla F $ promedio	Adimensional, $\uparrow$ mejor
MI_vis	Dependiente	Información mutua $F \leftrightarrow VIS$	Bits, $\uparrow$ mejor
MI_ir	Dependiente	Información mutua $F \leftrightarrow IR$	Bits, $\uparrow$ mejor
Métricas estándar y del review	Dependiente	SF, SSIM, PSNR (§2.2.7)	Adimensional, $\uparrow$ mejor
Detección (mAP)	Dependiente	mAP@0,5 y mAP@0,5:0,95 de YOLOv8n reentrenado por modalidad (LLVIP)	Proporción [0, 1], $\uparrow$ mejor

4.5 Dataset y preprocesamiento

El corpus experimental son veinte pares VIS/IR del TNO Image Fusion Dataset, dataset público mantenido por TNO (Países Bajos) ampliamente utilizado como referencia en la literatura (Toet, 2017). Las imágenes se reorganizaron en dos directorios paralelos (data/raw/VIS y data/raw/IR) con nombres de archivo coincidentes para emparejado automático. Se cargan en escala de grises, se normalizan al rango [0, 1] como float32 y se asume registro espacial previo (los pares TNO ya están alineados). Conviene precisar la composición del corpus: los veinte pares corresponden a trece escenas distintas, porque cuatro de ellas aportan varias tomas del mismo sujeto —APC_1 y APC_3 con tres vistas cada una, el soldado tras la cortina de humo con tres instantes y el soldado en trinchera con dos—. Los veinte bloques de las pruebas no son, por tanto, plenamente independientes, y el tamaño de muestra efectivo es menor que veinte; este punto se retoma en las limitaciones.

Para la evaluación orientada a tarea con verdad de campo (sección 5.5.1) se emplea adicionalmente el dataset LLVIP (Jia et al., 2021), compuesto por 15.488 pares VIS/IR registrados espacialmente, con peatones anotados en escenas de baja iluminación. Se utilizó un subconjunto de 2.000 imágenes de entrenamiento y 500 de validación por modalidad (VIS, IR y

cada fusión), reentrenando el detector YOLOv8n durante 40 épocas con configuración idéntica en todas las modalidades; al estar los pares registrados, las anotaciones originales son válidas para toda versión fusionada, de modo que las diferencias de mAP resultan atribuibles al método de fusión.

4.6 Implementación

Toda la implementación se realizó en Python 3.11 con las bibliotecas NumPy, OpenCV, scikit-image, SciPy, PyWavelets, Pandas, Matplotlib y Seaborn. El código se organizó en módulos separados (datasets, fusion, metrics, utils) bajo control de versiones git, priorizando la reproducibilidad: cualquier figura, tabla o estadístico de esta tesis puede regenerarse ejecutando los scripts del directorio experiments/.

4.7 Análisis estadístico

Se aplicaron tres procedimientos no paramétricos. Primero, la prueba de Friedman (Friedman, 1937) global por métrica, considerando las imágenes como bloques y los métodos como tratamientos, contrasta la hipótesis nula de que todos los métodos producen distribuciones idénticas. Segundo, la prueba de Wilcoxon de rangos signados (Wilcoxon, 1945) se aplica de manera pareada entre cada uno de los dos métodos morfológicos —la Propuesta Novedosa y la metodología clásica Top-Hat— y cada uno de los cinco comparativos del estado del arte, más el contraste directo entre ambos morfológicos: once contrastes por métrica y 99 en total, controlando por imagen; dado el número de contrastes se aplica corrección de Holm dentro de cada métrica y se reporta el tamaño de efecto rank-biserial. Tercero, se calcula el ranking promedio por método y métrica (1 = mejor), respetando la dirección de cada una (todas de tipo «mayor es mejor») y promediando entre métricas para obtener un ranking global. Todos los cálculos utilizan scipy.stats con $\alpha = 0,05$.

5. ANÁLISIS E INTERPRETACIÓN DE RESULTADOS

El capítulo presenta primero la caracterización del corpus y los análisis cualitativo y cuantitativo del benchmark —la Propuesta Novedosa (operador de suma de ramas, $r = 25$, $m = 0,30$) frente a la metodología clásica de la transformada Top-Hat y a cinco métodos representativos del estado del arte (LP, RP, DWT, DTCWT y CVT)—, luego el análisis estadístico no paramétrico (sección 5.4), la evaluación orientada a tarea (sección 5.5) y la optimización del método (sección 5.6), cerrando con la discusión integrada (sección 5.7).

5.1 Caracterización del dataset

Las veinte (20) imágenes pareadas del TNO Image Fusion Dataset cubren escenarios variados: vehículos blindados a la luz del día y nocturno, soldados detrás de humo, escenas urbanas con humanos a contraluz, espacios industriales y vegetación. Los pares poseen registro espacial previo y resoluciones del orden de 360×270 a 768×576 píxeles. La modalidad VIS exhibe textura rica en contornos, mientras que la IR concentra la información en focos de calor y siluetas humanas. Esta heterogeneidad es deliberada: la fusión multimodal solo es interesante cuando las dos fuentes aportan información que la otra no captura.

5.2 Análisis cualitativo: comparación visual

La figura 6 muestra tres pares representativos del dataset junto con los resultados de los métodos del benchmark. Visualmente, la pirámide de Laplace y la DTCWT recuperan detalle fino con buen equilibrio, aunque introducen ligeros artefactos en bordes muy contrastantes; la RP acentúa el contraste local a costa de cierta sobreamplificación; la DWT presenta el granulado característico de la fusión por máxima magnitud de coeficiente; y el Top-Hat clásico produce la imagen de mayor contraste aparente, pero con halos visibles alrededor de los objetivos térmicos, consecuencia de inyectar el detalle sin ponderación. La Propuesta Novedosa (destacada en rojo) ofrece el resultado visualmente más limpio y equilibrado: integra la silueta térmica de la IR y la textura del VIS con bordes definidos, sin el granulado de la DWT ni los halos del operador clásico. Esto es coherente con sus indicadores cuantitativos: la mayor entropía y la mayor eficiencia de fusión del estudio ($EN = 6,9855$; $FE = 1,1047$), con un realce moderado que evita la saturación del operador clásico.




Figura 6. Comparación cualitativa de los métodos de fusión sobre tres pares representativos del dataset.

5.3 Resultados cuantitativos: promedio por método

La Tabla 4 presenta los promedios de las seis métricas clásicas y la Tabla 5 los de la frecuencia espacial, la similitud estructural y el PSNR, sobre los 20 pares para los siete métodos del benchmark. La propuesta lidera la entropía ($EN = 6,9855$) y la eficiencia de fusión ($FE = 1,1047$) del benchmark, y se ubica segunda en desviación estándar ($SD = 0,1439$), gradiente medio ($MG = 0,0355$) y frecuencia espacial ($SF = 17,4425$), por detrás únicamente de la pirámide de Laplace en contraste y del Top-Hat clásico en gradiente y frecuencia. En las métricas de fidelidad la relación se invierte: los métodos multiescala lideran la similitud estructural y el PSNR, y la pirámide de Laplace la información mutua con las fuentes. Frente al operador clásico, la propuesta mejora simultáneamente la entropía, el contraste y la eficiencia de fusión y además eleva la similitud estructural de 0,5640 a 0,6584, mostrando que el banco de elementos estructurantes realza sin degradar la estructura tanto como el disco único sin ponderación.

Tabla 4. Promedios de las seis métricas clásicas por método ($n = 20$).

Método	EN	SD	FE	MG	MI_vis	MI_ir
Pirámide de Laplace (LP)	6,8400	0,1550	1,0806	0,0252	1,9242	0,9178
Ratio Pyramid (RP)	6,8098	0,1271	1,0770	0,0275	0,9485	0,6504
Wavelet discreta (DWT)	6,6816	0,1166	1,0566	0,0275	1,0764	0,6658
DTCWT	6,6877	0,1172	1,0577	0,0255	1,0781	0,6728
Curvelet (CVT)	6,6445	0,1132	1,0507	0,0260	1,0961	0,6695

Top-Hat clásico	6,9220	0,1352	1,0952	0,0478	0,7867	0,4928
Propuesta Novedosa	6,9855	0,1439	1,1047	0,0355	0,8970	0,6003

Tabla 5. Promedios de frecuencia espacial (SF), similitud estructural (SSIM) y PSNR por método (n = 20 pares).

Método	SF ↑	SSIM ↑	PSNR ↑
Pirámide de Laplace (LP)	13,2205	0,7059	14,9401
Ratio Pyramid (RP)	13,6209	0,7051	17,3689
Wavelet discreta (DWT)	14,1888	0,7014	17,5886
DTCWT	13,1990	0,7249	17,5974
Curvelet (CVT)	13,3379	0,7162	17,6523
Top-Hat clásico	23,1000	0,5640	16,8728
Propuesta Novedosa	17,4425	0,6584	16,8409

Estas métricas, ponderadas por bordes y estructura local, complementan a las anteriores: la pirámide de Laplace lidera FMI (0,2362), QW (0,8470) y QE (0,3856), y DTCWT lidera Q0 (0,7411); la propuesta no encabeza ninguna de las cuatro. La Propuesta Novedosa lidera en cambio SCD (1,5427) y VIF (0,3805), y presenta la mayor tasa de artefactos del benchmark después del Top-Hat clásico (Nabf 0,3742, frente a 0,1593 de DTCWT).

Una distribución más completa de las métricas, no reducida al promedio, se aprecia en los diagramas de caja de la figura 7.




Figura 7. Diagramas de caja de seis métricas representativas (SSIM, SF, EN, SD, MI_ir, PSNR) por método (n = 20 pares VIS/IR).

5.4 Análisis estadístico no paramétrico

5.4.1 Prueba de Friedman global

La Tabla 6 reporta la prueba de Friedman aplicada de forma independiente a cada métrica, considerando los siete métodos del benchmark como tratamientos y los 20 pares como bloques. La hipótesis nula se rechaza con amplio margen en las nueve métricas ($p \ll 0,001$), lo que habilita el análisis pareado posterior: existen diferencias reales y sistemáticas entre los métodos comparados.

Tabla 6. Prueba de Friedman por métrica (χ^2 , p-valor; $\alpha = 0,05$).

Métrica	χ^2 de Friedman	p-valor	Significativo ($\alpha = 0,05$)
EN	88,29	< 0,001	Sí
SD	105,13	< 0,001	Sí
FE	88,29	< 0,001	Sí
MG	101,74	< 0,001	Sí
MI_vis	73,63	< 0,001	Sí
MI_ir	58,01	< 0,001	Sí
SF	97,31	< 0,001	Sí
SSIM	100,46	< 0,001	Sí
PSNR	111,84	< 0,001	Sí

5.4.2 Comparaciones pareadas Wilcoxon

Para precisar dónde residen las diferencias se aplicó la prueba de Wilcoxon de rangos signados entre los métodos morfológicos (la propuesta y el Top-Hat clásico) y cada método del estado del arte, sobre las nueve métricas, con corrección de Holm y tamaño de efecto rank-biserial (99 contrastes; detalle en el Apéndice C). El hallazgo central: la propuesta mejora de forma estadísticamente significativa la entropía, la eficiencia de fusión, el gradiente medio y la frecuencia espacial (EN, FE, MG, SF) frente a los cinco métodos del estado del arte ($p_{\text{Holm}} < 0,05$), y el contraste (SD) frente a cuatro de los cinco, mientras que cede de manera sistemática en las métricas de fidelidad a las fuentes (SSIM, PSNR) y en la información mutua, donde lideran los métodos multiescala. Frente al Top-Hat clásico la ventaja es más amplia: la propuesta gana en seis de las nueve métricas y cede solo en gradiente medio y frecuencia espacial.

5.4.3 Ranking promedio

La Tabla 7 muestra el ranking promedio de cada método (1 = mejor) en seis de las nueve métricas —SD, MG, SF, SSIM, PSNR y MI_ir— y el ranking global obtenido al promediar las

nueve métricas, respetando la dirección de cada una. La propuesta encabeza el ranking global (3,39), seguida por la pirámide de Laplace (3,91), el Top-Hat clásico (3,94), RP (3,98), DTCWT (4,11), DWT (4,21) y CVT (4,44); es primera en el rango medio de entropía, contraste y eficiencia de fusión, segunda en gradiente medio y frecuencia espacial, y queda relegada en las métricas de fidelidad a las fuentes. Conviene notar que su primer puesto en contraste es de rango y no de media: la pirámide de Laplace alcanza un SD promedio mayor (0,1550 frente a 0,1439), pero la propuesta la supera en más pares de los que pierde, y el rango medio recoge esa consistencia por escena que el promedio aritmético oculta. El ranking se calcula promediando, para cada método, los rangos que obtiene dentro de cada par de imágenes —el complemento habitual de la prueba de Friedman—, y no rankeando los promedios, procedimiento que ignora la variabilidad entre escenas. Debe además tenerse presente que FE es la entropía de la fusión dividida por el promedio de las entropías de las fuentes: dentro de un mismo par el divisor es constante, de modo que FE reproduce exactamente los rangos de EN y no constituye evidencia independiente. Excluyéndola, la propuesta sigue primera (3,631 frente a 3,994 de la pirámide de Laplace), de modo que su primer lugar no depende de la redundancia; el resto del orden sí se reacomoda —solo cuatro de las siete posiciones se conservan, y el Top-Hat clásico cae del tercer al sexto lugar—. Distinto es lo que ocurre al ampliar la batería en lugar de recortarla. Sumando Nabf —la única métrica de dirección inversa del estudio, que penaliza artefactos, y cuya incorporación este trabajo recomienda en sus conclusiones— la propuesta pasa al segundo lugar (3,655) y el primero corresponde a la pirámide de Laplace (3,620), lo que es consistente con su Nabf medio: 0,3742 la propuesta frente a 0,1138 de aquella. Aun así, al mezclar familias de métricas con pesos iguales, el ranking debe leerse junto a los contrastes pareados de la sección anterior.

Tabla 7. Ranking promedio por método y métrica (1 = mejor).

Método	SD	MG	SF	SSIM	PSNR	MI_ir	Global
Propuesta Novedosa	1,65	2,00	2,00	5,90	5,35	5,25	3,39
Pirámide de Laplace (LP)	2,00	6,25	5,65	3,80	6,95	2,20	3,91
Top-Hat clásico	2,85	1,00	1,00	7,00	5,35	6,70	3,94
Ratio Pyramid (RP)	3,60	4,65	4,95	3,00	4,35	3,45	3,98
DTCWT	5,05	6,05	6,00	1,30	2,25	3,30	4,11
Wavelet discreta (DWT)	5,85	3,30	3,20	4,50	2,75	3,90	4,21
Curvelet (CVT)	7,00	4,75	5,20	2,50	1,00	3,20	4,44




Figura 8. Ranking global por método (promedio de rangos sobre las nueve métricas, con la dirección de cada una corregida).

5.5 Evaluación orientada a tarea: detección con YOLO (LLVIP y M3FD)

Para una evaluación concluyente —con verdad de campo— se reentrenó el mismo detector (YOLOv8n) por separado sobre cada modalidad, 5 veces por entrada cambiando únicamente la semilla de inicialización usando el conjunto LLVIP (15.488 pares VIS/IR registrados, peatones en baja luz; subconjunto de 2.000/500 imágenes, 40 épocas, idéntica configuración). Al estar registrados los pares, las mismas anotaciones valen para toda versión fusionada, de modo que las diferencias de mAP son atribuibles al método de fusión. La Tabla 8 reporta mAP@0,5 y mAP@0,5:0,95.

Tabla 8. Detección de peatones en LLVIP — mAP por modalidad (YOLOv8n; subconjunto 2000 train / 500 val, 40 épocas).

Método	mAP@0,5 ↑ (media ± desv.)	mAP@0,5:0,95 ↑ (media ± desv.)	Precisión ↑	Recall ↑
VIS (solo)	0,795 ± 0,0123	0,429 ± 0,0120	0,831	0,714
IR (solo)	0,961 ± 0,0139	0,592 ± 0,0259	0,969	0,884
Pirámide de Laplace (LP)	0,952 ± 0,0064	0,583 ± 0,0162	0,966	0,889
Ratio Pyramid (RP)	0,904 ± 0,0063	0,511 ± 0,0090	0,925	0,835
Wavelet discreta (DWT)	0,918 ± 0,0288	0,575 ± 0,0229	0,907	0,821
Dual-Tree Complex Wavelet (DTCWT)	0,936 ± 0,0095	0,589 ± 0,0118	0,940	0,819
Curvelet (CVT)	0,926 ± 0,0128	0,578 ± 0,0217	0,946	0,807

Top-Hat clásico	$0,923 \pm 0,0131$	$0,587 \pm 0,0260$	0,950	0,830
Propuesta Novedosa ($r=25$, $m=0,30$)	$0,928 \pm 0,0130$	$0,577 \pm 0,0149$	0,944	0,828

La Tabla 8 admite tres lecturas. Primero, toda fusión mejora con claridad sobre el visible solo ($0,795$ de media frente a una banda de $0,904$ – $0,952$, en las 5 semillas, es decir entre $+0,09$ y $+0,14$ puntos): cuando el canal visible es débil —escenas nocturnas—, fusionar aporta información decisiva. Segundo, el infrarrojo solo es la modalidad más fuerte ($mAP@0,5 = 0,971$; $mAP@0,5:0,95 = 0,621$) y ninguna fusión lo supera, coherente con que LLVIP es detección de peatones en baja luz, donde la firma térmica domina. Tercero, entre las fusiones la pirámide de Laplace encabeza ($0,952$), seguida por DTCWT ($0,936$), mientras que la Propuesta Novedosa queda 3.^a con $0,9283$ e indistinguible de 4 de sus seis rivales, porque las diferencias entre ellas caen por debajo del desvío de una misma entrada ($0,0128$). La conclusión es matizada y relevante: el realce acentuado que favorece a las métricas de actividad no mejora la detección —el detector se beneficia más de una fusión conservadora y fiel a las fuentes que de un contraste elevado—, de modo que la calidad de imagen medida por actividad no se traslada a la tarea; la elección del método depende del criterio operativo prioritario —en consonancia con lo señalado por Singh et al. (2023)—.




Figura 12. Dispersión de cada entrada del detector sobre las 5 semillas de entrenamiento en LLVIP. El punto es la media, la barra une el mínimo con el máximo y los círculos son las 45 corridas. Cuando las barras de dos entradas se superponen, la diferencia entre ellas no se distingue del ruido de inicialización: el desvío mediano de una misma entrada es $0,0128$ y su

recorrido mediano 0,0308; en el caso extremo, la wavelet discreta recorre 0,0710 consigo misma, más que la distancia entre la mejor y la peor de las siete fusiones.

Detección con clases complementarias (M3FD). Como complemento se diseñó un experimento de clases complementarias sobre el dataset M3FD (Liu et al., 2022): una partición estratificada y disjunta en tres subconjuntos —2.000 pares de entrenamiento, 500 de validación y 500 de prueba, de los cuales 499 resultan utilizables— con seis clases anotadas, dos de ellas de visibilidad opuesta —las personas dominan en el infrarrojo por su firma térmica y las luces (Lamp) son esencialmente visibles solo en el canal visible—. Un único detector YOLOv8n se entrenó con las imágenes de ambas modalidades mezcladas (4.000 imágenes, 40 épocas, etiquetas compartidas) y se evaluó por inferencia, sin reentrenar, sobre la partición de prueba de cada modalidad y de cada método de fusión, con la configuración adoptada en la sección 5.6 ($r = 25$, $m = 0,30$). El conteo por escena de la sección 5.8.5 se calcula sobre un subconjunto complementario de 232 escenas, disjunto del entrenamiento, formado por las que contienen simultáneamente las dos clases de visibilidad opuesta.

Tabla 9. Clases complementarias en M3FD: AP@0,5 por clase y mAP global con un detector único entrenado sobre VIS+IR (medias sobre las 499 imágenes de la partición de prueba, disjunta de las de entrenamiento y de validación).

Entrada del detector	AP People ↑	AP Lamp ↑	Promedio del par ↑	mAP@0,5 ↑
VIS (solo)	0,621	0,616	0,618	0,676
IR (solo)	0,779	0,348	0,563	0,668
Pirámide de Laplace (LP)	0,684	0,545	0,614	0,674
Ratio Pyramid (RP)	0,694	0,550	0,622	0,677
Wavelet discreta (DWT)	0,664	0,528	0,596	0,652
Dual-Tree Complex Wavelet (DTCWT)	0,669	0,542	0,606	0,665
Curvelet (CVT)	0,642	0,490	0,566	0,643
Top-Hat clásico ($r = 5$; $m = 1$)	0,575	0,438	0,506	0,608
Propuesta Novedosa ($r = 25$; $m = 0,30$)	0,641	0,488	0,564	0,651

La Tabla 9 muestra una complementariedad real pero asimétrica, y menos extrema de lo que sugiere la intuición. El infrarrojo domina con claridad en personas ($AP@0,5 = 0,779$ frente a 0,621 del visible) y se degrada en las luces (0,348), mientras que el visible sostiene ambas clases en un nivel parejo (0,621 y 0,616). No hay, por tanto, un patrón espejo: el visible no fracasa en personas, de modo que el argumento a favor de fusionar no es que una modalidad sea ciega, sino que ninguna es la mejor en las dos clases a la vez. Entre las fusiones, la Ratio Pyramid alcanza el

mejor promedio del par (0,622) y es la única entrada que supera a las dos modalidades individuales (VIS 0,618; IR 0,563); también obtiene el mejor mAP global de seis clases (0,677), apenas por encima del visible solo (0,676). La Propuesta Novedosa recupera ambas clases con un promedio de 0,564 (personas 0,641 y luces 0,488), es decir al nivel del infrarrojo solo y por debajo del visible: el realce acentuado que optimiza las métricas de actividad no favorece al detector, un resultado coherente con lo observado en LLVIP. Los valores absolutos son moderados (499 imágenes de prueba y modelo nano): el experimento no busca récords, sino delimitar el escenario donde la fusión aporta algo que ninguna modalidad sola aporta. La Figura 9 ilustra el fenómeno sobre dos escenas de la prueba: en la primera la fusión detecta once personas frente a tres del visible y diez del infrarrojo, y en la segunda conserva siete luces frente a cinco luces del visible y una sola del infrarrojo.

Detecciones del modelo único VIS+IR — People en granate, Lamp en azul (conf $\geq 0,30$)



Figura 9. Detecciones del modelo único VIS+IR en dos escenas de la partición de prueba de M3FD (personas en recuadro granate, luces en azul): en la escena superior la fusión detecta once personas, frente a tres del visible y diez del infrarrojo; en la inferior conserva siete luces y ocho personas, frente a cinco luces del visible y una sola del infrarrojo.

5.6 Propuesta Novedosa (método central)

La Propuesta Novedosa —método central de esta tesis— se optimizó con PSO sobre un subconjunto representativo de escenas, maximizando una aptitud orientada a la fusión ($F_o = SSIM_{avg} + En + PSNR_n$). La configuración del enjambre se seleccionó mediante un barrido de 25 combinaciones de partículas e iteraciones ($2-10 \times 10-50$, replicando el diseño de Ortega y

Espinoza, 2025) con el espacio de búsqueda publicado, $r \in [1, 25]$ y $m \in [0,30; 2,00]$; el peso óptimo converge al límite inferior del rango ($m^* = 0,30$) en las 25 configuraciones, y el radio se fija en $r = 25$ porque maximiza el bloque de actividad de las nueve métricas de evaluación, sin que $r = 1$ desactive el banco. Esta aptitud premia simultáneamente la fidelidad estructural (SSIM), el contenido informativo (entropía) y la reducción de la distorsión (PSNR).

La Tabla 10 compara la propuesta, en su configuración óptima ($r = 25$, $m = 0,30$), con la metodología clásica Top-Hat y con métodos representativos del estado del arte (LP, RP y DTCWT; los valores de DWT y CVT, del mismo orden, se detallan en el material complementario) sobre las cinco métricas clásicas de actividad e información. La propuesta lidera la entropía ($EN = 6,9855$) y la eficiencia de fusión ($FE = 1,1047$) —por encima del Top-Hat clásico ($6,9220$ y $1,0952$) y de los tres métodos multiescala— y queda segunda en desviación estándar ($0,1439$, tras la pirámide de Laplace), gradiente medio ($0,0355$) y frecuencia espacial ($17,4425$, frente a $23,1000$ del clásico). El operador clásico alcanza mayor actividad bruta en gradiente y frecuencia, pero a costa de la peor similitud estructural del estudio ($0,5640$ frente a $0,6584$ de la propuesta).

La significación de estas diferencias se verificó con la prueba de Wilcoxon pareada ($n = 20$, corrección de Holm por métrica; detalle completo en el Apéndice C). Frente a la metodología clásica Top-Hat, la propuesta gana de forma estadísticamente significativa en seis de las nueve métricas —entropía ($6,9855$ frente a $6,9220$), contraste ($0,1439$ frente a $0,1352$), eficiencia de fusión ($1,1047$ frente a $1,0952$), información mutua con ambas fuentes y similitud estructural ($0,6584$ frente a $0,5640$; $p_{\text{Holm}} \leq 0,001$)— y cede en gradiente medio y frecuencia espacial, donde el disco único inyecta el detalle sin ponderación; la diferencia en PSNR no resulta significativa. Frente a los cinco métodos del estado del arte, la propuesta gana de forma significativa en entropía, eficiencia de fusión, gradiente medio y frecuencia espacial contra todos ellos, y en contraste contra cuatro de los cinco; en cambio cede en las métricas de fidelidad a las fuentes y en información mutua. Con ello queda sostenida H1.

La elección del peso es robusta: las 25 combinaciones del barrido convergieron al mismo valor, $m^* = 0,30$, el límite inferior del rango publicado, porque la aptitud F_0 decrece de forma monótona al aumentar el realce. El radio $r = 25$ se adopta porque maximiza el bloque de actividad de las nueve métricas de evaluación —todas de tipo «mayor es mejor»—: a igual peso supera a $r = 1$ en entropía, contraste, eficiencia de fusión, gradiente medio y frecuencia espacial, mientras $r = 1$ preserva mejor la fidelidad a las fuentes, de modo que un vecindario amplio

captura los objetivos térmicos completos. Conviene precisar que $r = 1$ no desactiva el banco: con $r = 1$ el disco es la cruz de 3×3 y las cuatro líneas orientadas son cuatro máscaras 3×3 distintas, de modo que los cinco elementos siguen operativos. La elección del radio se apoya, por tanto, en el criterio de evaluación y no en la optimización.

Tabla 10. Propuesta Novedosa frente a la metodología clásica Top-Hat y al estado del arte — medias sobre 20 pares ($n = 20$).

Métrica	Propuesta Novedosa ($r=25, m=0,30$)	Top-Hat clásico	Pirámide de Laplace (LP)	Ratio Pyramid (RP)	DTCWT
EN $\uparrow$	6,9855	6,9220	6,8400	6,8098	6,6877
FE $\uparrow$	1,1047	1,0952	1,0806	1,0770	1,0577
SD $\uparrow$	0,1439	0,1352	0,1550	0,1271	0,1172
MG $\uparrow$	0,0355	0,0478	0,0252	0,0275	0,0255
SF $\uparrow$	17,4425	23,1000	13,2205	13,6209	13,1990




Figura 10. Propuesta Novedosa ($r = 25$ por diseño; $m = 0,30$, piso del rango) frente a la metodología clásica Top-Hat y a tres métodos del estado del arte en las cinco métricas de actividad e información de la Tabla 10 (EN, FE, SD, MG, SF) y en la similitud estructural, donde el operador cede.

La Figura 11 resume la optimización del método. El panel izquierdo muestra la aptitud F_o en función del peso de contraste con el radio fijo en $r = 25$: decrece de forma monótona a partir de valores pequeños de m , de modo que el óptimo dentro del rango publicado cae en su piso, $m^* = 0,30$, donde $F_o = 1,7057$. El panel derecho y la Tabla 11 sintetizan el barrido de 25 configuraciones: todas convergen al mismo peso, $m^* = 0,30$, el límite inferior del rango publicado, lo que refleja que F_o decrece de forma monótona con el realce; la contribución de los

elementos estructurantes lineales sobre el disco reside en la cobertura de orientaciones, que el criterio de evaluación premia al fijar $r = 25$.




Figura 11. Aptitud F_o en función del peso de contraste con el radio fijo en $r = 25$ (izq.) y mejor aptitud alcanzada por cada combinación de partículas e iteraciones del barrido (der.), sobre tres escenas representativas. La aptitud decrece de forma monótona a partir de valores pequeños de m , de modo que el óptimo se sitúa en el piso del rango publicado.

Tabla 11. Barrido de configuraciones del PSO con el rango publicado $m \in [0,30; 2,00]$: mejor aptitud F_o por combinación de partículas (n) e iteraciones (T). Las 25 configuraciones convergen al mismo peso óptimo ($m^* = 0,30$); las diferencias reflejan el radio hallado ($r = 1$ donde la aptitud llega a 1,7350 y $r = 25$ donde llega a 1,7057).

Partículas Iteraciones	T = 10	T = 20	T = 30	T = 40	T = 50
n = 2	1,6990	1,7350	1,7057	1,7350	1,7350
n = 4	1,7350	1,7057	1,7350	1,7350	1,7350
n = 6	1,7350	1,7350	1,7350	1,7350	1,7350
n = 8	1,7057	1,7350	1,7057	1,7057	1,7350
n = 10	1,7057	1,7350	1,7350	1,7057	1,7057

5.7 Discusión integrada

Los hallazgos cuantitativos pueden sintetizarse en seis observaciones. Primero, la Propuesta Novedosa ($r = 25$, $m = 0,30$) encabeza el ranking agregado (3,39, por delante de la pirámide de Laplace con 3,91 y del Top-Hat clásico con 3,94): lidera la entropía ($EN = 6,9855$) y la eficiencia de fusión ($FE = 1,1047$) y es segunda en contraste, gradiente medio y frecuencia espacial, cediendo en las cuatro métricas de fidelidad a las fuentes. Segundo, no existe un método universalmente dominante: la pirámide de Laplace lidera el contraste (SD) y la información mutua, el Top-Hat clásico el gradiente y la frecuencia espacial, los métodos multiescala la similitud estructural y el PSNR, y la propuesta la entropía y la eficiencia de fusión; son óptimos de criterios distintos y complementarios. Tercero, la comparación con la metodología clásica de la transformada Top-Hat aísla el aporte de la propuesta: con el mismo

esquema de reconstrucción y un peso idéntico, el banco de disco más líneas mejora simultáneamente la entropía (6,9855 frente a 6,9220), el contraste (0,1439 frente a 0,1352), la eficiencia de fusión (1,1047 frente a 1,0952), la información mutua con ambas fuentes y la similitud estructural (0,6584 frente a 0,5640), y solo cede en gradiente medio y frecuencia espacial, donde el disco único inyecta el detalle sin ponderación; en PSNR la diferencia no es distinguible ($p_{\text{Holm}} = 0,674$). Cuarto, las métricas de actividad crecen de forma monótona con el realce hasta que la saturación degrada la imagen, de modo que deben interpretarse junto a las de fidelidad y a un control visual del nivel de saturación. Quinto, la evaluación orientada a tarea (detección sobre LLVIP, repetida con 5 semillas de entrenamiento por entrada) constituye un criterio complementario y arroja el hallazgo más matizado: toda fusión supera netamente al visible solo (+0,09 a +0,14 en $\text{mAP}@0,5$), el infrarrojo solo es la modalidad más fuerte (0,961) y la propuesta queda 3.^a de las siete fusiones (0,9283), indistinguible de 4 de ellas, de modo que el realce que premian las métricas de actividad no mejora —y en este caso perjudica— el desempeño del detector. Sexto, el experimento de clases complementarias sobre M3FD delimita el escenario donde la fusión es insustituible: cuando la escena contiene objetos térmicos (personas) y objetos exclusivamente visibles (luces), el infrarrojo se degrada en las luces ($\text{AP}@0,5 = 0,348$ frente a 0,779 en personas) y el visible mantiene ambas clases en un nivel parejo (0,621 y 0,616), de modo que la ventaja de fusionar no es que el visible fracase, sino que ninguna modalidad sola es la mejor en las dos clases a la vez. La Ratio Pyramid es la única entrada que supera a ambas modalidades en el promedio del par (0,622 frente a 0,618 del visible y 0,563 del infrarrojo), mientras que la propuesta alcanza 0,564, al nivel del infrarrojo solo y por debajo del visible. Ambos experimentos convergen en una conclusión metodológica: optimizar las métricas de actividad y optimizar el desempeño en tarea son objetivos distintos, y la evaluación de un método de fusión debe reportar ambos.

5.8 Auditoría del protocolo de evaluación

Las secciones anteriores aplican el protocolo de evaluación; esta lo pone a prueba. El segundo aporte de la tesis consiste en usar el propio desarrollo como caso de estudio para establecer qué autoriza a concluir el criterio con el que se lo juzga: una batería de métricas sin referencia interpretadas todas como «mayor es mejor», un ajuste de hiperparámetros guiado en parte por esas mismas métricas y una validación en tarea posterior. Los cinco experimentos que siguen están versionados en el repositorio y contrastan las hipótesis H2, H3, H4, H5, H6 y H7.

5.8.1 Sensibilidad del orden de mérito y redundancia interna (H2, H4)

El orden de mérito no es una propiedad del operador sino del criterio. Con las nueve métricas del trabajo de referencia la propuesta encabeza el benchmark (3,394 de rango medio). Sumando sólo Nabf, la única de dirección inversa y la que este trabajo recomienda incorporar, ya desciende al segundo lugar (3,655) por detrás de la pirámide de Laplace (3,620). Incorporando las ocho métricas adicionales que el mismo evaluador calcula —Qabf, Nabf, SCD, VIF, FMI, Q0, QW y QE, con Nabf en su dirección inversa— la propuesta desciende al tercer lugar (3,459), el primer puesto pasa a la pirámide de Laplace (3,147), el segundo a DTCWT (3,259) y el Top-Hat clásico cae al último (5,000). Ninguna imagen fusionada cambió entre los tres cálculos: cambió el conjunto de métricas, y el descenso es monótono a medida que la batería se completa. Se sostiene, por tanto, H2, y de ello se sigue que todo orden agregado debe reportarse junto a la composición del conjunto que lo produce.

La batería contiene además redundancia interna. La eficiencia de fusión se define como el cociente entre la entropía de la imagen fusionada y el promedio de las entropías de las fuentes; como ese denominador no depende del método, dentro de cada par la eficiencia de fusión es la entropía reescalada por una constante. Sus rangos intra-bloque coinciden con los de la entropía en los veinte pares y su estadístico de Friedman es idéntico ($\chi^2 = 88,2857$ en ambas). El número efectivo de dimensiones evaluadas es ocho y no nueve, lo que sostiene H4. Excluyendo la eficiencia de fusión del promedio, la propuesta sigue primera (3,631 frente a 3,994 de la pirámide de Laplace), de modo que la redundancia no explica su primer lugar. El resto del orden sí se reacomoda: solo cuatro de las siete posiciones se conservan, y el Top-Hat clásico cae del tercer lugar al sexto (3,944 a 4,131).

5.8.2 Control negativo con degradaciones conocidas (H3)

Si la batería mide calidad de fusión, una imagen deliberadamente degradada debería quedar por debajo de cualquier método razonable. Para verificarlo se incorporaron al ranking siete entradas de control junto a los siete métodos: la imagen base sin operador, cuatro fusiones artificiales construidas sumando ruido gaussiano de desviación creciente a esa base, y dos desenfoques gaussianos. La Tabla 12 presenta el rango medio de las catorce entradas bajo tres composiciones del criterio.

Tabla 12. Control negativo: rango medio de los siete métodos y de siete entradas degradadas, bajo tres composiciones del criterio (menor rango = mejor; $n = 20$ pares).

Entrada evaluada	Rango con 9 ↓	Con 9 + Nabf ↓	Con 17 ↓
Propuesta Novedosa	6,383	6,760	5,344

Pirámide de Laplace (LP)	6,561	6,325	4,876
Ruido gaussiano $\sigma = 0,20$	6,767	7,490	10,138
Ratio Pyramid (RP)	6,950	7,015	5,844
Ruido gaussiano $\sigma = 0,10$	6,972	7,565	9,685
Top-Hat clásico	7,106	7,600	7,229
DTCWT	7,117	6,960	5,079
Wavelet discreta (DWT)	7,261	7,405	6,565
Imagen base (VIS+IR)/2	7,322	6,690	6,521
Curvelet (CVT)	7,556	7,525	6,685
Ruido gaussiano $\sigma = 0,05$	7,850	8,155	9,462
Desenfoque gaussiano 5×5	8,417	7,785	8,524
Ruido gaussiano $\sigma = 0,02$	8,917	8,595	8,994
Desenfoque gaussiano 11×11	9,822	9,130	10,053

El resultado es inequívoco. Con las nueve métricas, la fusión de ruido con $\sigma = 0,20$ alcanza el tercer lugar de catorce (6,767): queda por delante de cinco de los seis métodos comparativos y por delante de la imagen base. Y su rango mejora monótonamente al aumentar el ruido —8,917, 7,850, 6,972 y 6,767 para $\sigma = 0,02$, 0,05, 0,10 y 0,20—, es decir que la batería juzga mejor a la imagen cuanto más ruido se le inyecta. El fallo es específico de la varianza y no de la degradación en general: el desenfoque sí resulta penalizado, y el de 11×11 queda último (9,822). Incorporando Nabf —la única métrica implementada con dirección inversa, que penaliza artefactos— el ruido de $\sigma = 0,20$ desciende al séptimo lugar, y con las diecisiete métricas cae al último (10,138). Se sostiene H3: la batería de nueve métricas de tipo «mayor es mejor» no distingue detalle útil de ruido, y basta una métrica que penalice artefactos para corregirlo.

5.8.3 Aporte del banco con hiperparámetros igualados (H7)

La comparación con el Top-Hat clásico de la sección 5.6 no aísla el aporte del banco, porque aquel operador emplea otro radio y otro peso ($r = 5$, $m = 1$). Para aislarlo se fijaron $r = 25$ y $m = 0,30$ en seis brazos que comparten todo salvo la forma de combinar las respuestas morfológicas. La Tabla 13 recoge el rango medio de cada brazo.

Tabla 13. Ablación del banco de elementos estructurantes con $(r, m) = (25; 0,30)$ fijos en los seis brazos (menor rango = mejor; $n = 20$ pares).

Brazo ($r = 25$; $m = 0,30$ fijos)	Rango con 9 ↓	Con 9 sin FE ↓	Con 17 ↓
--------------------------------------	---------------	----------------	----------

Suma disco + promedio de líneas (propuesta)	3,222	3,500	3,621
Máximo entre disco y líneas	3,311	3,444	2,932
Solo el disco B_r	3,367	3,444	3,153
Promedio de disco y líneas	3,533	3,475	3,179
Imagen base, sin operador	3,783	3,506	4,359
Solo las cuatro líneas	3,783	3,631	3,756

Con las nueve métricas la suma de ramas —la combinación que adopta la propuesta— es la mejor de los seis brazos (3,222), por delante del máximo (3,311) y del disco único (3,367); las líneas solas y la imagen base empatan en el último lugar (3,783). Conviene, sin embargo, leer también la columna sin la eficiencia de fusión: como esa métrica duplica la entropía, y la entropía es donde la suma obtiene su mayor ventaja, al retirarla los seis brazos se comprimen en una banda de 3,444 a 3,631 y la suma desciende al cuarto lugar (3,500), por detrás del máximo y del disco (3,444 cada uno). La lectura prudente es entonces que el banco produce un perfil distinto del disco único —lo que sostiene H7— y que su ventaja en el recuento de nueve métricas se apoya en parte en que la entropía se cuenta dos veces; lo que sí queda firme en todas las composiciones es que el mérito no proviene de la imagen base. Con las diecisiete métricas, en cambio, el orden se invierte: encabeza el máximo (2,932), siguen el disco (3,153) y el promedio (3,179), y la suma desciende al cuarto lugar (3,621), mientras la base queda última (4,359). La dirección del aporte depende, una vez más, del criterio, exactamente como enuncia H2.

5.8.4 Robustez frente al ajuste simétrico de los comparativos

El protocolo concede a la propuesta un paso de ajuste de hiperparámetros que no concede a los comparativos, los cuales se ejecutan con sus valores por defecto. Para acotar la ventaja que eso introduce se recalculó el ranking dando a cada método comparativo el mismo tipo de barrido. La Tabla 14 resume los tres escenarios; el de ajustar además la propuesta arroja cifras idénticas al segundo, porque su configuración ya era la óptima bajo este criterio.

Tabla 14. Rango medio por escenario de ajuste: con los comparativos por defecto, con los comparativos ajustados, y con los comparativos ajustados sobre las diecisiete métricas (menor rango = mejor).

Método	A: todos por defecto ↓	B: comparativos ajustados ↓	C: con 17 métricas ↓
Propuesta Novedosa	3,394	3,583	3,821
Pirámide de Laplace (LP)	3,911	4,028	3,141
Top-Hat clásico	3,944	3,522	4,541

Ratio Pyramid (RP)	3,983	3,772	3,924
DTCWT	4,111	4,211	3,362
Wavelet discreta (DWT)	4,211	4,167	4,574
Curvelet (CVT)	4,444	4,717	4,638

Bajo el protocolo tal como está declarado —escenario A— la propuesta encabeza el benchmark con 3,394. Concediendo a los comparativos el mismo paso de ajuste, ninguna de las cinco configuraciones de referencia la alcanza, pero el Top-Hat clásico la supera por 0,061 (3,522 frente a 3,583); conviene precisar que lo hace con $m = 1$, más del triple del peso de la propuesta, de modo que la comparación a peso igualado sigue siendo la de la Tabla 13, donde la suma de ramas gana. Con las diecisiete métricas y los comparativos ajustados la propuesta desciende al tercer lugar (3,821), por detrás de la pirámide de Laplace (3,141) y de DTCWT (3,362). Y conviene añadir el contraste a peso igualado que la Tabla 14 no recoge: ejecutando el Top-Hat clásico con $(r, m) = (25; 0,30)$ —los mismos valores de la propuesta— la propuesta conserva el primer lugar del ranking de nueve métricas con 3,528 frente a 3,694, de modo que la ventaja del clásico en el escenario B proviene de su peso $m = 1$ y no del operador. El primer lugar del escenario A es, entonces, un resultado sólido dentro del criterio del trabajo de referencia y no una propiedad independiente del criterio.

5.8.5 Alcance de la optimización y contraste con la tarea (H5, H6)

La optimización no determina la configuración evaluada. El argmax de la aptitud dentro del rango publicado es $r = 1$ ($F_0 = 1,7350$) y no $r = 25$ (1,7057), y el peso queda en $m = 0,30$ en las veinticinco configuraciones porque es el piso del rango: la aptitud decrece estrictamente en m , al estar dos de sus tres sumandos del lado de la fidelidad. El radio adoptado proviene, pues, de la batería de evaluación, y el peso del piso del rango publicado: se sostiene H5. El barrido determinista de la aptitud precisa el alcance de esa afirmación. Enumerando los veinticinco radios enteros por 200 pesos —la aptitud es determinista y el radio es entero, de modo que el espacio se puede recorrer sin muestreo— el máximo dentro del rango publicado está en $r = 1$ con $F_0 = 1,7350$, pero con el peso libre está en $r = 25$, el radio que esta tesis adopta, con $m = 0,070$ y $F_0 = 1,7715$; el rango heredado cuesta 0,0365 de aptitud. El orden de los radios se invierte: con el peso libre la aptitud decrece al bajar el radio y $r = 1$ pasa a ser el peor (1,7607). La discrepancia no está, por tanto, en el radio sino en el peso: el $r = 25$ adoptado es el óptimo de la aptitud del trabajo de referencia una vez que el peso no está atado al piso de un intervalo calibrado para otro operador. Y la equivalencia de energía cierra el cuadro: ese óptimo libre

equivale a $m = 0,294$ sobre un disco único, esencialmente el piso 0,30 que la referencia publicó para su disco, que extrae 4,21 veces menos energía de detalle. El peso adoptado se sostiene, entonces, en los criterios independientes de la aptitud que se enumeran a continuación. El contraste con el trabajo de referencia delimita el alcance de esa afirmación. Con el disco único, y sobre el mismo rango y la misma aptitud, su barrido no converge al piso sino a valores interiores: la mediana del peso sobre sus 125 corridas —las 25 configuraciones de enjambre de cada una de sus cinco escenas— es 0,695, con recorrido $[0,300; 2,000]$, y solo una escena (Reek) se ancla en el piso, en 17 de sus 25 configuraciones. El anclaje que aquí se observa es entonces una propiedad del operador —el banco extrae 4,21 veces la energía de detalle del disco— y no de la función de aptitud ni del intervalo. A la inversa, en aquel trabajo lo que queda determinado por una cota es el radio: $r = 25$, el límite superior del intervalo, aparece en 104 de sus 125 corridas. En ambos casos, por tanto, uno de los dos hiperparámetros lo fija una decisión de acotación y no la búsqueda, lo que es precisamente el objeto de esta auditoría. El peso sí admite justificación independiente de la aptitud. Con $m = 0,30$ la fracción de píxeles saturados por recorte es del 0,73 % en promedio sobre el corpus y no supera el 1,56 % en ninguna escena, mientras que con $m = 1$ asciende al 6,50 % en promedio y al 16,14 % en el peor caso. El valor adoptado mantiene el recorte por debajo del uno por ciento, lo que constituye un criterio físico y no métrico.

El contraste con la tarea posterior cierra la auditoría. La correlación de Spearman entre el rango de calidad de los siete métodos y su mAP en LLVIP calculada sobre la media de las cinco semillas es $\rho = -0,357$ con $p = 0,432$: no hay asociación. Sobre la corrida de una sola semilla ese coeficiente era $\rho = +0,214$, de modo que el signo es el contrario al esperado, puesto que un rango menor indica mejor calidad. En el conteo por escena sobre M3FD —232 escenas que contienen simultáneamente las dos clases complementarias— la propuesta recupera ambas en el 50,0 % de los casos, frente al 53,0 % del visible solo, con 8 escenas ganadas y 15 perdidas (McNemar exacto $p = 0,2100$), y resuelve 2 de las 90 escenas críticas. La mejor entrada del conteo es la pirámide de Laplace, con el 57,8 %. Se sostiene H_6 , y con muestra suficiente: la hipótesis de que la mejora en las métricas de imagen se traslade a la tarea de detección queda rechazada, no simplemente sin confirmar.

6. CONCLUSIONES Y RECOMENDACIONES

6.1 Conclusiones

Se propuso, implementó y evaluó la Propuesta Novedosa, un método de fusión VIS/IR basado en Top-Hat con elementos estructurantes circulares y lineales sobre una sola escala y

parámetros optimizados por PSO, comparándolo estadísticamente con la metodología clásica de la transformada Top-Hat y con cinco métodos representativos del estado del arte (LP, RP, DWT, DTCWT y CVT) sobre el TNO Image Fusion Dataset. Las conclusiones específicas son:

1. La Propuesta Novedosa —con las respuestas lineales promediadas y sumadas a la del disco sobre una sola escala ($r=25$ adoptado como decisión de diseño sobre la batería de evaluación; $m=0,30$, el piso del rango heredado, al que converge el barrido de 25 configuraciones de enjambre)— logra el primer lugar del ranking agregado de nueve métricas (3,39, por delante de la pirámide de Laplace con 3,91 y del Top-Hat clásico con 3,94), liderando la entropía ($EN=6,9855$) y la eficiencia de fusión ($FE=1,1047$) y quedando segunda en contraste, gradiente medio y frecuencia espacial. Supera a la metodología clásica Top-Hat en seis de las nueve métricas —entropía, contraste, eficiencia de fusión, información mutua con ambas fuentes y similitud estructural— de forma estadísticamente significativa (Wilcoxon pareado con corrección de Holm: $p \leq 0,001$; sección 5.6). En la evaluación de detección sobre LLVIP, toda fusión supera al visible solo (0,795 de media frente a 0,904–0,952, en las 5 semillas) y el infrarrojo solo (0,961) supera a 6 de las siete, sin distinguirse de la séptima, y la propuesta queda 3.^a de las siete ($mAP@0,5 = 0,9283$): su ventaja en las métricas de actividad no se traslada a la tarea de detección, cuya estrategia óptima depende de la aplicación. En el experimento de clases complementarias (M3FD), la fusión muestra su valor distintivo —detecta simultáneamente los objetos térmicos (personas) y los exclusivamente visibles (luces) que cada modalidad pierde por separado—, aunque el mejor promedio del par corresponde a la Ratio Pyramid (0,622) y la propuesta alcanza 0,564, al nivel del infrarrojo solo. Quedan así sostenidas H1 y H6: el operador desplaza su punto de operación en lugar de mejorar de manera uniforme, y la mejora en las métricas de imagen no se traslada a la tarea de detección —la hipótesis de traslación queda rechazada, no simplemente sin confirmar—, resultado que constituye en sí mismo un aporte metodológico.

2. Entre los métodos del estado del arte no hay dominancia global: DTCWT lidera la similitud estructural ($SSIM = 0,7249$), la pirámide de Laplace el contraste ($SD = 0,1550$) y la información mutua con las fuentes, y el PSNR más alto corresponde a los métodos multiescala (CVT y DTCWT); la elección del comparativo altera el podio según la métrica priorizada, lo que refuerza la necesidad de evaluar con familias de métricas complementarias.

3. La propuesta presenta el mejor ranking global agregado (3,39 sobre los 7 métodos), sostenido por su liderazgo en el rango medio de entropía, contraste y eficiencia de

fusión y por su segundo puesto en gradiente medio y frecuencia espacial, y penalizada por las métricas de fidelidad a las fuentes; la sigue la pirámide de Laplace (3,91), sostenida por su ventaja en información mutua con las fuentes y por el mayor contraste promedio del estudio.

4. La información mutua premia la combinación lineal: en la ablación de la sección 5.8.3, el brazo sin operador —la imagen base $(VIS + IR)/2$ — obtiene la mayor información mutua con ambas fuentes de los seis brazos ($MI_{vis} = 1,3120$ y $MI_{ir} = 0,8537$, frente a 0,8970 y 0,6003 de la suma de ramas) junto con el contraste más bajo ($SD = 0,1055$). Conviene por tanto reportar MI siempre junto a métricas de actividad y no interpretarla aisladamente como veredicto de fidelidad.

5. Dentro de la familia Top-Hat, la forma de combinar las respuestas del banco introduce diferencias modestas. Con el radio y el peso igualados en (25; 0,30), la ablación de seis brazos ordena así el rango medio de las nueve métricas: suma de disco y promedio de líneas 3,222; máximo entre ambas ramas 3,311; disco único 3,367; promedio de ambas 3,533; y, últimas y empatadas, las líneas solas y la imagen base sin operador 3,783. No se compararon geometrías alternativas de elemento estructurante —cuadrado o cruz—, que no forman parte de la implementación.

6. Los dos hiperparámetros del método son el radio r y el peso m ; no hay profundidad de descomposición ni radio base, porque el operador es de una sola escala. Sus efectos son opuestos y bien delimitados: el radio gobierna la escala de las estructuras que el operador extrae —la aptitud del trabajo de referencia favorece $r = 1$ y la batería de evaluación $r = 25$ — y el peso gobierna la intensidad del realce, con el recorte por saturación creciendo del 0,73 % en $m = 0,30$ al 6,50 % en $m = 1$.

7. Las pruebas no paramétricas confirman que las diferencias observadas no son fruto del azar: la prueba de Friedman rechaza la igualdad en las nueve métricas, con valores p entre $8,4 \cdot 10^{-22}$ y $1,1 \cdot 10^{-10}$, y las comparaciones pareadas Wilcoxon con corrección de Holm corroboran las superioridades específicas reportadas (ganancia significativa en entropía, eficiencia de fusión, gradiente medio y frecuencia espacial frente a los cinco métodos del estado del arte).

8. El realce morfológico se paga en artefactos, y conviene declararlo: en Nabf —la única métrica del estudio que los mide, y que no integra la batería de nueve— los dos operadores morfológicos son los más agresivos del benchmark, con 0,374 la propuesta y 0,586 el Top-Hat clásico, frente a 0,114 de la pirámide de Laplace. No se evaluó una variante que prescindiera de la

rama Black Top-Hat: el esquema aditivo-sustractivo se emplea completo en todas las configuraciones, de modo que la contribución aislada de esa rama queda como trabajo futuro.

9. Es metodológicamente fundamental separar la regla de fusión de detalle (max-actividad por pixel) de la regla de fusión de la base (promedio): aplicar selección por actividad a la capa base introduce discontinuidades de iluminación y sesga las métricas de información mutua. Este aprendizaje es transferible a cualquier descomposición multiescala.

10. No existe un método universalmente óptimo: la decisión de qué algoritmo de fusión emplear debe estar guiada por el criterio operativo prioritario más que por una métrica única.

6.2 Recomendaciones

A partir de los hallazgos se proponen las siguientes líneas de trabajo futuro y de aplicación.

Repetir toda evaluación orientada a tarea con varias semillas de entrenamiento y reportar la dispersión junto con la media, empezando por M3FD, que conserva un único entrenamiento por entrada. En LLVIP, 5 semillas mostraron que el desvío de una misma entrada (0,0128 de $mAP@0,5$) es del orden de la distancia que separa a las fusiones entre sí, de modo que un único entrenamiento por entrada no autoriza a ordenarlas.

- Profundizar en reglas de fusión que aprovechen el Black Top-Hat de forma selectiva (p. ej. ponderando el detalle oscuro por su consistencia con las fuentes) para atenuar los artefactos que el esquema WTH+BTH adoptado introduce: la propuesta es el operador con la tasa de artefactos más alta del benchmark después del Top-Hat clásico ($N_{abf} = 0,374$ frente a 0,586 del clásico y 0,114 de la pirámide de Laplace).
- Replicar la evaluación sobre datasets adicionales (RoadScene, M3FD, MS-COCO multispectral) para verificar la transferibilidad de las conclusiones.
- Explorar reglas de fusión adaptativas que ponderen la actividad local en función de estadísticos globales de la imagen, en lugar de la regla de máximo aplicada en este trabajo.
- Evaluar híbridos Top-Hat $\leftrightarrow$ pirámide de Laplace que combinen la fidelidad a fuentes del primero con la riqueza global del segundo.

- Comparar contra modelos de fusión profundos preentrenados (FusionGAN, U2Fusion, SeAFusion) para situar el costo y el beneficio de los métodos clásicos en el panorama actual del estado del arte.
- Seleccionar el método de fusión según el criterio operativo prioritario: para aplicaciones donde prima la riqueza informativa y el detalle de la imagen fusionada, emplear la Propuesta Novedosa ($r = 25$, $m = 0,30$), que lidera la entropía y la eficiencia de fusión del benchmark con un realce controlado; para aplicaciones donde prima la fidelidad a las fuentes, los métodos multiescala (DTCWT, CVT) siguen siendo preferibles, y la metodología clásica Top-Hat conserva su valor como referencia interpretable y de muy bajo costo computacional.
- Reportar siempre la información mutua junto con métricas de calidad global (EN, SD, MG) para evitar interpretaciones engañosas; el caso de la imagen base sin operador de la sección 5.8.3 ilustra que MI alta no equivale necesariamente a fusión de mejor calidad perceptual.

7. REFERENCIAS BIBLIOGRÁFICAS

Aslantas, V., y Bendes, E. (2015). A new image quality metric for image fusion: The sum of the correlations of differences. *AEU - International Journal of Electronics and Communications*, 69(12), 1890–1896. <https://doi.org/10.1016/j.aeue.2015.09.004>

Bai, X. (2013). Morphological image fusion using the extracted image regions and details based on multi-scale top-hat transform and toggle contrast operator. *Digital Signal Processing*, 23(2), 542–554. <https://doi.org/10.1016/j.dsp.2012.11.001>

Bai, X., Zhou, F., y Xue, B. (2012). Image enhancement using multi scale image features extracted by top-hat transform. *Optics & Laser Technology*, 44(2), 328–336. <https://doi.org/10.1016/j.optlastec.2011.07.009>

Bajac Figueredo, Y. C., Bazán, J. P., Mello-Román, J. C., Vázquez Noguera, J. L., y Legal-Ayala, H. (2024). Infrared and visible image fusion using the Top Hat transform. *Proceeding Series of the Brazilian Society of Computational and Applied Mathematics (CNMAC 2024)*, Universidad Comunera y Facultad Politécnica, Universidad Nacional de Asunción.

Bala, A. A., Aruna Priya, P., y Maik, V. (2024). Hybrid technique for fundus image enhancement using modified morphological filter and denoising net. *The Journal of Supercomputing*, 80(9), 13317–13340. <https://doi.org/10.1007/s11227-024-05952-x>

Burt, P. J., y Adelson, E. H. (1983). The Laplacian pyramid as a compact image code. *IEEE Transactions on Communications*, 31(4), 532–540.

Candès, E., Demanet, L., Donoho, D., y Ying, L. (2006). Fast discrete curvelet transforms. *SIAM Multiscale Modeling & Simulation*, 5(3), 861–899.

Flores, S., Bujaico, C., Mello-Román, J. C., Vázquez Noguera, J. L., y Legal-Ayala, H. (s. f.). Método de realce de contraste local y nitidez en imágenes mamográficas basado en la transformada top-hat multiescala con elementos estructurantes circulares y lineales [Manuscrito]. *Digital Image Processing Research Group, Facultad Politécnica, Universidad Nacional de Asunción*.

Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200), 675–701.

- Gonzalez, R. C., y Woods, R. E. (2018). Digital Image Processing (4^a ed.). Pearson.
- Haghighat, M., Aghagolzadeh, A., y Seyedarabi, H. (2011). A non-reference image fusion metric based on mutual information of image features. *Computers & Electrical Engineering*, 37(5), 744–756. <https://doi.org/10.1016/j.compeleceng.2011.07.012>
- Jia, X., Zhu, C., Li, M., Tang, W., y Zhou, W. (2021). LLVIP: A visible-infrared paired dataset for low-light vision. *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*, 3489–3497. <https://doi.org/10.1109/ICCVW54120.2021.00389>
- Jocher, G., Chaurasia, A., y Qiu, J. (2023). Ultralytics YOLOv8 (versión 8.0.0) [software]. <https://github.com/ultralytics/ultralytics>
- Kennedy, J., y Eberhart, R. (1995). Particle swarm optimization. *Proceedings of ICNN'95 - International Conference on Neural Networks*, 4, 1942–1948.
- Kingsbury, N. (2001). Complex wavelets for shift invariant analysis and filtering of signals. *Applied and Computational Harmonic Analysis*, 10(3), 234–253. <https://doi.org/10.1006/acha.2000.0343>
- Li, S., Kang, X., Fang, L., Hu, J., y Yin, H. (2017). Pixel-level image fusion: A survey of the state of the art. *Information Fusion*, 33, 100–112.
- Liu, J., Fan, X., Huang, Z., Wu, G., Liu, R., Zhong, W., y Luo, Z. (2022). Target-aware dual adversarial learning and a multi-scenario multi-modality benchmark to fuse infrared and visible for object detection. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 5792–5801. <https://doi.org/10.1109/CVPR52688.2022.00571>
- Ma, J., Ma, Y., y Li, C. (2019). Infrared and visible image fusion methods and applications: A survey. *Information Fusion*, 45, 153–178.
- Ma, J., Yu, W., Liang, P., Li, C., y Jiang, J. (2019). FusionGAN: A generative adversarial network for infrared and visible image fusion. *Information Fusion*, 48, 11–26.
- Malviya, P., y Saxena, A. K. (2014). An improved image fusion technique based on texture feature optimization using wavelet transform and particle of swarm optimization (POS). *International Journal of Computer Applications*, 101(6), 19–22.

Mukhopadhyay, S., y Chanda, B. (2000). A multiscale morphological approach to local contrast enhancement. *Signal Processing*, 80(4), 685–696. [https://doi.org/10.1016/S0165-1684\(99\)00161-9](https://doi.org/10.1016/S0165-1684(99)00161-9)

Ortega Rodríguez, M. A., y Espinoza Ríos, G. A. (2025). Optimización de los parámetros de la transformada Top-Hat mediante PSO para la fusión de imágenes visibles e infrarrojas. Proyecto de Trabajo Final de Grado, Facultad Politécnica, Universidad Nacional de Asunción.

Piella, G., y Heijmans, H. (2003). A new quality metric for image fusion. *Proceedings IEEE ICIP*, vol. 3, 173–176. <https://doi.org/10.1109/ICIP.2003.1247209>

Redmon, J., Divvala, S., Girshick, R., y Farhadi, A. (2016). You only look once: Unified, real-time object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779–788. <https://doi.org/10.1109/CVPR.2016.91>

Román, J. C. M., Vázquez Noguera, J. L., y Legal-Ayala, H. (2020). A multiscale morphological method for visible and infrared images fusion. *Proceedings of the 2020 XLVI Latin American Computing Conference (CLEI)*, 488–495. IEEE.

Serra, J. (1982). *Image Analysis and Mathematical Morphology*. Academic Press.

Sheikh, H. R., y Bovik, A. C. (2006). Image information and visual quality. *IEEE Transactions on Image Processing*, 15(2), 430–444. <https://doi.org/10.1109/TIP.2005.859378>

Singh, S., Singh, H., Bueno, G., Deniz, O., Singh, S., Monga, H., Hrisheekesha, P. N., y Pedraza, A. (2023). A review of image fusion: Methods, applications and performance metrics. *Digital Signal Processing*, 137, 104020.

Soille, P. (2003). *Morphological Image Analysis: Principles and Applications* (2^a ed.). Springer.

Tang, L., Yuan, J., y Ma, J. (2022). Image fusion in the loop of high-level vision tasks: A semantic-aware real-time infrared and visible image fusion network. *Information Fusion*, 82, 28–42.

Tao, J., Li, S., y Yang, B. (2010). Multimodal image fusion algorithm using dual-tree complex wavelet transform and particle swarm optimization. En *Advanced Intelligent Computing Theories and Applications (Communications in Computer and Information Science*, vol. 93, pp. 296–303). Springer.

Toet, A. (1989). Image fusion by a ratio of low-pass pyramid. *Pattern Recognition Letters*, 9(4), 245–253.

Toet, A. (2017). The TNO multiband image data collection. *Data in Brief*, 15, 249–251. <https://doi.org/10.1016/j.dib.2017.09.038>

Wang, J., Peng, J., Feng, X., He, G., y Fan, J. (2014). Fusion method for infrared and visible images by using non-negative sparse representation. *Infrared Physics & Technology*, 67, 477–489. <https://doi.org/10.1016/j.infrared.2014.09.019>

Wang, Z., Bovik, A. C., Sheikh, H. R., y Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612. <https://doi.org/10.1109/TIP.2003.819861>

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83.

Xydeas, C. S., y Petrović, V. (2000). Objective image fusion performance measure. *Electronics Letters*, 36(4), 308–309. <https://doi.org/10.1049/el:20000267>

Zhang, X., y Demiris, Y. (2023). Visible and infrared image fusion using deep learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(8), 10535–10554.

8. APÉNDICE

A. Repositorio del código

La totalidad del código de esta tesis está disponible en el repositorio del proyecto, organizado en módulos: `src/datasets.py` (carga y emparejado VIS/IR), `src/fusion/` (`optimal_top_hat.py` para la propuesta —operador de suma de ramas, función `fuse_optimal`— y `comparatives.py` para los seis métodos comparativos: LP, RP, DWT, DTCWT, CVT y la fusión Top-Hat clásica), `src/metrics/evaluators.py` (las nueve métricas), `src/utils/` (entrada/salida y visualización), `experiments/run_all_fusions.py` (benchmark inter-método), `experiments/run_stats_analysis.py` (Friedman, Wilcoxon con Holm y ranking), `experiments/psa_grid_search.py` (barrido de 25 configuraciones del PSO con la aptitud Fo), `experiments/detection_llvip/` (preparación, entrenamiento y estudio de semillas en LLVIP), `notebooks/` (análisis exploratorios). El archivo `requirements.txt` consigna las dependencias exactas.

B. Configuraciones del barrido PSO

Las 25 configuraciones evaluadas resultan del producto cartesiano de los siguientes valores:

- Número de partículas del enjambre: 2, 4, 6, 8, 10.
- Número de iteraciones: 10, 20, 30, 40, 50.
- Espacio de búsqueda: $r \in [1, 25]$; $m \in [0,30; 2,00]$.

Cada combinación del barrido ejecuta una corrida PSO independiente con semilla propia (25 corridas, 4.500 evaluaciones de fusión en total). El estado completo y reanudable se conserva en `experiments/results/psa/psa_grid_fo_propuesta_state.json` y la tabla resumen en `experiments/results/metrics_reports/psa_grid_search_fo_propuesta.csv`.

C. Tablas estadísticas extendidas

Las tablas completas con los 99 contrastes Wilcoxon (la propuesta frente a los 5 métodos del estado del arte y frente al Top-Hat clásico, y el Top-Hat clásico frente a los mismos 5, en las 9 métricas) se almacenan en `experiments/results/metrics_reports/wilcoxon_results.csv`. Cada fila contiene la métrica, las medias comparadas, la diferencia, el estadístico W, el p-valor, el p-valor corregido por Holm, la marca de significación a $\alpha = 0,05$ y el tamaño de efecto rank-biserial. El ranking promedio está en `ranking_methods.csv` y los resultados de Friedman en

friedman_results.csv. Los 54 contrastes de la propuesta frente a sus seis rivales (9 métricas $\times$ 6 rivales: los cinco del estado del arte y el Top-Hat clásico, Wilcoxon con Holm y tamaño de efecto rank-biserial) se consignan en wilcoxon_propuesta_vs_metodos.csv.

D. Pseudocódigo de la fusión Top-Hat clásica

Entrada: imágenes f_{VIS} , f_{IR} (escala de grises, normalizadas en $[0,1]$), radio r del disco ($r = 5$). Salida: imagen fusionada F . 1. $I_{\text{base}} \leftarrow (f_{\text{VIS}} + f_{\text{IR}})/2$. 2. Para cada fuente S : $\text{WTH}_S \leftarrow S - \text{apertura}(S, \text{disco}(r))$; $\text{BTH}_S \leftarrow \text{cierre}(S, \text{disco}(r)) - S$. 3. $\text{WTH}_{\text{max}} \leftarrow \max(\text{WTH}_{\text{VIS}}, \text{WTH}_{\text{IR}})$; $\text{BTH}_{\text{max}} \leftarrow \max(\text{BTH}_{\text{VIS}}, \text{BTH}_{\text{IR}})$. 4. $F \leftarrow \text{recortar}(I_{\text{base}} + \text{WTH}_{\text{max}} - \text{BTH}_{\text{max}}, [0,1])$.

Pseudocódigo de la Propuesta Novedosa (una sola escala)

ENTRADA: I_{VIS} , I_{IR} en $[0,1]$ alineadas; radio r ; peso m
SALIDA: imagen fusionada F

```
para cada fuente S en {I_VIS, I_IR}:
  L <- {linea(r,0), linea(r,45), linea(r,90), linea(r,135)} # 4 lineas
  WTH_lin <- promedio_{b en L} ( S - apertura(S,b) ) # ec. (7)
  BTH_lin <- promedio_{b en L} ( cierre(S,b) - S )
  WTH_disco <- S - apertura(S, disco(r)) # ec. (8)
  BTH_disco <- cierre(S, disco(r)) - S
  Iopt_top[S] <- WTH_lin + WTH_disco # ec. (9)
  Iopt_bot[S] <- BTH_lin + BTH_disco

# combinacion entre fuentes (maximo por pixel) # ec. (10)
Iopt_top <- max(Iopt_top[VIS], Iopt_top[IR])
Iopt_bot <- max(Iopt_bot[VIS], Iopt_bot[IR])
I_base <- (I_VIS + I_IR) / 2
F <- recortar( I_base + m*Iopt_top - m*Iopt_bot, 0, 1 ) # ec. (11)
devolver F
```

(r , m) se optimizan por PSO (barrido de 25 configuraciones) $\rightarrow r = 25$, $m = 0,30$

Nota: la versión definitiva y única del método (sección 2.2.5) promedia las cuatro respuestas lineales y las suma a la del disco sobre una sola escala —sin descomposición multiescala ni diferencias en cascada— y optimiza (r , m) por PSO mediante un barrido de 25 configuraciones de enjambre, con óptimo $r = 25$, $m = 0,30$. Su implementación de referencia es src/fusion/optimal_top_hat.py (función fuse_optimal, modo 'sum').

E. Refinamiento metodológico de la regla de fusión

Durante el desarrollo iterativo de la implementación se identificó un punto sutil pero sustantivo en la regla de fusión multiescala. Una primera versión aplicaba selección por máxima actividad local de manera uniforme a todas las capas, incluyendo la base. La distinción correcta separa las dos clases de capas: las de detalle se fusionan por máxima actividad local y la base por promedio simple. Conviene precisar el alcance: esto concierne a los métodos comparativos multiescala, no al operador propuesto, que es de una sola escala y no tiene capas —su única

respuesta de detalle se combina por máximo entre fuentes y se reconstruye sobre $I_{\text{base}} = (\text{VIS} + \text{IR})/2$, promedio simple de las dos fuentes por definición—. Esta distinción es coherente con la práctica establecida en la literatura clásica de fusión multiescala. El refinamiento eliminó discontinuidades de iluminación y sesgos artificiales en la información mutua.

F. Hardware y tiempos de ejecución

La totalidad de los experimentos se ejecutó en una notebook estándar (Intel i7, 16 GB de RAM, sin GPU dedicada) bajo Windows 11 con Python 3.11. Cada fusión Top-Hat consume entre 20 y 80 milisegundos según la configuración; la pirámide de Laplace y el curvelet se sitúan en órdenes de magnitud comparables. La ejecución completa del benchmark (140 fusiones: 7 métodos $\times$ 20 pares) toma aproximadamente 90 segundos. Esta liviandad computacional confirma la viabilidad del método para aplicaciones en tiempo real.