



**Universidad
Comunera**

FACULTAD DE CIENCIAS Y TECNOLOGÍA

MAESTRÍA EN CIENCIAS DE DATOS

FUSIÓN DE IMÁGENES INFRARROJAS Y VISIBLES MEDIANTE MORFOLOGÍA MATEMÁTICA

Una propuesta de Top-Hat/Bottom-Hat de una sola escala con elementos estructurantes de disco y lineales, optimizada por PSO

Autores:

Lic. Juan Pablo Bazán

Ing. Yan Bajac

Tesis presentada a la Universidad Comunera, Facultad de Ciencias y Tecnología, Maestría en Ciencias de Datos, como requisito parcial para la obtención del título de Magíster en Ciencias de Datos.

Asunción – Paraguay

SEPTIEMBRE 2026

FUSIÓN DE IMÁGENES INFRARROJAS Y VISIBLES MEDIANTE MORFOLOGÍA MATEMÁTICA

Una propuesta de Top-Hat/Bottom-Hat de una sola escala con elementos estructurantes de disco y lineales, optimizada por PSO

Autores:

Lic. Juan Pablo Bazán

Ing. Yan Bajac

Orientador:

D.Sc. Julio César Mello

Tesis presentada a la Universidad Comunera, Facultad de Ciencias y Tecnología, Maestría en Ciencias de Datos, como requisito parcial para la obtención del título de Magíster en Ciencias de Datos.

Asunción – Paraguay

SEPTIEMBRE 2026

PÁGINA DE APROBACIÓN

Esta tesis, titulada «Fusión de Imágenes Infrarrojas y Visibles mediante Morfología Matemática», fue presentada por Lic. Juan Pablo Bazán e Ing. Yan Bajac como requisito parcial para la obtención del título de Magíster en Ciencias de Datos, y aprobada por el siguiente tribunal examinador.

Director de Tesis – D.Sc. Julio César Mello

Examinador 1

Examinador 2

Asunción, Paraguay

2026

DEDICATORIA

A nuestras familias, por sostener cada noche larga y cada decisión difícil que llevó este trabajo a término.

A nuestros profesores y compañeros de la Maestría en Ciencias de Datos, por las discusiones que afilaron las ideas.

Y a la comunidad de software libre, sin la cual una tesis empírica como esta sería materialmente imposible.

AGRADECIMIENTOS

A la Universidad Comunera (UCOM) y a la Facultad de Ciencias y Tecnología, por brindar el marco académico de la Maestría en Ciencias de Datos.

A nuestro director de tesis, D.Sc. Julio César Mello, por el rigor metodológico, la paciencia y la orientación constante a lo largo del desarrollo de este trabajo.

A los autores y mantenedores del dataset TNO Image Fusion Dataset, cuyo material puesto a disposición pública hizo posible la evaluación experimental.

A los desarrolladores de las bibliotecas científicas de Python (NumPy, OpenCV, scikit-image, SciPy, PyWavelets, Matplotlib, Pandas), pilares de toda la implementación.

A nuestros colegas y compañeros de cohorte, por las revisiones cruzadas y los comentarios que mejoraron tanto el código como la redacción.

RESUMEN

La fusión de imágenes visible (VIS) e infrarroja (IR) es clave para la percepción computacional en condiciones adversas (vigilancia, conducción nocturna, búsqueda y rescate). Este trabajo propone la PROPUESTA NOVEDOSA, un método de fusión basado en la transformada Top-Hat que, sobre una única escala, promedia las respuestas de cuatro elementos estructurantes lineales (0° , 45° , 90° , 135°) y las suma a la respuesta de un disco para obtener transformadas Top-Hat y Bottom-Hat óptimas; la reconstrucción sigue el esquema aditivo–sustractivo de Bala et al., y el radio r del banco de elementos estructurantes y el peso de contraste m se ajustan automáticamente por Optimización por Enjambre de Partículas (PSO), cuya configuración se selecciona mediante un barrido sistemático de 25 combinaciones de partículas e iteraciones ($2-10 \times 10-50$), replicando el diseño experimental de Ortega y Espinoza (2025). Se lo compara con seis métodos: cinco representativos del estado del arte —pirámide de Laplace (LP), Ratio of low-pass Pyramid (RP), wavelet discreta (DWT), Dual-Tree Complex Wavelet (DTCWT) y curvelet (CVT)— y la metodología clásica de la transformada Top-Hat, sobre el TNO Image Fusion Dataset, con nueve métricas sin referencia bajo pruebas no paramétricas (Friedman y Wilcoxon con corrección de Holm). En su configuración óptima (PSO: $r=25$, $m=0,070$) la propuesta alcanza la mayor similitud estructural del estudio (SSIM=0,782), significativamente superior a los cinco métodos del estado del arte, y se ubica segunda en información mutua con las fuentes (MI); es más conservadora en las métricas de actividad y contraste (EN, SD, SF), lideradas por los métodos de mayor realce como el Top-Hat clásico y la pirámide de Laplace. Como evaluación orientada a tarea, el reentrenamiento de un detector (YOLOv8n) sobre el conjunto etiquetado LLVIP muestra que toda fusión supera con claridad al visible solo (mAP@0,5 de 0,81 a 0,93–0,95), aunque el infrarrojo solo es la modalidad más fuerte (0,957) y la propuesta resulta competitiva (0,936) sin liderar, evidenciando que la superioridad en calidad de imagen no se traslada automáticamente a la detección. En un experimento complementario sobre M3FD, con dos clases de visibilidad opuesta (personas/IR y luces/VIS) y un único detector entrenado con ambas modalidades, la fusión detecta ambas clases en una sola imagen y la propuesta es la mejor fusión del estudio (mAP@0,5 = 0,239). Se concluye que la propuesta destaca en fidelidad estructural (SSIM) y preservación de información, aporta un operador morfológico de una sola escala interpretable y de bajo costo optimizado con una metodología publicada (Ortega y Espinoza, 2025), y resulta competitiva en la evaluación orientada a tarea —siendo la mejor fusión en el escenario de clases complementarias—.

Palabras clave: fusión de imágenes, morfología matemática, top-hat, infrarrojo, visible, PSO, métricas sin referencia.

SUMMARY

Visible (VIS) and infrared (IR) image fusion is key for computer perception under adverse conditions (surveillance, night driving, search and rescue). This work proposes the NOVEL PROPOSAL, a fusion method based on the Top-Hat transform that, on a single scale, averages the responses of four linear structuring elements (0° , 45° , 90° , 135°) and adds them to the disk response to obtain optimal Top-Hat and Bottom-Hat transforms; reconstruction follows the additive–subtractive scheme of Bala et al., and the structuring-element radius r and the contrast weight m are tuned automatically by Particle Swarm Optimization (PSO), whose configuration is selected through a systematic sweep of 25 particle/iteration combinations ($2\text{--}10 \times 10\text{--}50$), replicating the experimental design of Ortega and Espinoza (2025). It is compared against six methods: five representative of the state of the art —Laplacian pyramid (LP), Ratio of low-pass Pyramid (RP), Discrete Wavelet Transform (DWT), Dual-Tree Complex Wavelet Transform (DTCWT) and Curvelet (CVT)— plus the classical Top-Hat fusion methodology, on the TNO Image Fusion Dataset, using nine no-reference metrics under non-parametric testing (Friedman, Wilcoxon with Holm correction). At its optimal configuration (PSO: $r=25$, $m=0.070$) the proposal attains the highest structural similarity of the study (SSIM=0.782), significantly above the five state-of-the-art methods, and ranks second in mutual information with the sources (MI); it is more conservative in activity and contrast metrics (EN, SD, SF), led by higher-enhancement methods such as the classical Top-Hat and the Laplacian pyramid. As a task-oriented evaluation, retraining a detector (YOLOv8n) on the labeled LLVIP dataset shows that every fusion clearly outperforms the visible modality alone (mAP@0.5 from 0.81 to 0.93–0.95), although the infrared alone remains the strongest modality (0.957) and the proposal is competitive (0.936) without leading, evidencing that superiority in image quality does not automatically transfer to detection. In a complementary experiment on M3FD, with two classes of opposite visibility (people/IR and lamps/VIS) and a single detector trained on both modalities, fusion detects both classes in a single image and the proposal is the best fusion in the study (mAP@0.5 = 0.239). We conclude that the proposal stands out in structural fidelity (SSIM) and information preservation, contributes an interpretable single-scale morphological operator optimized with a published methodology (Ortega and Espinoza, 2025), and is competitive in the task-oriented evaluation —the best fusion in the complementary-class scenario—.

Keywords: image fusion, mathematical morphology, top-hat, infrared, visible, multi-scale, no-reference metrics.

CONTENIDO

LISTA DE SIGLAS.....	8
LISTA DE FIGURAS.....	8
LISTA DE TABLAS.....	8
INTRODUCCIÓN.....	14
1. PROBLEMA DE INVESTIGACIÓN.....	16
1.1 Descripción del problema.....	16
1.2 Justificación e importancia.....	16
1.3 Objetivos.....	17
1.3.1 General.....	17
1.3.2 Específicos.....	17
1.4 Formulación del problema.....	17
1.4.1 Problema general.....	17
1.4.2 Problemas específicos.....	18
1.5 Hipótesis.....	18
1.6 Limitaciones de la investigación.....	18
1.7 Alcance.....	19
2. MARCO TEÓRICO.....	20
2.1 Estado del arte.....	20
2.2 Fundamentación teórica.....	21
2.2.1 Fusión de imágenes multimodal.....	21
2.2.2 Morfología matemática.....	22
2.2.3 Transformada Top-Hat.....	22
2.2.4 Metodología clásica de fusión Top-Hat.....	23
2.2.5 Propuesta Novedosa: método de fusión Top-Hat con elementos estructurantes circulares y lineales optimizado por PSO.....	24
2.2.6 Métodos comparativos del benchmark.....	29
2.2.7 Métricas de evaluación.....	29
3. MARCO CONCEPTUAL.....	33
3.1 Imagen visible (VIS).....	33
3.2 Imagen infrarroja (IR).....	33
3.3 Elemento estructurante (SE).....	33
3.4 White Top-Hat (WTH).....	33

3.5 Black Top-Hat (BTH).....	33
3.6 Descomposición multiescala.....	33
3.7 Regla de fusión por actividad local.....	33
3.8 Métrica sin referencia.....	34
3.9 Prueba de Friedman.....	34
3.10 Prueba de Wilcoxon.....	34
3.11 Elemento estructurante lineal.....	34
3.12 Combinación de respuestas por suma.....	34
3.13 Fusión Top-Hat clásica.....	34
3.14 Peso de ajuste de contraste (m).....	35
3.15 Optimización por Enjambre de Partículas (PSO).....	35
3.16 Función de aptitud.....	35
4. MARCO METODOLÓGICO.....	36
4.1 Enfoque.....	36
4.2 Tipo.....	36
4.3 Diseño.....	36
4.4 Operacionalización de las variables.....	36
4.5 Dataset y preprocesamiento.....	37
4.6 Implementación.....	38
4.7 Análisis estadístico.....	38
5. ANÁLISIS E INTERPRETACIÓN DE RESULTADOS.....	39
5.1 Caracterización del dataset.....	39
5.2 Análisis cualitativo: comparación visual.....	39
5.3 Resultados cuantitativos: promedio por método.....	40
5.4 Análisis estadístico no paramétrico.....	43
5.4.1 Prueba de Friedman global.....	43
5.4.2 Comparaciones pareadas Wilcoxon.....	44
5.4.3 Ranking promedio.....	44
5.5 Evaluación orientada a tarea: detección con YOLO (LLVIP y M3FD).....	48
5.6 Propuesta Novedosa (método central).....	50
5.7 Discusión integrada.....	53
6. CONCLUSIONES Y RECOMENDACIONES.....	55
6.1 Conclusiones.....	55

6.2 Recomendaciones.....	56
7. REFERENCIAS BIBLIOGRÁFICAS.....	58
8. APÉNDICE.....	61
A. Repositorio del código.....	61
B. Configuraciones del barrido PSO.....	61
C. Tablas estadísticas extendidas.....	61
D. Pseudocódigo de la fusión Top-Hat clásica.....	62
E. Refinamiento metodológico de la regla de fusión.....	62
F. Hardware y tiempos de ejecución.....	63

LISTA DE SIGLAS

Sigla	Significado
VIS	Espectro visible
IR	Infrarrojo
SE	Elemento estructurante (Structuring Element)
WTH	White Top-Hat (Top-Hat blanco)
BTH	Black Top-Hat (Top-Hat negro)
MM	Morfología matemática
EN	Entropía de Shannon
SD	Desviación estándar
FE	Factor / eficiencia de fusión
MG	Gradiente medio
MI	Información mutua (Mutual Information)
TNO	TNO Image Fusion Dataset (Países Bajos)
PCA	Análisis de componentes principales
DWT	Transformada wavelet discreta
DTCWT	Transformada wavelet compleja de árbol dual
CNN	Red neuronal convolucional
GAN	Red generativa antagónica
SF	Frecuencia espacial (Spatial Frequency)
Qabf	Métrica de preservación de bordes (Xydeas-Petrovic)
Nabf	Artefactos añadidos por la fusión (menor es mejor)
SSIM	Índice de similitud estructural (Structural Similarity)
SCD	Suma de correlaciones de las diferencias
VIF	Fidelidad de información visual (Visual Information Fidelity)

Sigla	Significado
YOLO	You Only Look Once (detector de objetos)
FPS	Cuadros por segundo (Frames Per Second)
mAP	Precisión media promedio (mean Average Precision)
PSO	Optimización por Enjambre de Partículas (Particle Swarm Optimization)
PSNR	Relación señal-ruido de pico (Peak Signal-to-Noise Ratio)

LISTA DE FIGURAS

Figura 1. Operaciones morfológicas (erosión, dilatación, apertura y cierre) y transformada Top-Hat sobre un perfil de intensidad.

Figura 2. Esquema conceptual de la fusión Top-Hat clásica: disco único, combinación por máximo entre fuentes y reconstrucción sin ponderación.

Figura 3. Banco de cinco elementos estructurantes (un disco y cuatro líneas) empleados por el operador en la escala de radio r .

Figura 4. Flujograma de la Propuesta Novedosa (proceso paso a paso).

Figura 5. Optimización por enjambre de partículas (PSO) del vector de hiperparámetros (r , m).

Figura 6. Comparación cualitativa de los métodos de fusión sobre tres pares representativos del dataset.

Figura 7. Diagramas de caja de seis métricas representativas (SSIM, SF, EN, SD, MI_{ir}, PSNR) por método ($n = 20$ pares VIS/IR).

Figura 8. Ranking global por método (promedio de rangos sobre las nueve métricas, con la dirección de cada una corregida).

Figura 9. Detecciones del modelo único VIS+IR en dos escenas de M3FD: la fusión recupera las personas que el visible pierde y las luces que el infrarrojo pierde.

Figura 10. Propuesta Novedosa (PSO: $r = 25$, $m = 0,070$) frente a la metodología clásica Top-Hat y al estado del arte.

Figura 11. Convergencia del PSO según el número de partículas (izq.) y aptitud del barrido de configuraciones (der.), sobre tres escenas representativas.

LISTA DE TABLAS

Tabla 1. Notación empleada en el marco teórico.

Tabla 2. Configuración de la Propuesta Novedosa y del PSO.

Tabla 3. Métodos comparativos del benchmark.

Tabla 4. Promedios de las seis métricas clásicas por método ($n = 20$).

Tabla 5. Promedios de frecuencia espacial (SF), similitud estructural (SSIM) y PSNR por método ($n = 20$ pares).

Tabla 6. Prueba de Friedman por métrica (χ^2 , p-valor; $\alpha = 0,05$).

Tabla 7. Ranking promedio por método y métrica (1 = mejor).

Tabla 8. Detección de peatones en LLVIP — mAP por modalidad (YOLOv8n; subconjunto 2000 train / 500 val, 40 épocas).

Tabla 9. Clases complementarias en M3FD: AP@0,5 por clase y mAP global con un detector único VIS+IR.

Tabla 10. Propuesta Novedosa frente a la metodología clásica Top-Hat y al estado del arte — medias sobre 20 pares ($n = 20$).

Tabla 11. Barrido de configuraciones del PSO: mejor aptitud F por combinación de partículas (n) e iteraciones (T).

INTRODUCCIÓN

La percepción visual computacional moderna depende, en numerosas aplicaciones críticas, de la integración de información proveniente de sensores complementarios. Las cámaras del espectro visible (VIS) capturan la reflectancia de la luz solar, ofreciendo alta resolución textural y cromática, pero degradándose ante condiciones de iluminación adversas como noche cerrada, niebla densa o humo. Por su parte, las cámaras infrarrojas (IR), particularmente las del rango térmico de onda larga, registran la radiación emitida por los cuerpos según su temperatura, siendo robustas a la oscuridad y a la mayoría de los ocluidores atmosféricos, aunque con menor resolución espacial y escaso detalle de textura. La fusión de imágenes VIS+IR busca reunir estas fortalezas complementarias en una sola representación que sea, simultáneamente, rica en detalles, discriminativa térmicamente y útil para tareas posteriores de detección, clasificación o decisión.

Las aplicaciones que se benefician de esta integración son numerosas y de alto impacto: vigilancia perimetral, búsqueda y rescate, conducción de vehículos autónomos en condiciones de baja visibilidad, sistemas de visión nocturna para defensa, inspección no destructiva en líneas de producción y diagnóstico médico complementario. En todas ellas, la calidad de la imagen fusionada condiciona directamente la calidad del análisis subsiguiente.

Existen, en términos generales, tres familias de métodos de fusión: las de píxel, ampliamente estudiadas y operadas sobre intensidades; las de característica, que extraen rasgos abstractos antes de combinar; y las de decisión, que fusionan salidas de clasificadores. Dentro del nivel píxel, las técnicas multiescala (pirámides, wavelets, curvelets) y las morfológicas han sido pilares clásicos por su interpretabilidad y bajo costo computacional, en contraposición a los enfoques recientes basados en redes neuronales profundas, que ofrecen alto rendimiento pero demandan grandes volúmenes de datos pareados y operan como cajas negras.

Esta tesis se sitúa explícitamente en el espacio de los métodos clásicos interpretables. Propone como núcleo la Propuesta Novedosa, un método de fusión basado en la transformada Top-Hat que, sobre una única escala definida por el radio r , combina un banco de cinco elementos estructurantes —un disco y cuatro segmentos lineales a 0° , 45° , 90° y 135° , con las respuestas lineales promediadas y sumadas a la del disco para obtener transformadas óptimas— y reconstruye la imagen fusionada mediante el esquema aditivo–sustractivo de Bala et al. (2024) ponderado por el peso de contraste m ; sus hiperparámetros (radio r y peso m) se ajustan

automáticamente por Optimización por Enjambre de Partículas (PSO). Como línea base morfológica se emplea la metodología clásica de fusión Top-Hat —disco único, máximo entre fuentes y reconstrucción sin ponderación— y, como referencia externa, cinco métodos representativos del estado del arte (LP, RP, DWT, DTCWT y CVT). La hipótesis subyacente es que la sensibilidad direccional del banco de elementos estructurantes y la búsqueda automática de hiperparámetros permiten ajustar la fusión a las características del par VIS/IR sin renunciar a la transparencia algorítmica; complementariamente, se evalúa el impacto de la fusión en una tarea posterior de detección de objetos sobre un conjunto etiquetado (LLVIP).

El presente documento está organizado de la siguiente manera. En el capítulo de Problema de Investigación se delimita la pregunta científica y los objetivos. El Marco Teórico revisa el estado del arte y los fundamentos de morfología matemática, descomposición multiescala y métricas de evaluación. El Marco Conceptual define los términos operativos clave. El Marco Metodológico precisa el diseño experimental. El capítulo de Análisis e Interpretación de Resultados expone el benchmark de la propuesta frente a la metodología clásica Top-Hat y a los métodos de referencia del estado del arte, sustentado en pruebas estadísticas no paramétricas. Finalmente, las Conclusiones y Recomendaciones sintetizan los hallazgos y delinean trabajos futuros.

1. PROBLEMA DE INVESTIGACIÓN

1.1 Descripción del problema

Pese a más de tres décadas de investigación en fusión de imágenes multimodal, no existe un método universalmente óptimo: cada familia algorítmica presenta compromisos distintos entre preservación de detalle, contraste, transferencia de información y costo computacional. Los métodos basados en promedio, los más simples, sufren pérdida sistemática de detalle y reducción de contraste. Las pirámides de Laplace y los esquemas wavelet/curvelet ofrecen mejor manejo multiescala, pero pueden introducir artefactos de orla en bordes de alto contraste y son sensibles a desalineaciones residuales. Los métodos profundos, por su parte, requieren grandes corpora pareados y carecen de interpretabilidad.

La morfología matemática ofrece un marco intermedio: opera directamente sobre la geometría de las estructuras locales mediante elementos estructurantes (SE) parametrizables, lo cual la hace natural para preservar bordes y formas. La transformada Top-Hat, en particular, aísla con precisión los componentes de alta frecuencia que la apertura morfológica suprime. Sin embargo, la literatura existente sobre fusión morfológica suele restringirse a una única escala o a un único tipo de SE, sin un estudio sistemático que articule simultáneamente la geometría del SE, el número de niveles de descomposición y el radio base. Esta tesis aborda precisamente ese vacío empírico mediante un benchmark exhaustivo y la comparación con baselines clásicos.

1.2 Justificación e importancia

La justificación de este trabajo descansa sobre tres ejes. Primero, la relevancia aplicada: en contextos de vigilancia, seguridad pública y operaciones militares, los algoritmos de fusión deben ejecutarse bajo restricciones de tiempo real, sobre hardware limitado y con garantías de auditoría. La interpretabilidad y el bajo costo computacional de los métodos morfológicos los tornan especialmente valiosos en estos escenarios. Segundo, la relevancia metodológica: aportar evidencia empírica sistemática sobre el efecto de cada hiperparámetro (SE, L , r_0) ayuda a desmitificar decisiones de diseño que históricamente se han tomado por convención. Tercero, la relevancia académica regional: existen pocas tesis en el ámbito paraguayo que aborden de manera rigurosa la evaluación cuantitativa con pruebas no paramétricas en problemas de fusión multimodal, y este trabajo busca aportar a esa base.

1.3 Objetivos

1.3.1 General

Proponer y evaluar la Propuesta Novedosa, un método de fusión de imágenes visibles e infrarrojas basado en la transformada Top-Hat con elementos estructurantes circulares y lineales sobre una sola escala y parámetros optimizados por enjambre de partículas (PSO), comparándolo con la metodología clásica de fusión Top-Hat y con métodos representativos del estado del arte, y analizando su impacto en tareas posteriores de detección de objetos.

1.3.2 Específicos

1. Formular la Propuesta Novedosa: sobre una sola escala, un banco de cinco elementos estructurantes (un disco y cuatro lineales a 0° , 45° , 90° y 135°) cuyas respuestas lineales se promedian y se confrontan por máximo con la del disco para obtener transformadas Top-Hat y Bottom-Hat óptimas, con reconstrucción aditivo–sustractiva ponderada, adaptada al esquema de fusión VIS/IR.
2. Optimizar automáticamente los hiperparámetros del método (el radio r del banco de elementos estructurantes y el peso de contraste m) mediante PSO con una función de aptitud orientada a la calidad de fusión.
3. Comparar el método óptimo con la metodología clásica de fusión Top-Hat y con cinco métodos representativos del estado del arte (LP, RP, DWT, DTCWT y CVT) sobre nueve métricas sin referencia, con pruebas no paramétricas (Friedman y Wilcoxon con corrección de Holm).
4. Analizar el impacto de la fusión en una tarea posterior de detección de objetos (YOLO), evaluando la detectabilidad por modalidad de entrada.

1.4 Formulación del problema

1.4.1 Problema general

¿La Propuesta Novedosa de fusión VIS+IR basada en la transformada Top-Hat, con elementos estructurantes de disco y lineales sobre una sola escala e hiperparámetros optimizados por PSO, mejora la calidad de fusión —evaluada con métricas sin referencia y pruebas no paramétricas sobre el TNO Image Fusion Dataset— respecto de la metodología clásica de fusión Top-Hat y de los métodos del estado del arte, y qué efecto produce en el desempeño de una tarea posterior de detección de objetos?

1.4.2 Problemas específicos

- ¿Cómo debe formularse el operador —banco de disco y líneas, combinación de respuestas y regla de reconstrucción— para adaptar el realce morfológico multidireccional al esquema de fusión VIS/IR?
- ¿Qué valores del radio r y del peso de contraste m maximizan una aptitud orientada a la calidad de fusión, y puede el PSO hallarlos automáticamente de forma estable?
- ¿Existen diferencias estadísticamente significativas entre la Propuesta Novedosa, la metodología clásica de fusión Top-Hat y los métodos del estado del arte (LP, RP, DWT, DTCWT y CVT), y en qué métricas?
- ¿La fusión —y en particular el método propuesto— mejora el desempeño de un detector de objetos (mAP sobre LLVIP) respecto de las modalidades visible e infrarroja por separado?

1.5 Hipótesis

De la formulación anterior se derivan tres hipótesis de trabajo. H1: la combinación de elementos estructurantes de disco y lineales sobre una sola escala —con las respuestas lineales promediadas y sumadas a la del disco— mejora la fidelidad estructural (SSIM) frente a la metodología clásica de fusión Top-Hat y a los métodos del estado del arte. H2: la optimización automática de los hiperparámetros (r , m) por PSO, con una función de aptitud orientada a la fusión, alcanza un perfil de calidad superior al de la parametrización manual del operador clásico. H3: una mejor calidad de fusión se traduce en un mejor desempeño de detección de objetos (mAP) que el de las modalidades individuales. Las hipótesis H1 y H2 se contrastan en las secciones 5.4 y 5.6; H3 se somete a prueba en la sección 5.5.

1.6 Limitaciones de la investigación

Esta investigación se circunscribe a las siguientes limitaciones, que deben tenerse presentes al interpretar los resultados. Primero, el corpus experimental son veinte pares del TNO Image Fusion Dataset, registrados principalmente en escenas militares y urbanas; las conclusiones pueden no transferirse íntegramente a otros dominios (médico, aéreo de muy alta resolución). Segundo, la evaluación se realiza con métricas sin referencia, dado que no existe una imagen fusionada óptima conocida; esto introduce inevitablemente una dependencia de las métricas elegidas. Tercero, la evaluación orientada a tarea con verdad de campo se realizó con un único detector (YOLOv8n) sobre un subconjunto de LLVIP (2.000 imágenes de entrenamiento y

500 de validación, 40 épocas); extenderla a otros detectores y al conjunto completo queda como trabajo futuro. Cuarto, la regla de fusión por capa es la de selección por actividad local máxima, sin explorar reglas adaptativas. Quinto, no se evaluaron métodos basados en aprendizaje profundo, dado que tales comparaciones requieren protocolos de entrenamiento cuyos sesgos exceden el alcance de esta tesis.

1.7 Alcance

El alcance de la tesis abarca: la implementación íntegra y reproducible del método propuesto y de los baselines en Python (NumPy, OpenCV, scikit-image, SciPy, PyWavelets); la organización modular del código en un repositorio versionado; el preprocesamiento y emparejado del dataset; la ejecución del benchmark exhaustivo y de la comparación contra baselines; el análisis estadístico no paramétrico; la generación de tablas y figuras científicas; y la redacción del presente informe. Quedan fuera del alcance la generación de un nuevo dataset, la integración con sistemas en tiempo real y la comparación con métodos de aprendizaje profundo entrenados desde cero.

2. MARCO TEÓRICO

2.1 Estado del arte

La fusión de imágenes multimodal, particularmente VIS+IR, cuenta con una literatura abundante. Li et al. (2017) presentan una revisión integral de los métodos a nivel pixel, agrupándolos en cuatro grandes familias: dominios espaciales (promedio, máximo, PCA), dominios transformados multiescala (pirámides, wavelets, curvelets), métodos basados en representaciones dispersas y métodos híbridos. Ma et al. (2019) actualizan el panorama con énfasis en la creciente adopción de redes neuronales profundas, distinguiendo arquitecturas de auto-encoder, redes generativas antagónicas (GAN) y enfoques de fusión guiada por tareas. En paralelo, Zhang y Demiris (2023) documentan la consolidación de benchmarks estandarizados (TNO, RoadScene, M3FD) y el establecimiento progresivo de métricas sin referencia como estándar de facto.

Específicamente en fusión morfológica, Mukhopadhyay y Chanda (2001) introducen una de las primeras descomposiciones multiescala basadas en operadores Top-Hat para realce e interpretación de imágenes médicas. Bai (2013) extiende la idea a fusión VIS+IR, mostrando que la transformada Top-Hat puede capturar simultáneamente detalles brillantes y oscuros con bajo costo computacional. Trabajos posteriores, como los de Bai et al. (2015) y Wang et al. (2017), exploran combinaciones de Top-Hat con otras representaciones, pero rara vez sistematizan el efecto cruzado del tipo de elemento estructurante, el número de niveles y el radio base sobre múltiples métricas.

Los métodos profundos, por su parte, han avanzado rápidamente. Ma et al. (2019, FusionGAN) y Tang et al. (2022, SeAFusion) ofrecen arquitecturas de fusión guiadas por percepción semántica. Sin embargo, su dependencia de datos pareados y la dificultad de auditarlos los hacen problemáticos en aplicaciones donde la trazabilidad es obligatoria. En este contexto, los métodos clásicos siguen siendo no solo relevantes sino estratégicamente valiosos como baselines reproducibles.

Una visión panorámica reciente la ofrece la revisión de Singh et al. (2023), que sistematiza la fusión de imágenes en tres grandes familias —dominio espacial, descomposición multiescala (MSD: pirámides, wavelets y análisis geométrico multiescala) y aprendizaje automático— y en tres niveles de abstracción (píxel, característica y decisión). En esa taxonomía, la propuesta de esta tesis se ubica en la familia MSD, rama de pirámides

morfológicas, y opera a nivel de píxel (PLIF). La revisión documenta además el uso de metaheurísticas para ajustar parámetros de fusión —enjambre de partículas (PSO), colonia de abejas, búsqueda cuco—, con precedentes específicos de PSO aplicado a la fusión (p. ej. Tao et al., 2010, DTCWT+PSO; Malviya y Saxena, 2014, WT+PSO), lo que respalda la estrategia de optimización adoptada aquí.

2.2 Fundamentación teórica

Tabla 1. Notación empleada en el marco teórico.

Símbolo	Significado
f	Imagen de entrada en escala de gris [0,1] (VIS o IR)
b	Elemento estructurante (disco o segmento lineal)
$\varepsilon(f,b), \delta(f,b)$	Erosión y dilatación de f con b
$\gamma(f,b), \phi(f,b)$	Apertura y cierre de f con b
WTH, BTH	White Top-Hat y Black Top-Hat
r	Radio del elemento estructurante (disco y líneas)
m	Peso de ajuste de contraste
WTH_i, BTH_i	Top-Hat de líneas (promedio) y de disco (radio r)
$I_{opt}^{top}, I_{opt}^{bot}$	Transformadas óptimas: suma de ramas (líneas + disco) por fuente
I_{base}	Imagen base, $(I_{VIS} + I_{IR})/2$
F	Imagen fusionada
x, v	Posición y velocidad de una partícula (PSO)
$pbest, gbest$	Mejor posición individual y global del enjambre
w, c_1, c_2	Inercia y coeficientes cognitivo y social (PSO)

2.2.1 Fusión de imágenes multimodal

La fusión de imágenes a nivel píxel se formaliza como un operador $F: \mathbb{R}^{H \times W} \times \mathbb{R}^{H \times W} \rightarrow \mathbb{R}^{H \times W}$ que recibe dos imágenes alineadas espacialmente, I_{VIS} e I_{IR} , y produce una imagen fusionada $F(I_{VIS}, I_{IR})$ que maximice algún criterio de calidad. Tres etapas son comunes a todas las pipelines: preprocesamiento (registro, normalización), descomposición y fusión por capa, reconstrucción. La descomposición transforma cada imagen en una representación multi-escala que expone los detalles a distintas resoluciones; la fusión por

capa aplica una regla de selección (típicamente basada en actividad local máxima); la reconstrucción invierte la descomposición.

2.2.2 Morfología matemática

La morfología matemática es un cuerpo algebraico para el análisis de estructuras geométricas en imágenes, basado en la teoría de retículas completas (Serra, 1982; Soille, 2003; Gonzalez y Woods, 2018). Sus operaciones fundamentales en imágenes de niveles de gris son la erosión $\varepsilon(f, b)$ y la dilatación $\delta(f, b)$, definidas como mínimo y máximo locales bajo el patrón impuesto por el elemento estructurante b . A partir de ellas se derivan apertura $\gamma(f, b) = \delta(\varepsilon(f, b), b)$ y cierre $\phi(f, b) = \varepsilon(\delta(f, b), b)$, que eliminan respectivamente picos brillantes y valles oscuros menores que el SE. La elección del SE (geometría y radio) es la decisión de diseño central: define qué orientaciones, simetrías y escalas de detalle se preservan o suprimen.

Las dos operaciones fundamentales son la dilatación (δ) y la erosión (ε). En escala de grises, para un elemento estructurante b , se definen como el máximo y el mínimo local, respectivamente (Román et al., 2020):

$$\delta(f, b)(u, v) = \max_{(j, k) \in b} f(u - j, v - k), \varepsilon(f, b)(u, v) = \min_{(j, k) \in b} f(u + j, v + k) \quad (1)$$

$$\gamma(f, b) = \delta(\varepsilon(f, b), b), \phi(f, b) = \varepsilon(\delta(f, b), b) \quad (2)$$

2.2.3 Transformada Top-Hat

La transformada White Top-Hat se define como la diferencia entre la imagen original y su apertura: $WTH(f, b) = f - \gamma(f, b)$. Aísla las estructuras brillantes más pequeñas que el SE. Su dual, la Black Top-Hat, $BTH(f, b) = \phi(f, b) - f$, aísla los valles oscuros. Una propiedad clave es que el WTH es siempre no negativo y se anula en regiones donde la imagen es localmente plana a la escala del SE, lo que la convierte en un detector natural de detalles. La elección del tipo de SE (disco para isotropía, línea para direcciones específicas, cuadrado o cruz para sensibilidades distintas) determina qué tipo de detalle se enfatiza.

$$WTH(f, b) = f - \gamma(f, b), BTH(f, b) = \phi(f, b) - f \quad (3)$$

Para realzar estructuras direccionales, Bala et al. (2024) promedian las respuestas Top-Hat obtenidas con elementos estructurantes lineales en n orientaciones angulares:

$$WTH^m = \frac{1}{n} \sum_{\theta} (f - \gamma(f, b_{\theta})), BTH^m = \frac{1}{n} \sum_{\theta} (\phi(f, b_{\theta}) - f) \quad (4)$$

y reconstruyen la imagen realzada sumando los realces claros y restando los oscuros, combinando las respuestas lineales (multidireccionales) y la del disco:

$$I_{en} = I + (I_{top} - I_{bot}), I_{top} = WT H^m + WT H^d, I_{bot} = BT H^m + BT H^d \quad (5)$$

Operaciones morfológicas básicas y transformada Top-Hat




Figura 1. Operaciones morfológicas (erosión, dilatación, apertura y cierre) y transformada Top-Hat sobre un perfil de intensidad.

2.2.4 Metodología clásica de fusión Top-Hat

La metodología clásica de fusión por transformada Top-Hat constituye la referencia morfológica directa de este trabajo. Dada cada imagen de entrada f (visible e infrarroja), se aplican la White Top-Hat y la Black Top-Hat con un único elemento estructurante de disco B_r (aquí, radio $r = 5$), extrayendo respectivamente el detalle brillante y el oscuro más finos que el disco. Los detalles de ambas fuentes se combinan conservando, píxel a píxel, la respuesta máxima —el detalle más saliente de cualquiera de las dos modalidades— y la imagen fusionada se reconstruye sobre la base $I_{base} = (I_{VIS} + I_{IR})/2$ mediante el esquema aditivo–sustractivo sin ponderación: $F = I_{base} + \max(WTH_{VIS}, WTH_{IR}) - \max(BTH_{VIS}, BTH_{IR})$. Se trata de un método interpretable y de muy bajo costo computacional, pero con dos limitaciones que motivan la propuesta: el disco único carece de sensibilidad direccional —trata por igual estructuras alargadas e isotropas— y la reconstrucción sin peso de contraste inyecta todo el detalle extraído, lo que en la práctica dispara los artefactos y degrada la similitud estructural (SSIM), como se cuantifica en el capítulo de resultados.

La imagen fusionada final se reconstruye según la regla:

$$F = I_{base} + \max(WTH_{VIS}, WTH_{IR}) - \max(BTH_{VIS}, BTH_{IR}) \quad (6)$$

El operador clásico admite dos modos: emplear únicamente la White Top-Hat (realce del detalle brillante) o el esquema completo White+Black (realce de ambos extremos). En este trabajo se emplea el esquema completo con disco de radio $r = 5$, la configuración estándar reportada en la literatura, sin peso de contraste ($m = 1$) y sin optimización de hiperparámetros: esas dos carencias son precisamente las que la Propuesta Novedosa aborda.




Figura 2. Esquema conceptual de la fusión Top-Hat clásica: disco único, combinación por máximo entre fuentes y reconstrucción sin ponderación.

2.2.5 Propuesta Novedosa: método de fusión Top-Hat con elementos estructurantes circulares y lineales optimizado por PSO

La propuesta central de esta tesis —la Propuesta Novedosa— es un método de fusión morfológica que, sobre una única escala definida por el radio r , combina un banco de elementos estructurantes circulares y lineales. Integra tres ideas: el promediado multiangular de las respuestas lineales y la reconstrucción aditivo-sustractiva de Bala et al. (2024); el uso simultáneo de un disco y cuatro segmentos lineales para atender por igual a estructuras isotropas y orientadas; y la optimización por enjambre de partículas de Ortega y Espinoza (2025), que fija automáticamente los hiperparámetros. Frente a la metodología clásica de la transformada Top-Hat —un único disco y reconstrucción sin ponderación—, la propuesta añade sensibilidad direccional y sustituye el ajuste manual por una búsqueda guiada por la calidad de fusión.

Elementos estructurantes circulares y lineales. El operador se calcula sobre una sola escala, fijada por el radio r . En cada fuente se emplean cinco elementos estructurantes: un disco B_r de radio r , isotrópico, y cuatro segmentos lineales $L_{r,\theta}$ de longitud $2r+1$ orientados a 0° , 45° , 90° y 135° . Las cuatro respuestas lineales se promedian —siguiendo el esquema multiangular de Bala et al. (ecuaciones 2 y 4)— tanto para el White Top-Hat como para el Black Top-Hat. La respuesta del disco se calcula por separado con el mismo radio. El promedio multiangular atenúa el ruido y realza estructuras alargadas en cualquier orientación, mientras que el disco preserva las estructuras isotrópicas.

Para cada fuente f y radio r , la ecuación (7) define la respuesta lineal promediada —White y Black Top-Hat sobre los cuatro segmentos $L_{r,\theta}$ — y la ecuación (8) la respuesta del elemento circular B_r del mismo radio:

$$WTH_{lin} = \frac{1}{4} \sum_{\theta} [f - \gamma(f, L_{r,\theta})], BT H_{lin} = \frac{1}{4} \sum_{\theta} [\varphi(f, L_{r,\theta}) - f] \quad (7)$$

$$WTH_{disco} = f - \gamma(f, B_r), BT H_{disco} = \varphi(f, B_r) - f \quad (8)$$

Banco de 5 elementos estructurantes por fuente (radio r) — Propuesta Novedosa




Figura 3. Banco de cinco elementos estructurantes (un disco y cuatro líneas): las respuestas lineales promediadas se suman a la del disco.

Transformadas óptimas por suma. Siguiendo el esquema de Bala et al., la respuesta lineal promediada y la del disco se suman: el realce acumula la evidencia de ambas ramas, de modo que las estructuras orientadas e isotrópicas contribuyen conjuntamente al detalle extraído. Así se obtienen, para cada fuente, la transformada óptima superior I_{opt}^{top} y la inferior I_{opt}^{bot} , según la ecuación (9). Las transformadas de la imagen visible y de la infrarroja se combinan luego entre fuentes tomando de nuevo el máximo por píxel (ecuación 10), conservando el detalle más saliente de cada modalidad.

$$I_{opt}^{top} = WTH_{lin} + WTH_{disco}, I_{opt}^{bot} = BTH_{lin} + BTH_{disco} \quad (9)$$

$$I_{opt}^{top,F} = \max(I_{opt}^{top,IR}, I_{opt}^{top,VIS}), I_{opt}^{bot,F} = \max(I_{opt}^{bot,IR}, I_{opt}^{bot,VIS}) \quad (10)$$

Reconstrucción y regla de fusión. Sobre la imagen base $I_{base} = (I_{VIS} + I_{IR})/2$ —que retiene la iluminación del visible y la temperatura global del infrarrojo— se reconstruye la imagen fusionada según la ecuación (11): se añaden las estructuras brillantes (término con I_{opt}^{top}) y se restan las oscuras (término con I_{opt}^{bot}), moduladas por el peso de contraste m . Valores altos de m maximizan el contraste a costa de artefactos; valores bajos preservan la fidelidad. Esta regla adapta la reconstrucción aditivo-sustractiva de Bala et al. (ecuación 9 de ese trabajo, aquí ecuación 5) al esquema de fusión ponderada VIS/IR de Ortega y Espinoza.

$$F = I_{base} + m I_{opt}^{top, F} - m I_{opt}^{bot, F}, I_{base} = 1/2 (I_{VIS} + I_{IR}) \quad (11)$$




Figura 4. Flujograma de la Propuesta Novedosa: proceso paso a paso (banco de cinco elementos estructurantes por fuente, promediado de las respuestas lineales, suma con la respuesta del disco para obtener las transformadas óptimas, combinación entre fuentes por máximo y reconstrucción ponderada con el peso m).

Optimización por Enjambre de Partículas (PSO). El método tiene dos hiperparámetros —el radio r del banco de elementos estructurantes y el peso de contraste m — cuyo ajuste manual

es costoso y subjetivo. Para fijarlos se emplea la Optimización por Enjambre de Partículas (Kennedy y Eberhart, 1995), metaheurística poblacional inspirada en el comportamiento colectivo de las bandadas. Cada partícula es una solución candidata $x = (r, m)$ que recuerda su mejor posición propia (p_{best}) y la mejor del enjambre (g_{best}); en cada iteración su velocidad y posición se actualizan según la ecuación (13), donde w es la inercia y c_1, c_2 los coeficientes cognitivo y social. La configuración del enjambre se seleccionó mediante un barrido sistemático de 25 combinaciones —número de partículas de 2 a 10 en incrementos de 2 y número de iteraciones de 10 a 50 en incrementos de 10, replicando el diseño experimental de Ortega y Espinoza (2025)—, con $c_1 = c_2 = 1,5$ e inercia decreciente de 0,9 a 0,4.

El PSO optimiza el vector de hiperparámetros del método dentro del espacio de búsqueda acotado:

$$x = (r, m), r \in \{1, \dots, 25\}, m \in [0.05, 1.20] \quad (12)$$

$$v_{t+1} = w v_t + c_1 r_1 (p_{best} - x_t) + c_2 r_2 (g_{best} - x_t), x_{t+1} = x_t + v_{t+1} \quad (13)$$




Figura 5. Optimización por enjambre de partículas (PSO) del vector de hiperparámetros (r, m) .

Función de aptitud (Ortega y Espinoza). Los hiperparámetros (r, m) se ajustan maximizando la función objetivo del trabajo de referencia, $Fo = SSIMavg + En + PSNRn$ (ecuación 14): la similitud estructural promedio con las fuentes (SSIMavg; Wang et al., 2004), la entropía normalizada ($En = E/8$) y la relación señal-ruido de pico normalizada ($PSNRn = PSNR/100$), sin pesos arbitrarios, equilibrando preservación estructural, contenido informativo y reducción de la distorsión (Ortega y Espinoza, 2025). El barrido de 25 configuraciones (partículas 2–10 $\times$ iteraciones 10–50, Cuadro 1 de dicho trabajo) sobre tres escenas

representativas, con $r \in [1, 25]$ y $m \in [0,05; 1,20]$ —el rango de m se amplía respecto del original $[0,3; 2,0]$ porque el operador con suma de ramas inyecta del orden de cuatro veces más energía de detalle que el disco único para el que se calibró—, alcanza el óptimo $r = 25$, $m \approx 0,07$ ($F_o = 1,7654$), de forma consistente con los enjambres de 10 partículas y 30 o más iteraciones; se adopta la configuración operativa $r = 25$, $m = 0,0703$ —sobre la meseta plana del óptimo de F_o —, con la que se evalúa el método en el capítulo de resultados.

Tabla 2. Configuración de la Propuesta Novedosa y del PSO.

Parámetro	Valor
Elementos estructurantes	5: un disco (radio r) + cuatro líneas (0° , 45° , 90° , 135° ; longitud $2r+1$)
Combinación de las respuestas	Promedio de las 4 líneas (ec. 7) y suma con la respuesta del disco (ec. 9)
Escala (radio)	Única, de radio r (ajustado por PSO)
Regla de fusión entre fuentes	Máximo por píxel (ec. 10)
Función de aptitud	$F_o = SSIM_{avg} + E_n + PSNR_n$
Partículas del enjambre	2–10 (barrido, paso 2)
Iteraciones	10–50 (barrido, paso 10)
Inercia w	$0,9 \rightarrow 0,4$ (decreciente)
Coeficientes c_1 , c_2	1,5 ; 1,5
Rangos de búsqueda	$r \in [1, 25]$; $m \in [0,05, 1,20]$
Óptimo hallado	$r = 25$; $m = 0,0703$ ($F_o = 1,7654$; mejor de 25 configuraciones)

$$F_o = SSIM_{avg} + E_n + PSNR_n \quad (14)$$

2.2.6 Métodos comparativos del benchmark

Para situar el método propuesto en el panorama de la disciplina se utilizan seis métodos comparativos: cinco representativos del estado del arte en fusión multiescala y la metodología clásica de la transformada Top-Hat:

Tabla 3. Métodos comparativos del benchmark.

Método	Descripción	Referencia
Ratio of low-pass Pyramid (RP)	Razones entre niveles gaussianos consecutivos; se conserva en cada	Toet (1989)

	píxel la razón que más se aparta de 1 y se reconstruye multiplicativamente	
Pirámide de Laplace (LP)	Descomposición Gaussiana–Laplaciana de 4 niveles; fusión por máxima actividad local y reconstrucción inversa	Burt y Adelson (1983)
Curvelet (CVT, vía wavelet 2D)	Subbandas direccionales (Daubechies db4, 3 niveles); máxima magnitud en detalle, promedio en aproximación	Candès et al. (2006)
Wavelet discreta (DWT)	Subbandas de detalle y aproximación (Haar, 3 niveles); detalle por máxima magnitud, aproximación por promedio	—
Dual-Tree Complex Wavelet (DTCWT)	Seis subbandas direccionales complejas por nivel (4 niveles), invariante al desplazamiento; fusión por máxima magnitud	Kingsbury
Top-Hat clásico	Fusión morfológica básica: disco único B_5 , detalle entre fuentes por máximo y reconstrucción sin ponderación ($m = 1$)	—

2.2.7 Métricas de evaluación

Dado que en la fusión VIS/IR no existe una imagen de referencia (ground truth) —como subraya la revisión de Singh et al. (2023)—, la evaluación se realiza con nueve métricas que computan el puntaje a partir de la imagen fusionada y de sus fuentes: la entropía (EN), la desviación estándar (SD), la entropía de bordes (FE), el gradiente medio (MG), la información mutua con el visible y el infrarrojo (MI_{vis} , MI_{ir}), la frecuencia espacial (SF), la similitud estructural promedio con las fuentes (SSIM) y la relación señal-ruido de pico calculada frente a ambas fuentes (PSNR). Este subconjunto —alineado con la metodología de referencia (Ortega y Espinoza, 2025)— cubre la actividad y el contenido informativo, la fidelidad estructural y la distorsión. La literatura de fusión define además una familia de índices de calidad orientados a la preservación de bordes y a la reducción de artefactos (Q_{abf} , N_{abf} , SCD, VIF, FMI y los índices de Piella y Heijmans, 2003), cuyas definiciones se recogen en la sección siguiente por completitud; la evaluación empírica de esta tesis reporta el subconjunto de nueve métricas descrito.

A continuación se formalizan las principales métricas sin referencia empleadas en la evaluación. Las primeras cuantifican propiedades intrínsecas de la imagen fusionada

(información, contraste, nitidez) y las restantes miden cuánta información de las fuentes se transfiere y con qué fidelidad estructural:

Entropía (EN). Cantidad de información de la imagen fusionada; mayor es mejor ($p_1 =$ histograma normalizado, L niveles de gris).

$$EN = - \sum_{l=0}^{L-1} p_l \log_2 p_l \quad (15)$$

Desviación estándar (SD). Contraste global respecto de la media μ ; mayor SD indica mayor dispersión de intensidades.

$$SD = \sqrt{\frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N (F(i, j) - \mu)^2} \quad (16)$$

Frecuencia espacial (SF). Nitidez y nivel de detalle, combinando las frecuencias por filas (RF) y por columnas (CF).

$$SF = \sqrt{RF^2 + CF^2}, RF = \sqrt{\frac{1}{MN} \sum_i \sum_j (F(i, j) - F(i, j-1))^2} \quad (17)$$

Gradiente medio (MG). Definición y agudeza de los bordes a partir de los gradientes $\Delta x, \Delta y$.

$$\bar{G} = \frac{1}{MN} \sum_i \sum_j \sqrt{\Delta x^2 + \Delta y^2} \quad (18)$$

Información mutua (MI). Información de las fuentes A y B transferida a la fusión F; suma de las MI por par.

$$MI = MI_{AF} + MI_{BF}, MI_{XF} = \sum_x \sum_f p(x, f) \log_2 \frac{p(x, f)}{p(x)p(f)} \quad (19)$$

$Q^{AB/F}$ (Xydeas–Petrović). Preservación de la información de bordes, ponderada por la intensidad de borde de cada fuente (w^A, w^B).

$$Q^{AB/F} = \frac{\sum_{i,j} (Q_{i,j}^{AF} w_{i,j}^A + Q_{i,j}^{BF} w_{i,j}^B)}{\sum_{i,j} (w_{i,j}^A + w_{i,j}^B)} \quad (20)$$

$N^{AB/F}$ (Nabf). Tasa de ruido y artefactos introducidos por la fusión ($AM =$ mapa de artefactos); menor es mejor.

$$N^{AB/F} = \frac{\sum_{i,j} A M_{i,j} (w_{i,j}^A + w_{i,j}^B)}{\sum_{i,j} (w_{i,j}^A + w_{i,j}^B)} \quad (21)$$

SSIM. Similitud estructural entre la fusión y las fuentes (luminancia, contraste y estructura; C_1, C_2 constantes de estabilidad).

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (22)$$

SCD. Suma de correlaciones de las diferencias D_1, D_2 entre la fusión y cada fuente.

$$SCD = r(D_1, I_1) + r(D_2, I_2), D_1 = F - I_2, D_2 = F - I_1 \quad (23)$$

VIF. Fidelidad visual de la información, basada en un modelo de información en el dominio de subbandas.

$$VIF = \frac{\sum_j I(C^j; F^j | s^j)}{\sum_j I(C^j; E^j | s^j)} \quad (24)$$

FMI. Información mutua de los mapas de características (gradiente), normalizada por las entropías (Haghighat et al., 2011).

$$FMI = \frac{MI_{AF}}{H_A + H_F} + \frac{MI_{BF}}{H_B + H_F} \quad (25)$$

Q_0 / Piella. Calidad estructural universal; las variantes Q_W y Q_E la ponderan por la saliencia y los bordes locales (Piella y Heijmans, 2003).

	$Q_0 = \frac{4\sigma_{xy}\mu_x\mu_y}{(\sigma_x^2 + \sigma_y^2)(\mu_x^2 + \mu_y^2)}$			(26)
Métrica	Definición operativa	Interpretación	Dirección	
EN	Entropía de Shannon del histograma de la imagen fusionada	Riqueza informacional global	↑	
SD	Desviación estándar de los niveles de gris	Contraste global	↑	
FE	EN(F) ÷ media(EN(VIS), EN(IR))	Ganancia informacional sobre las fuentes	↑	
MG	Promedio de la magnitud del	Nitidez y preservación de	↑	

	gradiente	bordes	
MI_vis	Información mutua entre F y la imagen VIS	Fidelidad a la fuente visible	↑
MI_ir	Información mutua entre F y la imagen IR	Fidelidad a la fuente infrarroja	↑
SF	Frecuencia espacial: actividad espacial global (filas y columnas)	Detalle y textura global	↑
Qabf	Información de borde de las fuentes transferida a la fusión (Xydeas-Petrovic)	Preservación de bordes	↑
Nabf	Bordes/ruido añadidos por la fusión inexistentes en las fuentes	Artefactos (menor es mejor)	↓
SSIM	Similitud estructural promedio respecto a VIS e IR	Fidelidad estructural	↑
SCD	Suma de correlaciones de las diferencias (Aslantas-Bendes)	Información de fuente retenida	↑
VIF	Fidelidad de información visual promedio (Sheikh-Bovik)	Fidelidad perceptual	↑

3. MARCO CONCEPTUAL

3.1 Imagen visible (VIS)

Imagen capturada en el rango espectral de 400 a 700 nanómetros, correspondiente a la sensibilidad del ojo humano. Resolución típica alta y dependencia fuerte de la iluminación ambiente.

3.2 Imagen infrarroja (IR)

Imagen capturada en el rango térmico (típicamente 8 a 14 micras, IR de onda larga) que registra la radiación emitida por los cuerpos en función de su temperatura. Resolución espacial típicamente inferior a la VIS pero independiente de la iluminación visible.

3.3 Elemento estructurante (SE)

Conjunto plano y compacto que define la geometría del vecindario sobre el que actúan las operaciones morfológicas. En esta tesis se exploran SE de tipo disco, cuadrado y cruz, con radios de 2, 3 y 5 píxeles.

3.4 White Top-Hat (WTH)

Operador morfológico definido como la diferencia entre la imagen original y su apertura. Aísla las estructuras brillantes locales menores que el SE.

3.5 Black Top-Hat (BTH)

Operador morfológico dual del WTH, definido como la diferencia entre el cierre de la imagen y la imagen original: $BTH(f, b) = \phi(f, b) - f$. Aísla las estructuras oscuras locales (valles) menores que el SE. Incorporarlo permite capturar simultáneamente el detalle brillante (vía WTH) y el detalle oscuro (vía BTH) de cada escala.

3.6 Descomposición multiescala

Representación de una imagen como suma de capas que aíslan estructuras a distintas escalas. En esta tesis se construye iterativamente aplicando WTH con SE de radio creciente.

3.7 Regla de fusión por actividad local

Mecanismo de selección capa-a-capas que escoge el aporte de la fuente cuya actividad local (magnitud del coeficiente suavizada con un kernel gaussiano) es mayor en cada posición.

3.8 Métrica sin referencia

Indicador cuantitativo de calidad calculado únicamente a partir de la imagen fusionada o de su relación con las fuentes, sin requerir una imagen objetivo conocida.

3.9 Prueba de Friedman

Prueba estadística no paramétrica para muestras relacionadas con tres o más tratamientos. Se utiliza para detectar diferencias globales entre métodos cuando los datos no cumplen normalidad.

3.10 Prueba de Wilcoxon

Prueba estadística no paramétrica de rangos signados para comparaciones pareadas, utilizada en esta tesis para confrontar cada configuración Top-Hat contra cada baseline.

3.11 Elemento estructurante lineal

Segmento recto de longitud $2r+1$ orientado a un ángulo determinado (0° , 45° , 90° o 135°), usado como elemento estructurante para resaltar estructuras alargadas en esa dirección. A diferencia del disco, que es isótropo, el SE lineal es direccional; el método óptimo combina un disco y cuatro líneas por escala para cubrir todas las orientaciones.

3.12 Combinación de respuestas por suma

Regla que, dadas las transformadas Top-Hat obtenidas con distintos elementos estructurantes sobre la misma imagen, acumula sus respuestas sumándolas píxel a píxel (la lineal promediada y la del disco), de modo que las estructuras captadas por cada geometría contribuyen conjuntamente al detalle extraído.

3.13 Fusión Top-Hat clásica

Esquema de fusión morfológica de referencia: White y Black Top-Hat con un único disco sobre cada fuente, combinación del detalle entre fuentes por máximo píxel a píxel y reconstrucción aditivo–sustractiva sin ponderación sobre la imagen base.

3.14 Peso de ajuste de contraste (m)

Escalar que pondera cuánto se suman los realces brillantes (WTH) y se restan los oscuros (BTH) sobre la imagen base en la regla de fusión. Valores altos aumentan el contraste a riesgo de artefactos; valores bajos preservan la fidelidad a las fuentes. En el método óptimo se ajusta automáticamente por PSO.

3.15 Optimización por Enjambre de Partículas (PSO)

Metaheurística poblacional (Kennedy y Eberhart, 1995) que busca el óptimo de una función moviendo un conjunto de partículas según su mejor posición individual (pbest) y la mejor global del enjambre (gbest). En esta tesis ajusta automáticamente los hiperparámetros (r , m) dla Propuesta Novedosa.

3.16 Función de aptitud

Criterio escalar que el PSO maximiza para evaluar cada solución candidata. Aquí es una combinación orientada a la fusión, $Fo = SSIM_{avg} + En + PSNR_n$, que premia la fidelidad estructural, la preservación de bordes y la correlación, y penaliza los artefactos.

4. MARCO METODOLÓGICO

4.1 Enfoque

La investigación adopta un enfoque cuantitativo. Todos los hallazgos se sostienen en mediciones numéricas sobre conjuntos de imágenes definidos a priori, calculadas mediante implementaciones reproducibles y contrastadas con pruebas estadísticas no paramétricas.

4.2 Tipo

La investigación es de tipo experimental, con carácter descriptivo y comparativo. Se manipulan sistemáticamente los hiperparámetros del método propuesto y se observan los efectos sobre las métricas de calidad. La comparación con baselines aporta el componente comparativo.

4.3 Diseño

El diseño es comparativo inter-método: siete métodos de fusión —la Propuesta Novedosa, la metodología clásica Top-Hat y cinco representativos del estado del arte (LP, RP, DWT, DTCWT y CVT)— se aplican a cada uno de los 20 pares del dataset, totalizando 140 fusiones evaluadas con las nueve métricas sin referencia, base del análisis estadístico inter-método. Los dos hiperparámetros de la propuesta (el radio r del banco de elementos estructurantes y el peso de contraste m) se ajustan mediante PSO, seleccionando la configuración del enjambre con un barrido de 25 combinaciones (partículas $2-10 \times$ iteraciones $10-50$, replicando el diseño de Ortega y Espinoza, 2025) sobre un subconjunto de tres escenas representativas; la configuración óptima resultante ($r = 25$, $m = 0,070$) se compara sobre los 20 pares con las nueve métricas, incluyendo contrastes pareados de Wilcoxon con corrección de Holm.

4.4 Operacionalización de las variables

Variable	Tipo	Definición operacional	Indicador / Valores
Método	Independiente	Algoritmo de fusión empleado	7 métodos del benchmark (§4.3)
Radio del SE (r)	Independiente	Radio del disco y longitud ($2r+1$) de las líneas del banco de SE	1–25 (ajustado por PSO)
Peso de contraste (m)	Independiente	Ponderación del realce en la regla de fusión	0,05–1,20 (ajustado por PSO)
Entropía (EN)	Dependiente	Entropía de Shannon de la fusionada	Bits, $\uparrow$ mejor

Variable	Tipo	Definición operacional	Indicador / Valores
Desv. estándar (SD)	Dependiente	σ de niveles de gris	Adimensional, $\uparrow$ mejor
Eficiencia FE	Dependiente	EN(F) sobre media de fuentes	Razón, $\uparrow$ mejor
Gradiente medio (MG)	Dependiente	$ \nabla F $ promedio	Adimensional, $\uparrow$ mejor
MI_vis	Dependiente	Información mutua $F \leftrightarrow \text{VIS}$	Bits, $\uparrow$ mejor
MI_ir	Dependiente	Información mutua $F \leftrightarrow \text{IR}$	Bits, $\uparrow$ mejor
Métricas estándar y del review	Dependiente	SF, SSIM, PSNR (§2.2.7)	Adimensional, $\uparrow$ mejor
Detección (mAP)	Dependiente	mAP@0,5 y mAP@0,5:0,95 de YOLOv8n reentrenado por modalidad (LLVIP)	Proporción [0, 1], $\uparrow$ mejor

4.5 Dataset y preprocesamiento

El corpus experimental son veinte pares VIS/IR del TNO Image Fusion Dataset, dataset público mantenido por TNO (Países Bajos) ampliamente utilizado como referencia en la literatura (Toet, 2014). Las imágenes se reorganizaron en dos directorios paralelos (data/raw/VIS y data/raw/IR) con nombres de archivo coincidentes para emparejado automático. Se cargan en escala de grises, se normalizan al rango [0, 1] como float32 y se asume registro espacial previo (los pares TNO ya están alineados).

Para la evaluación orientada a tarea con verdad de campo (sección 5.5.1) se emplea adicionalmente el dataset LLVIP (Jia et al., 2021), compuesto por 15.488 pares VIS/IR registrados espacialmente, con peatones anotados en escenas de baja iluminación. Se utilizó un subconjunto de 2.000 imágenes de entrenamiento y 500 de validación por modalidad (VIS, IR y cada fusión), reentrenando el detector YOLOv8n durante 40 épocas con configuración idéntica en todas las modalidades; al estar los pares registrados, las anotaciones originales son válidas para toda versión fusionada, de modo que las diferencias de mAP resultan atribuibles al método de fusión.

4.6 Implementación

Toda la implementación se realizó en Python 3.11 con las bibliotecas NumPy, OpenCV, scikit-image, SciPy, PyWavelets, Pandas, Matplotlib y Seaborn. El código se organizó en módulos separados (datasets, fusion, metrics, utils) bajo control de versiones git, priorizando la reproducibilidad: cualquier figura, tabla o estadístico de esta tesis puede regenerarse ejecutando los scripts del directorio experiments/.

4.7 Análisis estadístico

Se aplicaron tres procedimientos no paramétricos. Primero, la prueba de Friedman (Friedman, 1937) global por métrica, considerando las imágenes como bloques y los métodos como tratamientos, contrasta la hipótesis nula de que todos los métodos producen distribuciones idénticas. Segundo, la prueba de Wilcoxon de rangos signados (Wilcoxon, 1945) se aplica de manera pareada entre cada configuración Top-Hat (WTH y WTH+BTH) y cada baseline, así como entre la propuesta central (Propuesta Novedosa) y el método anterior y cada baseline, controlando por imagen; dado el elevado número de contrastes se aplica corrección de Holm por métrica y se reporta el tamaño de efecto rank-biserial. Tercero, se calcula el ranking promedio por método y métrica (1 = mejor), respetando la dirección de cada una (todas de tipo «mayor es mejor») y promediando entre métricas para obtener un ranking global. Todos los cálculos utilizan scipy.stats con $\alpha = 0,05$.

5. ANÁLISIS E INTERPRETACIÓN DE RESULTADOS

El capítulo presenta primero la caracterización del corpus y los análisis cualitativo y cuantitativo del benchmark —la Propuesta Novedosa (operador de suma de ramas, $r = 25$, $m = 0,070$) frente a la metodología clásica de la transformada Top-Hat y a cinco métodos representativos del estado del arte (LP, RP, DWT, DTCWT y CVT)—, luego el análisis estadístico no paramétrico (sección 5.4), la evaluación orientada a tarea (sección 5.5) y la optimización del método (sección 5.6), cerrando con la discusión integrada (sección 5.7).

5.1 Caracterización del dataset

Las veinte (20) imágenes pareadas del TNO Image Fusion Dataset cubren escenarios variados: vehículos blindados a la luz del día y nocturno, soldados detrás de humo, escenas urbanas con humanos a contraluz, espacios industriales y vegetación. Los pares poseen registro espacial previo y resoluciones del orden de 360×270 a 768×576 píxeles. La modalidad VIS exhibe textura rica en contornos, mientras que la IR concentra la información en focos de calor y siluetas humanas. Esta heterogeneidad es deliberada: la fusión multimodal solo es interesante cuando las dos fuentes aportan información que la otra no captura.

5.2 Análisis cualitativo: comparación visual

La figura 6 muestra tres pares representativos del dataset junto con los resultados de los métodos del benchmark. Visualmente, la pirámide de Laplace y la DTCWT recuperan detalle fino con buen equilibrio, aunque introducen ligeros artefactos en bordes muy contrastantes; la RP acentúa el contraste local a costa de cierta sobreamplificación; la DWT presenta el granulado característico de la fusión por máxima magnitud de coeficiente; y el Top-Hat clásico produce la imagen de mayor contraste aparente, pero con halos visibles alrededor de los objetivos térmicos, consecuencia de inyectar el detalle sin ponderación. La Propuesta Novedosa (destacada en rojo) ofrece el resultado visualmente más limpio y equilibrado: integra la silueta térmica de la IR y la textura del VIS con bordes definidos, sin el granulado de la DWT ni los halos del operador clásico. Esto es coherente con su indicador cuantitativo más destacado: la mayor similitud estructural del estudio ($SSIM = 0,782$). La Propuesta Novedosa (destacada en rojo) ofrece el resultado visualmente más limpio y equilibrado: integra la silueta térmica de la IR y la textura del VIS con bordes definidos, sin el granulado del Curvelet ni el exceso de brillo de las variantes más agresivas. Esto es coherente con su indicador cuantitativo más destacado: la mayor similitud estructural del estudio ($SSIM = 0,782$), reflejo de una fusión más fiel a las fuentes y menos propensa al realce agresivo.




Figura 6. Comparación cualitativa de los métodos de fusión sobre tres pares representativos del dataset.

5.3 Resultados cuantitativos: promedio por método

La Tabla 4 presenta los promedios de las seis métricas clásicas y la Tabla 5 los de la frecuencia espacial, la similitud estructural y el PSNR, sobre los 20 pares para los siete métodos del benchmark. En las métricas clásicas la pirámide de Laplace lidera la desviación estándar y la información mutua, mientras que el Top-Hat clásico maximiza EN, MG y SF al inyectar la energía de detalle sin ponderación. La propuesta, en cambio, alcanza la mayor similitud estructural del benchmark ($SSIM = 0,782$) y se ubica segunda en información mutua con las fuentes, mostrando una fusión más fiel y conservadora; el operador clásico, en el extremo opuesto, maximiza la actividad pero pierde una cuarta parte de la similitud estructural ($SSIM = 0,578$).

Tabla 4. Promedios de las seis métricas clásicas por método ($n = 20$).

Método	EN	SD	FE	MG	MI_vis	MI_ir
Pirámide de Laplace (LP)	6,8350	0,1548	1,0792	0,0248	2,1183	1,0717
Ratio Pyramid (RP)	6,8285	0,1304	1,0790	0,0269	1,1698	0,8807
Wavelet discreta (DWT)	6,7002	0,1199	1,0586	0,0270	1,2846	0,8809
DTCWT	6,7060	0,1205	1,0596	0,0251	1,2887	0,8908
Curvelet (CVT)	6,6645	0,1167	1,0529	0,0256	1,3038	0,8843
Top-Hat clásico	6,9334	0,1387	1,0961	0,0473	0,8722	0,5864
Propuesta Novedosa	6,6406	0,1173	1,0487	0,0194	1,3422	0,9088

Tabla 5. Promedios de frecuencia espacial (SF), similitud estructural (SSIM) y PSNR por método ($n = 20$ pares).

Método	SF ↑	SSIM ↑	PSNR ↑
Pirámide de Laplace (LP)	13,0400	0,7208	20,2687
Ratio Pyramid (RP)	13,3376	0,7212	21,9655
Wavelet discreta (DWT)	13,9341	0,7163	22,7767
DTCWT	13,0266	0,7386	22,7857
Curvelet (CVT)	13,1510	0,7305	22,8375
Top-Hat clásico	22,8554	0,5781	17,4947
Propuesta Novedosa	9,6441	0,7822	18,7313

Estas métricas, ponderadas por bordes y estructura local, complementan a las anteriores: Pirámide de Laplace (LP) lidera FMI, Propuesta Novedosa lidera Q0, DTCWT lidera QW y Pirámide de Laplace (LP) lidera QE. La Propuesta Novedosa se mantiene competitiva en toda la familia, coherente con su perfil de fidelidad estructural y limpieza.

Una distribución más completa de las métricas, no reducida al promedio, se aprecia en los diagramas de caja de la figura 7.




Figura 7. Diagramas de caja de seis métricas representativas (SSIM, SF, EN, SD, MI_{ir}, PSNR) por método (n = 20 pares VIS/IR).

5.4 Análisis estadístico no paramétrico

5.4.1 Prueba de Friedman global

La Tabla 6 reporta la prueba de Friedman aplicada de forma independiente a cada métrica, considerando los siete métodos del benchmark como tratamientos y los 20 pares como bloques. La hipótesis nula se rechaza con amplio margen en las nueve métricas ($p \ll 0,001$), lo que habilita el análisis pareado posterior: existen diferencias reales y sistemáticas entre los métodos comparados.

Tabla 6. Prueba de Friedman por métrica (χ^2 , p-valor; $\alpha = 0,05$).

Métrica	χ^2 de Friedman	p-valor	Significativo ($\alpha = 0,05$)
EN	85,96	< 0,001	Sí
SD	98,92	< 0,001	Sí
FE	85,96	< 0,001	Sí
MG	94,97	< 0,001	Sí
MI_vis	75,83	< 0,001	Sí
MI_ir	62,39	< 0,001	Sí
SF	90,16	< 0,001	Sí
SSIM	96,52	< 0,001	Sí
PSNR	107,47	< 0,001	Sí

5.4.2 Comparaciones pareadas Wilcoxon

Para precisar dónde residen las diferencias se aplicó la prueba de Wilcoxon de rangos signados entre los métodos morfológicos (la propuesta y el Top-Hat clásico) y cada método del estado del arte, sobre las nueve métricas, con corrección de Holm y tamaño de efecto rank-biserial (90 contrastes; detalle en el Apéndice C). El hallazgo central: la propuesta mejora de forma estadísticamente significativa la similitud estructural (SSIM) frente a los cinco métodos del estado del arte ($p_{\text{Holm}} \leq 0,001$) y la información mutua con las fuentes frente a la mayoría de ellos, mientras que cede de manera sistemática en las métricas de actividad y contraste (EN, SD, MG, SF), donde lideran los operadores de mayor realce. Frente al Top-Hat clásico, la ventaja en SSIM e información mutua es amplia y significativa.

5.4.3 Ranking promedio

La Tabla 7 muestra el ranking promedio de cada método (1 = mejor) en seis métricas clave y el ranking global obtenido al promediar las nueve métricas, respetando la dirección de cada una. La pirámide de Laplace encabeza el ranking global (3,11), seguida por DTCWT y el Top-Hat clásico (3,78) y RP (3,89); la propuesta ocupa el séptimo lugar (5,00), penalizada por las métricas de actividad y contraste —que premian el realce agresivo, liderado por el Top-Hat clásico—, pese a ser primera en SSIM y segunda en información mutua. El ranking agregado, al mezclar familias de métricas con pesos iguales, debe leerse junto a los contrastes pareados de la sección anterior.

Tabla 7. Ranking promedio por método y métrica (1 = mejor).

Método	SD	MG	SF	SSIM	PSNR	MI_ir	Global
Pirámide de Laplace (LP)	1,0	6,0	5,0	5,0	5,0	1,0	3,11

Ratio Pyramid (RP)	3,0	3,0	3,0	4,0	4,0	6,0	3,89
DTCWT	4,0	5,0	6,0	2,0	2,0	3,0	3,78
Propuesta Novedosa	6,0	7,0	7,0	1,0	6,0	2,0	5,00
Top-Hat clásico	2,0	1,0	1,0	7,0	7,0	7,0	3,78
Wavelet discreta (DWT)	5,0	2,0	2,0	6,0	3,0	5,0	4,22
Curvelet (CVT)	7,0	4,0	4,0	3,0	1,0	4,0	4,22




Figura 8. Ranking global por método (promedio de rangos sobre las nueve métricas, con la dirección de cada una corregida).

5.5 Evaluación orientada a tarea: detección con YOLO (LLVIP y M3FD)

Para una evaluación concluyente —con verdad de campo— se reentrenó el mismo detector (YOLOv8n) por separado sobre cada modalidad usando el conjunto LLVIP (15.488 pares VIS/IR registrados, peatones en baja luz; subconjunto de 2.000/500 imágenes, 40 épocas, idéntica configuración). Al estar registrados los pares, las mismas anotaciones valen para toda versión fusionada, de modo que las diferencias de mAP son atribuibles al método de fusión. La Tabla 8 reporta $mAP@0,5$ y $mAP@0,5:0,95$.

Tabla 8. Detección de peatones en LLVIP — mAP por modalidad (YOLOv8n; subconjunto 2000 train / 500 val, 40 épocas).

Método	mAP@0,5 ↑	mAP@0,5:0,95 ↑	Precisión ↑	Recall ↑
VIS (solo)	0,808	0,451	0,803	0,751
IR (solo)	0,957	0,663	0,968	0,894
Pirámide de Laplace (LP)	0,949	0,651	0,943	0,879
Ratio Pyramid (RP)	0,926	0,538	0,940	0,866

Wavelet discreta (DWT)	0,946	0,614	0,974	0,853
Dual-Tree Complex Wavelet (DTCWT)	0,948	0,633	0,949	0,858
Curvelet (CVT)	0,941	0,639	0,972	0,868
Top-Hat clásico	0,938	0,609	0,957	0,866
Propuesta Novedosa (r=25, m=0,070)	0,936	0,609	0,936	0,859

La Tabla 8 admite tres lecturas. Primero, toda fusión mejora con claridad sobre el visible solo (mAP@0,5 de 0,808 a una banda de 0,926–0,949, es decir entre +0,12 y +0,14 puntos): cuando el canal visible es débil —escenas nocturnas—, fusionar aporta información decisiva. Segundo, el infrarrojo solo es la modalidad más fuerte (mAP@0,5 = 0,957; mAP@0,5:0,95 = 0,663) y ninguna fusión lo supera, coherente con que LLVIP es detección de peatones en baja luz, donde la firma térmica domina. Tercero, entre las siete fusiones las diferencias son pequeñas (mAP@0,5 en una banda estrecha de 0,926 a 0,949): la pirámide de Laplace encabeza (0,949), seguida de cerca por DTCWT (0,948) y DWT (0,946), mientras que la Propuesta Novedosa resulta competitiva (0,936), en la banda de las fusiones y a pocos puntos del mejor, sin ser líder. La conclusión es matizada y relevante: la superioridad de la propuesta en la calidad estructural de imagen (SSIM) no se traslada automáticamente a la tarea de detección, donde la banda de fusiones es estrecha y la modalidad térmica domina; la elección del método depende del criterio operativo prioritario —en consonancia con lo señalado por Singh et al. (2023)—.

Detección con clases complementarias (M3FD). Como complemento se diseñó un experimento de clases complementarias sobre el dataset M3FD (Liu et al., 2022): 2.000 pares de entrenamiento y 500 de validación con seis clases anotadas, dos de ellas de visibilidad opuesta —las personas dominan en el infrarrojo por su firma térmica y las luces (Lamp) son esencialmente visibles solo en el canal visible—. Un único detector YOLOv8n se entrenó con las imágenes de ambas modalidades mezcladas (4.000 imágenes, 40 épocas, etiquetas compartidas) y se evaluó por inferencia, sin reentrenar, sobre la validación de cada modalidad y de cada método de fusión, incluidos los dos óptimos del PSO de la sección 5.6.

Tabla 9. Clases complementarias en M3FD: AP@0,5 por clase y mAP global con un detector único entrenado sobre VIS+IR (medias sobre 500 imágenes de validación).

Entrada del detector	AP People ↑	AP Lamp ↑	Promedio del par ↑	mAP@0,5 ↑
VIS (solo)	0,178	0,135	0,157	0,245
IR (solo)	0,220	0,018	0,119	0,191

Pirámide de Laplace (LP)	0,147	0,096	0,122	0,215
Ratio Pyramid (RP)	0,198	0,133	0,165	0,231
Wavelet discreta (DWT)	0,165	0,110	0,137	0,228
Dual-Tree Complex Wavelet (DTCWT)	0,159	0,114	0,137	0,229
Curvelet (CVT)	0,167	0,100	0,133	0,228
Top-Hat clásico ($r = 5$; $m = 1$)	0,125	0,054	0,090	0,198
PSO del trabajo de referencia (clásico + Fo)	0,174	0,118	0,146	0,229
Propuesta Novedosa ($r = 25$; $m = 0,070$)	0,207	0,117	0,162	0,239

La Tabla 9 confirma la complementariedad de forma extrema: el infrarrojo domina en personas ($AP@0,5 = 0,220$) pero es prácticamente ciego a las luces (0,018), y el visible presenta el patrón espejo (0,178 y 0,135). Las mejores fusiones superan en el promedio del par a ambas modalidades individuales —algo que ninguna logra por separado—, con la Propuesta Novedosa como la mejor fusión del estudio tanto en mAP global (0,239) como en personas (0,207, cerca del infrarrojo puro), manteniendo las luces cerca del visible. El visible solo conserva el mejor mAP global de seis clases (0,245) por la abundancia de vehículos diurnos, y los valores absolutos son moderados (subconjunto de 500 imágenes y modelo nano): el experimento no busca récords, sino aislar el escenario donde la fusión es insustituible —detectar en una sola imagen objetos que cada modalidad pierde por separado—. La Figura 9 ilustra el fenómeno sobre dos escenas de la validación: el visible no ve a las personas que la fusión recupera y el infrarrojo no ve las luces que la fusión conserva.

Detecciones del modelo único VIS+IR — People en granate, Lamp en azul (conf $\geq 0,25$)




Figura 9. Detecciones del modelo único VIS+IR en dos escenas de la validación de M3FD (personas en recuadro granate, luces en azul): en la escena superior el visible no detecta ninguna persona y la fusión las recupera; en la inferior el infrarrojo no detecta ninguna luz y la fusión las recupera.

5.6 Propuesta Novedosa (método central)

La Propuesta Novedosa —método central de esta tesis— se optimizó con PSO sobre un subconjunto representativo de escenas, maximizando una aptitud orientada a la fusión ($Fo = SSIM_{avg} + En + PSNR_n$). La configuración del enjambre se seleccionó mediante un barrido de 25 combinaciones de partículas e iteraciones ($2-10 \times 10-50$, replicando el diseño de Ortega y Espinoza, 2025) con $r \in [1, 25]$; el óptimo global $r = 25$ y $m \approx 0,07$ ($Fo = 1,7654$) fue alcanzado de forma consistente por los enjambres de 10 partículas con 30 o más iteraciones. Esta aptitud premia simultáneamente la fidelidad estructural (SSIM), el contenido informativo (entropía) y la reducción de la distorsión (PSNR), evitando el realce trivial al que conduce una aptitud de contraste puro.

La Tabla 10 compara la propuesta, en su configuración óptima ($r = 25$, $m = 0,070$), con la metodología clásica Top-Hat y con métodos representativos del estado del arte (LP, RP y DTCWT; los valores de DWT y CVT, del mismo orden, se detallan en el material complementario) sobre métricas representativas. La propuesta alcanza la mayor similitud estructural del estudio ($SSIM = 0,782$, frente a $0,578$ del Top-Hat clásico) y una preservación de información competitiva ($MI_{ir} = 0,909$), a costa de una menor actividad de contraste ($SF = 9,6$

frente a 22,9 del clásico) y un PSNR intermedio (18,7). Refleja así una fusión conservadora y estructuralmente fiel, en contraste con el realce agresivo del operador clásico.

La significación de estas diferencias se verificó con la prueba de Wilcoxon pareada ($n = 20$, corrección de Holm por métrica; detalle completo en el Apéndice C). Frente a la metodología clásica Top-Hat, la propuesta gana de forma estadísticamente significativa en similitud estructural (SSIM) e información mutua con las fuentes (MI_{vis} , MI_{ir} ; $p_{Holm} \leq 0,001$) y cede en las métricas de actividad y contraste (EN, SD, FE, MG, SF), que el operador clásico infla a costa de la fidelidad estructural. Frente a los cinco métodos del estado del arte, la ventaja significativa más consistente de la propuesta es en SSIM —supera a los cinco ($p_{Holm} < 0,05$)— y en información mutua mejora a la mayoría; en cambio cede de forma sistemática en las métricas de actividad y contraste, donde lideran los operadores de mayor realce. Con ello, la ventaja de la propuesta en fidelidad estructural (SSIM) frente a todos los rivales resulta estadísticamente significativa, quedando sostenidas H1 y H2.

La elección de la configuración es robusta: en el barrido de 25 combinaciones, seis configuraciones independientes alcanzaron el mismo óptimo global ($r = 25$, $m = 0,070$) y todos los enjambres de 10 partículas con 30 o más iteraciones convergieron a él, mientras que los enjambres de 2 partículas quedaron atrapados en el óptimo local $r = 1$. La aptitud crece con el radio hasta el tope del rango explorado, lo que indica que el operador aprovecha vecindarios amplios para capturar los objetivos térmicos completos, con el peso m compensando a la baja la mayor energía de detalle que inyecta la suma de ramas.

Tabla 10. Propuesta Novedosa frente a la metodología clásica Top-Hat y al estado del arte — medias sobre 20 pares ($n = 20$).

Métrica	Propuesta Novedosa ($r=25$, $m=0,070$)	Top-Hat clásico	Pirámide de Laplace (LP)	Ratio Pyramid (RP)	DTCWT
SSIM ↑	0,782	0,578	0,721	0,721	0,739
PSNR ↑	18,73	17,49	20,27	21,97	22,79
SF ↑	9,64	22,86	13,04	13,34	13,03
MI_{ir} ↑	0,909	0,586	1,072	0,881	0,891
SD ↑	0,117	0,139	0,155	0,130	0,120




Figura 10. Propuesta Novedosa (PSO: $r = 25$, $m = 0,070$) frente a la metodología clásica Top-Hat y al estado del arte en las métricas estándar de calidad.

La Figura 11 resume la optimización del método. El panel izquierdo muestra la mejor aptitud alcanzada según el número de partículas ($T_{max} = 50$): los enjambres grandes escapan del óptimo local $r = 1$ y alcanzan la aptitud máxima $F_o = 1,7654$. El panel derecho y la Tabla 11 sintetizan el barrido de 25 configuraciones: el óptimo global ($r = 25$, $m = 0,070$) es alcanzado por seis configuraciones y de forma consistente por los enjambres de 10 partículas con 30 o más iteraciones; la contribución de los elementos estructurantes lineales sobre el disco reside en la cobertura de orientaciones.




Figura 11. Convergencia del PSO según el número de partículas (izq.) y aptitud del barrido de configuraciones (der.), sobre tres escenas representativas.

Tabla 11. Barrido de configuraciones del PSO: mejor aptitud F por combinación de partículas (n) e iteraciones (T).

Partículas \ Iteraciones	T = 10	T = 20	T = 30	T = 40	T = 50
n = 2	1,7622	1,7556	1,7642	1,7556	1,7572
n = 4	1,7633	1,7654	1,7642	1,7642	1,7642
n = 6	1,7580	1,7642	1,7642	1,7642	1,7642
n = 8	1,7642	1,7558	1,7642	1,7654	1,7642
n = 10	1,7642	1,7642	1,7642	1,7642	1,7654

5.7 Discusión integrada

Los hallazgos cuantitativos pueden sintetizarse en seis observaciones. Primero, la Propuesta Novedosa ($r = 25$, $m = 0,070$) prioriza la fidelidad sobre el realce: alcanza la mayor similitud estructural del benchmark ($SSIM = 0,782$), significativamente superior a los cinco métodos del estado del arte, y se ubica segunda en información mutua con las fuentes, a costa de ceder en las métricas de actividad y contraste (EN, SD, MG, SF). Segundo, no existe un método universalmente dominante: la pirámide de Laplace lidera el contraste (SD) y la información mutua, el Top-Hat clásico la actividad bruta (EN, MG, SF) y la propuesta la similitud estructural (SSIM); son óptimos de criterios distintos y complementarios. Tercero, la comparación con la metodología clásica de la transformada Top-Hat aísla el aporte de la propuesta: el operador clásico maximiza la actividad bruta (EN, MG, SF) pero registra la peor similitud estructural del estudio ($SSIM = 0,578$), mientras que la propuesta la eleva a 0,782; la diferencia entre ambas mide la contribución del banco disco + líneas y del ajuste (r , m) por PSO. Cuarto, las métricas de actividad e información premian el realce agresivo y deben leerse junto a la similitud estructural, pues por sí solas favorecerían al operador más ruidoso a costa de la fidelidad. Quinto, la evaluación orientada a tarea (detección sobre LLVIP) constituye un criterio complementario: toda fusión supera netamente al visible solo (+0,12 a +0,14 en $mAP@0,5$), el infrarrojo solo es la modalidad más fuerte (0,957) y entre las fusiones —en una banda estrecha de 0,926 a 0,949— la propuesta es competitiva (0,936) sin ser líder, lo que confirma que la superioridad en calidad de imagen no se traslada automáticamente a la detección. Sexto, el experimento de clases complementarias sobre M3FD delimita el escenario donde la fusión es insustituible: cuando la escena contiene objetos térmicos (personas) y objetos exclusivamente visibles (luces), las mejores fusiones superan en el par complementario a ambas modalidades individuales y la propuesta es la mejor fusión del estudio, detectando ambas clases en una sola imagen.

6. CONCLUSIONES Y RECOMENDACIONES

6.1 Conclusiones

Se propuso, implementó y evaluó la Propuesta Novedosa, un método de fusión VIS/IR basado en Top-Hat con elementos estructurantes circulares y lineales sobre una sola escala y parámetros optimizados por PSO, comparándolo estadísticamente con la metodología clásica de la transformada Top-Hat y con cinco métodos representativos del estado del arte (LP, RP, DWT, DTCWT y CVT) sobre el TNO Image Fusion Dataset. Las conclusiones específicas son:

1. La Propuesta Novedosa —con las respuestas lineales promediadas y sumadas a la del disco sobre una sola escala (PSO: $r=25$, $m=0,070$, seleccionado mediante un barrido de 25 configuraciones de enjambre)— logra la mayor similitud estructural del benchmark (SSIM=0,782) y una preservación de información competitiva (segunda en información mutua con las fuentes), con una fusión conservadora y fiel a las fuentes. Supera a la metodología clásica Top-Hat en similitud estructural e información mutua de forma estadísticamente significativa (Wilcoxon pareado con corrección de Holm: $p \leq 0,001$; sección 5.6). En la evaluación de detección sobre LLVIP, toda fusión supera al visible solo (mAP@0,5 de 0,808 a 0,926–0,949) pero ninguna al infrarrojo solo (0,957), y la propuesta resulta competitiva (mAP@0,5 = 0,936), dentro de una banda estrecha de fusiones, sin ser la mejor: su ventaja en calidad de imagen no se traslada directamente a la tarea de detección, cuya estrategia óptima depende de la aplicación. En el experimento de clases complementarias (M3FD), en cambio, la fusión muestra su valor distintivo: detecta simultáneamente los objetos térmicos (personas) y los exclusivamente visibles (luces) que cada modalidad pierde por separado, con la propuesta como la mejor fusión del estudio (mAP@0,5 = 0,239). Quedan así sostenidas las hipótesis H1 y H2, y solo parcialmente H3.

2. Entre los métodos del estado del arte no hay dominancia global: DTCWT es el rival más equilibrado en similitud estructural (SSIM=0,739), la pirámide de Laplace lidera el contraste (SD) y la información mutua con las fuentes, y el PSNR más alto corresponde a los métodos multiescala (CVT y DTCWT); la elección del comparativo altera el podio según la métrica priorizada, lo que refuerza la necesidad de evaluar con familias de métricas complementarias.

3. La pirámide de Laplace presenta el mejor ranking global agregado (3,11 sobre los 7 métodos), sostenido por su ventaja en contraste (SD) e información mutua con las fuentes; no domina, en cambio, en fidelidad estructural, donde la propuesta la supera de forma

estadísticamente significativa. La propuesta, penalizada por las métricas de actividad y contraste, queda en el séptimo lugar (5,00) pese a liderar la similitud estructural.

4. La métrica de información mutua (MI) está sesgada a favor del promedio simple, dado que la combinación lineal preserva trivialmente contenido de ambas fuentes. Este hallazgo invita a reportar MI siempre acompañada de métricas de calidad global y a no interpretarla aisladamente como veredicto de fidelidad.

5. Dentro de la familia Top-Hat, la geometría del elemento estructurante introduce diferencias modestas: el disco tiende a maximizar EN, SD y FE; la cruz preserva ligeramente mejor la información mutua entre las configuraciones morfológicas; el cuadrado se sitúa en una posición intermedia.

6. La profundidad de descomposición (L) y el radio base (r_0) tienen efectos complementarios: mayor profundidad incrementa entropía y contraste; menor radio preserva mejor el gradiente.

7. Las pruebas no paramétricas confirman que las diferencias observadas no son fruto del azar: la prueba de Friedman es altamente significativa ($p < 0,001$) en las nueve métricas, y las comparaciones pareadas Wilcoxon con corrección de Holm corroboran las superioridades específicas reportadas (ganancia significativa en SSIM frente a la pirámide de Laplace y a los demás métodos del estado del arte).

8. La variante con Black Top-Hat no se recomienda como configuración por defecto: aunque incrementa el contraste y la actividad (EN, SD, SF, MG), degrada significativamente la fidelidad estructural (SSIM) y la información mutua con las fuentes (MI). El detalle oscuro que añade es en gran parte ruido no presente en las fuentes.

9. Es metodológicamente fundamental separar la regla de fusión de detalle (max-actividad por pixel) de la regla de fusión de la base (promedio): aplicar selección por actividad a la capa base introduce discontinuidades de iluminación y sesga las métricas de información mutua. Este aprendizaje es transferible a cualquier descomposición multiescala.

10. No existe un método universalmente óptimo: la decisión de qué algoritmo de fusión emplear debe estar guiada por el criterio operativo prioritario más que por una métrica única.

6.2 Recomendaciones

A partir de los hallazgos se proponen las siguientes líneas de trabajo futuro y de aplicación.

- Profundizar en reglas de fusión que aprovechen el Black Top-Hat de forma selectiva (p. ej. ponderando el detalle oscuro por su consistencia con las fuentes) para capturar valles oscuros sin introducir los artefactos observados en la variante WTH+BTH directa.
- Replicar la evaluación sobre datasets adicionales (RoadScene, M3FD, MS-COCO multispectral) para verificar la transferibilidad de las conclusiones.
- Explorar reglas de fusión adaptativas que ponderen la actividad local en función de estadísticos globales de la imagen, en lugar de la regla de máximo aplicada en este trabajo.
- Evaluar híbridos Top-Hat $\leftrightarrow$ pirámide de Laplace que combinen la fidelidad a fuentes del primero con la riqueza global del segundo.
- Comparar contra modelos de fusión profundos preentrenados (FusionGAN, U2Fusion, SeAFusion) para situar el costo y el beneficio de los métodos clásicos en el panorama actual del estado del arte.
- Seleccionar el método de fusión según el criterio operativo prioritario: para aplicaciones donde prima la fidelidad estructural a las fuentes, emplear la Propuesta Novedosa ($r = 25$, $m = 0,070$), que registra la mayor similitud estructural (SSIM) del benchmark y una preservación de información competitiva; para un balance que privilegie el contraste global y la actividad, la pirámide de Laplace y la metodología clásica Top-Hat siguen siendo opciones sólidas, esta última interpretable y de muy bajo costo computacional.
- Reportar siempre la información mutua junto con métricas de calidad global (EN, SD, MG) para evitar interpretaciones engañosas; el caso del promedio simple ilustra que MI alta no equivale necesariamente a fusión de mejor calidad perceptual.

7. REFERENCIAS BIBLIOGRÁFICAS

Aslantas, V., y Bendes, E. (2015). A new image quality metric for image fusion: The sum of the correlations of differences. *AEU - International Journal of Electronics and Communications*, 69(12), 1890–1896.

Bai, X. (2013). Morphological image fusion using the extracted image regions and details based on multi-scale top-hat transform and toggle contrast operator. *Digital Signal Processing*, 23(1), 244–263.

Bai, X., Zhou, F., y Xue, B. (2015). Image enhancement using multi-scale image features extracted by top-hat transform. *Optics & Laser Technology*, 65, 145–150.

Bala, A. A., Aruna Priya, P., y Maik, V. (2024). Hybrid technique for fundus image enhancement using modified morphological filter and denoising net. *The Journal of Supercomputing*, 80, 13317–13340. <https://doi.org/10.1007/s11227-024-05952-x>

Burt, P. J., y Adelson, E. H. (1983). The Laplacian pyramid as a compact image code. *IEEE Transactions on Communications*, 31(4), 532–540.

Candès, E., Demanet, L., Donoho, D., y Ying, L. (2006). Fast discrete curvelet transforms. *SIAM Multiscale Modeling & Simulation*, 5(3), 861–899.

Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200), 675–701.

Gonzalez, R. C., y Woods, R. E. (2018). *Digital Image Processing* (4^a ed.). Pearson.

Haghighat, M., Aghagolzadeh, A., y Seyedarabi, H. (2011). A non-reference image fusion metric based on mutual information of image features. *Computers & Electrical Engineering*, 37(5), 744–756.

Jia, X., Zhu, C., Li, M., Tang, W., y Zhou, W. (2021). LLVIP: A visible-infrared paired dataset for low-light vision. *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*, 3496–3504.

Kennedy, J., y Eberhart, R. (1995). Particle swarm optimization. *Proceedings of ICNN'95 - International Conference on Neural Networks*, 4, 1942–1948.

Li, S., Kang, X., Fang, L., Hu, J., y Yin, H. (2017). Pixel-level image fusion: A survey of the state of the art. *Information Fusion*, 33, 100–112.

Liu, J., Fan, X., Huang, Z., Wu, G., Liu, R., Zhong, W., y Luo, Z. (2022). Target-aware dual adversarial learning and a multi-scenario multi-modality benchmark to fuse infrared and visible for object detection. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 5802–5811.

Ma, J., Ma, Y., y Li, C. (2019). Infrared and visible image fusion methods and applications: A survey. *Information Fusion*, 45, 153–178.

Ma, J., Yu, W., Liang, P., Li, C., y Jiang, J. (2019). FusionGAN: A generative adversarial network for infrared and visible image fusion. *Information Fusion*, 48, 11–26.

Malviya, P., y Saxena, A. K. (2014). An improved image fusion technique based on texture feature optimization using wavelet transform and particle of swarm optimization (POS). *International Journal of Computer Applications*, 101(6), 19–22.

Mukhopadhyay, S., y Chanda, B. (2001). A multi-scale morphological approach to local contrast enhancement. *Signal Processing*, 80(4), 685–696.

Ortega Rodríguez, M. A., y Espinoza Ríos, G. A. (2025). Optimización de los parámetros de la transformada Top-Hat mediante PSO para la fusión de imágenes visibles e infrarrojas. *Proyecto de Trabajo Final de Grado, Facultad Politécnica, Universidad Nacional de Asunción*.

Piella, G., y Heijmans, H. (2003). A new quality metric for image fusion. *Proceedings IEEE ICIP*, vol. 3, 173–176.

Román, J. C. M., Vázquez Noguera, J. L., y Legal-Ayala, H. (2020). A multiscale morphological method for visible and infrared images fusion. *Proceedings of the 2020 XLVI Latin American Computing Conference (CLEI)*, 488–495. IEEE.

Serra, J. (1982). *Image Analysis and Mathematical Morphology*. Academic Press.

Sheikh, H. R., y Bovik, A. C. (2006). Image information and visual quality. *IEEE Transactions on Image Processing*, 15(2), 430–444.

Singh, S., Singh, H., Bueno, G., Deniz, O., Singh, S., Monga, H., Hrisheekesha, P. N., y Pedraza, A. (2023). A review of image fusion: Methods, applications and performance metrics. *Digital Signal Processing*, 137, 104020.

Soille, P. (2003). *Morphological Image Analysis: Principles and Applications* (2^a ed.). Springer.

Tang, L., Yuan, J., y Ma, J. (2022). Image fusion in the loop of high-level vision tasks: A semantic-aware real-time infrared and visible image fusion network. *Information Fusion*, 82, 28–42.

Tao, J., Li, S., y Yang, B. (2010). Multimodal image fusion algorithm using dual-tree complex wavelet transform and particle swarm optimization. En *Advanced Intelligent Computing Theories and Applications (Communications in Computer and Information Science*, vol. 93, pp. 296–303). Springer.

Toet, A. (1989). Image fusion by a ratio of low-pass pyramid. *Pattern Recognition Letters*, 9(4), 245–253.

Toet, A. (2014). The TNO multiband image data collection. *Data in Brief*, 4, 187–192.

Wang, J., Peng, J., Feng, X., He, G., y Fan, J. (2017). Fusion method for infrared and visible images by using non-negative sparse representation. *Infrared Physics & Technology*, 80, 1–9.

Wang, Z., Bovik, A. C., Sheikh, H. R., y Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612.

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83.

Xydeas, C. S., y Petrović, V. (2000). Objective image fusion performance measure. *Electronics Letters*, 36(4), 308–309.

Zhang, X., y Demiris, Y. (2023). Visible and infrared image fusion using deep learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(8), 10535–10554.

8. APÉNDICE

A. Repositorio del código

La totalidad del código de esta tesis está disponible en el repositorio del proyecto, organizado en módulos: `src/datasets.py` (carga y emparejado VIS/IR), `src/fusion/` (`optimal_top_hat.py` para la propuesta —operador de suma de ramas, función `fuse_optimal`— y `comparatives.py` para los seis métodos comparativos: LP, RP, DWT, DTCWT, CVT y la fusión Top-Hat clásica), `src/metrics/evaluators.py` (las nueve métricas), `src/utils/` (entrada/salida y visualización), `experiments/run_all_fusions.py` (benchmark inter-método), `experiments/run_stats_analysis.py` (Friedman, Wilcoxon con Holm y ranking), `experiments/pso_grid_search.py` (barrido de 25 configuraciones del PSO), `experiments/detection_llvip/` (preparación y entrenamiento mAP en LLVIP), `notebooks/` (análisis exploratorios). El archivo `requirements.txt` consigna las dependencias exactas.

B. Configuraciones del barrido PSO

Las 36 configuraciones evaluadas resultan del producto cartesiano de los siguientes valores:

- Número de partículas del enjambre: 2, 4, 6, 8, 10.
- Número de iteraciones: 10, 20, 30, 40, 50.
- Espacio de búsqueda: $r \in [1, 25]$; $m \in [0,05; 1,20]$.

Cada combinación del barrido ejecuta una corrida PSO independiente con semilla propia (25 corridas, 4.500 evaluaciones de fusión en total). El estado completo y reanudable se conserva en `experiments/results/pso/pso_grid_state.json` y la tabla resumen en `experiments/results/metrics_reports/pso_grid_search.csv`.

C. Tablas estadísticas extendidas

Las tablas completas con los 90 contrastes Wilcoxon (2 métodos morfológicos $\times 5$ métodos del estado del arte $\times 9$ métricas) se almacenan en `experiments/results/metrics_reports/wilcoxon_results.csv`. Cada fila contiene la métrica, las medias comparadas, la diferencia, el estadístico W, el p-valor, el p-valor corregido por Holm, la marca de significación a $\alpha = 0,05$ y el tamaño de efecto rank-biserial. El ranking promedio está en `ranking_methods.csv` y los resultados de Friedman en `friedman_results.csv`. Los 48 contrastes de la propuesta central frente al método anterior y a los baselines (9 métricas $\times 4$ rivales,

Wilcoxon con Holm y tamaño de efecto rank-biserial) se consignan en wilcoxon_propuesta_vs_metodos.csv.

D. Pseudocódigo de la fusión Top-Hat clásica

Entrada: imágenes f_{VIS} , f_{IR} (escala de grises, normalizadas en $[0,1]$), radio r del disco ($r = 5$). Salida: imagen fusionada F . 1. $I_{base} \leftarrow (f_{VIS} + f_{IR})/2$. 2. Para cada fuente S : $WTH_S \leftarrow S - apertura(S, disco(r))$; $BTH_S \leftarrow cierre(S, disco(r)) - S$. 3. $WTH_max \leftarrow \max(WTH_VIS, WTH_IR)$; $BTH_max \leftarrow \max(BTH_VIS, BTH_IR)$. 4. $F \leftarrow recortar(I_{base} + WTH_max - BTH_max, [0,1])$.

Pseudocódigo de la Propuesta Novedosa (una sola escala)

ENTRADA: I_{VIS} , I_{IR} en $[0,1]$ alineadas; radio r ; peso m
SALIDA: imagen fusionada F

```
para cada fuente S en {I_VIS, I_IR}:
  L <- {linea(r,0), linea(r,45), linea(r,90), linea(r,135)} # 4 lineas
  WTH_lin <- promedio_{b en L} ( S - apertura(S,b) ) # ec. (7)
  BTH_lin <- promedio_{b en L} ( cierre(S,b) - S )
  WTH_disco <- S - apertura(S, disco(r)) # ec. (8)
  BTH_disco <- cierre(S, disco(r)) - S
  lopt_top[S] <- WTH_lin + WTH_disco # ec. (9)
  lopt_bot[S] <- BTH_lin + BTH_disco

# combinacion entre fuentes (maximo por pixel) # ec. (10)
lopt_top <- max(lopt_top[VIS], lopt_top[IR])
lopt_bot <- max(lopt_bot[VIS], lopt_bot[IR])
I_base <- (I_VIS + I_IR) / 2
F <- recortar( I_base + m*lopt_top - m*lopt_bot, 0, 1 ) # ec. (11)
devolver F
```

(r , m) se optimizan por PSO (barrido de 25 configuraciones) $\rightarrow r = 25$, $m = 0,0703$

Nota: la versión definitiva y única del método (sección 2.2.5) promedia las cuatro respuestas lineales y las suma a la del disco sobre una sola escala —sin descomposición multiescala ni diferencias en cascada— y optimiza (r , m) por PSO mediante un barrido de 25 configuraciones de enjambre, con óptimo $r = 25$, $m = 0,0703$. Su implementación de referencia es src/fusion/optimal_top_hat.py (función fuse_optimal, modo 'sum').

E. Refinamiento metodológico de la regla de fusión

Durante el desarrollo iterativo de la implementación se identificó un punto sutil pero sustantivo en la regla de fusión multiescala. Una primera versión aplicaba selección por máxima actividad local de manera uniforme a todas las capas, incluyendo la base. La versión definitiva, reportada en los resultados de esta tesis, distingue las dos clases de capas: las L capas de detalle WTH se fusionan por máxima actividad local; la capa base se fusiona por promedio simple. Esta distinción es coherente con la práctica establecida en la literatura clásica de fusión multiescala.

El refinamiento eliminó discontinuidades de iluminación y sesgos artificiales en la información mutua.

F. Hardware y tiempos de ejecución

La totalidad de los experimentos se ejecutó en una notebook estándar (Intel i7, 16 GB de RAM, sin GPU dedicada) bajo Windows 11 con Python 3.11. Cada fusión Top-Hat consume entre 20 y 80 milisegundos según la configuración; la pirámide de Laplace y el curvelet se sitúan en órdenes de magnitud comparables. La ejecución completa del benchmark exhaustivo (720 fusiones) toma aproximadamente 90 segundos. Esta liviandad computacional confirma la viabilidad del método para aplicaciones en tiempo real.