



**Universidad
Comunera**

FACULTAD DE CIENCIAS Y TECNOLOGÍA

MAESTRÍA EN CIENCIAS DE DATOS

FUSIÓN DE IMÁGENES INFRARROJAS Y VISIBLES MEDIANTE MORFOLOGÍA MATEMÁTICA

Una propuesta de Top-Hat/Bottom-Hat de una sola escala con elementos estructurantes de disco y lineales, optimizada por PSO

Autores:

Lic. Juan Pablo Bazán

Ing. Yan Bajac

Tesis presentada a la Universidad Comunera, Facultad de Ciencias y Tecnología, Maestría en Ciencias de Datos, como requisito parcial para la obtención del título de Magíster en Ciencias de Datos.

Asunción – Paraguay

SEPTIEMBRE 2026

FUSIÓN DE IMÁGENES INFRARROJAS Y VISIBLES MEDIANTE MORFOLOGÍA MATEMÁTICA

Una propuesta de Top-Hat/Bottom-Hat de una sola escala con elementos estructurantes de disco y lineales, optimizada por PSO

Autores:

Lic. Juan Pablo Bazán

Ing. Yan Bajac

Orientador:

D.Sc. Julio César Mello

Tesis presentada a la Universidad Comunera, Facultad de Ciencias y Tecnología, Maestría en Ciencias de Datos, como requisito parcial para la obtención del título de Magíster en Ciencias de Datos.

Asunción – Paraguay

SEPTIEMBRE 2026

PÁGINA DE APROBACIÓN

Esta tesis, titulada «Fusión de Imágenes Infrarrojas y Visibles mediante Morfología Matemática», fue presentada por Lic. Juan Pablo Bazán e Ing. Yan Bajac como requisito parcial para la obtención del título de Magíster en Ciencias de Datos, y aprobada por el siguiente tribunal examinador.

Director de Tesis – D.Sc. Julio César Mello

Examinador 1

Examinador 2

Asunción, Paraguay

2026

DEDICATORIA

A nuestras familias, por sostener cada noche larga y cada decisión difícil que llevó este trabajo a término.

A nuestros profesores y compañeros de la Maestría en Ciencias de Datos, por las discusiones que afilaron las ideas.

Y a la comunidad de software libre, sin la cual una tesis empírica como esta sería materialmente imposible.

AGRADECIMIENTOS

A la Universidad Comunera (UCOM) y a la Facultad de Ciencias y Tecnología, por brindar el marco académico de la Maestría en Ciencias de Datos.

A nuestro director de tesis, D.Sc. Julio César Mello, por el rigor metodológico, la paciencia y la orientación constante a lo largo del desarrollo de este trabajo.

A los autores y mantenedores del dataset TNO Image Fusion Dataset, cuyo material puesto a disposición pública hizo posible la evaluación experimental.

A los desarrolladores de las bibliotecas científicas de Python (NumPy, OpenCV, scikit-image, SciPy, PyWavelets, Matplotlib, Pandas), pilares de toda la implementación.

A nuestros colegas y compañeros de cohorte, por las revisiones cruzadas y los comentarios que mejoraron tanto el código como la redacción.

RESUMEN

La fusión de imágenes visible (VIS) e infrarroja (IR) es clave para la percepción computacional en condiciones adversas (vigilancia, conducción nocturna, búsqueda y rescate). Este trabajo propone la PROPUESTA NOVEDOSA, un método de fusión basado en la transformada Top-Hat que, sobre una única escala, promedia las respuestas de cuatro elementos estructurantes lineales (0° , 45° , 90° , 135°) y toma el máximo frente a la respuesta de un disco para obtener transformadas Top-Hat y Bottom-Hat óptimas; la reconstrucción sigue el esquema aditivo–sustractivo de Bala et al., y el radio r del banco de elementos estructurantes y el peso de contraste m se ajustan automáticamente por Optimización por Enjambre de Partículas (PSO). Se lo compara con el método anterior (Torre Top-Hat) y con baselines clásicos (promedio, pirámide de Laplace, curvelet) sobre el TNO Image Fusion Dataset, con dieciséis métricas sin referencia (doce de ellas bajo pruebas no paramétricas: Friedman y Wilcoxon con corrección de Holm). En su configuración óptima (PSO: $r=12$, $m=0,127$) la propuesta obtiene una tasa de artefactos muy baja ($Nabf=0,035$), la mayor similitud estructural entre los métodos reales ($SSIM=0,783$) y la mejor preservación de bordes y correlación de su familia ($Qabf=0,495$; $SCD=1,421$). Como evaluación orientada a tarea, el reentrenamiento de un detector (YOLOv8n) sobre el conjunto etiquetado LLVIP muestra que la fusión supera al visible solo ($mAP@0,5$ de 0,81 a 0,90–0,95), aunque el infrarrojo solo es la modalidad más fuerte (0,957) y las fusiones simples igualan a las morfológicas; la propuesta es competitiva (0,905) pero no líder en mAP, evidenciando que la superioridad en calidad de imagen no se traslada automáticamente a la detección. Se concluye que la propuesta mejora la calidad de fusión —en particular la limpieza y la fidelidad estructural— frente al método anterior y a los baselines, manteniendo bajo costo computacional e interpretabilidad morfológica.

Palabras clave: fusión de imágenes, morfología matemática, top-hat, infrarrojo, visible, PSO, métricas sin referencia.

SUMMARY

Visible (VIS) and infrared (IR) image fusion is key for computer perception under adverse conditions (surveillance, night driving, search and rescue). This work proposes the NOVEL PROPOSAL, a fusion method based on the Top-Hat transform that, on a single scale, averages the responses of four linear structuring elements (0° , 45° , 90° , 135°) and takes the maximum against a disk response to obtain optimal Top-Hat and Bottom-Hat transforms; reconstruction follows the additive–subtractive scheme of Bala et al., and the structuring-element radius r and the contrast weight m are tuned automatically by Particle Swarm Optimization (PSO). It is compared with the previous method (Top-Hat Tower) and classical baselines (average, Laplacian pyramid, curvelet) on the TNO Image Fusion Dataset, using sixteen no-reference metrics (twelve of them under non-parametric testing: Friedman, Wilcoxon with Holm correction). At its optimal configuration (PSO: $r=12$, $m=0.127$) the proposal attains a very low artifact rate ($N_{abf}=0.035$), the highest structural similarity among real methods ($SSIM=0.783$) and the best edge preservation and correlation in its family ($Q_{abf}=0.495$; $SCD=1.421$). As a task-oriented evaluation, retraining a detector (YOLOv8n) on the labeled LLVIP dataset shows that fusion clearly outperforms the visible modality alone ($mAP@0.5$ from 0.81 to 0.90–0.95), although the infrared alone remains the strongest modality (0.957) and simple fusions match the morphological ones; the proposal is competitive (0.905) but not the mAP leader, showing that superiority in image quality does not automatically transfer to detection. We conclude that the proposal improves fusion quality —particularly cleanliness and structural fidelity— over the previous method and the baselines, while keeping low computational cost and morphological interpretability.

Keywords: image fusion, mathematical morphology, top-hat, infrared, visible, multi-scale, no-reference metrics.

CONTENIDO

LISTA DE SIGLAS.....	8
LISTA DE FIGURAS.....	8
LISTA DE TABLAS.....	8
INTRODUCCIÓN.....	14
1. PROBLEMA DE INVESTIGACIÓN.....	16
1.1 Descripción del problema.....	16
1.2 Justificación e importancia.....	16
1.3 Objetivos.....	17
1.3.1 General.....	17
1.3.2 Específicos.....	17
1.4 Formulación del problema.....	17
1.4.1 Problema general.....	17
1.4.2 Problemas específicos.....	18
1.5 Hipótesis.....	18
1.6 Limitaciones de la investigación.....	18
1.7 Alcance.....	19
2. MARCO TEÓRICO.....	20
2.1 Estado del arte.....	20
2.2 Fundamentación teórica.....	21
2.2.1 Fusión de imágenes multimodal.....	21
2.2.2 Morfología matemática.....	22
2.2.3 Transformada Top-Hat.....	22
2.2.4 Torre Top-Hat (método anterior).....	23
2.2.5 Propuesta Novedosa: método de fusión Top-Hat con elementos estructurantes circulares y lineales optimizado por PSO.....	24
2.2.6 Algoritmos de referencia (baselines).....	29
2.2.7 Métricas de evaluación.....	29
3. MARCO CONCEPTUAL.....	33
3.1 Imagen visible (VIS).....	33
3.2 Imagen infrarroja (IR).....	33
3.3 Elemento estructurante (SE).....	33
3.4 White Top-Hat (WTH).....	33

3.5 Black Top-Hat (BTH).....	33
3.6 Descomposición multiescala.....	33
3.7 Regla de fusión por actividad local.....	33
3.8 Métrica sin referencia.....	34
3.9 Prueba de Friedman.....	34
3.10 Prueba de Wilcoxon.....	34
3.11 Elemento estructurante lineal.....	34
3.12 Combinación de respuestas por máximo.....	34
3.13 Descomposición multiescala en cascada.....	34
3.14 Peso de ajuste de contraste (m).....	35
3.15 Optimización por Enjambre de Partículas (PSO).....	35
3.16 Función de aptitud.....	35
4. MARCO METODOLÓGICO.....	36
4.1 Enfoque.....	36
4.2 Tipo.....	36
4.3 Diseño.....	36
4.4 Operacionalización de las variables.....	36
4.5 Dataset y preprocesamiento.....	37
4.6 Implementación.....	38
4.7 Análisis estadístico.....	38
5. ANÁLISIS E INTERPRETACIÓN DE RESULTADOS.....	39
5.1 Caracterización del dataset.....	39
5.2 Análisis cualitativo: comparación visual.....	39
5.3 Resultados cuantitativos: promedio por método.....	40
5.4 Análisis estadístico no paramétrico.....	43
5.4.1 Prueba de Friedman global.....	43
5.4.2 Comparaciones pareadas Wilcoxon.....	44
5.4.3 Ranking promedio.....	44
5.5 Análisis del benchmark exhaustivo de la Torre Top-Hat.....	46
5.6 Efecto de la variante Black Top-Hat.....	47
5.7 Evaluación orientada a tarea: detección con YOLO.....	48
5.7.1 Evaluación con dataset etiquetado: mAP en LLVIP.....	49
5.8 Propuesta Novedosa (método central).....	50

5.9 Discusión integrada.....	53
6. CONCLUSIONES Y RECOMENDACIONES.....	55
6.1 Conclusiones.....	55
6.2 Recomendaciones.....	56
7. REFERENCIAS BIBLIOGRÁFICAS.....	58
8. APÉNDICE.....	61
A. Repositorio del código.....	61
B. Configuraciones del benchmark exhaustivo.....	61
C. Tablas estadísticas extendidas.....	61
D. Pseudocódigo de la Torre Top-Hat.....	62
E. Refinamiento metodológico de la regla de fusión.....	62
F. Hardware y tiempos de ejecución.....	63

LISTA DE SIGLAS

Sigla	Significado
VIS	Espectro visible
IR	Infrarrojo
SE	Elemento estructurante (Structuring Element)
WTH	White Top-Hat (Top-Hat blanco)
BTH	Black Top-Hat (Top-Hat negro)
MM	Morfología matemática
EN	Entropía de Shannon
SD	Desviación estándar
FE	Factor / eficiencia de fusión
MG	Gradiente medio
MI	Información mutua (Mutual Information)
TNO	TNO Image Fusion Dataset (Países Bajos)
PCA	Análisis de componentes principales
DWT	Transformada wavelet discreta
DTCWT	Transformada wavelet compleja de árbol dual
CNN	Red neuronal convolucional
GAN	Red generativa antagónica
SF	Frecuencia espacial (Spatial Frequency)
Qabf	Métrica de preservación de bordes (Xydeas-Petrovic)
Nabf	Artefactos añadidos por la fusión (menor es mejor)
SSIM	Índice de similitud estructural (Structural Similarity)
SCD	Suma de correlaciones de las diferencias
VIF	Fidelidad de información visual (Visual Information Fidelity)

Sigla	Significado
YOLO	You Only Look Once (detector de objetos)
FPS	Cuadros por segundo (Frames Per Second)
mAP	Precisión media promedio (mean Average Precision)
PSO	Optimización por Enjambre de Partículas (Particle Swarm Optimization)
PSNR	Relación señal-ruido de pico (Peak Signal-to-Noise Ratio)

LISTA DE FIGURAS

Figura 1. Operaciones morfológicas (erosión, dilatación, apertura y cierre) y transformada Top-Hat sobre un perfil de intensidad.

Figura 2. Esquema conceptual de la Torre Top-Hat (método anterior).

Figura 3. Banco de cinco elementos estructurantes (un disco y cuatro líneas) empleados por el operador en la escala de radio r .

Figura 4. Flujograma de la Propuesta Novedosa (proceso paso a paso).

Figura 5. Optimización por enjambre de partículas (PSO) del vector de hiperparámetros (r , m).

Figura 6. Comparación cualitativa de los métodos de fusión sobre tres pares representativos del dataset.

Figura 7. Diagramas de caja de seis métricas estándar de calidad (Qabf, Nabf, SSIM, SCD, VIF, SF) para métodos representativos ($n = 20$ pares VIS/IR).

Figura 8. Ranking global por método (promedio de rangos sobre las doce métricas, con la dirección de cada una corregida).

Figura 9. Mapas de calor de las seis métricas para las 36 configuraciones de la Torre Top-Hat.

Figura 10. Impacto de añadir Black Top-Hat sobre las configuraciones disco L3 y L5: cambio relativo por métrica (verde = mejora, rojo = empeora).

Figura 11. Detectabilidad de YOLOv8n preentrenado por método (izq.: personas vs vehículos por método; der.: detecciones por método; la Propuesta Novedosa resaltada).

Figura 12. Propuesta Novedosa (PSO: $r = 12$, $m = 0,127$) frente al método anterior y a los baselines.

Figura 13. Convergencia del PSO (izq.) y sensibilidad al radio r (der.) de la Propuesta Novedosa, sobre tres escenas representativas.

LISTA DE TABLAS

Tabla 1. Notación empleada en el marco teórico.

Tabla 2. Configuración de la Propuesta Novedosa y del PSO.

Tabla 3. Algoritmos de referencia utilizados como línea base.

Tabla 4. Promedios de las seis métricas clásicas por método ($n = 20$).

Tabla 5. Promedios de las seis métricas estándar de calidad de fusión por método ($n = 20$ pares).

Tabla 5b. Métricas adicionales del review (FMI y Piella Q0/QW/QE) por método — medias sobre 20 pares.

Tabla 6. Prueba de Friedman por métrica (χ^2 , p-valor; $\alpha = 0,05$).

Tabla 7. Ranking promedio por método y métrica (1 = mejor).

Tabla 8. Detectabilidad de YOLOv8n por método (suma sobre 20 imágenes; inferencia en GPU).

Tabla 8b. Detección de peatones en LLVIP — mAP por modalidad (YOLOv8n; subconjunto 2000 train / 500 val, 40 épocas).

Tabla 9. Propuesta Novedosa frente al método anterior y a los baselines — medias sobre 20 pares ($n = 20$).

Tabla 10. Sensibilidad al radio r de la Propuesta Novedosa (tres escenas representativas).

INTRODUCCIÓN

La percepción visual computacional moderna depende, en numerosas aplicaciones críticas, de la integración de información proveniente de sensores complementarios. Las cámaras del espectro visible (VIS) capturan la reflectancia de la luz solar, ofreciendo alta resolución textural y cromática, pero degradándose ante condiciones de iluminación adversas como noche cerrada, niebla densa o humo. Por su parte, las cámaras infrarrojas (IR), particularmente las del rango térmico de onda larga, registran la radiación emitida por los cuerpos según su temperatura, siendo robustas a la oscuridad y a la mayoría de los ocluidores atmosféricos, aunque con menor resolución espacial y escaso detalle de textura. La fusión de imágenes VIS+IR busca reunir estas fortalezas complementarias en una sola representación que sea, simultáneamente, rica en detalles, discriminativa térmicamente y útil para tareas posteriores de detección, clasificación o decisión.

Las aplicaciones que se benefician de esta integración son numerosas y de alto impacto: vigilancia perimetral, búsqueda y rescate, conducción de vehículos autónomos en condiciones de baja visibilidad, sistemas de visión nocturna para defensa, inspección no destructiva en líneas de producción y diagnóstico médico complementario. En todas ellas, la calidad de la imagen fusionada condiciona directamente la calidad del análisis subsiguiente.

Existen, en términos generales, tres familias de métodos de fusión: las de píxel, ampliamente estudiadas y operadas sobre intensidades; las de característica, que extraen rasgos abstractos antes de combinar; y las de decisión, que fusionan salidas de clasificadores. Dentro del nivel píxel, las técnicas multiescala (pirámides, wavelets, curvelets) y las morfológicas han sido pilares clásicos por su interpretabilidad y bajo costo computacional, en contraposición a los enfoques recientes basados en redes neuronales profundas, que ofrecen alto rendimiento pero demandan grandes volúmenes de datos pareados y operan como cajas negras.

Esta tesis se sitúa explícitamente en el espacio de los métodos clásicos interpretables. Propone como núcleo la Propuesta Novedosa, un método de fusión basado en la transformada Top-Hat que, sobre una única escala definida por el radio r , combina un banco de cinco elementos estructurantes —un disco y cuatro segmentos lineales a 0° , 45° , 90° y 135° , con las respuestas lineales promediadas y confrontadas por máximo con la del disco para obtener transformadas óptimas— y reconstruye la imagen fusionada mediante el esquema aditivo–sustractivo de Bala et al. (2024) ponderado por el peso de contraste m ; sus hiperparámetros (radio r y peso m) se ajustan automáticamente por Optimización por Enjambre de Partículas (PSO). Como línea base propia se

emplea la Torre Top-Hat, descomposición multiescala iterativa de radio creciente desarrollada en la primera etapa de esta investigación, que aquí se denomina método anterior. La hipótesis subyacente es que la sensibilidad direccional del banco de elementos estructurantes y la búsqueda automática de hiperparámetros permiten ajustar la fusión a las características del par VIS/IR sin renunciar a la transparencia algorítmica; complementariamente, se evalúa el impacto de la fusión en una tarea posterior de detección de objetos sobre un conjunto etiquetado (LLVIP).

El presente documento está organizado de la siguiente manera. En el capítulo de Problema de Investigación se delimita la pregunta científica y los objetivos. El Marco Teórico revisa el estado del arte y los fundamentos de morfología matemática, descomposición multiescala y métricas de evaluación. El Marco Conceptual define los términos operativos clave. El Marco Metodológico precisa el diseño experimental. El capítulo de Análisis e Interpretación de Resultados expone tanto el benchmark exhaustivo de la Torre Top-Hat como la comparación frente a métodos de referencia, sustentado en pruebas estadísticas no paramétricas. Finalmente, las Conclusiones y Recomendaciones sintetizan los hallazgos y delinean trabajos futuros.

1. PROBLEMA DE INVESTIGACIÓN

1.1 Descripción del problema

Pese a más de tres décadas de investigación en fusión de imágenes multimodal, no existe un método universalmente óptimo: cada familia algorítmica presenta compromisos distintos entre preservación de detalle, contraste, transferencia de información y costo computacional. Los métodos basados en promedio, los más simples, sufren pérdida sistemática de detalle y reducción de contraste. Las pirámides de Laplace y los esquemas wavelet/curvelet ofrecen mejor manejo multiescala, pero pueden introducir artefactos de orla en bordes de alto contraste y son sensibles a desalineaciones residuales. Los métodos profundos, por su parte, requieren grandes corpora pareados y carecen de interpretabilidad.

La morfología matemática ofrece un marco intermedio: opera directamente sobre la geometría de las estructuras locales mediante elementos estructurantes (SE) parametrizables, lo cual la hace natural para preservar bordes y formas. La transformada Top-Hat, en particular, aísla con precisión los componentes de alta frecuencia que la apertura morfológica suprime. Sin embargo, la literatura existente sobre fusión morfológica suele restringirse a una única escala o a un único tipo de SE, sin un estudio sistemático que articule simultáneamente la geometría del SE, el número de niveles de descomposición y el radio base. Esta tesis aborda precisamente ese vacío empírico mediante un benchmark exhaustivo y la comparación con baselines clásicos.

1.2 Justificación e importancia

La justificación de este trabajo descansa sobre tres ejes. Primero, la relevancia aplicada: en contextos de vigilancia, seguridad pública y operaciones militares, los algoritmos de fusión deben ejecutarse bajo restricciones de tiempo real, sobre hardware limitado y con garantías de auditoría. La interpretabilidad y el bajo costo computacional de los métodos morfológicos los tornan especialmente valiosos en estos escenarios. Segundo, la relevancia metodológica: aportar evidencia empírica sistemática sobre el efecto de cada hiperparámetro (SE, L , r_0) ayuda a desmitificar decisiones de diseño que históricamente se han tomado por convención. Tercero, la relevancia académica regional: existen pocas tesis en el ámbito paraguayo que aborden de manera rigurosa la evaluación cuantitativa con pruebas no paramétricas en problemas de fusión multimodal, y este trabajo busca aportar a esa base.

1.3 Objetivos

1.3.1 General

Proponer y evaluar la Propuesta Novedosa, un método de fusión de imágenes visibles e infrarrojas basado en la transformada Top-Hat con elementos estructurantes circulares y lineales sobre una sola escala y parámetros optimizados por enjambre de partículas (PSO), comparándolo con el método anterior (Torre Top-Hat) y con baselines clásicos, y analizando su impacto en tareas posteriores de detección de objetos.

1.3.2 Específicos

1. Formular la Propuesta Novedosa: sobre una sola escala, un banco de cinco elementos estructurantes (un disco y cuatro lineales a 0° , 45° , 90° y 135°) cuyas respuestas lineales se promedian y se confrontan por máximo con la del disco para obtener transformadas Top-Hat y Bottom-Hat óptimas, con reconstrucción aditivo–sustractiva ponderada, adaptada al esquema de fusión VIS/IR.
2. Optimizar automáticamente los hiperparámetros del método (el radio r del banco de elementos estructurantes y el peso de contraste m) mediante PSO con una función de aptitud orientada a la calidad de fusión.
3. Comparar el método óptimo con el método anterior (Torre Top-Hat) y los baselines clásicos (promedio, pirámide de Laplace y curvelet) sobre doce métricas sin referencia, con pruebas no paramétricas (Friedman y Wilcoxon con corrección de Holm).
4. Analizar el impacto de la fusión en una tarea posterior de detección de objetos (YOLO), evaluando la detectabilidad por modalidad de entrada.

1.4 Formulación del problema

1.4.1 Problema general

¿La Propuesta Novedosa de fusión VIS+IR basada en la transformada Top-Hat, con elementos estructurantes de disco y lineales sobre una sola escala e hiperparámetros optimizados por PSO, mejora la calidad de fusión —evaluada con métricas sin referencia y pruebas no paramétricas sobre el TNO Image Fusion Dataset— respecto del método anterior (Torre Top-Hat) y de los baselines clásicos, y qué efecto produce en el desempeño de una tarea posterior de detección de objetos?

1.4.2 Problemas específicos

- ¿Cómo debe formularse el operador —banco de disco y líneas, combinación de respuestas y regla de reconstrucción— para adaptar el realce morfológico multidireccional al esquema de fusión VIS/IR?
- ¿Qué valores del radio r y del peso de contraste m maximizan una aptitud orientada a la calidad de fusión, y puede el PSO hallarlos automáticamente de forma estable?
- ¿Existen diferencias estadísticamente significativas entre la Propuesta Novedosa, el método anterior (Torre Top-Hat) y los baselines de promedio, pirámide de Laplace y curvelet, y en qué métricas?
- ¿La fusión —y en particular el método propuesto— mejora el desempeño de un detector de objetos (mAP sobre LLVIP) respecto de las modalidades visible e infrarroja por separado?

1.5 Hipótesis

De la formulación anterior se derivan tres hipótesis de trabajo. H1: la combinación de elementos estructurantes de disco y lineales sobre una sola escala —con las respuestas lineales promediadas y confrontadas por máximo con la del disco— mejora la fidelidad estructural (SSIM) y reduce los artefactos (Nabf) frente al método anterior (Torre Top-Hat). H2: la optimización automática de los hiperparámetros (r , m) por PSO, con una función de aptitud orientada a la fusión, alcanza un perfil de calidad superior al de la parametrización manual del método anterior. H3: una mejor calidad de fusión se traduce en un mejor desempeño de detección de objetos (mAP) que el de las modalidades individuales. Las hipótesis H1 y H2 se contrastan en las secciones 5.4 y 5.8; H3 se somete a prueba en la sección 5.7.1.

1.6 Limitaciones de la investigación

Esta investigación se circunscribe a las siguientes limitaciones, que deben tenerse presentes al interpretar los resultados. Primero, el corpus experimental son veinte pares del TNO Image Fusion Dataset, registrados principalmente en escenas militares y urbanas; las conclusiones pueden no transferirse íntegramente a otros dominios (médico, aéreo de muy alta resolución). Segundo, la evaluación se realiza con métricas sin referencia, dado que no existe una imagen fusionada óptima conocida; esto introduce inevitablemente una dependencia de las métricas elegidas. Tercero, la evaluación orientada a tarea con verdad de campo se realizó con un único detector (YOLOv8n)

sobre un subconjunto de LLVIP (2.000 imágenes de entrenamiento y 500 de validación, 40 épocas); extenderla a otros detectores y al conjunto completo queda como trabajo futuro. Cuarto, la regla de fusión por capa es la de selección por actividad local máxima, sin explorar reglas adaptativas. Quinto, no se evaluaron métodos basados en aprendizaje profundo, dado que tales comparaciones requieren protocolos de entrenamiento cuyos sesgos exceden el alcance de esta tesis.

1.7 Alcance

El alcance de la tesis abarca: la implementación íntegra y reproducible del método propuesto y de los baselines en Python (NumPy, OpenCV, scikit-image, SciPy, PyWavelets); la organización modular del código en un repositorio versionado; el preprocesamiento y emparejado del dataset; la ejecución del benchmark exhaustivo y de la comparación contra baselines; el análisis estadístico no paramétrico; la generación de tablas y figuras científicas; y la redacción del presente informe. Quedan fuera del alcance la generación de un nuevo dataset, la integración con sistemas en tiempo real y la comparación con métodos de aprendizaje profundo entrenados desde cero.

2. MARCO TEÓRICO

2.1 Estado del arte

La fusión de imágenes multimodal, particularmente VIS+IR, cuenta con una literatura abundante. Li et al. (2017) presentan una revisión integral de los métodos a nivel pixel, agrupándolos en cuatro grandes familias: dominios espaciales (promedio, máximo, PCA), dominios transformados multiescala (pirámides, wavelets, curvelets), métodos basados en representaciones dispersas y métodos híbridos. Ma et al. (2019) actualizan el panorama con énfasis en la creciente adopción de redes neuronales profundas, distinguiendo arquitecturas de auto-encoder, redes generativas antagónicas (GAN) y enfoques de fusión guiada por tareas. En paralelo, Zhang y Demiris (2023) documentan la consolidación de benchmarks estandarizados (TNO, RoadScene, M3FD) y el establecimiento progresivo de métricas sin referencia como estándar de facto.

Específicamente en fusión morfológica, Mukhopadhyay y Chanda (2001) introducen una de las primeras descomposiciones multiescala basadas en operadores Top-Hat para realce e interpretación de imágenes médicas. Bai (2013) extiende la idea a fusión VIS+IR, mostrando que la transformada Top-Hat puede capturar simultáneamente detalles brillantes y oscuros con bajo costo computacional. Trabajos posteriores, como los de Bai et al. (2015) y Wang et al. (2017), exploran combinaciones de Top-Hat con otras representaciones, pero rara vez sistematizan el efecto cruzado del tipo de elemento estructurante, el número de niveles y el radio base sobre múltiples métricas.

Los métodos profundos, por su parte, han avanzado rápidamente. Ma et al. (2019, FusionGAN) y Tang et al. (2022, SeAFusion) ofrecen arquitecturas de fusión guiadas por percepción semántica. Sin embargo, su dependencia de datos pareados y la dificultad de auditarlos los hacen problemáticos en aplicaciones donde la trazabilidad es obligatoria. En este contexto, los métodos clásicos siguen siendo no solo relevantes sino estratégicamente valiosos como baselines reproducibles.

Una visión panorámica reciente la ofrece la revisión de Singh et al. (2023), que sistematiza la fusión de imágenes en tres grandes familias —dominio espacial, descomposición multiescala (MSD: pirámides, wavelets y análisis geométrico multiescala) y aprendizaje automático— y en tres niveles de abstracción (píxel, característica y decisión). En esa taxonomía, la propuesta de esta tesis se ubica en la familia MSD, rama de pirámides morfológicas, y opera a nivel de píxel (PLIF).

La revisión documentada además el uso de metaheurísticas para ajustar parámetros de fusión —enjambre de partículas (PSO), colonia de abejas, búsqueda cuco—, con precedentes específicos de PSO aplicado a la fusión (p. ej. Tao et al., 2010, DTCWT+PSO; Malviya y Saxena, 2014, WT+PSO), lo que respalda la estrategia de optimización adoptada aquí.

2.2 Fundamentación teórica

Tabla 1. Notación empleada en el marco teórico.

Símbolo	Significado
f	Imagen de entrada en escala de gris [0,1] (VIS o IR)
b	Elemento estructurante (disco o segmento lineal)
$\varepsilon(f,b), \delta(f,b)$	Erosión y dilatación de f con b
$\gamma(f,b), \phi(f,b)$	Apertura y cierre de f con b
WTH, BTH	White Top-Hat y Black Top-Hat
r	Radio del elemento estructurante (disco y líneas)
m	Peso de ajuste de contraste
WTH_i, BTH_i	Top-Hat de líneas (promedio) y de disco (radio r)
$WTH_M, WTHS_M$	Transformadas óptimas: máx(líneas, disco) por fuente
I_base	Imagen base, $(I_VIS + I_IR)/2$
F	Imagen fusionada
x, v	Posición y velocidad de una partícula (PSO)
$pbest, gbest$	Mejor posición individual y global del enjambre
w, c_1, c_2	Inercia y coeficientes cognitivo y social (PSO)

2.2.1 Fusión de imágenes multimodal

La fusión de imágenes a nivel pixel se formaliza como un operador $F: \mathbb{R}^{H \times W} \times \mathbb{R}^{H \times W} \rightarrow \mathbb{R}^{H \times W}$ que recibe dos imágenes alineadas espacialmente, I_VIS e I_IR , y produce una imagen fusionada $F(I_VIS, I_IR)$ que maximice algún criterio de calidad. Tres etapas son comunes a todas las pipelines: preprocesamiento (registro, normalización), descomposición y fusión por capa, reconstrucción. La descomposición transforma cada imagen en una representación multi-escala que expone los detalles a distintas resoluciones; la fusión por capa aplica una regla de

selección (típicamente basada en actividad local máxima); la reconstrucción invierte la descomposición.

2.2.2 Morfología matemática

La morfología matemática es un cuerpo algebraico para el análisis de estructuras geométricas en imágenes, basado en la teoría de retículas completas (Serra, 1982; Soille, 2003; Gonzalez y Woods, 2018). Sus operaciones fundamentales en imágenes de niveles de gris son la erosión $\varepsilon(f, b)$ y la dilatación $\delta(f, b)$, definidas como mínimo y máximo locales bajo el patrón impuesto por el elemento estructurante b . A partir de ellas se derivan apertura $\gamma(f, b) = \delta(\varepsilon(f, b), b)$ y cierre $\phi(f, b) = \varepsilon(\delta(f, b), b)$, que eliminan respectivamente picos brillantes y valles oscuros menores que el SE. La elección del SE (geometría y radio) es la decisión de diseño central: define qué orientaciones, simetrías y escalas de detalle se preservan o suprimen.

Las dos operaciones fundamentales son la dilatación (δ) y la erosión (ε). En escala de grises, para un elemento estructurante b , se definen como el máximo y el mínimo local, respectivamente (Román et al., 2024):

$$\delta(f, b)(u, v) = \max_{(j, k) \in b} f(u - j, v - k), \varepsilon(f, b)(u, v) = \min_{(j, k) \in b} f(u + j, v + k) \quad (1)$$

$$\gamma(f, b) = \delta(\varepsilon(f, b), b), \phi(f, b) = \varepsilon(\delta(f, b), b) \quad (2)$$

2.2.3 Transformada Top-Hat

La transformada White Top-Hat se define como la diferencia entre la imagen original y su apertura: $WTH(f, b) = f - \gamma(f, b)$. Aísla las estructuras brillantes más pequeñas que el SE. Su dual, la Black Top-Hat, $BTH(f, b) = \phi(f, b) - f$, aísla los valles oscuros. Una propiedad clave es que el WTH es siempre no negativo y se anula en regiones donde la imagen es localmente plana a la escala del SE, lo que la convierte en un detector natural de detalles. La elección del tipo de SE (disco para isotropía, línea para direcciones específicas, cuadrado o cruz para sensibilidades distintas) determina qué tipo de detalle se enfatiza.

$$WTH(f, b) = f - \gamma(f, b), BTH(f, b) = \phi(f, b) - f \quad (3)$$

Para realzar estructuras direccionales, Bala et al. (2024) promedian las respuestas Top-Hat obtenidas con elementos estructurantes lineales en n orientaciones angulares:

$$WTH^m = \frac{1}{n} \sum_{\theta} (f - \gamma(f, b_{\theta})), BTH^m = \frac{1}{n} \sum_{\theta} (\phi(f, b_{\theta}) - f) \quad (4)$$

y reconstruyen la imagen realizada sumando los realces claros y restando los oscuros, combinando las respuestas lineales (multidireccionales) y la del disco:

$$I_{en} = I + (I_{top} - I_{bot}), I_{top} = WT H^m + WT H^d, I_{bot} = BT H^m + BT H^d \quad (5)$$

Operaciones morfológicas básicas y transformada Top-Hat




Figura 1. Operaciones morfológicas (erosión, dilatación, apertura y cierre) y transformada Top-Hat sobre un perfil de intensidad.

2.2.4 Torre Top-Hat (método anterior)

Sobre la transformada Top-Hat de una sola escala, esta tesis desarrolló inicialmente una descomposición multiescala iterativa, la Torre Top-Hat, que en este trabajo constituye el método anterior o base de comparación. Dada una imagen de entrada f , se aplica White Top-Hat con SE de radio r_0 , obteniendo la primera capa de detalle WTH_1 ; el residual de la apertura $\gamma(f, b_1)$ se procesa nuevamente con SE de radio $2 \cdot r_0$, dando WTH_2 ; el procedimiento se repite hasta el nivel L . La imagen queda descompuesta en L capas de detalle más una capa base (la apertura iterada R_L). La descomposición es exacta: la suma de las L capas WTH más la base reconstruye f . Para fusionar dos imágenes (VIS e IR) se aplica esta descomposición a cada una en paralelo y se opera capa a capa con dos reglas distintas: (i) las L capas de detalle WTH se fusionan por selección de máxima actividad local (suavizado gaussiano del valor absoluto), preservando por píxel el detalle más saliente de cualquiera de las fuentes; y (ii) la capa base, que codifica la iluminación o temperatura global de baja frecuencia, se fusiona por promedio simple. Esta distinción es crítica: aplicar selección por máxima actividad a la base genera saltos de brillo y sesga las métricas de información mutua.

La imagen fusionada final se reconstruye según la regla:

$$F = I_{\text{base}} + \sum_k WTH_k^{\text{fus}} - \sum_k BTH_k^{\text{fus}} \quad (6)$$

Existen por tanto dos modos de operación. En el modo White Top-Hat (WTH), por defecto, el término de BTH es nulo y la fusión es $F = \text{base} + \sum WTH_k^{\text{fus}}$, sumando únicamente el detalle brillante. En el modo White+Black Top-Hat (WTH+BTH), las capas BTH de VIS e IR también se fusionan por máxima actividad local y se restan en la reconstrucción, de modo que el WTH realza las estructuras brillantes y el BTH oscurece las estructuras oscuras, amplificando el contraste en ambos extremos. Esta tesis evalúa y compara ambos modos (Sección de resultados). Los parámetros explorados son: tipo de SE $\in \{\text{disco, cuadrado, cruz}\}$, niveles $L \in \{2, 3, 4, 5\}$ y radio base $r_0 \in \{2, 3, 5\}$, lo que arroja treinta y seis configuraciones por modo.




Figura 2. Esquema conceptual de la Torre Top-Hat (método anterior).

2.2.5 Propuesta Novedosa: método de fusión Top-Hat con elementos estructurantes circulares y lineales optimizado por PSO

La propuesta central de esta tesis —la Propuesta Novedosa— es un método de fusión morfológica que, sobre una única escala definida por el radio r , combina un banco de elementos estructurantes circulares y lineales. Integra tres ideas: el promediado multiangular de las respuestas lineales y la reconstrucción aditivo-sustractiva de Bala et al. (2024); el uso simultáneo de un disco y cuatro segmentos lineales para atender por igual a estructuras isótropas y orientadas; y la optimización por enjambre de partículas de Ortega y Espinoza (2025), que fija automáticamente

los hiperparámetros. Frente a la Torre Top-Hat (método anterior) —que emplea un único disco y reglas de selección ajustadas a mano—, la propuesta añade sensibilidad direccional y sustituye el ajuste manual por una búsqueda guiada por la calidad de fusión.

Elementos estructurantes circulares y lineales. El operador se calcula sobre una sola escala, fijada por el radio r . En cada fuente se emplean cinco elementos estructurantes: un disco B_r de radio r , isotrópico, y cuatro segmentos lineales $L_{r,\theta}$ de longitud $2r+1$ orientados a 0° , 45° , 90° y 135° . Las cuatro respuestas lineales se promedian —siguiendo el esquema multiangular de Bala et al. (ecuaciones 2 y 4)— tanto para el White Top-Hat como para el Black Top-Hat. La respuesta del disco se calcula por separado con el mismo radio. El promedio multiangular atenúa el ruido y realza estructuras alargadas en cualquier orientación, mientras que el disco preserva las estructuras isotrópicas.

Para cada fuente f y radio r , la ecuación (7) define la respuesta lineal promediada —White y Black Top-Hat sobre los cuatro segmentos $L_{r,\theta}$ — y la ecuación (8) la respuesta del elemento circular B_r del mismo radio:

$$WTH_{lin} = \frac{1}{4} \sum_{\theta} [f - \gamma(f, L_{r,\theta})], BTH_{lin} = \frac{1}{4} \sum_{\theta} [\varphi(f, L_{r,\theta}) - f] \quad (7)$$

$$WTH_{disco} = f - \gamma(f, B_r), BTH_{disco} = \varphi(f, B_r) - f \quad (8)$$

Banco de 5 elementos estructurantes por fuente (radio r) — Propuesta Novedosa




Figura 3. Banco de cinco elementos estructurantes (un disco y cuatro líneas) combinados por máximo por píxel.

Transformadas óptimas por máximo. A diferencia de Bala et al., que suman la respuesta lineal y la del disco, la propuesta las combina tomando el máximo por píxel: en cada punto se conserva la respuesta más fuerte, provenga de una estructura orientada o isotrópica. Así se obtienen, para cada fuente, la transformada óptima superior I_{opt}^{top} y la inferior I_{opt}^{bot} , según la ecuación (9). Las transformadas de la imagen visible y de la infrarroja se combinan luego entre fuentes tomando de nuevo el máximo por píxel (ecuación 10), conservando el detalle más saliente de cada modalidad.

$$I_{opt}^{top} = \max(WTH_{lin}, WTH_{disco}), I_{opt}^{bot} = \max(BTH_{lin}, BTH_{disco}) \quad (9)$$

$$I_{opt}^{top,F} = \max(I_{opt}^{top,IR}, I_{opt}^{top,VIS}), I_{opt}^{bot,F} = \max(I_{opt}^{bot,IR}, I_{opt}^{bot,VIS}) \quad (10)$$

Reconstrucción y regla de fusión. Sobre la imagen base $I_{base} = (I_{VIS} + I_{IR})/2$ —que retiene la iluminación del visible y la temperatura global del infrarrojo— se reconstruye la imagen fusionada según la ecuación (11): se añaden las estructuras brillantes (término con I_{opt}^{top}) y se restan las oscuras (término con I_{opt}^{bot}), moduladas por el peso de contraste m . Valores altos de m maximizan el contraste a costa de artefactos; valores bajos preservan la fidelidad. Esta regla adapta la reconstrucción aditivo-sustractiva de Bala et al. (ecuación 9 de ese trabajo, aquí ecuación 5) al esquema de fusión ponderada VIS/IR de Ortega y Espinoza.

$$F = I_{base} + m I_{opt}^{top,F} - m I_{opt}^{bot,F}, I_{base} = 1/2 (I_{VIS} + I_{IR}) \quad (11)$$

Flujograma de la Propuesta Novedosa (una sola escala)




Figura 4. Flujograma de la Propuesta Novedosa: proceso paso a paso (banco de cinco elementos estructurantes por fuente, promediado de las respuestas lineales, máximo frente al disco para obtener las transformadas óptimas, combinación entre fuentes por máximo y reconstrucción ponderada con el peso m).

Optimización por Enjambre de Partículas (PSO). El método tiene dos hiperparámetros — el radio r del banco de elementos estructurantes y el peso de contraste m — cuyo ajuste manual es

costoso y subjetivo. Para fijarlos se emplea la Optimización por Enjambre de Partículas (Kennedy y Eberhart, 1995), metaheurística poblacional inspirada en el comportamiento colectivo de las bandadas. Cada partícula es una solución candidata $x = (r, m)$ que recuerda su mejor posición propia (pbest) y la mejor del enjambre (gbest); en cada iteración su velocidad y posición se actualizan según la ecuación (13), donde w es la inercia y c_1, c_2 los coeficientes cognitivo y social. La implementación emplea 30 partículas durante 50 iteraciones, con $c_1 = c_2 = 1,5$ e inercia decreciente de 0,9 a 0,4.

El PSO optimiza el vector de hiperparámetros del método dentro del espacio de búsqueda acotado:

$$x = (r, m), r \in \{1, \dots, 12\}, m \in [0.05, 1.20] \quad (12)$$

$$v_{t+1} = w v_t + c_1 r_1 (p_{\text{best}} - x_t) + c_2 r_2 (g_{\text{best}} - x_t), x_{t+1} = x_t + v_{t+1} \quad (13)$$




Figura 5. Optimización por enjambre de partículas (PSO) del vector de hiperparámetros (r, m) .

Función de aptitud orientada a la fusión. A diferencia de una aptitud de fidelidad pura (SSIM + E + PSNR), que premia el realce conservador y conduce a óptimos triviales, aquí el PSO maximiza una aptitud orientada explícitamente a la calidad de fusión, definida en la ecuación (14), que recompensa la similitud estructural, la preservación de bordes y la correlación de las diferencias, y penaliza los artefactos. El enjambre convergió de forma estable al óptimo $r = 12$ y $m = 0,127$, configuración con la que se evalúa el método en el capítulo de resultados.

Tabla 2. Configuración de la Propuesta Novedosa y del PSO.

Parámetro	Valor
-----------	-------

Elementos estructurantes	5: un disco (radio r) + cuatro líneas (0° , 45° , 90° , 135° ; longitud $2r+1$)
Combinación de las respuestas	Promedio de las 4 líneas (ec. 7) y máximo frente al disco (ec. 9)
Escala (radio)	Única, de radio r (ajustado por PSO)
Regla de fusión entre fuentes	Máximo por píxel (ec. 10)
Función de aptitud	$F = SSIM + Qabf + 0,5 \cdot SCD - Nabf$
Partículas del enjambre	30
Iteraciones	50
Inercia w	$0,9 \rightarrow 0,4$ (decreciente)
Coeficientes c_1 , c_2	1,5 ; 1,5
Rangos de búsqueda	$r \in [1, 12]$; $m \in [0,05, 1,20]$
Óptimo hallado	$r = 12$; $m = 0,127$

$$F = SSIM + Q^{ab/f} + 0.5 SCD - N^{ab/f} \quad (14)$$

2.2.6 Algoritmos de referencia (baselines)

Para situar el método propuesto en el panorama de la disciplina se utilizan tres baselines:

Tabla 3. Algoritmos de referencia utilizados como línea base.

Método	Descripción	Referencia
Promedio simple	$F = 0,5 \cdot I_VIS + 0,5 \cdot I_IR$; cota inferior de complejidad y desempeño	—
Pirámide de Laplace	Descomposición Gaussiana–Laplaciana de 4 niveles; fusión por máxima actividad local y reconstrucción inversa	Burt y Adelson (1983)
Curvelet (vía wavelet 2D)	Subbandas direccionales (Daubechies db4, 3 niveles); máxima magnitud en detalle, promedio en aproximación	Candès et al. (2006)

2.2.7 Métricas de evaluación

Dado que en la fusión VIS/IR no existe una imagen de referencia (ground truth) —como subraya la revisión de Singh et al. (2023)—, la evaluación se realiza con dieciséis métricas sin referencia, que computan el puntaje a partir de la imagen fusionada y de sus fuentes. Seis son

clásicas de actividad e información (EN, SD, FE, MG, MI_vis, MI_ir); seis son estándar de calidad de fusión (SF, Qabf, Nabf, SSIM, SCD, VIF); y cuatro se incorporan siguiendo dicha revisión: la información mutua de la fusión sobre mapas de gradiente (FMI; Haghighat et al., 2011) y los índices de Piella y Heijmans (2003) —Q0 (índice universal por ventana), QW (ponderado por saliencia local) y QE (dependiente de bordes)—. Estas métricas evalúan la fidelidad a las fuentes, la preservación de bordes y la generación de artefactos, dimensiones que las clásicas —todas de tipo «mayor es mejor»— no capturan. Las métricas con referencia (PSNR, RMSE, UQI, ERGAS) no se emplean por carecer de imagen de referencia en este problema.

A continuación se formalizan las principales métricas sin referencia empleadas en la evaluación. Las primeras cuantifican propiedades intrínsecas de la imagen fusionada (información, contraste, nitidez) y las restantes miden cuánta información de las fuentes se transfiere y con qué fidelidad estructural:

Entropía (EN). Cantidad de información de la imagen fusionada; mayor es mejor (p_l = histograma normalizado, L niveles de gris).

$$EN = - \sum_{l=0}^{L-1} p_l \log_2 p_l \quad (15)$$

Desviación estándar (SD). Contraste global respecto de la media μ ; mayor SD indica mayor dispersión de intensidades.

$$SD = \sqrt{\frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N (F(i, j) - \mu)^2} \quad (16)$$

Frecuencia espacial (SF). Nitidez y nivel de detalle, combinando las frecuencias por filas (RF) y por columnas (CF).

$$SF = \sqrt{RF^2 + CF^2}, RF = \sqrt{\frac{1}{MN} \sum_i \sum_j (F(i, j) - F(i, j-1))^2} \quad (17)$$

Gradiente medio (MG). Definición y agudeza de los bordes a partir de los gradientes Δx , Δy .

$$\bar{G} = \frac{1}{MN} \sum_i \sum_j \sqrt{\Delta x^2 + \Delta y^2} \quad (18)$$

Información mutua (MI). Información de las fuentes A y B transferida a la fusión F; suma de las MI por par.

$$MI = MI_{AF} + MI_{BF}, MI_{XF} = \sum_x \sum_f p(x, f) \log_2 \frac{p(x, f)}{p(x)p(f)} \quad (19)$$

Q^{AB/F} (Xydeas–Petrović). Preservación de la información de bordes, ponderada por la intensidad de borde de cada fuente (w^A , w^B).

$$Q^{AB/F} = \frac{\sum_{i,j} (Q_{i,j}^{AF} w_{i,j}^A + Q_{i,j}^{BF} w_{i,j}^B)}{\sum_{i,j} (w_{i,j}^A + w_{i,j}^B)} \quad (20)$$

N^{AB/F} (Nabf). Tasa de ruido y artefactos introducidos por la fusión (AM = mapa de artefactos); menor es mejor.

$$N^{AB/F} = \frac{\sum_{i,j} AM_{i,j} (w_{i,j}^A + w_{i,j}^B)}{\sum_{i,j} (w_{i,j}^A + w_{i,j}^B)} \quad (21)$$

SSIM. Similitud estructural entre la fusión y las fuentes (luminancia, contraste y estructura; C₁, C₂ constantes de estabilidad).

$$SSIM(x, y) = \frac{(2\mu_x \mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (22)$$

SCD. Suma de correlaciones de las diferencias D₁, D₂ entre la fusión y cada fuente.

$$SCD = r(D_1, I_1) + r(D_2, I_2), D_1 = F - I_2, D_2 = F - I_1 \quad (23)$$

VIF. Fidelidad visual de la información, basada en un modelo de información en el dominio de subbandas.

$$VIF = \frac{\sum_j I(C^j; F^j | s^j)}{\sum_j I(C^j; E^j | s^j)} \quad (24)$$

FMI. Información mutua de los mapas de características (gradiente), normalizada por las entropías (Haghighat et al., 2011).

$$FMI = \frac{MI_{AF}}{H_A + H_F} + \frac{MI_{BF}}{H_B + H_F} \quad (25)$$

Q₀ / Piella. Calidad estructural universal; las variantes Q_W y Q_E la ponderan por la saliencia y los bordes locales (Piella y Heijmans, 2003).

	$Q_0 = \frac{4\sigma_{xy}\mu_x\mu_y}{(\sigma_x^2 + \sigma_y^2)(\mu_x^2 + \mu_y^2)}$	(26)
--	---	------

Métrica	Definición operativa	Interpretación	Dirección
EN	Entropía de Shannon del histograma de la imagen fusionada	Riqueza informacional global	↑
SD	Desviación estándar de los niveles de gris	Contraste global	↑
FE	$EN(F) \div \text{media}(EN(VIS), EN(IR))$	Ganancia informacional sobre las fuentes	↑
MG	Promedio de la magnitud del gradiente	Nitidez y preservación de bordes	↑
MI_vis	Información mutua entre F y la imagen VIS	Fidelidad a la fuente visible	↑
MI_ir	Información mutua entre F y la imagen IR	Fidelidad a la fuente infrarroja	↑
SF	Frecuencia espacial: actividad espacial global (filas y columnas)	Detalle y textura global	↑
Qabf	Información de borde de las fuentes transferida a la fusión (Xydeas-Petrovic)	Preservación de bordes	↑
Nabf	Bordes/ruido añadidos por la fusión inexistentes en las fuentes	Artefactos (menor es mejor)	↓
SSIM	Similitud estructural promedio respecto a VIS e IR	Fidelidad estructural	↑
SCD	Suma de correlaciones de las diferencias (Aslantas-Bendes)	Información de fuente retenida	↑
VIF	Fidelidad de información visual promedio (Sheikh-Bovik)	Fidelidad perceptual	↑

3. MARCO CONCEPTUAL

3.1 Imagen visible (VIS)

Imagen capturada en el rango espectral de 400 a 700 nanómetros, correspondiente a la sensibilidad del ojo humano. Resolución típica alta y dependencia fuerte de la iluminación ambiente.

3.2 Imagen infrarroja (IR)

Imagen capturada en el rango térmico (típicamente 8 a 14 micras, IR de onda larga) que registra la radiación emitida por los cuerpos en función de su temperatura. Resolución espacial típicamente inferior a la VIS pero independiente de la iluminación visible.

3.3 Elemento estructurante (SE)

Conjunto plano y compacto que define la geometría del vecindario sobre el que actúan las operaciones morfológicas. En esta tesis se exploran SE de tipo disco, cuadrado y cruz, con radios de 2, 3 y 5 píxeles.

3.4 White Top-Hat (WTH)

Operador morfológico definido como la diferencia entre la imagen original y su apertura. Aísla las estructuras brillantes locales menores que el SE.

3.5 Black Top-Hat (BTH)

Operador morfológico dual del WTH, definido como la diferencia entre el cierre de la imagen y la imagen original: $BTH(f, b) = \phi(f, b) - f$. Aísla las estructuras oscuras locales (valles) menores que el SE. Incorporarlo permite capturar simultáneamente el detalle brillante (vía WTH) y el detalle oscuro (vía BTH) de cada escala.

3.6 Descomposición multiescala

Representación de una imagen como suma de capas que aíslan estructuras a distintas escalas. En esta tesis se construye iterativamente aplicando WTH con SE de radio creciente.

3.7 Regla de fusión por actividad local

Mecanismo de selección capa-a-capas que escoge el aporte de la fuente cuya actividad local (magnitud del coeficiente suavizada con un kernel gaussiano) es mayor en cada posición.

3.8 Métrica sin referencia

Indicador cuantitativo de calidad calculado únicamente a partir de la imagen fusionada o de su relación con las fuentes, sin requerir una imagen objetivo conocida.

3.9 Prueba de Friedman

Prueba estadística no paramétrica para muestras relacionadas con tres o más tratamientos. Se utiliza para detectar diferencias globales entre métodos cuando los datos no cumplen normalidad.

3.10 Prueba de Wilcoxon

Prueba estadística no paramétrica de rangos signados para comparaciones pareadas, utilizada en esta tesis para confrontar cada configuración Top-Hat contra cada baseline.

3.11 Elemento estructurante lineal

Segmento recto de longitud $2r+1$ orientado a un ángulo determinado (0° , 45° , 90° o 135°), usado como elemento estructurante para resaltar estructuras alargadas en esa dirección. A diferencia del disco, que es isótropo, el SE lineal es direccional; el método óptimo combina un disco y cuatro líneas por escala para cubrir todas las orientaciones.

3.12 Combinación de respuestas por máximo

Regla que, dadas varias transformadas Top-Hat obtenidas con distintos elementos estructurantes sobre la misma imagen, conserva en cada píxel el valor máximo. Selecciona localmente el SE que mejor capta el detalle, sin privilegiar a priori ninguna geometría ni orientación.

3.13 Descomposición multiescala en cascada

Esquema que evalúa la Top-Hat en escalas crecientes (radios $r_i = r \cdot i$) y calcula diferencias entre escalas consecutivas ($WTHS_i$, $BTHS_i$) para separar el detalle fino del grueso, agregando después cada familia por máximo. Es una técnica clásica de descomposición multiescala; la Propuesta Novedosa de esta tesis no la emplea, pues opera sobre una sola escala.

3.14 Peso de ajuste de contraste (m)

Escalar que pondera cuánto se suman los realces brillantes (WTH) y se restan los oscuros (BTH) sobre la imagen base en la regla de fusión. Valores altos aumentan el contraste a riesgo de

artefactos; valores bajos preservan la fidelidad a las fuentes. En el método óptimo se ajusta automáticamente por PSO.

3.15 Optimización por Enjambre de Partículas (PSO)

Metaheurística poblacional (Kennedy y Eberhart, 1995) que busca el óptimo de una función moviendo un conjunto de partículas según su mejor posición individual (pbest) y la mejor global del enjambre (gbest). En esta tesis ajusta automáticamente los hiperparámetros (r , m) dla Propuesta Novedosa.

3.16 Función de aptitud

Criterio escalar que el PSO maximiza para evaluar cada solución candidata. Aquí es una combinación orientada a la fusión, $F = SSIM + Qabf + 0,5 \cdot SCD - Nabf$, que premia la fidelidad estructural, la preservación de bordes y la correlación, y penaliza los artefactos.

4. MARCO METODOLÓGICO

4.1 Enfoque

La investigación adopta un enfoque cuantitativo. Todos los hallazgos se sostienen en mediciones numéricas sobre conjuntos de imágenes definidos a priori, calculadas mediante implementaciones reproducibles y contrastadas con pruebas estadísticas no paramétricas.

4.2 Tipo

La investigación es de tipo experimental, con carácter descriptivo y comparativo. Se manipulan sistemáticamente los hiperparámetros del método propuesto y se observan los efectos sobre las métricas de calidad. La comparación con baselines aporta el componente comparativo.

4.3 Diseño

El diseño es factorial $3 \times 4 \times 3$ sobre el método anterior (Torre Top-Hat) (3 elementos estructurantes $\times$ 4 niveles $\times$ 3 radios base = 36 configuraciones), aplicado a cada uno de los 20 pares del dataset, totalizando 720 fusiones del benchmark exhaustivo (evaluadas con las seis métricas clásicas). Adicionalmente, se compara un conjunto de 11 métodos (3 baselines, 4 configuraciones White Top-Hat y 4 variantes con Black Top-Hat) sobre los mismos 20 pares, lo que arroja 220 fusiones evaluadas con las doce métricas, base del análisis estadístico inter-método (las cuatro métricas complementarias del review —FMI, Q0, QW y QE— se reportan de forma descriptiva en la Tabla 5b). La propuesta central, la Propuesta Novedosa, se evalúa de forma específica: sus dos hiperparámetros (el radio r del banco de elementos estructurantes y el peso de contraste m) se ajustan mediante PSO (30 partículas $\times$ 50 iteraciones) maximizando una aptitud orientada a la fusión evaluada sobre un subconjunto de tres escenas representativas, y la configuración óptima resultante se compara con el método anterior y los baselines sobre los 20 pares con las doce métricas, incluyendo contrastes pareados de Wilcoxon con corrección de Holm.

4.4 Operacionalización de las variables

Variable	Tipo	Definición operacional	Indicador / Valores
Tipo de SE	Independiente	Geometría del elemento estructurante	disco, cuadrado, cruz
Niveles (L)	Independiente	Profundidad de la torre Top-Hat	2, 3, 4, 5
Radio base (r_0)	Independiente	Radio del SE en el primer nivel	2, 3, 5 píxeles
Método	Independiente	Algoritmo de fusión empleado	11 métodos (§4.3) +

Variable	Tipo	Definición operacional	Indicador / Valores
			Propuesta Novedosa
Radio del SE (r)	Independiente	Radio del disco y longitud (2r+1) de las líneas del banco de SE	1–12 (ajustado por PSO)
Peso de contraste (m)	Independiente	Ponderación del realce en la regla de fusión	0,05–1,20 (ajustado por PSO)
Entropía (EN)	Dependiente	Entropía de Shannon de la fusionada	Bits, ↑ mejor
Desv. estándar (SD)	Dependiente	σ de niveles de gris	Adimensional, ↑ mejor
Eficiencia FE	Dependiente	EN(F) sobre media de fuentes	Razón, ↑ mejor
Gradiente medio (MG)	Dependiente	$ \nabla F $ promedio	Adimensional, ↑ mejor
MI_vis	Dependiente	Información mutua F ↔ VIS	Bits, ↑ mejor
MI_ir	Dependiente	Información mutua F ↔ IR	Bits, ↑ mejor
Métricas estándar y del review	Dependiente	SF, Qabf, Nabf, SSIM, SCD, VIF; FMI, Q0, QW, QE (§2.2.7)	Adimensional, ↑ mejor (Nabf ↓)
Detección (mAP)	Dependiente	mAP@0,5 y mAP@0,5:0,95 de YOLOv8n reentrenado por modalidad (LLVIP)	Proporción [0, 1], ↑ mejor

4.5 Dataset y preprocesamiento

El corpus experimental son veinte pares VIS/IR del TNO Image Fusion Dataset, dataset público mantenido por TNO (Países Bajos) ampliamente utilizado como referencia en la literatura (Toet, 2014). Las imágenes se reorganizaron en dos directorios paralelos (data/raw/VIS y data/raw/IR) con nombres de archivo coincidentes para emparejamiento automático. Se cargan en escala de grises, se normalizan al rango [0, 1] como float32 y se asume registro espacial previo (los pares TNO ya están alineados).

Para la evaluación orientada a tarea con verdad de campo (sección 5.7.1) se emplea adicionalmente el dataset LLVIP (Jia et al., 2021), compuesto por 15.488 pares VIS/IR registrados espacialmente, con peatones anotados en escenas de baja iluminación. Se utilizó un subconjunto

de 2.000 imágenes de entrenamiento y 500 de validación por modalidad (VIS, IR y cada fusión), reentrenando el detector YOLOv8n durante 40 épocas con configuración idéntica en todas las modalidades; al estar los pares registrados, las anotaciones originales son válidas para toda versión fusionada, de modo que las diferencias de mAP resultan atribuibles al método de fusión.

4.6 Implementación

Toda la implementación se realizó en Python 3.11 con las bibliotecas NumPy, OpenCV, scikit-image, SciPy, PyWavelets, Pandas, Matplotlib y Seaborn. El código se organizó en módulos separados (datasets, fusion, metrics, utils) bajo control de versiones git, priorizando la reproducibilidad: cualquier figura, tabla o estadístico de esta tesis puede regenerarse ejecutando los scripts del directorio experiments/.

4.7 Análisis estadístico

Se aplicaron tres procedimientos no paramétricos. Primero, la prueba de Friedman (Friedman, 1937) global por métrica, considerando las imágenes como bloques y los métodos como tratamientos, contrasta la hipótesis nula de que todos los métodos producen distribuciones idénticas. Segundo, la prueba de Wilcoxon de rangos signados (Wilcoxon, 1945) se aplica de manera pareada entre cada configuración Top-Hat (WTH y WTH+BTH) y cada baseline, así como entre la propuesta central (Propuesta Novedosa) y el método anterior y cada baseline, controlando por imagen; dado el elevado número de contrastes se aplica corrección de Holm por métrica y se reporta el tamaño de efecto rank-biserial. Tercero, se calcula el ranking promedio por método y métrica (1 = mejor), respetando la dirección de cada una (en Nabf, menor es mejor) y promediando entre métricas para obtener un ranking global. Todos los cálculos utilizan scipy.stats con $\alpha = 0,05$.

5. ANÁLISIS E INTERPRETACIÓN DE RESULTADOS

5.1 Caracterización del dataset

Las veinte (20) imágenes pareadas del TNO Image Fusion Dataset cubren escenarios variados: vehículos blindados a la luz del día y nocturno, soldados detrás de humo, escenas urbanas con humanos a contraluz, espacios industriales y vegetación. Los pares poseen registro espacial previo y resoluciones del orden de 360×270 a 768×576 píxeles. La modalidad VIS exhibe textura rica en contornos, mientras que la IR concentra la información en focos de calor y siluetas humanas. Esta heterogeneidad es deliberada: la fusión multimodal solo es interesante cuando las dos fuentes aportan información que la otra no captura.

5.2 Análisis cualitativo: comparación visual

La figura 6 muestra tres pares representativos del dataset junto con los resultados de los principales métodos. Visualmente, el promedio simple produce la imagen más plana, con pérdida evidente de contraste. Curvelet y la pirámide de Laplace recuperan detalles finos pero pueden introducir ligeros artefactos en bordes muy contrastantes. La Torre Top-Hat (disk, $L = 3$) preserva con nitidez tanto los puntos calientes IR como los detalles texturales VIS, sin introducir artefactos visibles. La Propuesta Novedosa (destacada en rojo) ofrece el resultado visualmente más limpio y equilibrado: integra la silueta térmica de la IR y la textura del VIS con bordes definidos, sin el granulado del Curvelet ni el exceso de brillo de las variantes más agresivas. Esto es coherente con sus indicadores cuantitativos: una tasa de artefactos muy baja ($N_{abf} = 0,035$) y la mayor similitud estructural ($SSIM = 0,783$) entre los métodos reales.




Figura 6. Comparación cualitativa de los métodos de fusión sobre tres pares representativos del dataset.

5.3 Resultados cuantitativos: promedio por método

La Tabla 4 presenta los promedios de las seis métricas clásicas y la Tabla 5 los de las seis métricas estándar de calidad, sobre los 20 pares para los 11 métodos evaluados (3 baselines, 4 configuraciones White Top-Hat y 4 con White+Black Top-Hat). En las métricas clásicas la pirámide de Laplace lidera en EN, SD y FE, y las variantes +BTH maximizan EN, SD, MG y SF al inyectar energía de detalle. Sin embargo, el panorama cambia en las métricas estándar: las configuraciones Top-Hat WTH alcanzan los mejores valores de SSIM y SCD —incluso por encima de la pirámide de Laplace— y la menor generación de artefactos (Nabf) entre los métodos multiescala, mientras que las variantes +BTH disparan el Nabf. El promedio simple, pese a su pobre desempeño en calidad de imagen, exhibe alta MI y SSIM por construcción (la combinación lineal preserva trivialmente contenido de ambas fuentes).

Tabla 4. Promedios de las seis métricas clásicas por método ($n = 20$).

Método	EN	SD	FE	MG	MI_vis	MI_ir
Promedio	6.5178	0.1092	1.0290	0.0144	1.5119	1.0637
Pirámide Laplace	6.8350	0.1548	1.0792	0.0248	2.1183	1.0717
Curvelet	6.6645	0.1167	1.0529	0.0256	1.3038	0.8843
Top-Hat disco L3	6.6765	0.1197	1.0546	0.0230	1.3954	0.9182

Método	EN	SD	FE	MG	MI_vis	MI_ir
(WTH)						
Top-Hat cuadrado L3 (WTH)	6.6901	0.1209	1.0568	0.0231	1.3906	0.9145
Top-Hat cruz L3 (WTH)	6.6632	0.1187	1.0525	0.0226	1.3830	0.9381
Top-Hat disco L5 (WTH)	6.7217	0.1246	1.0618	0.0235	1.3628	0.9140
Top-Hat disco L3 +BTH	6.9721	0.1430	1.1022	0.0444	0.8758	0.6181
Top-Hat cuadrado L3 +BTH	6.9970	0.1459	1.1062	0.0440	0.8578	0.6123
Top-Hat cruz L3 +BTH	6.9762	0.1433	1.1031	0.0444	0.8859	0.6336
Top-Hat disco L5 +BTH	7.1065	0.1610	1.1240	0.0473	0.7729	0.5949

Tabla 5. Promedios de las seis métricas estándar de calidad de fusión por método (n = 20 pares).

Método	SF	Qabf	Nabf	SSIM	SCD	VIF
Promedio	7.1120	0.3098	0.0000	0.7921	1.3247	0.3305
Pirámide Laplace	13.0400	0.4419	0.1080	0.7208	1.3217	0.4101
Curvelet	13.1510	0.4762	0.1915	0.7305	1.3208	0.3067
Top-Hat disco L3 (WTH)	11.6270	0.4559	0.1019	0.7441	1.3967	0.3523
Top-Hat cuadrado L3 (WTH)	11.5761	0.4392	0.1040	0.7414	1.4042	0.3528
Top-Hat cruz L3 (WTH)	11.4187	0.4556	0.1071	0.7494	1.3917	0.3440
Top-Hat disco L5	11.9234	0.4583	0.1168	0.7392	1.4302	0.3564

(WTH)

Top-Hat disco L3 +BTH	21.7436	0.3259	0.5368	0.5765	1.3408	0.3137
Top-Hat cuadrado L3 +BTH	21.3473	0.3287	0.5319	0.5750	1.3386	0.3182
Top-Hat cruz L3 +BTH	21.8316	0.3109	0.5369	0.5724	1.3378	0.3004
Top-Hat disco L5 +BTH	22.9396	0.2913	0.5745	0.5338	1.2791	0.2977

Tabla 5b. Métricas adicionales del review (FMI y Piella Q0/QW/QE) por método — medias sobre 20 pares.

Método	FMI ↑	Q0 ↑	QW ↑	QE ↑
Promedio	0,215	0,691	0,727	0,341
Pirámide de Laplace	0,276	0,744	0,856	0,404
Curvelet	0,197	0,727	0,823	0,369
Torre TH disco L5	0,213	0,743	0,810	0,360
Óptimo Multiescala (prelim.)	0,207	0,767	0,831	0,379
Propuesta Novedosa	0,208	0,753	0,799	0,363

Estas métricas, ponderadas por bordes y estructura local, favorecen a los métodos de mayor contraste: la pirámide de Laplace lidera FMI, QW y QE, y la Propuesta Novedosa lidera Q0. La propuesta novedosa se mantiene competitiva, en coherencia con su perfil orientado a la limpieza (Nabf) y la fidelidad estructural (SSIM).

Una distribución más completa de las métricas, no reducida al promedio, se aprecia en los diagramas de caja de la figura 7.




Figura 7. Diagramas de caja de seis métricas estándar de calidad (Qabf, Nabf, SSIM, SCD, VIF, SF) para métodos representativos (n = 20 pares VIS/IR).

5.4 Análisis estadístico no paramétrico

5.4.1 Prueba de Friedman global

La Tabla 6 reporta la prueba de Friedman aplicada de forma independiente a cada métrica, considerando los 11 métodos como tratamientos y los 20 pares como bloques. La hipótesis nula se rechaza con amplio margen en las doce métricas (todos los $p \ll 0,001$), confirmando que la elección del método tiene un efecto estadísticamente significativo sobre cada dimensión de calidad.

Tabla 6. Prueba de Friedman por métrica (χ^2 , p-valor; $\alpha = 0,05$).

Métrica	χ^2 de Friedman	p-valor	Significativo ($\alpha = 0,05$)
EN	158.00	8.37e-29	Sí
SD	179.41	3.11e-33	Sí
FE	158.00	8.37e-29	Sí
MG	192.66	5.46e-36	Sí
MI_vis	159.67	3.79e-29	Sí
MI_ir	147.37	1.29e-26	Sí
SF	194.17	2.65e-36	Sí

Métrica	χ^2 de Friedman	p-valor	Significativo ($\alpha = 0,05$)
Qabf	148.59	7.26e-27	Sí
Nabf	187.84	5.51e-35	Sí
SSIM	195.34	1.51e-36	Sí
SCD	97.32	1.87e-16	Sí
VIF	170.10	2.64e-31	Sí

5.4.2 Comparaciones pareadas Wilcoxon

Para precisar dónde residen las diferencias se aplicó la prueba de Wilcoxon de rangos signados entre cada configuración Top-Hat (WTH y WTH+BTH) y cada baseline, sobre las doce métricas, con corrección de Holm y tamaño de efecto rank-biserial (288 contrastes; detalle en el Apéndice C). El hallazgo central es un reparto de fortalezas frente a la pirámide de Laplace: la mejor configuración Top-Hat WTH (disco, $L = 5$) supera a Laplace de forma significativa en SSIM (0,739 vs 0,721; $p_{\text{Holm}} = 0,001$; $r = 1,00$) y en SCD (1,430 vs 1,322; $p_{\text{Holm}} = 0,019$; $r = 0,78$); empata en Qabf (0,458 vs 0,442; diferencia no significativa) y en Nabf; y cede de forma significativa en SD ($p_{\text{Holm}} = 0,009$) y en VIF ($p_{\text{Holm}} = 0,003$). Es decir, la Torre Top-Hat preserva mejor la fidelidad estructural a las fuentes, mientras que Laplace produce mayor contraste y fidelidad perceptual. En las métricas de información mutua el promedio simple sigue siendo el más fuerte por el sesgo aritmético ya señalado.

5.4.3 Ranking promedio

La Tabla 7 muestra el ranking promedio de cada método (1 = mejor) en seis métricas clave y el ranking global obtenido al promediar las doce métricas, respetando la dirección de cada una. La pirámide de Laplace mantiene el primer lugar global (4,42), pero la mejor configuración Top-Hat WTH (disco $L = 5$) queda muy próxima en segundo lugar (5,00), seguida por disco $L = 3$ (5,25) y cuadrado $L = 3$ (5,42). Las cuatro variantes +BTH se ubican por debajo de sus contrapartes WTH (6,00 a 6,83), penalizadas por los artefactos. Notablemente, Curvelet cae al último lugar junto al promedio (7,08): al penalizar los artefactos (Nabf), su aparente competitividad bajo las métricas clásicas de actividad se desvanece. La brecha entre Laplace y la mejor Top-Hat se reduce respecto al análisis con sólo seis métricas y, sobre todo, cambia de naturaleza: ya no es una derrota en todos los frentes sino un equilibrio de fortalezas complementarias.

Tabla 7. Ranking promedio por método y métrica (1 = mejor).

Método	SD	MG	Qabf	Nabf	SSIM	VIF	Global
Pirámide Laplace	2.00	6.00	5.00	5.00	7.00	1.00	4.42
Top-Hat disco L5 (WTH)	6.00	7.00	2.00	6.00	5.00	2.00	5.00
Top-Hat disco L3 (WTH)	8.00	9.00	3.00	2.00	3.00	4.00	5.25
Top-Hat cuadrado L3 (WTH)	7.00	8.00	6.00	3.00	4.00	3.00	5.42
Top-Hat cuadrado L3 +BTH	3.00	4.00	7.00	8.00	9.00	7.00	6.00
Top-Hat disco L3 +BTH	5.00	2.50	8.00	9.00	8.00	8.00	6.21
Top-Hat cruz L3 (WTH)	9.00	10.00	4.00	4.00	2.00	5.00	6.33
Top-Hat cruz L3 +BTH	4.00	2.50	9.00	10.00	10.00	10.00	6.38
Top-Hat disco L5 +BTH	1.00	1.00	11.00	11.00	11.00	11.00	6.83
Promedio	11.00	11.00	10.00	1.00	1.00	6.00	7.08
Curvelet	10.00	5.00	1.00	7.00	6.00	9.00	7.08




Figura 8. Ranking global por método (promedio de rangos sobre las doce métricas, con la dirección de cada una corregida).

5.5 Análisis del benchmark exhaustivo de la Torre Top-Hat

Más allá de la comparación inter-método, se ejecutó un benchmark exhaustivo de las 36 configuraciones de la Torre Top-Hat. La figura 9 sintetiza los promedios por configuración mediante mapas de calor por métrica. Cuatro patrones emergen con claridad. Primero, en EN, SD y FE los valores crecen suavemente con el número de niveles y el radio base, alcanzando los máximos en SE cuadrado con $L = 5$ y $r_0 = 5$. Segundo, en MG la dependencia es más débil y el óptimo se sitúa en disco con $L = 5$ y $r_0 = 3$, sugiriendo que profundizar la descomposición sin agrandar excesivamente el SE preserva mejor el detalle de bordes. Tercero, las métricas de información mutua (MI_{vis} , MI_{ir}) muestran tendencia opuesta: alcanzan los valores más altos en configuraciones someras y radios pequeños (disco $L = 2$ $r_0 = 2$ para MI_{vis} ; cruz $L = 2$ $r_0 = 2$ para MI_{ir}), confirmando que cada nivel adicional de descomposición desacopla progresivamente la imagen fusionada de sus fuentes individuales. Cuarto, las diferencias absolutas dentro del cuadro de 36 configuraciones son modestas (rangos de aproximadamente 0,1 puntos en EN, 0,01 en SD, 0,002 en MG), lo que sugiere que la elección de hiperparámetros de la Torre Top-Hat es relativamente robusta dentro de los rangos explorados.




Figura 9. Mapas de calor de las seis métricas para las 36 configuraciones de la Torre Top-Hat.

5.6 Efecto de la variante Black Top-Hat

Se comparó cada configuración White Top-Hat con su contraparte que añade Black Top-Hat (WTH+BTH). El efecto es nítido y de signo opuesto entre familias de métricas, con todas las diferencias significativas ($p < 0,001$). Agregar el BTH incrementa fuertemente la actividad y el contraste —frecuencia espacial SF +87 %, gradiente medio MG +93 %, entropía y desviación estándar al alza— pero degrada la calidad de la fusión: la preservación de bordes Qabf cae 29 %, la similitud estructural SSIM 22 %, la fidelidad visual VIF y la información mutua descienden, y sobre todo los artefactos Nabf se multiplican por más de cinco (+427 %). En otras palabras, el Black Top-Hat infla las métricas de actividad inyectando energía de detalle oscuro que en gran parte no proviene fielmente de las fuentes, sino que constituye artefactos. Por ello todas las variantes +BTH quedan por debajo de su contraparte WTH en el ranking global (Tabla 7). La variante WTH+BTH sólo sería preferible en aplicaciones cuyo objetivo explícito es maximizar el realce de contraste aceptando artefactos, no la fusión fiel; el punto de operación recomendado del método propuesto es el modo White Top-Hat con disco y $L = 5$.




Figura 10. Impacto de añadir Black Top-Hat sobre las configuraciones disco L3 y L5: cambio relativo por métrica (verde = mejora, rojo = empeora).

5.7 Evaluación orientada a tarea: detección con YOLO

Para evaluar la utilidad de la fusión más allá de la calidad de imagen se realizó una evaluación orientada a tarea con un detector YOLOv8n preentrenado (clases COCO). Sin reentrenar ni anotar, se ejecutó inferencia sobre las 20 imágenes en cada modalidad —VIS, IR y las cinco fusiones (promedio, pirámide de Laplace, curvelet, Torre Top-Hat y Propuesta Novedosa)— y se contabilizó la detectabilidad: número de detecciones, clase (persona/vehículo) y confianza. La Tabla 8 resume los resultados por método.

Tabla 8. Detectabilidad de YOLOv8n por método (suma sobre 20 imágenes; inferencia en GPU).

Fuente	Detecciones	Personas	Vehículos	Confianza media	FPS
VIS	7	1	4	0,37	75,7
IR	14	5	4	0,47	97,1
Promedio	7	4	2	0,49	109,5
Pirámide de Laplace	6	2	2	0,54	113,7
Curvelet	7	3	0	0,45	112,2
Torre Top-Hat (disco L5)	8	4	2	0,52	115,1
Propuesta Novedosa	8	4	2	0,50	111,8

El hallazgo principal respalda la utilidad de la fusión: sobre la VIS sola el detector apenas encuentra una (1) persona en todo el conjunto, mientras que la información infrarroja eleva la detección de personas —el infrarrojo solo alcanza cinco (5) personas y catorce detecciones totales,

la cifra más alta, coherente con su dominancia térmica—. Entre las fusiones, la Propuesta Novedosa y la Torre Top-Hat encabezan con ocho detecciones cada una (cuatro personas y dos vehículos, detección en 8 de 20 escenas) y una confianza media alta (0,50 y 0,52); los baselines quedan algo por detrás (promedio y curvelet, siete detecciones; pirámide de Laplace, seis). Persiste el patrón complementario: la VIS favorece los vehículos y la IR y las fusiones las personas.




Figura 11. Detectabilidad de YOLOv8n preentrenado por método (izq.: personas vs vehículos por método; der.: detecciones por método; la Propuesta Novedosa resaltada).

Esta evaluación debe leerse con cautela. Se trata de detectabilidad sin verdad de campo (ground truth): un mayor número de detecciones no equivale necesariamente a mayor exactitud, pues podría incluir falsos positivos. Con solo 20 imágenes sin etiquetar, la prueba de Friedman sobre las métricas de detección no resultó significativa ($p = 0,34$ para el número de detecciones; $p = 0,35$ para la confianza), por lo que no es posible declarar un método de fusión ganador en términos de detección. La inferencia se ejecutó en GPU (~75–115 FPS). Para una comparación concluyente en términos de mAP se reentrenó un detector sobre un conjunto etiquetado, como se detalla a continuación.

5.7.1 Evaluación con dataset etiquetado: mAP en LLVIP

Para una evaluación concluyente —con verdad de campo— se reentrenó el mismo detector (YOLOv8n) por separado sobre cada modalidad usando el conjunto LLVIP (15.488 pares VIS/IR registrados, peatones en baja luz; subconjunto de 2.000/500 imágenes, 40 épocas, idéntica configuración). Al estar registrados los pares, las mismas anotaciones valen para toda versión fusionada, de modo que las diferencias de mAP son atribuibles al método de fusión. La Tabla 8b reporta mAP@0,5 y mAP@0,5:0,95.

Tabla 8b. Detección de peatones en LLVIP — mAP por modalidad (YOLOv8n; subconjunto 2000 train / 500 val, 40 épocas).

Método	mAP@0,5 ↑	mAP@0,5:0,95 ↑	Precisión ↑	Recall ↑
--------	-----------	----------------	-------------	----------

IR (solo)	0,957	0,663	0,968	0,894
Pirámide de Laplace	0,949	0,651	0,943	0,879
Promedio	0,948	0,639	0,968	0,866
Propuesta Novedosa	0,905	0,618	0,958	0,795
Óptimo Multiescala (prelim.)	0,899	0,628	0,933	0,788
VIS (solo)	0,808	0,451	0,803	0,751

Tres lecturas se desprenden de la Tabla 8b. Primero, la fusión mejora con claridad sobre el visible solo ($mAP@0,5$ de 0,808 a 0,90–0,95): cuando el canal visible es débil —escenas nocturnas—, fusionar aporta. Segundo, el infrarrojo solo es la modalidad más fuerte ($mAP@0,5 = 0,957$; $mAP@0,5:0,95 = 0,663$), coherente con que LLVIP es detección de peatones en baja luz, donde el térmico domina; ninguna fusión lo supera. Tercero, entre las fusiones, las simples (promedio, Laplace) preservan mejor la detección que las morfológicas: la propuesta novedosa resulta competitiva ($mAP@0,5 = 0,905$) pero no líder. La conclusión es matizada y relevante: la superioridad en métricas de calidad de imagen (Nabf, SSIM) no se traslada automáticamente a la tarea de detección, y la elección del método depende de la aplicación —en consonancia con lo señalado por Singh et al. (2023)—.

5.8 Propuesta Novedosa (método central)

La Propuesta Novedosa —método central de esta tesis— se optimizó con PSO sobre un subconjunto representativo de escenas, maximizando una aptitud orientada a la fusión ($F = SSIM + Qabf + 0,5 \cdot SCD - Nabf$). El enjambre (30 partículas, 50 iteraciones) convergió de forma estable al óptimo $r = 12$ y $m = 0,127$. Esta aptitud premia simultáneamente la similitud estructural, la preservación de bordes y la correlación de las diferencias, y penaliza los artefactos, evitando el realce trivial al que conduce una aptitud de fidelidad pura.

La Tabla 9 compara la propuesta, en su configuración óptima ($r = 12$, $m = 0,127$), con el método anterior (Torre Top-Hat, disco $L = 5$) y los baselines sobre las métricas estándar de calidad. La propuesta registra una tasa de artefactos muy baja ($Nabf = 0,035$, frente a 0,108 de Laplace y 0,117 del método anterior) y la mayor similitud estructural entre los métodos reales ($SSIM = 0,783$), con la mejor preservación de bordes y correlación de su familia ($Qabf = 0,495$; $SCD = 1,421$). Reúne así limpieza, fidelidad estructural y fuerza de bordes en un mismo operador, perfil adecuado para una fusión de propósito general.

La significación de estas diferencias se verificó con la prueba de Wilcoxon pareada ($n = 20$, corrección de Holm por métrica; detalle completo en el Apéndice C). Frente al método anterior (Torre disco L5), la propuesta reduce los artefactos (Nabf 0,035 vs 0,117; $p_{\text{Holm}} < 0,001$; $|r| = 0,99$) y eleva la similitud estructural (SSIM 0,783 vs 0,739; $p_{\text{Holm}} < 0,001$; $|r| = 0,99$) y la información mutua con ambas fuentes ($p_{\text{Holm}} \leq 0,039$); iguala estadísticamente —con medias iguales o superiores— en preservación de bordes (Qabf 0,495 vs 0,458; $p_{\text{Holm}} = 0,90$), correlación (SCD 1,421 vs 1,430; $p_{\text{Holm}} = 0,18$) y fidelidad perceptual (VIF; $p_{\text{Holm}} = 0,19$), y cede en las métricas de actividad (EN, SD, SF, MG, FE; $p_{\text{Holm}} < 0,001$). Frente a la pirámide de Laplace gana en Nabf y SSIM ($p_{\text{Holm}} < 0,001$), iguala en Qabf ($p_{\text{Holm}} = 0,90$) y SCD ($p_{\text{Holm}} = 0,18$) y cede en VIF y SD ($p_{\text{Holm}} \leq 0,001$). Frente a Curvelet gana de forma estadísticamente significativa en Nabf, SSIM, Qabf, SCD y VIF ($p_{\text{Holm}} \leq 0,001$). Con ello, la ventaja de la propuesta en limpieza (Nabf) y fidelidad estructural (SSIM) frente al método anterior y a los baselines resulta estadísticamente significativa, quedando sostenidas H1 y H2.

La configuración óptima es robusta al radio: un barrido de r muestra que la aptitud crece de forma marginal y monótona al aumentar r (meseta de saturación), incrementando ligeramente la preservación de bordes (Qabf) y la correlación (SCD) a costa de una leve pérdida de similitud estructural (SSIM) y un pequeño aumento de artefactos (Nabf); $r = 12$ constituye un punto de operación equilibrado que mantiene un tamaño de elemento estructurante razonable.

Tabla 9. Propuesta Novedosa frente al método anterior y a los baselines — medias sobre 20 pares ($n = 20$).

SSIM ↑	0,783	0,739	0,721	0,792	0,731
SCD ↑	1,421	1,430	1,322	1,325	1,321
Qabf ↑	0,495	0,458	0,442	0,310	0,476
Nabf ↓	0,035	0,117	0,108	0,000	0,192
VIF ↑	0,361	0,356	0,410	0,330	0,307
SD ↑	0,115	0,125	0,155	0,109	0,117




Figura 12. Propuesta Novedosa (PSO: $r = 12$, $m = 0,127$) frente al método anterior y a los baselines en las métricas estándar de calidad.

La Figura 13 resume la optimización y el análisis de sensibilidad del método. El panel izquierdo muestra la convergencia del PSO: el enjambre (30 partículas, 50 iteraciones) alcanza una aptitud estable hacia la décima iteración, en la configuración $r = 12$, $m = 0,127$. El panel derecho y la Tabla 10 cuantifican la sensibilidad al radio r : al aumentar r , la preservación de bordes (Qabf) y la correlación (SCD) mejoran de forma marginal y saturante, mientras que la similitud estructural (SSIM) desciende levemente y los artefactos (Nabf) aumentan poco; la contribución de los elementos estructurantes lineales sobre el disco es modesta en estas métricas y su valor reside en la cobertura de orientaciones.




Figura 13. Convergencia del PSO (izq.) y sensibilidad al radio r (der.) de la Propuesta Novedosa, sobre tres escenas representativas.

Tabla 10. Sensibilidad al radio r de la Propuesta Novedosa (tres escenas representativas).

Variante	Qabf ↑	SSIM ↑	SCD ↑	Nabf ↓
r = 6	0,482	0,785	1,384	0,031
r = 9	0,490	0,784	1,405	0,034
r = 12 (propuesta)	0,495	0,783	1,421	0,035
r = 15	0,497	0,783	1,432	0,036
r = 18	0,498	0,783	1,438	0,036
r = 22	0,499	0,783	1,445	0,037

5.9 Discusión integrada

Los hallazgos cuantitativos pueden sintetizarse en siete observaciones. Primero, la Propuesta Novedosa ($r = 12$, $m = 0,127$) exhibe el mejor perfil de calidad entre los métodos reales: una tasa de artefactos muy baja ($Nabf = 0,035$) y la mayor similitud estructural ($SSIM = 0,783$), con la mejor preservación de bordes y correlación de su familia ($Qabf = 0,495$; $SCD = 1,421$), a costa de ceder contraste (SD , EN). Segundo, no existe un método universalmente dominante: la pirámide de Laplace encabeza el ranking global (4,42) por su ventaja en contraste (SD) y fidelidad perceptual (VIF), pero la Torre Top-Hat WTH (disco $L = 5$, ranking 5,00) la supera de forma significativa en fidelidad estructural ($SSIM$, SCD) y la iguala en preservación de bordes ($Qabf$, $Nabf$). Son óptimos de criterios distintos y complementarios. Tercero, la incorporación de las métricas estándar de calidad es la que revela este reparto: bajo las métricas clásicas —todas de actividad e información— el método parecía simplemente segundo, porque esas métricas favorecen al contraste y a la combinación lineal. Cuarto, Curvelet resulta el método más débil al penalizar artefactos ($Nabf$), corrigiendo la impresión de las métricas de actividad. Quinto, la variante Black Top-Hat intercambia calidad por contraste: mejora EN , SD , SF y MG pero degrada $Qabf$, $SSIM$, VIF y MI y dispara el $Nabf$, por lo que no se recomienda por defecto. Sexto, la información mutua y, en menor medida, la $SSIM$ están sesgadas a favor del promedio simple, lo que obliga a reportarlas junto a métricas de preservación de bordes y artefactos. Séptimo, la evaluación orientada a tarea sobre LLVIP (mAP con verdad de campo, sección 5.7.1) matiza el alcance de esas ventajas: la fusión supera con claridad al visible solo (mAP@0,5 de 0,808 a 0,90–0,95) y H3 solo se sostiene parcialmente, porque el infrarrojo solo domina (0,957) y las fusiones simples igualan a las morfológicas; la propuesta resulta competitiva (0,905) sin ser líder, evidencia de que la superioridad en calidad de imagen no se traslada automáticamente a la detección y de que la elección del método debe subordinarse a la aplicación.

6. CONCLUSIONES Y RECOMENDACIONES

6.1 Conclusiones

Se propuso, implementó y evaluó la Propuesta Novedosa, un método de fusión VIS/IR basado en Top-Hat con elementos estructurantes circulares y lineales sobre una sola escala y parámetros optimizados por PSO, comparándolo estadísticamente con el método anterior (Torre Top-Hat) y con baselines clásicos sobre el TNO Image Fusion Dataset. Las conclusiones específicas son:

1. La Propuesta Novedosa —con las respuestas lineales promediadas y combinadas por máximo con la del disco sobre una sola escala (PSO: $r=12$, $m=0,127$)— logra el mejor perfil de calidad entre los métodos reales: una tasa de artefactos muy baja ($Nabf=0,035$) y la mayor similitud estructural ($SSIM=0,783$), con preservación de bordes y correlación destacadas ($Qabf=0,495$; $SCD=1,421$). Supera al método anterior (Torre Top-Hat) en limpieza y fidelidad estructural —de forma estadísticamente significativa (Wilcoxon pareado con corrección de Holm: $p < 0,001$ en $Nabf$ y $SSIM$; sección 5.8)—. En la evaluación de detección sobre LLVIP (mAP con etiquetas), la fusión supera al visible solo pero no al infrarrojo solo, y la propuesta resulta competitiva sin ser la mejor: su ventaja en calidad de imagen no se traslada directamente a la tarea de detección, cuya estrategia óptima depende de la aplicación. Quedan así sostenidas las hipótesis H1 y H2, y solo parcialmente H3.

2. La Torre Top-Hat en su modo White Top-Hat es un método de fusión VIS+IR competitivo y, en las métricas estándar de calidad, superior a la pirámide de Laplace en fidelidad estructural: gana de forma estadísticamente significativa en $SSIM$ y SCD , y empata en preservación de bordes ($Qabf$) y en artefactos ($Nabf$). Su mejor configuración es disco con $L = 5$ (segundo lugar en el ranking global de doce métricas, 5,00; Laplace primero con 4,42).

3. La pirámide de Laplace presenta el mejor ranking global agregado (4,42), sostenido por su ventaja en contraste (SD) y fidelidad perceptual (VIF); no domina, en cambio, en fidelidad estructural, donde la Torre Top-Hat la supera. Curvelet, al penalizar artefactos, resulta el método más débil.

4. La métrica de información mutua (MI) está sesgada a favor del promedio simple, dado que la combinación lineal preserva trivialmente contenido de ambas fuentes.

Este hallazgo invita a reportar MI siempre acompañada de métricas de calidad global y a no interpretarla aisladamente como veredicto de fidelidad.

5. Dentro de la familia Top-Hat, la geometría del elemento estructurante introduce diferencias modestas: el disco tiende a maximizar EN, SD y FE; la cruz preserva ligeramente mejor la información mutua entre las configuraciones morfológicas; el cuadrado se sitúa en una posición intermedia.

6. La profundidad de descomposición (L) y el radio base (r_0) tienen efectos complementarios: mayor profundidad incrementa entropía y contraste; menor radio preserva mejor el gradiente.

7. Las pruebas no paramétricas confirman que las diferencias observadas no son fruto del azar: la prueba de Friedman es altamente significativa ($p < 0,001$) en las doce métricas, y las comparaciones pareadas Wilcoxon con corrección de Holm corroboran las superioridades específicas reportadas (ganancia en SSIM y SCD frente a Laplace, paridad en Qabf y Nabf).

8. La variante con Black Top-Hat no se recomienda como configuración por defecto: aunque incrementa el contraste y la actividad (EN, SD, SF, MG), degrada significativamente la calidad de la fusión (Qabf, SSIM, VIF, MI) y multiplica los artefactos ($Nabf \times 5$). El detalle oscuro que añade es en gran parte ruido no presente en las fuentes.

9. Es metodológicamente fundamental separar la regla de fusión de detalle (max-actividad por pixel) de la regla de fusión de la base (promedio): aplicar selección por actividad a la capa base introduce discontinuidades de iluminación y sesga las métricas de información mutua. Este aprendizaje es transferible a cualquier descomposición multiescala.

10. No existe un método universalmente óptimo: la decisión de qué algoritmo de fusión emplear debe estar guiada por el criterio operativo prioritario más que por una métrica única.

6.2 Recomendaciones

A partir de los hallazgos se proponen las siguientes líneas de trabajo futuro y de aplicación.

- Profundizar en reglas de fusión que aprovechen el Black Top-Hat de forma selectiva (p. ej. ponderando el detalle oscuro por su consistencia con las fuentes) para

capturar valles oscuros sin introducir los artefactos observados en la variante WTH+BTH directa.

- Replicar la evaluación sobre datasets adicionales (RoadScene, M3FD, MS-COCO multiespectral) para verificar la transferibilidad de las conclusiones.
- Explorar reglas de fusión adaptativas que ponderen la actividad local en función de estadísticos globales de la imagen, en lugar de la regla de máximo aplicada en este trabajo.
- Evaluar híbridos Top-Hat ↔ pirámide de Laplace que combinen la fidelidad a fuentes del primero con la riqueza global del segundo.
- Comparar contra modelos de fusión profundos preentrenados (FusionGAN, U2Fusion, SeAFusion) para situar el costo y el beneficio de los métodos clásicos en el panorama actual del estado del arte.
- Seleccionar el método de fusión según el criterio operativo prioritario: para aplicaciones donde priman la fidelidad estructural, la preservación de bordes y la ausencia de artefactos, emplear la Propuesta Novedosa ($r = 12$, $m = 0,127$), que registra la menor tasa de artefactos (Nabf) y la mayor similitud estructural (SSIM) entre los métodos reales; para un balance que privilegie el contraste global, la pirámide de Laplace sigue siendo una opción sólida; y la Torre Top-Hat con disco ($L = 5$) ofrece un punto de partida interpretable y de bajo costo computacional.
- Reportar siempre la información mutua junto con métricas de calidad global (EN, SD, MG) para evitar interpretaciones engañosas; el caso del promedio simple ilustra que MI alta no equivale necesariamente a fusión de mejor calidad perceptual.

7. REFERENCIAS BIBLIOGRÁFICAS

Aslantas, V., y Bendes, E. (2015). A new image quality metric for image fusion: The sum of the correlations of differences. *AEU - International Journal of Electronics and Communications*, 69(12), 1890–1896.

Bai, X. (2013). Morphological image fusion using the extracted image regions and details based on multi-scale top-hat transform and toggle contrast operator. *Digital Signal Processing*, 23(1), 244–263.

Bai, X., Zhou, F., y Xue, B. (2015). Image enhancement using multi-scale image features extracted by top-hat transform. *Optics & Laser Technology*, 65, 145–150.

Bala, A. A., Aruna Priya, P., y Maik, V. (2024). Hybrid technique for fundus image enhancement using modified morphological filter and denoising net. *The Journal of Supercomputing*, 80, 13317–13340. <https://doi.org/10.1007/s11227-024-05952-x>

Burt, P. J., y Adelson, E. H. (1983). The Laplacian pyramid as a compact image code. *IEEE Transactions on Communications*, 31(4), 532–540.

Candès, E., Demanet, L., Donoho, D., y Ying, L. (2006). Fast discrete curvelet transforms. *SIAM Multiscale Modeling & Simulation*, 5(3), 861–899.

Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200), 675–701.

Gonzalez, R. C., y Woods, R. E. (2018). *Digital Image Processing* (4^a ed.). Pearson.

Haghighat, M., Aghagolzadeh, A., y Seyedarabi, H. (2011). A non-reference image fusion metric based on mutual information of image features. *Computers & Electrical Engineering*, 37(5), 744–756.

Jia, X., Zhu, C., Li, M., Tang, W., y Zhou, W. (2021). LLVIP: A visible-infrared paired dataset for low-light vision. *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*, 3496–3504.

Kennedy, J., y Eberhart, R. (1995). Particle swarm optimization. *Proceedings of ICNN'95 - International Conference on Neural Networks*, 4, 1942–1948.

Li, S., Kang, X., Fang, L., Hu, J., y Yin, H. (2017). Pixel-level image fusion: A survey of the state of the art. *Information Fusion*, 33, 100–112.

Ma, J., Ma, Y., y Li, C. (2019). Infrared and visible image fusion methods and applications: A survey. *Information Fusion*, 45, 153–178.

Ma, J., Yu, W., Liang, P., Li, C., y Jiang, J. (2019). FusionGAN: A generative adversarial network for infrared and visible image fusion. *Information Fusion*, 48, 11–26.

Malviya, P., y Saxena, A. K. (2014). An improved image fusion technique based on texture feature optimization using wavelet transform and particle of swarm optimization (POS). *International Journal of Computer Applications*, 101(6), 19–22.

Mukhopadhyay, S., y Chanda, B. (2001). A multi-scale morphological approach to local contrast enhancement. *Signal Processing*, 80(4), 685–696.

Ortega Rodríguez, M. A., y Espinoza Ríos, G. A. (2025). Optimización de los parámetros de la transformada Top-Hat mediante PSO para la fusión de imágenes visibles e infrarrojas. Proyecto de Trabajo Final de Grado, Facultad Politécnica, Universidad Nacional de Asunción.

Piella, G., y Heijmans, H. (2003). A new quality metric for image fusion. *Proceedings IEEE ICIP*, vol. 3, 173–176.

Román, J. C. M., Vázquez Noguera, J. L., y Legal-Ayala, H. (2024). Algoritmo de realce para mamografías basado en Top-Hat multiescala con elementos estructurantes circulares y lineales. (Realce de contraste local y nitidez en imágenes mamográficas). [COMPLETAR revista/actas, volumen(número), páginas o DOI].

Serra, J. (1982). *Image Analysis and Mathematical Morphology*. Academic Press.

Sheikh, H. R., y Bovik, A. C. (2006). Image information and visual quality. *IEEE Transactions on Image Processing*, 15(2), 430–444.

Singh, S., Singh, H., Bueno, G., Deniz, O., Singh, S., Monga, H., Hrisheekesha, P. N., y Pedraza, A. (2023). A review of image fusion: Methods, applications and performance metrics. *Digital Signal Processing*, 137, 104020.

Soille, P. (2003). *Morphological Image Analysis: Principles and Applications* (2ª ed.). Springer.

Tang, L., Yuan, J., y Ma, J. (2022). Image fusion in the loop of high-level vision tasks: A semantic-aware real-time infrared and visible image fusion network. *Information Fusion*, 82, 28–42.

Tao, J., Li, S., y Yang, B. (2010). Multimodal image fusion algorithm using dual-tree complex wavelet transform and particle swarm optimization. En *Advanced Intelligent Computing Theories and Applications (Communications in Computer and Information Science*, vol. 93, pp. 296–303). Springer.

Toet, A. (2014). The TNO multiband image data collection. *Data in Brief*, 4, 187–192.

Wang, J., Peng, J., Feng, X., He, G., y Fan, J. (2017). Fusion method for infrared and visible images by using non-negative sparse representation. *Infrared Physics & Technology*, 80, 1–9.

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83.

Xydeas, C. S., y Petrović, V. (2000). Objective image fusion performance measure. *Electronics Letters*, 36(4), 308–309.

Zhang, X., y Demiris, Y. (2023). Visible and infrared image fusion using deep learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(8), 10535–10554.

8. APÉNDICE

A. Repositorio del código

La totalidad del código de esta tesis está disponible en el repositorio del proyecto, organizado en módulos: `src/datasets.py` (carga y emparejado VIS/IR), `src/fusion/` (`novel_fusion.py` para la propuesta definitiva, `prop_top_hat.py` para el método anterior —Torre Top-Hat—, `optimal_top_hat.py` para el óptimo monoescala del avance y `comparatives.py` para los baselines), `src/metrics/evaluators.py` (las dieciséis métricas), `src/utils/` (entrada/salida y visualización), `experiments/run_all_fusions.py` (comparación inter-método), `experiments/run_stats_analysis.py` (Friedman, Wilcoxon con Holm y ranking), `experiments/benchmark_fusion.py` (benchmark exhaustivo), `experiments/pso_novel.py` (optimización PSO de la propuesta), `experiments/detection_llvip/` (preparación y entrenamiento mAP en LLVIP), `notebooks/` (análisis exploratorios). El archivo `requirements.txt` consigna las dependencias exactas.

B. Configuraciones del benchmark exhaustivo

Las 36 configuraciones evaluadas resultan del producto cartesiano de los siguientes valores:

- Tipo de elemento estructurante: disco, cuadrado, cruz.
- Número de niveles de descomposición: 2, 3, 4, 5.
- Radio base del SE: 2, 3, 5 píxeles.

Cada configuración se aplicó a los 20 pares VIS/IR, generando 720 imágenes fusionadas y 720 mediciones por métrica. Los archivos individuales se encuentran en `experiments/results/fused_images/<config>/` y los promedios cuantitativos están consolidados en `experiments/results/metrics_reports/benchmark_top_hat.csv`.

C. Tablas estadísticas extendidas

Las tablas completas con los 288 contrastes Wilcoxon (8 configuraciones Top-Hat $\times$ 3 baselines $\times$ 12 métricas) se almacenan en `experiments/results/metrics_reports/wilcoxon_results.csv`. Cada fila contiene la métrica, las medias comparadas, la diferencia, el estadístico W, el p-valor, el p-valor corregido por Holm, la marca de significación a $\alpha = 0,05$ y el tamaño de efecto rank-biserial. El ranking promedio está en `ranking_methods.csv` y los resultados de Friedman en `friedman_results.csv`. Los 48 contrastes de

la propuesta central frente al método anterior y a los baselines (12 métricas $\times$ 4 rivales, Wilcoxon con Holm y tamaño de efecto rank-biserial) se consignan en wilcoxon_propuesta_vs_metodos.csv.

D. Pseudocódigo de la Torre Top-Hat

Entrada: imágenes f_{VIS} , f_{IR} (escala de grises, normalizadas en $[0,1]$), tipo de SE, número de niveles L , radio base r_0 Salida: imagen fusionada F

1. Para cada modalidad $m \in \{VIS, IR\}$:
2. $R \leftarrow f_m$
3. Para $k = 1$ hasta L :
4. $b_k \leftarrow$ SE de tipo y radio $k \cdot r_0$
5. $WTH_k^m \leftarrow R - \text{apertura}(R, b_k)$
6. $R \leftarrow R - WTH_k^m$
7. $base_m \leftarrow R$
8. Para $k = 1$ hasta L :
9. $a_{VIS} \leftarrow \text{gaussiana}(|WTH_k^{VIS}|)$
10. $a_{IR} \leftarrow \text{gaussiana}(|WTH_k^{IR}|)$
11. $mask \leftarrow (a_{VIS} \geq a_{IR})$
12. $WTH_k^F \leftarrow mask * WTH_k^{VIS} + (1 - mask) * WTH_k^{IR}$
13. $base_F \leftarrow (base_{VIS} + base_{IR}) / 2$ # promedio (NO max-actividad)
14. $F \leftarrow \sum_k WTH_k^F + base_F$
15. $F \leftarrow \text{clip}(F, 0, 1)$
16. devolver F

Pseudocódigo de la Propuesta Novedosa (una sola escala)

ENTRADA: I_{VIS} , I_{IR} en $[0,1]$ alineadas; radio r ; peso m
 SALIDA: imagen fusionada F

para cada fuente S en $\{I_{VIS}, I_{IR}\}$:

```

L <- {linea(r,0), linea(r,45), linea(r,90), linea(r,135)} # 4 lineas
WTH_lin <- promedio_{b en L} ( S - apertura(S,b) ) # ec. (7)
BTH_lin <- promedio_{b en L} ( cierre(S,b) - S )
WTH_disco <- S - apertura(S, disco(r)) # ec. (8)
BTH_disco <- cierre(S, disco(r)) - S
Iopt_top[S] <- max(WTH_lin, WTH_disco) # ec. (9)
Iopt_bot[S] <- max(BTH_lin, BTH_disco)

# combinacion entre fuentes (maximo por pixel) # ec. (10)
Iopt_top <- max(Iopt_top[VIS], Iopt_top[IR])
Iopt_bot <- max(Iopt_bot[VIS], Iopt_bot[IR])
I_base <- (I_VIS + I_IR) / 2
F <- recortar( I_base + m*Iopt_top - m*Iopt_bot, 0, 1 ) # ec. (11)
devolver F

```

(r , m) se optimizan por PSO $\rightarrow r = 12$, $m = 0,127$

Nota: la versión definitiva y única del método (sección 2.2.5) promedia las cuatro respuestas lineales y las confronta por máximo con la del disco sobre una sola escala —sin descomposición multiescala ni diferencias en cascada— y optimiza (r , m) por PSO, con óptimo $r = 12$, $m = 0,127$. Su implementación de referencia es src/fusion/optimal_top_hat.py (función fuse_optimal, modo 'max').

E. Refinamiento metodológico de la regla de fusión

Durante el desarrollo iterativo de la implementación se identificó un punto sutil pero sustantivo en la regla de fusión multiescala. Una primera versión aplicaba selección por máxima actividad local de manera uniforme a todas las capas, incluyendo la base. La versión definitiva, reportada en los resultados de esta tesis, distingue las dos clases de capas: las L capas de detalle WTH se fusionan por máxima actividad local; la capa base se fusiona por promedio simple. Esta

distinción es coherente con la práctica establecida en la literatura clásica de fusión multiescala. El refinamiento eliminó discontinuidades de iluminación y sesgos artificiales en la información mutua.

F. Hardware y tiempos de ejecución

La totalidad de los experimentos se ejecutó en una notebook estándar (Intel i7, 16 GB de RAM, sin GPU dedicada) bajo Windows 11 con Python 3.11. Cada fusión Top-Hat consume entre 20 y 80 milisegundos según la configuración; la pirámide de Laplace y el curvelet se sitúan en órdenes de magnitud comparables. La ejecución completa del benchmark exhaustivo (720 fusiones) toma aproximadamente 90 segundos. Esta liviandad computacional confirma la viabilidad del método para aplicaciones en tiempo real.